

A Validation-First Evaluation Framework for
LLM-Generated Corporate Credit-Rating Recourse:
An Oracle - RL - LLM Pipeline

검증 우선 평가 프레임워크를 통한
LLM 생성 기업 신용등급 개선권고 평가:
신용평가모형 - 강화학습 - LLM 파이프라인

2026 년 12 월

서강대학교 AI·SW 대학원

데이터사이언스·인공지능 전공

조 종 선

검증 우선 평가 프레임워크를 통한
LLM 생성 기업 신용등급 개선권고 평가:
신용평가모형 - 강화학습 - LLM 파이프라인

지도교수 최 준 석

이 논문을 공학석사 학위논문으로 제출함

2026 년 12 월 일

서강대학교 AI·SW 대학원

데이터사이언스·인공지능 전공

조 종 선

논 문 인 준 서

조 종 선의 공학석사 학위논문을 인준함

2026 년 12 월 일

주심 (인)

부심 (인)

부심 (인)

차 례

Abstract.....	xi
초록.....	xiii
제 1 장 서론.....	1
1.1 연구 배경과 문제 제기.....	1
1.2 연구문제와 평가의 두 간극.....	3
1.3 연구의 목적과 연구질문.....	4
1.4 연구의 전체적 접근.....	5
1.5 연구의 기여.....	6
1.6 논문의 구성.....	7
제 2 장 이론적 배경과 분석틀.....	8
2.1 기업 신용위험 측정과 신용평가.....	8
2.1.1 예측 문제로서의 신용위험: 회계·구조·기계학습 모형.....	8
2.1.2 검증가능성과 사용범위.....	9
2.1.3 LLM 과 신용위험: 진단에서 처방으로.....	9
2.2 알고리즘적 권고와 반사실적 설명.....	10
2.2.1 반사실적 설명에서 실행가능한 권고로.....	10
2.2.2 기업 신용 영역의 recourse 와 본 연구의 위치.....	11
2.2.3 개인 recourse 와 기업 recourse 의 구조적 차이.....	12
2.3 순차적 의사결정과 오프라인 강화학습.....	12
2.3.1 오프라인 설정과 분포이동.....	12
2.3.2 Candidate-IQL 의 지위와 선택 불확실성.....	13
2.4 정책으로서의 LLM.....	14
2.4.1 프롬프트의 추론 유도과 API 추론 설정.....	14
2.4.2 자기 수정과 외부 정책 참조.....	15
2.4.3 출력 유창성·행동 유효성·정책가치.....	15
2.5 평가단위와 측정 타당성: 정책 하네스.....	16
2.5.1 동일 파운데이션 모델의 생성 정책 차이.....	16
2.5.2 정책 하네스와 평가 하네스의 구분.....	17
2.5.3 검증 우선 원칙의 적용범위.....	17

2.6 정책가치의 귀속 문제.....	18
2.6.1 평가도구 귀속.....	18
2.6.2 생성모델과 실행규칙 귀속.....	18
2.6.3 자기 재검토와 추가 참조 귀속.....	18
2.7 선행연구의 한계와 본 연구의 위치.....	19
2.8 연구가설과 추가 분석명제.....	19
제 3 장 연구설계와 실행·분석 계약.....	21
3.1 자료·표본·시점과 분석의 역할.....	21
3.1.1 재무패널과 시간 구분.....	21
3.1.2 기업 식별과 산업정보.....	22
3.2 관리행동, 표준후보와 정규화 행동예산.....	23
3.2.1 여덟 개 관리행동의 의미.....	23
3.2.2 B1 과 BINF.....	24
3.2.3 아홉 개 표준 후보행동.....	25
3.3 Simulator 와 Oracle 의 공통 평가경로.....	26
3.3.1 제안에서 재무상태로의 전파.....	26
3.3.2 세 Oracle 와 정책가치.....	26
3.4 Candidate-IQL 의 학습·선택·배포.....	27
3.4.1 표현학습, 행동모방과 가치학습.....	27
3.4.2 등급 신호와 보조보상.....	28
3.4.3 계층적 확률평균과 선택 독립성.....	28
3.5 LLM 모델과 생성 실행조건.....	29
3.6 정책조건·정보조건과 실행행렬.....	30
3.6.1 동일 초안의 재검토와 두 종류의 참조.....	30
3.6.2 실제 제공정보의 차이.....	31
3.6.3 Main Run1 과 Stability Run2.....	32
3.7 원응답과 네 행동층.....	33
3.8 Strict, Repaired 와 PP.....	34
3.8.1 두 실행정책의 구분.....	34
3.8.2 PP는 실행정책이 아니라 조건부 표본.....	34
3.9 대비, 불확실성과 반복성 분석.....	35
3.9.1 네 대비와 행동예산 상호작용.....	35

3.9.2 기업 단위 bootstrap 과 다중비교.....	35
3.9.3 네 종류의 반복성.....	36
3.10 실행명세의 불일치, 비용과 재현성.....	37
3.10.1 부모 응답 분기규칙의 문서 간 차이.....	37
3.10.2 비용과 산출물의 추적.....	37
제 4 장 평가기반 검증과 학습 참조정책.....	38
4.1 Oracle 와 실제 신용등급의 정렬성.....	38
4.2 Simulator 검증의 범위와 최신 실행 점검.....	39
4.2.1 회계적 일관성과 과거 상태 재현.....	39
4.2.2 수준, 기업 순위와 변화방향의 분리.....	39
4.2.3 V4.3 의미론 fixture 와 증거의 경계.....	40
4.3 최신 아홉 행동에서 Oracle 의 구별력.....	41
4.4 최종 비교정책의 공통 평가표면.....	42
4.5 C3-E 의 행동분포와 seed 구성.....	45
4.5.1 평균가치, 행동다양성과 손실 사례.....	45
4.5.2 matched seed 확장과 민감도.....	46
4.6 학습 참조정책의 사용범위.....	47
4.7 소결.....	47
제 5 장 Baseline 본실험 결과.....	48
5.1 응답 완결성과 사용 가능성.....	48
5.1.1 요청 단위와 평가 단위의 구분.....	48
5.1.2 행동 수용률과 전체 응답 형식.....	48
5.2 Baseline Run1 의 정책가치.....	50
5.2.1 전체 할당 기업의 A0 대비 가치.....	50
5.2.2 학습 참조와 비교할 때의 주의점.....	52
5.3 자기 재검토, 진단 지시와 참조의 효과.....	52
5.3.1 C4R-C4: 다시 검토하는 조건의 가치.....	53
5.3.2 C5-C4: 프롬프트 진단 유도.....	53
5.3.3 C6-E-C4R: 학습참조의 추가 가치.....	54
5.3.4 C6-E-C6-EX: 기업과 참조의 연결.....	55
5.4 행동예산과 수정효과의 상호작용.....	55
5.5 후보선택과 자유작성.....	56

5.6 정보조건: 업종코드와 기업명.....	57
5.7 Baseline 반복성과 본실험의 소결.....	57
제 6 장 추론 설정과 실행규칙에 대한 추가 분석.....	59
6.1 추가 분석의 지위와 두 축.....	59
6.2 High 에서의 계약준수와 행동강도.....	60
6.2.1 B1 자유작성 수용률.....	60
6.2.2 실제 사용 강도와 행동의 폭.....	62
6.3 결정론적 Repair 의 복구범위와 정책가치.....	63
6.3.1 원응답 보존과 정상행동 불변성.....	63
6.3.2 네 실행조합의 정책가치.....	63
6.4 High 의 수정효과와 Baseline 대비 변화.....	68
6.4.1 High regime 안의 네 중심 대비.....	68
6.4.2 효과의 크기가 정말 달라졌는가.....	69
6.5 행동예산, 행동공간과 평가모형.....	70
6.5.1 BINF 에서의 비단조성.....	70
6.5.2 후보선택과 자유작성 격차의 변화.....	71
6.5.3 다른 Oracle 에서의 참조 대비.....	72
6.6 PP 와 부모 응답 게이트의 민감도.....	73
6.6.1 Strict 수용 교집합에서의 비교.....	73
6.6.2 계획서와 pre-live 분기명세의 차이.....	73
6.7 평균, 기업별 효과와 행동의 반복성.....	75
6.7.1 절대점수와 증분가치의 구분.....	75
6.7.2 실제 행동벡터의 반복성.....	76
6.8 API 비용과 운영적 비용효율.....	77
6.8.1 대시보드 귀속가정.....	77
6.8.2 요청 한 건과 최종 권고 하나의 비용.....	78
6.8.3 토큰당 비용을 해석하는 한계.....	79
6.9 소결.....	79
제 7 장 종합 논의와 결론.....	80
7.1 연구결과의 요약.....	80
7.2 연구질문과 가설의 회수.....	81
7.3 학술적 기여.....	82

7.4 결과의 이론적 해석.....	83
7.4.1 추론과 재검토는 같은 개념이 아니다.....	83
7.4.2 참조의 평균품질과 참조를 쓰는 가치.....	83
7.4.3 실패 처리도 정책의 일부이다.....	84
7.5 실무적·감독적 시사점.....	84
7.5.1 검토·변경관리의 단위.....	84
7.5.2 집단 정책평가와 개별 기업 검토.....	85
7.6 연구의 한계.....	86
7.7 향후 연구.....	87
7.8 결론.....	87
참고문헌.....	88
부록 A. 최종 행동·입력 명세.....	93
A.1 행동 필드, 단위와 실제 계산값.....	93
A.1.1 성장성 CAPEX 축소율.....	93
A.1.2 이자부부채 상환율.....	93
A.1.3 단기차입 차환율.....	93
A.1.4 재고 회전을 변화.....	93
A.1.5 매출채권 회전을 변화.....	93
A.1.6 매입채무 회전을 변화.....	93
A.1.7 매출원가를 변화.....	94
A.1.8 판매관리비율 변화.....	94
A.2 아홉 후보의 실제 행동벡터.....	94
A.3 LLM 입력특징의 의미.....	95
부록 B. 평가기반의 개발 검증기록.....	97
부록 C. C3-E 배포와 학습 구성.....	100
C.1 최종 배포 식별과 정책의 정의.....	100
C.2 최종 configuration 의 Stage5 설정.....	101
C.3 28 개 actor 의 checkpoint 연결.....	101
부록 D. 실제 LLM 요청과 분기명세.....	103
D.1 모델·출력·정책 명세.....	103
D.1.1 공통 system 지시.....	103
D.1.2 공통 system 지시.....	103

D.1.3 공통 system 지시.....	103
D.1.4 공통 system 지시.....	103
D.1.5 공통 system 지시.....	104
D.2 정책별 추가 지시.....	104
D.2.1 C4 조건 지시.....	104
D.2.2 C4R 조건 지시.....	104
D.2.3 C5 조건 지시.....	104
D.2.4 C6-E 조건 지시.....	104
D.2.5 C6-EX 조건 지시.....	105
D.3 원응답의 구조와 action-usability.....	105
D.4 부모 원문을 전달하는 pre-live 규칙.....	105
D.5 재현 경로.....	106
부록 E. 최종 대비의 전체 Oracle 결과.....	107
E.1 Baseline · Strict / Gemini 3.1 Flash-Lite.....	107
E.2 Baseline · Strict / GPT-5.4-mini.....	108
E.3 Baseline · Repaired / Gemini 3.1 Flash-Lite.....	110
E.4 Baseline · Repaired / GPT-5.4-mini.....	112
E.5 High · Strict / Gemini 3.1 Flash-Lite.....	113
E.6 High · Strict / GPT-5.4-mini.....	115
E.7 High · Repaired / Gemini 3.1 Flash-Lite.....	116
E.8 High · Repaired / GPT-5.4-mini.....	118
부록 F. PP·반복성·비용과 증거 연결.....	120
F.1 주요 PP 표본의 구성.....	120
F.2 비용 계산식과 귀속 범위.....	120
F.3 재집계 산출물과 자료 출처.....	121
F.4 아직 남는 증거상 제한.....	122
부록 G. 구형 실험의 개발 이력과 분리 원칙.....	123

표 차례

표 1-1. 연구질문과 최종 실험의 대응.....	4
표 1-2. 평가경로와 보존하는 정보.....	6
표 2-1. 기존 가설과 최종 분석의 대응.....	20
표 3-1. 자료 집합과 사용목적의 구분.....	22
표 3-2. 자유작성 행동의 허용범위와 정규화 기준.....	24
표 3-3. 표준 후보의 내용과 정규화 강도 배분.....	25
표 3-4. 최종 네 configuration 의 보조보상 가중치.....	28
표 3-5. 공급자별 Baseline 과 High 생성 설정.....	29
표 3-6. 최종 다섯 정책조건과 비교대상.....	30
표 3-7. 정보조건별 실제 차이.....	32
표 3-8. 모델·regime 하나당 실행행렬.....	32
표 3-9. 행동층과 실패 처리.....	33
표 4-1. 개발 단계 Oracle 정렬성 검증기록.....	38
표 4-2. 개발 단계 Simulator 검사 3 의 기간별 결과.....	40
표 4-3. 현재 확보된 검증층과 해석 가능한 범위.....	41
표 4-4. V4.3 후보별 점수의 동물과 A0 최적 여부.....	42
표 4-5. 최신 비교정책의 A0 대비 평균 정책가치.....	43
표 4-6. 최종 C3-E 의 주요 지표.....	46
표 5-1. Gemini 3.1 Flash-Lite Baseline 자유작성의 수용률.....	48
표 5-2. GPT-5.4-mini Baseline 자유작성의 수용률.....	49
표 5-3. Gemini 3.1 Flash-Lite Baseline Strict ITT 정책가치.....	50
표 5-4. GPT-5.4-mini Baseline Strict ITT 정책가치.....	51
표 5-5. Gemini 3.1 Flash-Lite Baseline 의 네 중심 대비.....	52
표 5-6. GPT-5.4-mini Baseline 의 네 중심 대비.....	53
표 5-7. 진단 유도 전후의 행동강도와 활성 차원.....	54
표 5-8. Baseline 대비효과의 B1-BINF 차이.....	55
표 5-9. Baseline B1 의 자유작성-후보선택 대비.....	56
표 5-10. Baseline C4/free8/B1 의 정보조건 대비.....	57
표 5-11. Baseline 의 별도 Run1·Run2 반복 비교.....	57

표 6-1. 생성 regime 와 실행규칙의 2×2 구조.....	59
표 6-2. Gemini 3.1 Flash-Lite B1 의 추론 regime 별 행동 수용.....	60
표 6-3. GPT-5.4-mini B1 의 추론 regime 별 행동 수용.....	61
표 6-4. 직접생성 C4 의 실사용 강도와 활성 차원.....	62
표 6-5. Repair 복구와 원래 수용응답의 점수 불변성.....	63
표 6-6. Gemini 3.1 Flash-Lite 의 생성·실행 조합별 A0 대비 가치.....	63
표 6-7. GPT-5.4-mini 의 생성·실행 조합별 A0 대비 가치.....	65
표 6-8. Gemini 3.1 Flash-Lite High Strict ITT 의 네 대비.....	68
표 6-9. GPT-5.4-mini High Strict ITT 의 네 대비.....	68
표 6-10. B1 에서 대비효과와 High-Baseline 차이.....	69
표 6-11. 정책별 High-Baseline 변화: Strict ITT.....	70
표 6-12. High B1 의 자유작성-후보선택 대비.....	71
표 6-13. High Strict 의 참조 대비: Oracle 별 방향.....	72
표 6-14. Baseline B1 의 strict 교집합 PP 대비.....	73
표 6-15. B1 의 부모 수용 게이트 민감도.....	74
표 6-16. 학습참조 증분효과 C6-E-C4R 의 반복성.....	75
표 6-17. High 자유작성의 실제 8 차원 행동 반복성.....	76
표 6-18. 가정에 따른 공급자-regime 별 지출과 단가.....	78
표 7-1. 연구질문·가설별 증거와 결론의 범위.....	81
표 7-2. 정책 하네스의 변경요소와 필요한 검증.....	85
표 A-1. CAPEX·부채·재고 부분.....	94
표 A-2. 매출채권·매입채무·비용 부분.....	95
표 A-3. 재무특징과 제공정보의 정확한 정의.....	95
표 B-1. Oracle 공통 입력변수.....	97
표 B-2. 개발 단계 Oracle- α 항목 가중치.....	97
표 B-3. 개발 단계 Oracle- β 계수.....	98
표 B-4. 개발 단계 실제 등급 대비 예측성능.....	99
표 C-1. 배포정책의 동결값.....	100
표 C-2. 구성별 주요 Stage5 설정.....	101
표 C-3. 최종 구성원의 checkpoint 해시 접두어.....	101
표 E-1. Baseline · Strict / Gemini / Oracle- α	107
표 E-2. Baseline · Strict / Gemini / Oracle- β	107

표 E-3. Baseline · Strict / Gemini / Oracle- γ	108
표 E-4. Baseline · Strict / GPT / Oracle- α	108
표 E-5. Baseline · Strict / GPT / Oracle- β	109
표 E-6. Baseline · Strict / GPT / Oracle- γ	109
표 E-7. Baseline · Repaired / Gemini / Oracle- α	110
표 E-8. Baseline · Repaired / Gemini / Oracle- β	110
표 E-9. Baseline · Repaired / Gemini / Oracle- γ	111
표 E-10. Baseline · Repaired / GPT / Oracle- α	112
표 E-11. Baseline · Repaired / GPT / Oracle- β	112
표 E-12. Baseline · Repaired / GPT / Oracle- γ	113
표 E-13. High · Strict / Gemini / Oracle- α	113
표 E-14. High · Strict / Gemini / Oracle- β	114
표 E-15. High · Strict / Gemini / Oracle- γ	114
표 E-16. High · Strict / GPT / Oracle- α	115
표 E-17. High · Strict / GPT / Oracle- β	115
표 E-18. High · Strict / GPT / Oracle- γ	116
표 E-19. High · Repaired / Gemini / Oracle- α	116
표 E-20. High · Repaired / Gemini / Oracle- β	117
표 E-21. High · Repaired / Gemini / Oracle- γ	117
표 E-22. High · Repaired / GPT / Oracle- α	118
표 E-23. High · Repaired / GPT / Oracle- β	118
표 E-24. High · Repaired / GPT / Oracle- γ	119
표 F-1. 대비별 strict PP 교집합 N.....	120
표 F-2. 본문 표와 파생파일의 대응.....	121
표 F-3. 편집과 재집계로 없앨 수 없는 제한.....	122
표 G-1. 개발계약에서 최종계약으로의 주요 전환.....	123

그림 차례

그림 4-1. Oracle- α 에서의 최종 비교정책 순위.....	44
그림 4-2. 동결 C3-E 의 기업별 행동 분포.....	45
그림 6-1. Gemini 3.1 Flash-Lite B1 의 행동 수용률 변화.....	60
그림 6-2. GPT-5.4-mini B1 의 행동 수용률 변화.....	61
그림 6-3. Gemini 3.1 Flash-Lite B1 의 네 생성·실행 조합.....	64
그림 6-4. Gemini 3.1 Flash-Lite BINF 의 네 생성·실행 조합.....	65
그림 6-5. GPT-5.4-mini B1 의 네 생성·실행 조합.....	66
그림 6-6. GPT-5.4-mini BINF 의 네 생성·실행 조합.....	67

Abstract

A Validation-First Evaluation Framework for LLM-Generated Corporate Credit-Rating Recourse: An Oracle–RL–LLM Pipeline

This study examines how corporate credit-rating recourse generated by large language models (LLMs) should be evaluated when the effects of implementing the recommendations cannot be observed directly. It retains a validation-first distinction between the scope of an evaluation harness and the quality of policies measured within that harness. Three structurally different credit-scoring models and an accounting-consistent financial simulator provide a common, explicitly limited evaluation environment. Development-stage validation evidence, current action-level diagnostics, and real-world effectiveness are treated as different evidentiary claims.

The final V4.3 experiment evaluates 575 Korean listed firms using eight managerial action dimensions and nine canonical candidate actions. A normalized action budget of one (B1) is compared with a condition without an aggregate intensity cap (BINF). A Candidate-IQL reference policy, C3-E, combines 28 actors from four configurations and seven matched seeds by hierarchical probability averaging. Actor training does not directly optimize Oracle scores, but final policy selection used the repeatedly examined 2024 development/evaluation surface. The selected policy is therefore not presented as an Oracle-independent, untouched-holdout result.

The study compares direct generation (C4), diagnostic prompting (C5), self-review of the same draft (C4R), revision with the firm's learned-policy reference (C6-E), and revision with a fixed derangement of reference assignments (C6-EX). The baseline and subsequent high-reasoning campaigns each contain 24,150 requests; main and repeatability runs are analyzed separately. Strict execution assigns A0 to confirmed unusable completions, whereas deterministic repair is evaluated as a separate, offline execution policy. Per-protocol comparisons use the intersection of strict-usable firms required by each contrast.

In baseline B1 free-form generation, strict action usability for C4 was 15.3% for Gemini 3.1 Flash-Lite and 44.3% for GPT-5.4-mini; in the high regime it rose to 99.1% and 97.4%, respectively. In high B1, the C6-E minus C4R mean Oracle-alpha differences were +0.0897 and +0.1003. However, effects depended on budget, execution rule, and model. GPT's baseline B1 self-review difference decreased from +0.1693 under strict execution to +0.0047 under repaired execution. High reasoning did not uniformly improve BINF scores, and small differences from C3-E did not establish policy equivalence. Firm-level incremental effects were substantially less repeatable than absolute credit scores.

These findings support evaluating the complete policy harness—including inference settings, prompts, action constraints, reference assignment, validation, and execution rules—rather than the model name alone. A discrepancy between the planning document's parent-usability gate and the pre-live raw-draft branching specification is disclosed and assessed through offline sensitivity analysis. Output ceilings also changed in the high regime. Results are conditional on the selected firms, evaluator and implementation; they do not demonstrate actual rating improvement, universal policy superiority, or the safety of automated firm-level recommendations.

Keywords: large language model; corporate credit rating; algorithmic recourse; offline reinforcement learning; model validation; policy harness; execution validity

초록

검증 우선 평가 프레임워크를 통한 LLM 생성 기업 신용등급 개선권고 평가: 신용평가모형-강화학습-LLM 파이프라인

본 연구는 대규모 언어모형(LLM)이 생성한 기업 신용등급 개선권고의 실제 실행효과를 직접 관찰하기 어려운 상황에서, 권고를 어떤 평가기반과 실행규칙 아래에서 비교해야 하는지를 검토한다. 검증 우선 접근에 따라 평가 하네스가 제공하는 증거의 범위와 그 안에서 측정된 정책가치를 구분하였다. 서로 다른 구조의 세 신용평가모형과 회계적으로 일관된 재무 Simulator 를 공통 평가기반으로 사용하되, 개발 단계의 검증자료, 최신 행동별 평가, 현실의 실행효과를 동일한 근거로 취급하지 않았다.

최종 V4.3 실험은 2024 년 한국 상장기업 575 개를 대상으로 8 차원 관리행동과 9 개 표준후보를 비교한다. 행동크기는 P50 기준으로 정규화하고, 총 강도를 1 이하로 제한한 B1 과 총 강도 상한이 없는 BINF 를 함께 분석하였다. 학습 참조정책 C3-E 는 네 configuration 과 일곱 matched seed 의 28 개 actor 를 계층적 확률평균으로 결합한다. 개별 actor 의 학습목표에는 Oracle 점수를 직접 사용하지 않았지만, 최종 정책 선택에는 2024 년 개발·평가 표면의 반복적인 정책평가가 활용되었다. 따라서 선택과정까지 독립적인 외부 검증정책으로 해석하지 않았다.

LLM 조건은 직접 생성 C4, 진단 지시 C5, 동일 초안의 자기 재검토 C4R, 기업별 학습정책 참조를 제공한 C6-E, 참조의 주변분포를 보존하면서 기업 간 배정을 바꾼 C6-EX 로 구분하였다. Baseline 과 이후 추가한 High 추론 실행은 각각 24,150 건이며, 본실험 Run1 과 반복성 Run2 를 분리하였다. Strict 실행은 완료되었으나 사용할 수 없는 응답에 A0 를 적용하고, 결정론적 Repair 는 같은 원응답에 적용하는 별도 실행정책으로 평가하였다. PP 비교는 필요한 모든 조건에서 strict usable 인 동일 기업의 교집합으로 한정하였다.

B1 자유작성 C4 의 strict 행동 수용률은 Baseline 에서 Gemini 15.3%, GPT 44.3%였고, High 에서는 각각 99.1%, 97.4%였다. High B1 의 C6-E-C4R 정책가치 차이는 Oracle- α 에서 Gemini +0.0897, GPT +0.1003 이었다. 그러나 효과는 행동예산과 실행규칙에 의존하였다. GPT Baseline B1 의 C4R-C4 는 Strict +0.1693 에서 Repaired +0.0047 로 작아졌다. High 가

BINF의 점수를 항상 높이지는 않았고, C3-E와 평균이 비슷하다는 사실도 동등성을 입증하지 않았다. 기업별 증분효과의 반복성은 절대 신용평점의 반복성보다 낮았다.

이 결과는 모델명뿐 아니라 추론 설정, 프롬프트, 참조, 행동제약, 검증 및 실행규칙으로 구성된 정책 하네스를 함께 평가해야 함을 보여준다. 계획서의 부모 응답 수용 게이트와 실행 전 raw-draft 분기 명세의 차이는 공개하고 별도 민감도 분석으로 확인하였다. High에서 출력 토큰 상한도 변경되었으므로 순수한 단일 설정의 효과로 해석하지 않는다. 본 연구는 제한된 평가환경 안의 비교이며, 실제 신용등급 상승이나 개별 기업 권고의 안전성을 입증한 것은 아니다.

주제어: 대규모 언어모델, 기업 신용등급, 알고리즘적 권고, 오프라인 강화학습, 모델 검증, 정책 하네스, 실행 유효성

제 1 장 서론

1.1 연구 배경과 문제 제기

신용등급은 기업의 자금조달 비용, 투자자 접근성, 금융기관의 의사결정과 신용리스크 측정에 영향을 미치는 핵심 정보이다. 특히 투자등급과 투기등급 사이의 경계나 금융기관 내부등급 체계의 구간 이동은 기업의 차입조건뿐 아니라 금융기관의 한도 설정, 가격결정과 사후관리에도 실질적인 영향을 줄 수 있다. 따라서 기업의 현재 재무상태를 바탕으로 어떤 재무적·경영적 행동이 신용상태의 개선과 연결될 수 있는지를 체계적으로 검토하는 것은 기업과 금융기관 모두에 중요한 의사결정 문제이다.

최근 대규모 언어모형(Large Language Model, 이하 LLM)은 문서 요약이나 질의응답을 넘어 기업의 분석과 의사결정을 지원하는 도구로 활용 범위를 넓히고 있다. 기업의 재무정보와 산업정보를 해석하고 위험요인을 설명할 수 있다는 점에서, LLM은 신용위험의 원인을 진단하고 개선방안을 제안하는 조언 도구로도 활용될 가능성이 있다. 전통적인 신용평가모형이 기업의 신용위험을 예측하거나 분류하는 데 중점을 두었다면, LLM은 관측된 위험요인을 바탕으로 구체적인 행동방안을 자연어로 제안할 수 있다는 차별성을 가진다.

그러나 기업 신용등급 개선권고는 일반적인 정보제공이나 문서작성과 동일하게 다루기 어렵다. 권고가 기업의 재무정책에 반영될 경우 자금조달, 투자, 유동성과 자본구조에 영향을 줄 수 있으며, 금융기관이 이를 여신심사나 사후관리의 보조수단으로 활용할 경우 잘못된 권고의 실패비용도 커질 수 있다.

따라서 이 영역에서 LLM을 활용하려면 출력의 유창성이나 설득력뿐 아니라 권고의 신뢰성, 설명가능성, 제약 준수와 검증가능성을 함께 검토해야 한다. 금융분야의 인공지능 거버넌스에서도 의사결정 지원 도구에 대한 인간의 최종 책임, 모델리스크 관리와 지속적인 검증이 강조되는 이유가 여기에 있다.

본 연구에서 기업 신용등급 개선권고는 기업의 현재 재무상태를 바탕으로 신용상태를 개선할 수 있는 재무행동의 방향과 규모를 제안하는 것으로 정의한다. 이러한 권고는 단일 재무지표가 아닌 부채, 투자, 운전자본과 비용구조에 관한 복수의 행동을 동시에 제안할 수 있고, 한 항목의 개선이 다른 항목의 악화로 이어질 수도 있다. 따라서 LLM의 권고는 자연어 설명의

생성이라기보다, 제약된 다차원 행동공간에서 행동의 방향·규모·조합을 선택하는 정책 문제로 이해할 필요가 있다.

문제는 이러한 권고의 품질을 직접 관찰하기 어렵다는 데 있다. LLM 이 제안한 재무행동을 실제 기업에 임의로 적용하고 이후 신용등급의 변화를 관찰하는 실험은 현실적으로 수행할 수 없다. 또한 생성된 권고를 실제 신용평가사에서 사용하는 신용평가모형에 입력하여 가상의 신용등급을 산출할 수 없다. 따라서 LLM 권고를 평가할 기반(Evaluation Framework)의 설계 자체가 선행되어야 한다.

본 연구는 이러한 문제에 대하여 LLM 생성 신용등급 개선권고를 위한 검증 우선 평가체계를 제안한다. 기업의 재무상태와 정책행동을 입력받아 다음 해의 반사실적 재무상태를 산출하는 재무 Simulator 와, 그 상태를 평가하는 세 신용평가모형을 구분하여 구성한다. 여기서 반사실적 재무상태는 실제로 관측한 결과가 아니라 특정 행동과 계산 가정을 적용하여 얻은 가상적 결과이다. 권고를 만들기 위한 Candidate-IQL 과 LLM, 권고를 점수로 바꾸기 위한 평가기반은 서로 다른 역할을 담당한다.

권고 생성과 실행 사이에도 별도의 문제가 존재한다. 행동의 방향이 타당해 보이더라도 응답에서 하나의 행동을 읽을 수 없거나, 행동의 강도가 허용예산을 넘거나, 서로 양립할 수 없는 행동을 함께 제안하면 자동 적용할 수 없다. 반대로 설명문의 형식이 불완전하더라도 행동 자체는 명확할 수 있다. 따라서 출력의 완결성, 행동계약의 준수, 설명의 형식, 평가기반 안의 정책가치를 하나의 성공물로 합치지 않는다.

이 구분은 추론과 자기 재검토를 해석할 때 중요하다. 재검토 후 평균점수가 높아졌더라도 그 변화가 더 나은 재무판단 때문인지, 이전에 적용되지 못한 행동이 유효한 형식으로 다시 작성되었기 때문인지 확인해야 한다. 본 연구는 프롬프트에 진단 지시를 추가하는 변화와 API 의 추론 설정을 높이는 변화, 그리고 원응답을 처리하는 실행규칙의 변화를 분리하여 비교한다. 연구의 초점은 가장 높은 점수의 모델을 선정하는 데 있지 않고, 관측된 정책가치가 무엇을 측정하는지 밝히는 데 있다.

1.2 연구문제와 평가의 두 간극

본 연구의 배후에 있는 실무적 질문은 “LLM의 권고는 기업의 신용등급을 실제로 개선하는가”이다. 현실에서 이 효과를 직접 관찰하기 어려운 이유를 먼저 확인한 뒤, 본 연구가 다루는 두 가지 타당성 간극을 구분한다.

현실에서 정책효과를 직접 관찰하기 어려운 이유는 세 가지다. 첫째, 재무행동의 실행에서 재무상태의 변화까지, 그리고 재무상태의 변화에서 신용등급에의 반영까지는 각각 수개월에서 1년 이상의 시차가 존재한다. 둘째, 동일 기업에 서로 다른 행동을 동시에 적용하여 결과를 비교하는 반사실적 관찰은 원천적으로 불가능하다. 셋째, 실제 신용등급에는 재무행동과 무관한 거시환경, 산업충격과 다른 경영계획도 함께 반영된다. 이러한 관찰상의 제약과 별개로, 본 연구의 타당성 문제는 평가기반 내부의 Gap 1과 평가환경-현실 사이의 Gap 2로 구분된다.

이렇게 구축한 반사실적 평가환경이 실제 신용등급과 무관하다면 평가는 의미를 잃는다. 첫 번째 간극(Gap 1)은 평가기반 내부의 문제이다. 실제 재무제표에서 산출한 신용평점이 동일 기업-연도의 실제 신용등급과 순위상 정렬되는가, 그리고 신용평점의 변화가 다음 해 실제 신용등급의 변화에 선행하여 방향상 정렬되는가. 아울러 행동을 재무상태에 적용하는 시뮬레이터가 회계항등식과 사전 정의된 행동을 일관되게 적용하는가. 본 연구는 이 간극을 직접 검증한다. 두 번째 간극(Gap 2)은 평가환경과 현실 사이의 문제이다. 평가기반에서 높은 신용평점을 받은 행동을 실제로 실행하였을 때 실제 등급상승으로 이어지는지는 별개의 질문이다. 경영진 성향 등 외생적인 요인은 본 연구의 실험에 포함되지 않는다.

따라서 본 연구의 검증 대상은 “LLM의 권고가 실제 신용등급을 개선하는가”가 아니라, “실제 신용등급과의 제한적 정렬성이 확인된 평가기반에서 측정할 때, 서로 다른 LLM 권고와 비교정책의 상대적 가치는 어떠한가”이다. 정책을 비교하기에 앞서 평가기반의 타당성부터 검증하는 검증 우선(validation-first) 접근이 본 연구의 방법론적 출발점이다.

평가기반 내부의 타당성도 한 번의 검증으로 끝나지 않는다. 실제 재무자료에서 Oracle이 등급의 순서를 일정 부분 반영한다는 증거와, Simulator가 새로운 관리행동을 정확히

전파한다는 증거는 별개이다. 행동의 정의가 바뀌면 회계항등식이 유지되는지만이 아니라 차환의 원금중립성, 부채상환의 유동성 제약, 성장투자의 유예와 자산매각의 구분을 다시 점검해야 한다. 본 논문은 개발 단계의 검증 수치를 최신 V4.3 행동계약에 대한 전면 재검증 결과로 자동 승계하지 않는다.

또한 같은 기업의 무행동 점수를 빼는 것만으로 모든 Simulator 편향이 제거되지는 않는다. 두 경로에 공통인 수준오차는 상쇄될 수 있지만, 특정 행동에만 발생하는 자금조달·영업·회계 전파오차는 차이 안에 남는다. 따라서 정책가치의 차이는 공통 가정 아래의 상대적 비교로 해석하며, 실제 기업의 신용등급 상승이나 금전적 편익으로 직접 환산하지 않는다.

1.3 연구의 목적과 연구질문

연구의 목적은 세 가지이다. 첫째, 정책비교에 사용한 평가기반의 사용범위와 검증상의 한계를 구분한다. 둘째, 재현 가능한 학습정책 참조를 고정하고 LLM 정책을 동일한 기업·행동 의미론·평가경로에서 비교한다. 셋째, 출력공간, 행동예산, 진단 지시, 자기 재검토, 참조의 기업별 배정, 추론 설정과 실행규칙이 관측된 정책가치를 어떻게 바꾸는지 분해한다. 기존 연구질문 RQ1-RQ5의 번호와 문제의식은 유지하되, 최종 실험이 실제로 식별하는 비교범위를 명시한다.

표 1-1. 연구질문과 최종 실험의 대응

구분	연구질문	최종 분석범위
RQ1 평가기반 타당성	실제 재무자료에서 Oracle의 신용평점이 실제 등급의 순서와 이동방향에 정렬되는가? Simulator는 정해진 행동을 회계적으로 일관되게 적용하는가?	개발 검증의 범위, V4.3 의미론 점검, 최신 9 후보의 평가자 민감도
RQ2 행동가치· 상대순위	각 정책은 무행동·휴리스틱·고정행동·학습정책·후보공간 상한과 비교하여 어느 위치에 있는가?	A0, C1, C2, 고정 OE, C3-E 및 각 Oracle 내부의 후보 상한
RQ3 추론·재검토· 참조	진단 지시와 자기 재검토는 정책가치를 높이는가? 학습정책의 참조와 그 기업별 배정은 어떠한 차이를 만드는가?	C5-C4, C4R-C4, C6-E-C4R, C6-E-C6-EX; High는 별도 추가 분석

구분	연구질문	최종 분석범위
RQ4 강건성· 행동공간	정책효과는 평가모형과 행동예산에 따라 유지되는가? 후보선택과 자유작성의 결과는 다른가?	Oracle- $\alpha/\beta/\gamma$, B1/BINF, candidate9 와 free8 의 공통 B1 조건
RQ5 정보조건	제공하는 기업정보의 범위가 넓어지면 행동과 정책가치가 달라지는가?	C4/free8/B1 의 IC-a $\rightarrow$ IC-b $\rightarrow$ IC-c; 기업명 회상 프로브는 미실행

주: C6-EX 는 균등 무작위 후보를 새로 뽑는 조건이 아니라, C3-E 의 참조행동 분포를 유지하면서 기업 간 배정을 바꾼 조건이다. 모든 분석의 단위는 575 개 기업이다.

1.4 연구의 전체적 접근

본 연구의 평가는 다음 경로로 이루어진다. LLM 또는 참조정책이 기업의 현재 재무상태를 입력받아 재무행동을 제안하면, Simulator 가 회계항등식을 준수하며 그 행동을 최근 시점의 재무상태에 적용하였을 때 1 년 후의 반사실적 재무상태를 산출한다. Oracle 은 산출된 반사실적 재무상태를 신용평점으로 변환한다. 재무행동의 가치는 아무 행동도 하지 않은 상태(no-op)의 평점과의 차이로 측정한다.

학습 참조정책은 Candidate-IQL actor 28 개를 결합한 C3-E 로 고정하였다. 네 configuration 각각에서 일곱 seed 의 행동확률을 평균하고, 네 평균을 동일한 25% 비중으로 결합한다. 동결 이후 기업별 행동은 이 확률벡터의 최댓값으로 정하며 Oracle 점수나 critic Q 값으로 다시 순위를 정하지 않는다. 다만 최종 configuration 과 encoder 를 정하는 과정에는 2024 년 평가가 활용되었으므로, 학습목표의 분리와 선택과정의 독립성을 구별한다.

LLM 은 9 개 표준후보 중 하나를 고르거나, 8 차원의 관리행동을 자유롭게 작성한다. B1 은 정규화된 총 행동강도를 1 이하로 제한하고 BINF 는 그 총합 상한만 제거한다. 두 조건 모두 축별 허용범위와 DL-RF 상호배타 조건은 유지된다. 따라서 BINF 를 아무 제약도 없는 조건이라고 부르지 않는다.

Baseline 은 실행 전에 동결한 기본 생성 설정이고, High 는 그 결과를 확인한 뒤 추가한 추론설정 민감도 실행이다. Repaired 는 추가 생성이 아니라 보존된 원응답에 결정론적 변환을 적용한 별도 실행정책이다. 이러한 구분에 따라 본문은 Baseline Strict 의 Run1 을 먼저 보고하고, 이후 High 와 Repaired 에서 결과의 해석이 어떻게 달라지는지 분석한다.

표 1-2. 평가경로와 보존하는 정보

단계	입력과 처리	분리하여 보존할 대상
생성	기업정보·행동계약·프롬프트·추론 설정을 입력하여 원응답 생성	모델 식별자, request ID, 부모 초안, 원응답
검증·실행	행동 파싱 및 계약 검사; Strict 또는 Repaired 규칙 적용	proposed, accepted, ITT, 오류와 변환내역
재무 전파	동일 기업의 정책행동과 A0 를 같은 Simulator 에 적용	실행 행동, 재무상태, 유동성·cash-plug 관련 가정
평가	각 Oracle 내부에서 정책행동과 A0 의 차이 계산	절대 신용평점과 A0 대비 정책가치
비교	동일 기업의 조건 간 차이를 집계; Run1/Run2 분리	ITT, strict 교집합 PP, 불확실성, 반복성

1.5 연구의 기여

첫째, LLM 권고의 품질을 평가하기 전에 평가기반이 무엇을 검증했는지 구분하는 틀을 제시한다. Oracle 의 등급 정렬, Simulator 의 회계적 일관성, 행동별 평가 민감도와 현실의 실행효과를 동일시하지 않는다. 이를 통해 검증자료가 존재한다는 사실보다 그 자료가 현재의 주장에 적용되는 범위를 확인한다.

둘째, 동일한 C4 초안에서 출발한 자기 재검토·학습정책 참조·불일치 참조를 비교하고, B1 과 BINF 에서 같은 대비를 반복한다. 이 설계는 최종 수정효과를 재검토 조건의 차이와 추가 참조 조건의 차이로 나눈다. 참조가 있다는 사실, 참조의 내용, 참조와 기업의 연결을 구분하여 서술할 수 있다는 점이 중요하다.

셋째, 생성모델과 실행규칙의 결합이 관측된 정책가치에 영향을 준다는 것을 실제 원응답과 재평가 기록으로 확인한다. 특히 Strict 와 Repaired 의 차이를 모델의 본래 의도 복원으로 해석하지 않고, 서로 다른 실행정책의 차이로 취급한다. 높은 추론 설정에서 수용률이 개선되더라도 평균 정책가치와 개별 권고의 반복성은 다른 결과일 수 있음을 함께 제시한다.

이 연구는 실제 신용등급 개선을 입증하거나 특정 모델의 보편적 우월성을 주장하지 않는다. 연구의 기여는 제한된 평가환경에서의 비교를 더 명료하게 만들고, 같은 모델명 아래에서도 달라질 수 있는 생성·검증·실행 조건을 재현 가능한 평가단위로 제시하는 데 있다.

1.6 논문의 구성

제 2 장은 기업 신용위험 측정, 알고리즘적 권고, 오프라인 강화학습과 정책으로서의 LLM 문헌을 검토하고 연구질문에 대응하는 분석틀을 제시한다. 제 3 장은 V4.3 행동계약, 표본과 실행조건, 참조정책의 결합, 네 행동 계층, Strict·Repaired 및 PP, 통계적 비교를 정의한다.

제 4 장은 평가기반 개발검증과 최신 의미론 점검의 범위를 구분하고, 9 개 후보행동의 평가결과와 C3-E 의 역할을 살펴본다. 제 5 장은 Baseline Run1 의 실행완결성, 수용률, 정책가치, 네 핵심 대비, 행동공간과 정보조건을 제시한다. 제 6 장은 High 와 Repaired, 추론설정과 조건효과의 상호작용, 부모 분기규칙에 대한 민감도, 반복성과 API 비용을 다룬다. 제 7 장은 연구질문을 회수하고 실무적 함의와 한계를 정리한다. 부록은 현재 행동명세, 전체 수치표, 추적정보와 프롬프트를 제공하고 구형 실험의 지위를 별도로 기록한다.

제 2 장 이론적 배경과 분석틀

본 장은 본 연구가 참고하는 기존 연구인 기업 신용위험의 계량화, 알고리즘적 권고 (algorithmic recourse), 오프라인 강화학습, 그리고 정책으로서의 LLM 을 차례로 검토한다. 각 절은 해당 연구가 무엇을 해결하였고 무엇을 미해결로 남겼는지 확인한 뒤, 미해결 지점이 본 연구의 어떤 설계요소로 이어지는지를 서술한다.

이어 제 2.5 절에서 본 연구의 평가단위인 정책 하네스와 그 이론적 근거인 측정 타당성 연구를 정리하고, 제 2.6 절에서 이 평가단위를 검증 없이 다룰 때 발생하는 세 가지 귀속 문제를 정의한다. 제 2.7 절은 선행연구의 공백을 종합하며, 제 2.8 절은 제 1 장의 연구질문 RQ1-RQ5 에 대응하는 가설 H1-H5 를 도출한다.

2.1 기업 신용위험 측정과 신용평가

2.1.1 예측 문제로서의 신용위험: 회계·구조·기계학습 모형

기업 신용위험의 계량화는 세 가지 흐름으로 발전해 왔다. 첫 번째는 회계정보 기반 평가이다. Beaver(1966)는 개별 재무비율이 부도기업과 건전기업을 수년 전부터 구분할 수 있음을 보였고, Altman(1968)은 다섯 개 재무비율의 판별함수(Z-score)로 이를 다변량 문제로 확장하였다. Ohlson(1980)은 판별분석의 분포 가정 문제를 지적하며 로지스틱 회귀로 부도확률을 직접 추정하는 틀을 제시하였고, 이 확률적 접근은 이후 순서형 모형을 통한 등급 예측으로 이어졌다.

두 번째는 시장정보 기반 구조모형이다. Merton(1974)은 기업의 자기자본을 기업가치에 대한 콜옵션으로 보아 부도를 기업가치가 부채가치를 하회하는 사건으로 정의하였고, 이 구조에서 도출되는 부도거리(distance-to-default)는 KMV 모형을 통해 실무 부도예측의 표준 지표로 정착하였다(Kealhofer, 2003). Jarrow 와 Turnbull(1995)의 축약형 모형은 부도를 외생적 강도과정으로 다루어 시장가격에서 위험을 역산하는 보완적 경로를 마련하였다.

세 번째는 기계학습 방법으로, 트리 앙상블과 신경망이 비선형성과 상호작용을 포착하여 예측 정확도를 추가로 끌어올렸다.

이 세 가지 흐름은 공통적으로 하나의 질문, 즉 "이 기업의 신용상태는 얼마나 위험한가"라는 측정·예측 문제를 다룬다. 본 연구는 기존 연구들을 반영하여, 세 가지 Oracle 을 구성할 때 각 흐름별 대표 구조 - 스코어카드 신용평가모형(회계정보 기반 표준), 순서형 로짓(확률적 등급모형), 트리 앙상블(기계학습) - 를 그대로 차용하며, Candidate-IQL 의 보조보상에는 Merton 모형에 따른 부도거리 근사가 포함된다.

2.1.2 검증가능성과 사용범위

신용위험 예측의 개선과 기업이 실행할 행동의 제안은 서로 다른 문제이다. 예측모형은 자료에서 위험의 차이를 구분하는 것을 목표로 하지만, 권고는 어떤 변화를 실행하고 그 변화가 다른 재무항목에 미치는 영향을 함께 다루어야 한다. 따라서 예측 정확도가 높다는 사실만으로 처방의 타당성이 확보되는 것은 아니다.

금융 업무에서 모형을 사용할 때 예측 정확도가 유일한 설계기준은 아니며, 특히 Basel Framework 의 내부등급법(IRB) 최소요건은 내부등급법의 승인, 검증, 문서화, 지속적 사용 가능성을 요구하므로(Basel Committee on Banking Supervision, 2022), 정확도가 높다는 사실만으로는 모형의 도입이 정당화되지 않는다.

본 연구는 이러한 규제적 요구를 두 가지 방식으로 반영한다. 하나는 주 평가도구인 Oracle- α 를 금융 실무에서 널리 쓰이는 스코어카드 구조로 구성하는 것이고, 다른 하나는 LLM 등 정책의 성과를 비교하기 전에 평가도구가 개발기간외 데이터(OOT)에서도 실제 신용등급과 정렬되는지를 먼저 검증하는 것이다.

본 논문에서 규제환경은 연구의 동기를 제공한다. 제시한 실험이 감독상 모형승인 요건 전체를 충족한다는 의미로 사용하지 않는다. 회계항등식과 출력형식 검증은 승인에 필요한 여러 검토 중 일부이며, 실제 고객·기업에 적용할 경우에는 별도의 실행가능성 및 책임구조 검토가 필요하다.

2.1.3 LLM 과 신용위험: 진단에서 처방으로

최근에는 LLM 을 신용평가 영역에 적용하려는 연구가 빠르게 축적되고 있다. Golec 과 Alabduljalil(2026)의 체계적 문헌검토는 이 흐름을 해석가능성 중심으로 분류하면서, 대다수

연구가 여전히 분류·예측 과제(부도 예측, 등급 분류, 텍스트 기반 위험신호 추출)에 LLM을 투입하고 있음을 보였다. 반면 재무정보를 해석하고 위험요인을 자연어로 설명할 수 있다는 LLM의 특성은 구체적인 개선행동을 제안하는 처방의 가능성을 시사한다. 본 연구는 이러한 예측·진단의 활용과 구분하여, 처방으로 생성된 재무행동을 어떤 실행규칙과 평가기반 아래에서 비교할지를 연구문제로 삼는다.

2.2 알고리즘적 권고와 반사실적 설명

2.2.1 반사실적 설명에서 실행가능한 권고로

기계학습의 설명가능성 연구에서 반사실적 설명(counterfactual explanation)은 "입력이 어떻게 달라져야 결과물이 바뀌었을 것인가"를 제시하는 접근이다. (Wachter et al., 2017). Karimi et al.(2020a)은 모델에 종속되지 않는 반사실적 설명의 생성문제를 다루었고, Ustun 등 (2019)은 이를 실행가능성(actionability)의 문제로 전환하였다. 결과를 뒤집는 입력 변화가 존재한다는 것과, 그 변화의 구현 가능성은 다르다는 것이다. 실행가능한 권고(actionable recourse)는 변경 가능한 특성의 구분, 변화의 방향 제약, 감당 가능한 변화량의 상한을 문제의 표준 구성요소로 확립하였다.

Karimi 등(2021)은 이 흐름을 개입(intervention)의 관점에서 재정의하였다. 특성들 사이에 인과구조가 존재한다면, 한 특성의 변경은 다른 특성으로 전파되므로 권고는 특성값의 나열이 아니라 인과모형 위의 개입 집합으로 정의되어야 한다는 것이다(Pearl, 2009). 인과지식이 불완전한 현실에서는 권고의 성공이 확률적일 수밖에 없다는 점(Karimi et al., 2020b), 권고 실행 자체에 잡음이 개입하는 순차적 환경의 문제(Xuan et al., 2025), 그리고 권고가 유발할 수 있는 위험을 정책 차원에서 관리해야 한다는 문제(Wu et al., 2024)가 후속 연구에서 다루어졌다.

이 논의는 본 연구의 행동표현과 Simulator 설계로 이어진다. 단순히 부채비율이 낮아졌다는 목표를 제시하는 대신, 상환·차환·성장 CAPEX 유예와 같이 재무제표에 적용할 수 있는 관리행동을 먼저 정한다. 같은 비율 개선이라도 자산 증가에 의한 변화와 차입금 상환에 의한 변화는 필요한 현금과 위험이 다르기 때문이다.

V4.3의 행동크기는 각 관리행동을 고정된 기준척도로 나눈 정규화 강도의 합이다. 이 값은 서로 다른 단위의 항목을 연구용 예산으로 비교하기 위한 정의이지, 모든 행동을 같은 원화 비용으로 만들었다는 뜻이 아니다. 회계적 실행가능성과 경제적 실행가능성도 구분한다. Simulator가 균형 재무제표를 만들 수 있어도 차환시장 접근, 고객과의 결제협상, 비용절감의 조직적 실행을 보장하지는 않는다.

2.2.2 기업 신용 영역의 recourse와 본 연구의 위치

Recourse 문헌은 일반적으로 단일 시점의 개인 신용상태에 대한 평가결과를 대상으로 발전하였다. 기업 신용등급으로 대상을 옮긴 연구는 최근에야 나타난다. Wang, D. 등(2023)은 기업 신용등급 모형에 대해 회소성 제약 하의 최적 반사실적 설명을 탐색하는 알고리즘을 제안하여, "가장 적은 수의 재무비율 변경으로 등급을 바꾸는 조합"을 찾는 문제를 다루었다. Lashkevich와 Zelenkov(2026)는 부실기업을 대상으로 회계적 일관성을 유지하는 실행가능한 권고를 생성하는 의사결정지원 프레임워크를 제안하였으며, 이는 본 연구의 문제의식을 상당 부분 공유한다. Dong 등(2026)은 표 형식 데이터에서 문맥내학습(in-context learning)으로 recourse를 생성하는 접근을 제안하여, LLM을 권고 생성기로 쓰는 경로를 열었다.

직접적인 반사실적 설명에서는 예측모형의 결과를 바꾸는 입력을 찾는 것이 성공의 정의가 될 수 있다. 그러나 기업 권고에서는 입력 변화가 회계적으로 연결되는 과정과 평가모형의 사용범위를 함께 살펴야 한다. 본 연구는 권고 생성과 평가를 구분하고, 학습된 참조정책을 LLM의 외부 입력으로 활용하되 이를 정답정책으로 두지 않는다.

이때 분리의 정도를 과장하지 않는 것이 중요하다. 개별 actor의 학습에 Oracle 점수를 직접 넣지 않았다는 사실과, 연구자가 Oracle 평가를 보며 configuration이나 앙상블을 선택하지 않았다는 주장은 다르다. 본 연구의 최종 참조정책은 전자의 분리를 갖지만 후자의 완전한 독립성을 갖지는 않는다. 따라서 제한된 개발·평가 표면에서 얻은 참조정책을 사용한 비교라고 명시한다.

또한 본 연구는 산출물 하나뿐 아니라 생성조건과 실행규칙의 조합을 비교한다. 입력정보, 후보선택과 자유작성, 행동예산, 추가 추론, 재검토와 참조배정, 파싱 실패의 처리방식은 모두

서로 다른 권고분포를 만들 수 있다. 이러한 조건의 차이가 최종 평가에 어느 단계에서 반영되는지를 구분하는 것이 본 연구의 분석단위이다.

2.2.3 개인 recourse 와 기업 recourse 의 구조적 차이

대상을 개인에서 기업으로 옮기는 것은 단순한 응용 확장이 아니다. 세 가지 차이가 문제의 구조를 바꾼다. 첫째, 행동의 차원성과 결합성이다. 기업의 재무행동은 부채, 투자, 운전자본, 비용, 자본에 걸친 다차원 벡터이며, 여러 재무항목을 함께 바꾸는 조합 자체가 전략(부채 축소, 차환, 유동성 확충 등)을 구성한다. 둘째, 회계적 전파이다. 부채 상환은 현금을 줄이고 자산 매각은 수익 기반을 줄이는 것처럼, 한 재무항목의 변화는 회계항등식을 통해 다른 항목으로 필연적으로 전파된다. 셋째, 시차이다. 행동과 등급 반영 사이에는 회계결산과 정기신용평가의 주기가 있으므로, 권고의 평가는 단일 시점의 특성 변경이 아니라 1년 후의 반사실적 재무상태에 대한 평가여야 한다.

8차원 관리행동과 회계항등식을 보존하는 전파구조, 1년 후 반사실 상태에서의 정책가치 계산은 이러한 결합성과 시차를 반영한다. 다만 1년의 비교기간을 사용했다는 사실은 장기 성장·투자능력의 손실까지 모두 평가했다는 의미가 아니다. 성장투자를 늦추어 단기 유동성을 높이는 행동은 다기간 관점에서 다른 결과를 만들 수 있으므로, 분석기간과 가정을 함께 제시한다.

2.3 순차적 의사결정과 오프라인 강화학습

2.3.1 오프라인 설정과 분포이동

기업의 재무행동은 매년 재무상태에서 경영계획을 이행하고 그 결과로 회계연도 결산이 이루어져 다음 재무상태로 이동하는 순차적 과정이며, 상태·행동·보상·전이로 구성되는 마르코프결정과정(Markov Decision Process)으로 형식화할 수 있다. 그러나 기업에 임의의 재무 의사결정을 시행하여 그 등급 변화를 관측할 수는 없으므로, 환경과 직접 상호작용한다는 강화학습의 표준 전제가 본 연구에는 성립하지 않는다.

따라서 본 연구는 과거 데이터만으로 정책을 학습하는 오프라인 강화학습 (Offline Reinforcement Learning, Levine et al. 2020)을 채택하였다. 오프라인 강화학습의 핵심 난점은 분포 이동(distribution shift)이다. 학습된 정책이 데이터에 거의 없던 행동을 시도할 때, 가치함수가 그 행동을 학습한 적이 없어 임의로 높은 값을 부여하고, 그 결과 정책이 잘못된 방향으로 향하는 문제이다.

이에 대한 대응은 두 갈래로 나뉜다. 첫째는 보수적 방안으로, 학습 정책을 데이터의 행동 분포 가까이로 제약하거나(Fujimoto et al. 2019의 BCQ, Kumar et al. 2019의 BEAR), 분포 밖 행동의 Q 값에 페널티를 부과하여 가치를 보수적으로 추정한다(Kumar et al. 2020의 CQL).

둘째는 데이터 증강으로, 전이모형(dynamics model)을 학습하여 합성된 경험을 생성하되 부정확한 영역으로 벗어나는 것을 억제하거나(Yu et al. 2020의 MOPO, Kidambi et al. 2020의 MOREL, Yu et al. 2021의 COMBO), Pitis et al.(2020)의 CoDA 처럼 국소 인과구조를 활용하여 반사실적 전이를 생성하는 접근도 제안되었다.

2.3.2 Candidate-IQL의 지위와 선택 불확실성

본 연구는 분포 밖 행동의 가치를 아예 참조하지 않고 데이터 내부의 행동으로 가치를 추정하는 Kostrikov et al.(2022)의 IQL을 채택하고, 회계 항등식에 기반한 결정론적 재무 시뮬레이터를 전이모형으로 사용하여 관측된 기업-연도에서 행동만을 표준 행동으로 교체한 반사실 전이를 생성하고 행동별 학습 신호를 보강한다. 이로써 확률적 전이모형에서 발생하는 불확실성은 줄일 수 있으나, 회계 항등식 기반 시뮬레이터 자체에서 비롯되는 모형위험은 별도의 검증으로 점검한다.

다만 본 학위논문에서의 실험 단위는 1년 단위의 단일 행동 선택이므로, 장기 누적보상을 직접 학습하는 완전한 다기간 MDP라기보다 contextual-bandit-like one-step offline decision problem에 가깝다. 따라서 본 연구는 강화학습 정책을 주된 연구 대상으로 두기보다, LLM의 개선권고를 비교할 도메인을 학습한 참조 정책으로 사용한다.

최종 V4.3 학습은 할인계수 $\gamma=0$ 의 단일기간 설정으로 이해한다. 따라서 장기 누적보상의 최적 정책을 발견했다는 주장보다, 관측자료와 도메인 보조보상을 이용한 한 시점의 후보행동 비교정책을 구성했다는 기술이 적절하다. 관측 전이에서 불인 의사행동은 실제 경영진의 전략 선택을 관찰한 라벨이 아니라, 재무변화를 표준후보와 연결한 분석용 표현이다.

여러 seed의 확률평균은 특정 초기값의 변동을 줄이는 방법이지만, configuration 탐색이나 평가표면의 반복 사용으로 발생한 선택 불확실성을 제거하지는 않는다. 또한 여러 actor의 성능을 평균한 수치와 평균확률의 argmax가 생성한 하나의 배포정책 성능은 다르다. 본 논문은 후자를 최종 C3-E의 성능으로 보고하며, seed·configuration 제거 분석을 선택 이후의 강건성 진단으로 제시한다.

2.4 정책으로서의 LLM

2.4.1 프롬프트의 추론 유도과 API 추론 설정

본 연구와 관련되는 문헌은 추론 유도, 자기 수정과 외부 정책 참조의 세 흐름으로 나눌 수 있다. 추론 유도(reasoning elicitation) 연구는 중간 추론을 생성하게 하는 지시가 일부 과제의 성능을 높일 수 있음을 보였다(Wei et al., 2022; Wang, X. et al., 2023; Yao et al., 2023). 반면 그 이득이 수학·기호 과제에 집중되거나 응답형식의 제약이 강할수록 줄어든다는 결과도 보고되었다(Sprague et al., 2024; Tam et al., 2024; Schall & de Melo, 2025). 따라서 8차원 관리행동을 작성하는 본 연구의 조건에서 추론 유도가 점수를 높이는지는 경험적으로 확인해야 한다(H1). 또한 점수가 오르지 않더라도 행동크기, 변경된 재무항목 수와 표준후보와의 거리가 달라질 수 있으므로 행동의 변화도 함께 측정한다(H2).

최종 실험에서는 ‘추론’이라는 용어를 두 수준으로 나눈다. 첫째, C5는 같은 모델·API 추론 설정에서 유동성, 레버리지·만기구조, 영업효율과 수익성을 진단하도록 명시하는 프롬프트 조건이다. C5-C4는 이러한 지시가 추가된 정책의 차이를 묻는다. 둘째, High는 같은 조건표를 별도로 실행하면서 공급자의 추론 설정을 높인 생성 체제이다. High-Baseline은 프롬프트 지시의 효과와 동일하지 않다.

또한 High 실행에서는 최대 출력 토큰 상한이 함께 변경되었다. 후속 조건은 각 생성 체제에서 나온 C4를 사용하므로 부모 초안의 내용도 달라진다. 따라서 이 비교는 동일한 문자열 입력에서 추론 파라미터 하나만 바꾼 통제실험이 아니라, 기록된 기술변경을 포함하는 추론 실행 체제의

민감도 분석이다. 두 공급자가 모두 high 라는 이름을 사용하더라도 같은 계산량을 투입했다는 의미는 아니다.

2.4.2 자기 수정과 외부 정책 참조

다음은 자기 수정(self-correction) 연구이다. Self-Refine 은 모델이 자신의 출력에 피드백을 만들고 다시 수정하는 절차가 여러 과제에서 유효할 수 있음을 보였다(Madaan et al., 2023). 그러나 외부 피드백이 없는 자기 수정은 정답률을 높이지 못하거나 오히려 낮출 수 있으며(Huang et al., 2024), 성공 사례 가운데 상당수는 두 번째 단계에서 유입된 외부 정보나 인위적으로 낮춘 최초 응답의 영향을 포함한다는 비판도 있다(Kamoi et al., 2024). 따라서 수정 결과가 좋아졌다면 다시 검토했기 때문인지, 새 정보가 들어왔기 때문인지 분리해야 한다. 본 연구의 C4R 은 외부 정책 참조 없이 두 번째 검토만 부여하여 이 차이를 확인하는 조건이다.

마지막은 외부 정책 참조(external policy reference)와 조언 수용 연구이다. 참조의 가치는 참조 자체의 평균 품질만으로 결정되지 않는다. 현재 초안보다 나은 정보인지, 초안과 어느 방향으로 다른지, 모델이 그 차이를 최종 행동에 반영할 수 있는지에 따라 결과가 달라질 수 있다. 이에 본 연구는 기업별 Candidate-IQL 참조와 기업 간 불일치 참조에 대한 반응이 구별되는지 확인하고(H3), 같은 참조의 가치가 기업과 행동크기 제약에 따라 달라지는지도 제 6 장에서 분석한다.

자기 재검토의 이득은 처음 초안의 상태와 실행규칙에 따라 달라질 수 있다. 처음부터 usable 한 초안을 다시 판단하는 과제와, 형식 또는 예산을 지키지 못한 초안을 수정하는 과제는 동일하지 않다. 최종 정책가치의 변화에는 실제 행동의 재구성과 실행 가능 상태로의 전환이 함께 들어갈 수 있다. 이러한 가능성을 확인하기 위해 본 연구는 전체 기업의 ITT 와 strict-usable 교집합 PP 를 함께 보고한다.

2.4.3 출력 유창성·행동 유효성·정책가치

LLM 을 정책으로 볼 때에는 자연어 설명의 유창성과 최종 행동의 품질을 구분해야 한다. LLM 은 금융 영역에서 수치, 계산과 시점에 관한 오류를 그럴듯한 문장으로 제시할 수 있다(Huang, L. et al., 2023; Kang & Liu, 2023). 설명이 자연스럽더라도 필요한 행동값을 읽을 수 없거나, 허용범위를 벗어나거나, 설명에 적힌 행동값과 실제 행동값이 일치하지 않으면 권고의

효과를 제대로 평가할 수 없다. 따라서 본 연구는 필요한 행동값을 읽을 수 있는지, 요구한 형식과 행동크기 제한을 지켰는지를 확인하고, 행동 수용 여부와 설명 형식을 따로 기록한다. Strict ITT에서는 완료된 unusable 응답을 제외하지 않고 무행동으로 실행한 전체 정책을 평가한다. 방향이 잘못된 권고, 실제로 실행하기 어려운 권고, 외부 정책 참조를 지나치게 따른 권고와 근거가 부족한 권고는 결과를 해석할 때 따로 살펴본다.

따라서 전송 성공, 행동 수용, 전체 응답형식 준수와 신용평점 변화는 각각 다른 지표이다. HTTP 요청이 정상 종료되어도 행동계약을 위반할 수 있으며, JSON이 올바르게더라도 예산을 넘을 수 있다. 반대로 설명부의 필드가 요구 형식과 다르지만 행동은 명확한 경우에는 행동 수용률과 전체 형식 준수율이 다르게 집계된다. 이 구분 없이 한 가지 오류율로 정책의 유용성을 결론 내리지 않는다.

2.5 평가단위와 측정 타당성: 정책 하네스

2.5.1 동일 파운데이션 모델의 생성 정책 차이

LLM 평가는 흔히 모델명과 벤치마크 점수를 중심으로 이루어진다. 그러나 행동을 생성하는 상황에서는 같은 모델이 항상 같은 정책이 아니다. 어떤 정보를 주는지, 행동공간을 어떻게 제한하는지, 참조를 언제 보여주는지와 어떤 후처리를 거치는지에 따라 서로 다른 행동이 생성된다.

측정 타당성 연구는 평가점수가 실제로 측정하려는 개념을 반영하는지 먼저 확인해야 한다고 본다(Jacobs & Wallach, 2021). HELM은 정확도 하나가 아니라 평가 시나리오와 여러 평가항목을 함께 명시해야 함을 강조했고(Liang et al., 2022), 최근 연구는 LLM 벤치마크의 구성 타당성 부족을 지적하였다(Beaumont et al., 2025). 에이전트 평가 연구도 평가 대상이 모델 하나가 아니라 프롬프트·도구·후처리가 결합된 하네스이며, 조합을 특정하지 않으면 결과 비교와 재현이 어렵다고 보았다(Yehudai et al., 2025; Kapoor et al., 2025; Zhu et al., 2026). 본 논문에서는 이러한 결합을 정책 하네스(policy harness)라 칭한다.

2.5.2 정책 하네스와 평가 하네스의 구분

정책 하네스는 파운데이션 모델, 추론 설정과 출력 상한, 제공정보, 프롬프트와 호출구조, 출력형식, 행동예산, 참조배정 및 검증·실행규칙의 결합으로 정의한다. 반면 평가 하네스는 행동의 재무 전파와 그 상태의 점수화에 사용하는 Simulator 와 Oracle 의 결합이다. 전자는 어떤 행동이 만들어지고 적용되는지를, 후자는 그 행동이 연구환경에서 어떤 값을 받는지를 결정한다.

정책 하네스 h = (모델, 추론 설정, 정보, 프롬프트, 출력형식, 행동예산, 참조, 실행규칙)

평가 하네스 e = (Simulator, 시나리오, Oracle, 평가시점)

두 하네스를 구분하면 변경의 의미가 명료해진다. Repair 는 동일한 생성응답에 다른 실행규칙을 적용한 정책 하네스의 변경이다. Oracle 을 바꾸는 것은 동일한 행동을 다른 평가함수로 측정하는 평가 하네스의 변경이다. 어느 경우든 점수 차이를 파운데이션 모델 자체의 차이로만 귀속할 수 없다.

2.5.3 검증 우선 원칙의 적용범위

평가도구가 무엇을 측정하는지 확인하지 않고 정책가치를 비교하면, 평가도구의 특성을 정책의 효과로 잘못 해석할 수 있다. 따라서 본 연구는 먼저 평가모형의 신용평점이 실제 신용등급과 어느 정도 맞는지, Simulator 가 회계항등식을 지키는지 확인한다. 그다음 Candidate-IQL 을 비교용 참조정책으로 마련하여 LLM 정책들과 비교한다. 이후에는 정책조건에 따라 관측된 차이가 어디에서 생겼는지 살펴보고, 평균 정책가치뿐 아니라 기업별 효과와 구체적인 행동이 반복되는지도 확인한다.

검증 우선은 모든 불확실성을 없앤 뒤에만 비교한다는 의미가 아니라, 어떤 검증이 어떤 주장을 뒷받침하는지 먼저 드러내는 원칙이다. 본 연구에서는 개발 단계의 경험적 정렬성, 현재 계약의 의미론 검사, 최종 행동별 비교와 현실적 실행가능성의 미검증 영역을 구별한다. 데이터와 실행기록의 미해결 불일치는 점수표에서 숨기지 않고 해석범위에 반영한다.

2.6 정책가치의 귀속 문제

2.6.1 평가도구 귀속

Oracle 이 산출한 신용평점이 높아졌다고 해서 실제 신용등급이 높아졌다고 볼 수는 없다. 또한 같은 행동이라도 Oracle 의 계산방식에 따라 신용평점 변화가 크게 나타나거나 전혀 나타나지 않을 수 있다. 구간별 점수를 사용하는 Oracle- α 는 같은 구간 안의 변화를 동일한 신용평점으로 기록하지만, 다른 두 Oracle 은 더 작은 차이도 신용평점에 반영할 수 있다. 따라서 정책을 비교하기 전에 각 평가모형이 재무상태의 변화를 신용평점에 어떻게 반영하는지 확인해야 한다. 제 4 장에서는 시간외표본에서 평가모형의 성능을 확인하고, B2 지표가 실제로 측정한 평가경로의 타당성과 세 Oracle 에서 정책행동의 효과가 어떻게 나타나는지를 검증한다.

특히 원점수의 높은 기업 간 상관은 행동효과의 높은 일치도를 보장하지 않는다. 기업의 기본 신용상태가 공통으로 들어가면 두 정책의 절대점수 순위는 거의 같을 수 있다. 정책을 비교할 때에는 A0 대비 변화와 조건 간 증분효과를 별도로 계산하여, 기업 자체의 차이와 행동의 차이를 구분한다.

2.6.2 생성모델과 실행규칙 귀속

자유작성의 높은 정책가치를 기업별 맞춤능력 하나로 설명할 수는 없다. 허용하는 조합, 실제 사용 강도, 예산 위반을 처리하는 규칙이 다르면 관측 점수가 달라진다. 본 연구의 B1 은 비교 가능한 명목 예산을 제공하지만, 각 정책이 그 예산을 모두 소진한다는 뜻은 아니다. BINF 는 총합 상한을 제거하므로 원래의 후보공간 상한을 넘는 점수도 가능하다.

같은 원응답을 Strict 와 Repaired 로 평가한 차이는 실행규칙의 민감도를 보여준다. Repair 가 문법과 행동량을 바꿀 수 있으므로 이 차이를 ‘LLM 이 본래 의도한 올바른 응답의 가치’로 부르지 않는다. 또한 조건별 usable 기업이 다르면 그 기업들의 평균을 따로 빼는 방식으로 판단능력의 순수한 차이를 추정할 수 없다. 동일 기업의 교집합이 필요하다.

2.6.3 자기 재검토와 추가 참조 귀속

C4R 과 C6-E 는 같은 C4 에서 각각 출발하는 후속 조건이다. C4R 은 외부 정책정보 없이 다시 검토하고, C6-E 는 기업별 C3-E 의 행동 내용을 추가로 받는다. 두 값을 비교하면 재검토

기회를 공통으로 둔 상태에서 추가 참조 조건의 차이를 확인할 수 있다. C6-EX는 같은 참조행동 분포에서 기업별 배정만 바꾼 대조조건이다.

$$E \text{ 전체} = V(C6-E) - V(C4)$$

$$E \text{ 전체} = [V(C4R) - V(C4)] + [V(C6-E) - V(C4R)]$$

이 항등식은 같은 기업집단에서 계산할 때 성립한다. C4R을 실제로 거친 뒤 C6-E가 생성되었다는 뜻도, 두 항이 독립적인 인과 매개효과라는 뜻도 아니다. PP에서항마다 다른 교집합을 사용하면 그 평균을 단순히 더할 수 없으므로, 분해 전체를 보고할 때에는 필요한 조건의 공통집단을 고정해야 한다.

2.7 선행연구의 한계와 본 연구의 위치

앞의 논의는 평가의 네 가지 요구로 모인다. 권고의 점수를 실제 신용성과와 구분해야 하고, 점수화 이전에 어떤 행동이 수용·실행되었는지 밝혀야 하며, 재검토와 참조를 같은 출발점에서 비교해야 한다. 또한 평균적인 성과와 개별 기업 권고의 반복성을 별도로 확인해야 한다. 기존 문헌에서 제기된 평가 타당성, 자기 수정의 한계, 하네스 구성의 중요성은 이러한 요구를 뒷받침한다(Jacobs & Wallach, 2021; Kamoi et al., 2024; Liang et al., 2022).

본 연구는 Oracle과 Simulator의 역할을 분리하고, 학습정책을 외부 참조로 사용하는 조건과 기업 간 불일치 참조조건을 구성하며, 동일 응답을 다른 실행규칙으로 평가한다. 이는 새로운 파운데이션 모델을 제안하는 연구가 아니라, 기업 재무행동 생성에서 관측되는 정책가치의 조건 의존성을 분석하는 연구이다. 학습참조 선택과 추가 추론실험의 사후적 성격을 공개함으로써 분석이 답할 수 있는 범위를 제한한다.

2.8 연구가설과 추가 분석명제

H1-H5는 기존 연구질문에 대응하는 가설로 유지한다. 다만 최종 실행조건이 바뀌었으므로 가설의 취지와 이를 평가하는 대비를 구분하여 제시한다. 특히 과거의 균등 무작위 참조를 사용한 H3의 결과를 그대로 가져오지 않고, 최종 C6-E-C6-EX의 의미에 맞추어 참조배정에 대한 반응으로 평가한다. High와 Repaired에서 발견한 패턴을 최초 가설의 사전예측으로 소급하지 않는다.

표 2-1. 기존 가설과 최종 분석의 대응

구분	유지하는 질문·예측	최종 평가와 해석
H1	진단·추론 유도 지시가 정책가치를 높이는가?	같은 API 추론 설정에서 C5-C4; B1/BINF 별도
H2	진단 지시가 행동크기·구성·형식 준수를 바꾸는가?	강도·활성 차원·행동 수용률; 정책가치와 분리
H3	외부 참조내용에 따라 정책이 다르게 반응하는가?	C6-E-C6-EX; 주변분포를 고정한 배정조건 차이
H4-a	평가모형을 바꾸어도 주요 효과 방향이 유지되는가?	α 를 주 평가자로, $\beta \cdot \gamma$ 를 별도의 강건성 진단으로 사용
H4-b	자유작성과 후보선택은 가치와 행동에서 차이를 보이는가?	공통 B1 의 C4·C4R·C6-E; 자유작성 우위를 전제하지 않음
H5	정보범위가 정책행동과 가치를 바꾸는가?	C4/free8/B1 의 인접 정보조건 대비
추가 명제	추론 실행 체제와 Repair 가 결과의 해석을 바꾸는가?	High-Repaired 및 상호작용; 본실험 이후의 추가 분석

주: H4-b 의 기존 방향예측과 실제 최종 결과가 다르면 결과를 바꾸지 않고 그 차이를 보고한다. 외부 사전등록의 증거가 아닌 실행 전 동결 문서와 runtime 명세를 근거로 분석범위를 설명한다.

제 3 장 연구설계와 실행·분석 계약

본 장은 실제 실행된 V4.3 실험을 기준으로 자료, 행동, 학습 참조정책, LLM 호출 및 분석단위를 정의한다. 같은 이름의 정책이라도 행동의 의미나 응답 처리규칙이 달라지면 결과를 직접 합칠 수 없다. 따라서 본 연구에서 계약(contract)은 프로그램 이름이 아니라 입력의 의미, 허용된 행동, 실패 처리, 참조 배정, 표본 및 산출물의 대응관계를 고정한 명세를 뜻한다. 원자료를 다시 생성하는 작업과 저장된 결과를 재집계하는 작업도 구분한다.

이 개정에서는 원응답, 배포정책 및 기업별 평가값을 변경하지 않았다. Main Run1 만으로 정책가치를 다시 집계하고, strict-usable 교집합에 따라 PP 를 재구성했으며, 저장된 기업별 대응차이로 불확실성과 다중비교 표를 재산출하였다. 기존 집계표의 오류를 수정하는 것이지만 새로운 LLM 표본이나 새로운 Simulator 실행을 추가한 것은 아니다.

3.1 자료·표본·시점과 분석의 역할

3.1.1 재무패널과 시간 구분

연구의 기초자료는 금융업을 제외한 한국 상장기업의 재무패널이다. 원 연구자료의 표본 흐름은 전체 재무패널 70,777 개 기업-연도, 외부 신용등급이 연결된 4,924 개 기업-연도, 연속 관측으로 구성된 3,159 개 전이로 보고되었다. 이 규모는 자료 구축 단계의 기록이며, 최종 V4.3 의 모든 학습 단계에 동일한 행 수가 투입되었다는 뜻은 아니다. 특히 전이의 출발연도와 등급 결과연도를 제한한 뒤의 학습표본은 해당 단계의 manifest 로 구분해야 한다.

Oracle 개발기간은 2002-2019 년, 시간외 검증기간은 2020-2023 년으로 구분하였다. 최종 RL 설정은 전이의 출발연도를 2022 년 이하, 결과연도를 2023 년 이하로 제한한다. 정책의 평가 출발시점은 2024 년이고, Simulator 는 그 상태에서 한 해 후의 반사실적 결과를 계산한다. 따라서 2025 년은 시뮬레이션의 도착시점이지 실제로 관측된 권고 실행성과가 아니다.

2024 년 575 개 기업을 배우지 않은 입력표본이라고 표현하는 것과, 이 표본을 최종 정책의 선택에 사용하지 않았다고 표현하는 것은 다르다. 개별 actor 의 학습기간과 2024 년 정책평가 시점은 나뉘어 있지만, encoder 와 configuration 및 앙상블을 검토하는 과정에서 같은 2024 년 정책평가가 반복 사용되었다. 본 논문은 이를 개발·평가 표면(development/evaluation surface)으로 부르며, 손대지 않은 최종 검증표본이나 외부 일반화의 직접 증거로 제시하지 않는다.

표 3-1. 자료 집합과 사용목적의 구분

구분	규모·기간	본 논문에서의 지위
원 재무패널	70,777 기업 - 연도	자료 구축 단계의 보고 규모; 상장폐지 기업 포함
외부등급 연결	4,924 기업 - 연도	Oracle 및 등급전이 자료 구성의 출발점
연속 관측전이	3,159 전이	기존 전이 집합의 규모; 최종 단계별 필터 후 N 과 구분
Oracle 개발 / 검증	2002 - 2019 / 2020 - 2023	개발표본 2,032, 시간외표본 1,790 이라는 기존 검증기록
RL 시간 제한	출발 $t \leq 2022$; 결과 ≤ 2023	최종 설정의 학습 시점 제한
최종 정책평가	2024 년 575 개 기업	반복 선택에 사용된 개발·평가 표면
반사실적 도착시점	2025 년	Simulator 산출; 실제 실행성과 아님

자료: 개발 단계 분석기록의 자료 구축 기록, V4.3 RL 설정 및 최종 575 개 기업 매핑. 과거 전체 전이 수를 최종 actor 학습 N 으로 자동 대체하지 않았다.

상장폐지 기업을 기초패널에 포함한 것은 존속기업만 남기는 생존편향을 줄이기 위한 조치이다. 다만 외부등급이 존재하고 최종 평가에 필요한 재무상태를 구성할 수 있는 기업으로 범위가 좁아지므로, 575 개 기업이 전체 한국기업의 무작위 표본은 아니다. 비상장기업, 외부등급이 없는 기업 및 다른 시점으로 결과를 확대할 때에는 표본 선택의 차이를 별도로 고려해야 한다.

3.1.2 기업 식별과 산업정보

기업 식별은 최종 575 개 기업 universe 를 기준으로 유지하였다. OpenDART 법인 고유번호는 정확한 종목코드를 사용하여 대응시켰고, 최종 바인딩에는 575 개 기업 모두의 업종코드가 존재한다. 분석에서는 기업키와 평가행의 대응을 고정하고, 이름이 비슷하다는 이유로 임의의 법인에 연결하지 않는다.

산업정보는 2026 년 9 월 12 일에 조회한 company-profile 의 induty_code 이다. 응답에 사업연도를 지정하는 항목이 없으므로 이 값을 ‘2024 년 당시의 업종’이라고 부르지 않는다. 정확한 의미는 ‘2024 년 평가기업 집합에 대해 조회시점에 수집한 업종코드’이다. LLM 에 제시된 문자열도 업종에 관한 상세한 연구보고서가 아니라 ‘OpenDART 업종코드: < 코드>’이다. 따라서 정보조건의 효과는 이 표현방식과 시점에 한정된다.

조회 결과는 원 응답과 수집시각, 매핑 방식 및 해시를 함께 보존한다. 한 번 수집한 자료를 캐시에서 재사용하는 것은 요청비용과 일일 호출한도를 줄이는 운영 방식이며, 캐시가 역사적 시점의 진실성을 보장하는 것은 아니다. 기업명 공개 조건에서는 모델의 사전학습 지식이 개입할 수 있으나, 최종 clean run 에는 별도의 기업명 인식·수치회상 프로브를 포함하지 않았다.

3.2 관리행동, 표준후보와 정규화 행동예산

3.2.1 여덟 개 관리행동의 의미

V4.3 자유작성은 여덟 개 관리행동을 연속값으로 표현한다. 단순히 구형 벡터에서 두 열을 삭제한 것이 아니라, 설비투자와 부채 조정의 의미를 다시 정의한 것이다. 특히 성장성 CAPEX 축소는 기존 유형자산의 매각이 아니며, 부채축소와 차환은 서로 다른 행동이다. 매출성장률은 자유롭게 늘릴 수 있는 권고 차원에서 제외하고 외생적 사업계획과 구분한다.

부채축소(DL)는 기초 이자부부채의 일정 비율을 상환하려는 제안이다. 이자부부채에는 단기차입금, 유동성 장기부채, 비유동 장기차입금 및 사채가 포함되며, 매입채무를 포함한 총부채와 동일하지 않다. 실제 상환은 현금과 필요한 유동성 조건에 의해 제한될 수 있다. 이자절감은 실제로 상환된 금액과 연간 금리 기준으로 계산해야 하므로, 제안 상환율만으로 모든 기업에 같은 현금효과를 부여하지 않는다.

차환(RF)은 기초 단기차입의 일부를 장기로 옮기는 원금중립 행동이다. 차환 그 자체로 이자부부채 원금이 사라지지 않는다. 총부채 상환과 만기구조 변경을 하나의 행동처럼 섞으면 상환능력과 유동성 효과를 중복 계산할 수 있으므로, 양의 DL과 양의 RF의 동시 제안은 허용하지 않는다. CAPEX 축소는 유지·보수성 지출이 아니라 재량적·성장성 지출을 줄이는 방향으로 정의한다.

운전자본은 재고, 매출채권 및 매입채무 회전율의 변화로 표현한다. 비용은 매출원가율과 판매관리비율의 가산적 변화이다. 예를 들어 원가율 -0.01은 원가율의 1% 상대 감소가 아니라 1%포인트 하락을 뜻한다. 허용된 수치가 현실적으로 실행 가능하다는 보장은 없지만, 수치의 단위와 전파방식은 모든 정책에서 같아야 한다.

표 3-2. 자유작성 행동의 허용범위와 정규화 기준

축	관리행동	허용범위	기준 s_j
1	성장성 CAPEX 축소율	[0, 1]	0.631018
2	이자부부채 상환율	[0, 1]	0.346955
3	단기차입 차환율	[0, 1]	0.474106
4	재고 회전을 변화	[-3, 3]	1.398376
5	매출채권 회전을 변화	[-3, 3]	0.934104
6	매입채무 회전을 변화	[-3, 3]	2.453574
7	매출원가율 변화	[-0.03, 0.03]	0.026883
8	판매관리비율 변화	[-0.02, 0.02]	0.017169

자료: 동결 action_contract. 본 표의 기준값은 표시를 위해 소수 여섯 자리로 반올림했으며 실제 계산은 동결된 float64 값을 사용한다. 원 필드명과 후보 벡터는 부록 A에 제시한다.

3.2.2 B1과 BINF

행동크기는 각 차원의 절댓값을 동결된 P50 기준으로 나눈 뒤 합산한다. 서로 다른 단위의 원자료를 그대로 더한 구형 raw L1과 이 값은 동일하지 않다. 본 연구의 총 강도는 행동의 상대적 크기를 맞추기 위한 지표이지, 기업이 부담하는 원화 비용이나 자금조달 한도를 추정한 값은 아니다.

$$I(a) = \sum_{j=1}^8 |a_j| / s_j$$

B1은 $I(a) \leq 1$ 을 요구한다. 유한한 수치인지, 축별 허용범위를 만족하는지, DL-RF 상호배타 조건을 지키는지를 함께 검사하며, 총 강도 비교에는 10^{-9} 의 수치 허용오차를 적용한다. BINF는 총 강도의 상한만 제거한다. BINF에서도 축별 bounds, 차원 수, 유한값 및 상호배타 조건은 유지된다. 따라서 BINF를 무제한의 임의 재무행동으로 해석해서는 안 된다.

B1과 BINF는 생성 전에 프롬프트로 제시되는 조건이다. 이미 생성한 BINF 행동을 사후에 B1으로 줄인 결과와, 처음부터 B1을 전달받고 생성한 결과는 서로 다른 비교이다. 또한 두 정책에 같은 B1 상한을 부여하더라도 실제로 사용한 강도가 같지는 않다. 자유작성은 $I(a) < 1$ 또는 A0를 선택할 수 있으므로, 공통 상한과 실제 강도 분포를 따로 보고한다.

3.2.3 아홉 개 표준 후보행동

표준 후보는 A0, DL, RF, CX, WC1, WC2, OE, MX1, MX2 의 순서로 고정하였다. A0 이외의 모든 후보는 정규화 강도 1 이며, 후보선택형 LLM 과 Candidate-IQL 은 이 집합에서 하나를 선택한다. 후보의 강도가 1 이라는 것은 실제 현금효과가 같다는 뜻이 아니다. 동일한 비율과 회전을 변화도 기업의 기초 부채, 매출 및 재고 규모에 따라 서로 다른 재무상태를 만든다

복합후보는 단일후보의 행동량을 모두 더해 더 큰 예산을 사용하는 방식이 아니다. 정규화 강도 1 을 여러 차원에 나누어 배분한다. 예를 들어 OE 는 원가율과 판매비율에 각각 강도 0.5 를 배분하고, MX1 은 부채축소에 0.5, 두 비용 차원에 각각 0.25 를 배분한다. 이에 따라 후보 간 비교는 미리 정한 조합 안에서 이루어지며, 자유작성에서는 같은 총 강도를 다른 조합으로 배분할 수 있다.

표 3-3. 표준 후보의 내용과 정규화 강도 배분

ID	행동 의미	차원별 강도 배분
A0	추가 관리행동 없음	모든 차원 0
DL	이자부부채 축소	DL 1.0
RF	단기차입의 장기 차환	RF 1.0
CX	성장성 투자 절제	CAPEX 1.0
WC1	재고·매출채권 효율화	INV 0.5, AR 0.5
WC2	운전자본 조합	INV 1/3, AR 1/3, AP -1/3
OE	영업비용 효율화	COGS -0.5, SG&A -0.5
MX1	부채·비용 혼합	DL 0.5, COGS -0.25, SG&A -0.25
MX2	부채·운전자본 혼합	DL 0.5, INV 0.2, AR 0.2, AP -0.1

자료: 동결 후보 벡터를 정규화 기준으로 나누어 표시. 실제 행동값은 각 강도와 해당 s_j 의 곱이다. 음수는 회전을 또는 비용비율을 낮추는 방향이다.

A0 는 현재 재무제표를 복사해 두는 정책이 아니라, 동일한 외생 사업계획과 Simulator 를 통과하되 추가 관리행동을 주지 않는 기준이다. 모든 정책의 평가에서 A0 를 공통으로 사용해야 한다. 특정 기업에 가장 높은 Oracle 값을 주는 후보를 사후적으로 고른 ceiling 은 비교를 위한 상한이며, 배포정책이나 현실적으로 알려진 최적행동이 아니다.

3.3 Simulator 와 Oracle 의 공통 평가경로

3.3.1 제안에서 재무상태로의 전파

Simulator 는 같은 기업상태, 같은 사업계획 및 같은 적용행동을 입력하면 같은 반사실적 재무상태를 계산하는 결정론적 도구이다. 부채 상환은 현금과 부채를 함께 바꾸고, 운전자본 조정은 관련 자산·부채와 현금을 함께 바꾼다. 비용비율 변화는 영업성과와 이익누적 및 현금에 전파된다. 계산 후 회계항등식을 확인하며, 모델 내부의 실현 가능 범위와 LLM 출력의 제약준수 여부를 혼동하지 않는다.

현재 계산경로에는 현금부족을 단기차입으로 보충하는 cash-plug 및 동결된 배당 관련 가정이 포함된다. 이는 필요한 자금조달이 항상 가능하다는 현실의 관측이 아니라 모형의 처리규칙이다. 차입을 거절당하거나 부도에 이르는 상황, 기업별 재협상 및 실행기간을 충분히 모형화하지 못하므로, 결과는 그 가정 아래의 비교로 제한한다.

Strict parser 가 허용범위 밖의 제안행동을 잘라서 수용하는 것과, 허용된 행동을 Simulator 가 기업상태에 맞게 실현하는 것은 서로 다르다. 전자는 본실험의 Strict 규칙에서 금지된 응답 보정이고, 후자는 제안 상환액과 실제 상환액처럼 경제적 전파를 계산하는 단계이다. 따라서 realized 값이 proposed 값과 다르다는 사실만으로 계약위반이나 parser 보정이 있었다고 판단할 수 없다.

3.3.2 세 Oracle 와 정책가치

Oracle- α 는 구간별 점수와 가중치를 사용하는 스코어카드, Oracle- β 는 순서형 로짓, Oracle- γ 는 트리 앙상블에 기초한다. 입력의 재무적 의미를 공유하더라도 구간 경계, 연속성 및 비선형 결합이 다르므로 동일 행동에 대한 점수 차이도 달라질 수 있다. α 를 주요 평가축으로 사용하고 $\beta \cdot \gamma$ 는 각자의 점수척도에서 방향과 민감도를 확인한다.

기업 i 의 출발상태를 x_i , 공통 사업계획을 z_i , Simulator 를 S , Oracle 를 R_j 로 나타낸다. 정책 p 의 적용행동 a_{ip} 에 대한 정책가치는 동일 기업의 A0 결과를 뺀 값이다. LLM 정책의 한 조건과 다른 조건의 차이도 먼저 기업 안에서 계산한 뒤 평균한다.

$$V_{ij}(p) = R_j(S(x_i, z_i, a_{ip})) - R_j(S(x_i, z_i, A0))$$

$$\mathcal{J}_j(p, q) = N^{-1} \sum_i [V_{ij}(p) - V_{ij}(q)]$$

이 차이는 공통 출발상태와 공통 모형 가정을 맞추는 장점이 있지만, Simulator 의 모든 오차를 없애지는 않는다. 행동 a 의 모형 오차가 $\varepsilon_i(a)$ 라면 $A0$ 대비 차이의 오차에는 $\varepsilon_i(a) - \varepsilon_i(A0)$ 가 남는다. 동일한 상수 오차는 상쇄되지만 행동에 따라 달라지는 편향은 남기 때문에, 회계적 일관성과 현실적 효과의 타당성을 별도로 논의한다.

본 논문의 평균 Oracle 점수는 기업별 절대 신용평점을 평균한 값이고, 평균 정책가치는 위식의 $A0$ 대비 차이를 평균한 값이다. 예를 들어 55 점대 절대점수와 약 1 점의 증분가치를 같은 열에 섞지 않는다. β 와 γ 에서도 각자의 $A0$ 를 사용하며 세 Oracle 의 원점수를 더하거나 평균해 통합 순위를 만들지 않는다.

3.4 Candidate-IQL 의 학습·선택·배포

3.4.1 표현학습, 행동모방과 가치학습

Candidate-IQL 은 기업이 실제로 취한 행동을 완전하게 관찰할 수 없다는 제약 아래에서 학습한 참조정책이다. 재무제표에 전략명이 직접 기록되는 것은 아니므로, 관측된 재무변화와 표준 후보의 유사성을 이용한 의사행동 표지를 사용한다. 이 표지는 경영진이 해당 전략을 의도적으로 선택했다는 인과적 라벨이 아니다.

학습은 재무상태 표현학습, 행동모방, 최종 가치·정책 학습의 세 단계로 나뉜다. 표현학습은 다수 재무비율과 범주형 정보를 잠재표현으로 압축한다. 행동모방은 자주 나타나는 행동 및 행동군이 학습을 지배하지 않도록 불균형을 보정한 출발정책을 만든다. 최종 단계는 관측전이와 Simulator 가 제공하는 후보별 지지를 이용하여 행동의 가치를 학습하고 actor 를 갱신한다. 같은 seed 번호라도 앞 단계의 checkpoint 가 다르면 동일한 학습경로라고 간주하지 않는다.

최종 설정에서 할인율 γ 는 0 이다. 따라서 장기 누적보상을 학습했다는 주장보다, 기업상태에 조건부인 한 해의 행동 선택문제로 설명하는 것이 정확하다. CQL 항과 sector shaping 계수도 사용하지 않는다. 학습 종료 후 배포행동은 actor 의 확률로 결정하며, critic Q 값이나 Oracle 점수로 기업별 행동을 다시 정렬하지 않는다.

3.4.2 등급 신호와 보조보상

학습보상의 기본 신호는 실제 외부 신용등급의 변화이고, 부채부담, 현금흐름, 유동성 및 수익성의 변화를 보조 신호로 사용한다. 이때 Merton 기반 항은 회계자료로 구성된 부채부담 대리항이며, 완전한 시장기반 부도확률 추정치와 동일시하지 않는다. FCFF 역시 사용한 재무항목과 정규화에 종속된 대리항이다.

최신 reward contract 는 수익성 성분을 포함한다. 각 성분은 동결된 학습구간의 robust scale 과 clipping 범위에 따라 변환하며, Merton 항의 범위는 $[-1,1]$, 나머지 보조항은 $[-0.5,0.5]$ 이다. 수익성 보조항의 구현은 factual 기준 총자산 대비 counterfactual 영업이익익과 factual 영업이익의 차이를 사용한다. 학습보상의 정규화와 LLM 출력의 후처리는 전혀 다른 단계이므로 보상에 clipping 이 존재한다는 이유로 Strict 응답 보정이 허용되는 것은 아니다.

관측되지 않은 후보행동에 실제 다음 해 등급을 임의로 붙이지 않는다. 공개된 실행 스냅샷에서는 실제 등급사건, 충분한 행동투영 coverage 및 근접 동물 여부를 확인한 뒤 적격 관측행동에만 등급 지도신호를 연결한다. 적격성이 없는 후보의 미관측 등급효과를 실제 성과처럼 취급하지 않고 보조 신호와 구분한다. 세부 가중치는 configuration 마다 다르므로 구형 단일 가중치표를 전체 앙상블의 학습계약으로 사용할 수 없다.

$$r = r_rating + w_M r_M + w_F r_F + w_L r_L + w_P r_P$$

표 3-4. 최종 네 configuration 의 보조보상 가중치

Configuration	Merton	FCFF	유동성	수익성
B27	.448750	.000000	.298750	.132500
M2_S0935	.488750	.000000	.318750	.127500
DT06	.460000	.000000	.300000	.120000
T15_REWARD_S088	.606325	.075191	.131642	.066842

자료: RL 실행 마스터 카탈로그의 해당 최종 family 와 T15 검증기록. 외부 등급변화 계수는 모두 1.0 이다. 표시는 반올림값이며, 네 configuration 을 하나의 평균 reward 로 재학습한 것이 아니다.

3.4.3 계층적 확률평균과 선택 독립성

최종 C3-E 는 E2 encoder 계열의 네 configuration 을 일곱 matched seed 로 결합한다. 사용한 seed 는 2, 11, 12, 13, 14, 15, 16 이며 configuration 마다 일곱 actor 를 포함하여 총 28

개이다. 먼저 같은 configuration 안의 확률을 동일하게 평균하고, 그 결과 네 개를 각각 25%로 평균한다. 마지막으로 canonical 행동순서에 따른 argmax 를 취한다.

$$\bar{p}(a|x) = (1/4) \sum_{s=1}^4 [(1/7) \sum_{s=1}^7 p_s(a|x)]$$

$$a_{C3-E}(x) = \text{canonical argmax}_a \bar{p}(a|x)$$

현재는 모든 configuration 의 seed 수가 일곱으로 같으므로 결과적으로 각 actor 의 계수는 1/28 이다. 다만 정책의 정의는 configuration 내부 평균과 configuration 간 평균의 두 층이다. 이전처럼 seed 수가 다를 때 단순 actor 평균으로 바꾸면 configuration 의 비중이 달라지므로 같은 정책이 아니다. 또한 확률평균은 logits 평균이나 다수결과 일반적으로 같지 않다.

학습목표에 Oracle 점수를 넣지 않았다는 것, 최종 configuration·encoder·양상블을 선택할 때 Oracle 를 보지 않았다는 것, 동결 후 추론에서 Oracle 로 재정렬하지 않는다는 것은 서로 다른 주장이다. 본 연구는 첫 번째와 세 번째를 해당 실행계약의 범위에서 기술하고, 두 번째는 주장하지 않는다. 2024 년 평가를 보고 최종 참조정책을 선택한 사실은 제 4 장의 결과 및 제 7 장의 한계에 반영한다.

최종 release 의 이름은 C3E_E2_7SEED_BALANCED_DFEBafa6 이다. BALANCED 는 matched seed 구성을 나타내는 식별자이며 성능과 다양성의 사후 목표를 충족했다는 통계적 판정이 아니다. 각 actor 의 predecessor 와 semantic hash 및 최종 decision hash 를 보존하고, 최종 LLM 참조가 어떤 정책을 사용했는지 고정한다.

3.5 LLM 모델과 생성 실행조건

본실험과 추가 실험은 GPT-5.4-mini 와 Gemini 3.1 Flash-Lite 를 대상으로 한다. Baseline 은 먼저 동결·실행된 생성조건이며, High 는 Baseline 의 응답 유효성 문제를 확인한 뒤 추가한 추론설정 분석이다. 따라서 High 를 최초 본실험의 primary 로 소급 변경하지 않는다. C5 라는 진단 프롬프트와 API 의 추론 수준은 서로 다른 실험축으로 유지한다.

표 3-5. 공급자별 Baseline 과 High 생성 설정

항목	GPT Baseline	GPT High	Gemini Baseline	Gemini High
모델	5.4-mini 2026-03-17	같은 snapshot	3.1-flash-lite	같은 모델 ID
추론 설정	none	high	minimal	high

항목	GPT Baseline	GPT High	Gemini Baseline	Gemini High
최대 출력 토큰	4,096	32,768	4,096	32,768
호출 방식	Batch	Batch	Batch	Batch
도구 / native schema	사용 안 함	사용 안 함	사용 안 함	사용 안 함

자료: Baseline release_binding_sanitized.json, High artifacts/release.json. Gemini 의 thoughts/output 한도를 고려한 기술적 변경이 High 에 포함되었다. 모델 표시는 표 폭을 위해 축약했으며 정확한 ID 는 부록 D 에 제시한다.

두 공급자의 high 라는 명칭이 같은 추론 토큰 수나 같은 계산량을 의미하지 않는다. 또한 High 에서는 최대 출력 토큰도 함께 상향되었다. 후속 재검토는 해당 regime 에서 생성한 C4 를 사용하므로 부모 초안의 내용도 달라진다. 따라서 High-Baseline 은 동일한 실험 구조와 참조규칙 아래의 생성 regime 비교이며, 다른 모든 것이 byte 단위로 동일한 상태에서 추론 설정 하나만 바뀐 효과라고 기술하지 않는다.

이번 하네스는 엄격한 JSON 응답을 프롬프트로 요구했지만 공급자의 native structured output 강제기능은 사용하지 않았다. 관측된 형식 오류는 이 생성·검증 조합에서의 결과이다. 이를 해당 모델이 어떤 구조화 출력 방식에서도 같은 비율로 실패한다는 고유한 성질로 일반화할 수 없다.

3.6 정책조건·정보조건과 실행행렬

3.6.1 동일 초안의 재검토와 두 종류의 참조

표 3-6. 최종 다섯 정책조건과 비교대상

조건	생성 방식	비교의 의미
C4	기업정보에서 직접 생성	첫 번째 권고의 기준
C5	같은 정보에 진단 scaffold 를 추가하여 첫 생성	C4 대비 프롬프트 유도 효과
C4R	해당 Run 의 동일 C4 를 외부 참조 없이 재검토	초안을 다시 검토하는 효과
C6-E	동일 C4 에 해당 기업의 C3-E 행동을 제공	C4R 대비 학습참조가 포함된 수정조건

조건	생성 방식	비교의 의미
C6-EX	동일 C4 에 다른 기업으로부터 재배정한 참조를 제공	C6-E 대비 기업-참조 연결의 역할

자료: 최종 prompt 및 assignment 계약. C4R→C6-E의 연속 호출이 아니라 C4에서 각각 분기하는 조건이다. C5도 C4의 후속 응답이 아니다.

C6-E와 C6-EX에서는 참조 행동의 수치적 내용과 동일한 제시형식을 사용한다. 참조가 Oracle에 의해 최적이라고 알려주거나 참조의 사후 점수를 제공하지 않는다. 학습된 정책의 기업별 배정이 도움이 되는지를 보려면 단지 그럴듯한 행동을 더 보여준 효과와 구분해야 하므로, 참조의 주변분포를 유지하는 C6-EX를 대조로 사용한다.

C6-EX는 575개 기업의 C3-E 행동을 고정된 derangement로 재배정한다. 자신의 참조를 자신에게 돌려주는 donor 배정은 없지만, 여러 기업이 같은 행동을 선택하기 때문에 원래와 동일한 행동내용을 받는 경우는 남는다. 실제 같은 행동내용의 비율은 141/575, 약 24.5%이다. 이는 주변분포를 보존한 대조 설계의 특성이며, 이 충돌을 없애려고 사후에 다시 순열을 선택하지 않는다. 동일한 배정은 공급자와 행동예산 조건에 걸쳐 유지한다.

C6-E-C6-EX는 학습정책 참조가 아무 정보나 보여주는 것보다 좋은가라는 광범위한 질문과 같지 않다. 고정된 참조행동 분포 아래에서 기업과 행동을 원래대로 연결했을 때의 차이를 평가한다. 한 번의 고정 순열에 조건부인 결과이므로, 모든 무작위 참조 배정에 걸친 평균효과의 불확실성까지 포함했다고 주장하지 않는다.

3.6.2 실제 제공정보의 차이

최종 렌더러의 IC-a는 재무정보만이라는 추상적 명칭과 달리, 23개 파생 재무특징에 fiscal_year, log_assets, market을 포함한다. IC-b는 여기에 industry_class 하나를 추가하고, IC-c는 firm_name을 추가한다. 즉 산업정보를 비교할 때 연도와 기업규모가 함께 추가되는 설계가 아니다. 필드 집합은 IC-a 26개, IC-b 27개, IC-c 28개로 구분한다.

재무특징에는 부채·자본·유동성 비율, 수익성, 비용부담, 투자, 부채구성, 운전자본 및 전년 대비 변화가 포함된다. debt_to_assets의 분자는 총부채이지만, 단기·장기·사채 구성비의 분모는 이자부부채이므로 동일한 debt라는 단어를 쓰더라도 의미를 구분한다. 필요한 값이 없으면 null로 제시하며, 결측을 0으로 채우거나 Oracle 평가값을 입력으로 노출하지 않는다.

정보조건 비교는 C4/free8/B1 에서 수행한다. 다른 정책조건까지 모든 정보수준을 교차한 실험이 아니므로, 이 결과만으로 자기 재검토나 참조의 정보조건별 효과를 일반화하지 않는다. 최종 실험의 기업명 공개 효과와 구형 인식 프로브 결과를 합쳐 사전학습 오염이 없었다고 결론내리지 않는다.

표 3-7. 정보조건별 실제 차이

조건	필드 구성	추가로 달라지는 정보
IC-a	23 재무특징 + 연도·log 자산·시장	기준 26 개; 기업명과 업종코드 없음
IC-b	IC-a + industry_class	조회시점 OpenDART 업종코드 1 개
IC-c	IC-b + firm_name	기업명 1 개

자료: 최종 prompt_contract 의 information_conditions 와 feature_dictionary. IC-b-IC-a 는 이 업종코드 표현을 추가한 대비이다.

3.6.3 Main Run1 과 Stability Run2

표 3-8. 모델·regime 하나당 실행행렬

실행	조건 묶음	셀 수	요청 수
Run1	free8 / IC-b / B1 × 다섯 정책	5	2,875
Run1	free8 / IC-b / BINF × 다섯 정책	5	2,875
Run1	candidate9 / IC-b / B1 × C4·C4R·C6-E	3	1,725
Run1	free8 / B1 / C4 × IC-a·IC-c	2	1,150
Run2	free8 / IC-b / B1·BINF × C4·C4R·C6-E	6	3,450
합계	각 셀 575 개 기업	21	12,075

두 모델 합계 regime 당 42 셀·24,150 요청. Baseline 과 High 를 합한 생성 요청은 48,300 건이다. Repaired 와 PP 는 새 생성 요청이 아니다.

본실험 Run1 의 모델별 15 개 셀과 반복성 Run2 의 6 개 셀은 서로 다른 역할을 갖는다. C5 와 C6-EX 는 Run2 가 없으므로, 반복된 C4·C4R·C6-E 만 두 번 평균하고 나머지는 한 번의 결과를 사용하는 표는 조건별 추정량이 달라진다. 본문 정책가치는 Run1 로 통일하고 Run2 는 반복성 절에서 따로 비교한다.

Run2의 후속 조건은 Run1의 C4를 재사용하지 않고 자기 Run의 C4에서 분기한다. 한 기업의 반복 요청과 네 실행·분석 arm은 동일 기업에 대한 반복측정이지 표본 기업 수의 증가가 아니다. Stage8/9의 ITT 및 PP행을 합산한 수를 총 API 호출 수로 보고하지 않는다.

3.7 원응답과 네 행동층

전송 성공과 정책적 사용 가능성은 별개이다. 공급자가 정상적으로 응답을 반환했더라도 JSON을 해석할 수 없거나 필요한 행동차원이 없거나 예산을 위반할 수 있다. 본 연구는 원응답을 삭제하지 않고 제안행동, 수용행동, ITT 평가행동 및 실행결과를 구분한다.

표 3-9. 행동층과 실패 처리

층	의미	불용 응답에서의 처리
Raw response	공급자가 반환한 원문과 메타데이터	원문·식별자·종료정보 보존
Proposed	원문에서 추출한 제안행동	파싱 실패면 미확정; 임의 값 생성 안 함
Accepted	Strict 계약을 통과한 행동	terminal unusable은 None
ITT	전체 할당 기업의 운영 평가행동	확정 불용 completion은 A0
Realized	Simulator에서 실제 전파된 효과	A0 또는 수용·수리 행동을 동일 계산경로에 적용

자료: 최종 응답·Stage8/9 의미론, infrastructure failure는 completion 자체가 확정되지 않은 상태이며 terminal unusable과 다르다.

엄격한 검사에서는 중복 JSON key를 임의로 덮어쓰지 않고 오류로 남기며, 범위 밖의 값을 clipping하거나 B1 초과 벡터를 재비례화해 정상 응답으로 바꾸지 않는다. 완료되었으나 사용할 수 없는 응답은 accepted=None, ITT=A0이다. 전송·인프라 문제로 완료 여부가 미확정인 요청은 이 처리에 바로 넣지 않고 재개·수집 절차에서 해결한다.

행동 수용률과 전체 응답 schema 적합률도 따로 보고한다. 행동값을 평가할 수 있는지와 진단·근거·설명까지 요구한 형식을 모두 충족했는지는 서로 다른 검사이다. 정책가치 분석에 사용한 canonical action-usability mask와 전체 schema audit를 섞어 하나의 오류율로 부르지 않는다. 검증 로그의 오류원인이 겹칠 때는 원인별 건수의 합이 불용 응답 수와 같지 않을 수 있다.

3.8 Strict, Repaired 와 PP

3.8.1 두 실행정책의 구분

Strict ITT 는 확정 불용 응답의 A0 처리까지 포함한 원래 운영규칙의 가치를 평가한다. Repaired ITT 는 같은 원응답에 결정론적 처리규칙을 적용한 별도 실행정책이다. 재호출로 더 좋은 답을 선택하거나 Oracle 점수를 보고 보정하는 방식이 아니다. 형식 복구, 행동값만의 추출, 중복 key 의 선택규칙 및 B1 강도 축소와 같은 개입은 원래 출력과 구분하여 보존한다.

이 변환은 ‘모든 응답이 처음부터 정상적이었다면 모델이 무엇을 의도했을까’의 관측치가 아니다. 중복 key 중 하나를 택하는 것은 선택규칙이고, 예산 초과 행동을 줄이는 것은 행동량을 변경하는 것이다. 따라서 Repaired-Strict 는 특정 실행규칙 변경의 평가상 차이이며, 모델의 숨겨진 올바른 의도를 복원한 무편향 추정치라고 부르지 않는다.

재집계에서는 원래 strict usable 인 응답을 repaired 결과와 같은 요청키로 연결하고 점수 불변성을 검사하였다. 이 집합의 Oracle- α 값은 두 regime 와 두 모델 모두에서 변하지 않았다. 이미 정상인 응답을 포함해 전체 값을 재최적화한 분석이 아니라, 주로 불용 응답의 처리 차이가 드러나는 분석이라는 점을 수치로 확인하였다. 다만 상세한 수리 우선순위와 실행코드의 최종 동결 증빙은 결과 파일의 보존과 별도로 관리해야 한다.

3.8.2 PP 는 실행정책이 아니라 조건부 표본

PP(per-protocol)는 세 번째 생성모델이나 별도의 새 응답 집합이 아니다. 대비에 필요한 모든 조건에서 strict usable 인 동일 기업만 남기는 조건부 분석이다. 두 정책 p 와 q 를 비교할 때에는 $U_{ip}=1$ 이고 $U_{iq}=1$ 인 교집합에서 대응차이를 계산한다. 두 조건 각각의 usable 평균을 서로 다른 표본에서 구한 뒤 빼지 않는다.

$$S_{PP}(p,q) = \{i : U_{ip} = 1, U_{iq} = 1\}$$

High-Baseline 은 두 regime 의 같은 정책이 모두 strict usable 인 기업을 사용한다. 추론설정과 수정효과의 상호작용은 네 개 셀 모두를 요구하며, 행동예산의 상호작용까지 포함하면 관련된 모든 셀의 공통 완전사례를 사용해야 한다. repaired usable 로 마스크를 넓히면 기존 PP 와 다른 집합이 되므로 이를 같은 이름으로 보고하지 않는다.

PP 는 출력 유효성의 선택을 거친 표본이다. 예를 들어 재무특성이 다른 기업에서 오류 발생확률도 다르면 PP 의 기업 구성은 전체 575 개와 다를 수 있다. 따라서 PP 에서 차이가

커졌다고 ‘형식오류를 제거한 순수 경제적 판단능력’이라고 단정하지 않는다. ITT 와 PP 는 서로 다른 질문에 답하며 둘을 함께 제시하는 이유는 운영성과와 조건부 행동 비교를 구분하기 위해서이다.

3.9 대비, 불확실성과 반복성 분석

3.9.1 네 대비와 행동예산 상호작용

중심 대비는 C4R-C4, C5-C4, C6-E-C4R, C6-E-C6-EX 의 네 가지이다. 같은 모델, 같은 정보조건, 같은 행동공간, 같은 Run 및 같은 실행정책에서 비교한다. free8/IC-b 의 B1 과 BINF 를 함께 보고하며, B1 이 더 설명하기 쉬운 결과라는 이유로 BINF 를 제외하지 않는다.

전체 수정효과 C6-E-C4 는 동일한 기업 집합에서 자기 재검토 차이와 외부참조를 포함한 수정조건 차이의 합으로 나타낼 수 있다. 이 식은 대수적 분해이지 C4R 을 실제로 거쳐 C6-E 가 생성되었다는 순차적 매개모형이 아니다. PP 에서 각 차이의 교집합이 다르면 같은 항등식으로 합산하지 않는다.

$$\Delta(C6-E, C4) = \Delta(C4R, C4) + \Delta(C6-E, C4R)$$

$$\text{Interaction_B} = \Delta_{B1}(p, q) - \Delta_{BINF}(p, q)$$

High 가 수정효과를 더 크게 만들었는지는 High 에서 유의하고 Baseline 에서 비유의라는 비교가 아니라, 같은 기업의 [High 대비]-[Baseline 대비]를 직접 계산하여 판단한다. 공급자 간 차이도 마찬가지이다. 한 공급자에서 유의하고 다른 공급자에서 유의하지 않다는 사실만으로 두 공급자의 효과 차이가 입증되지 않는다.

3.9.2 기업 단위 bootstrap 과 다중비교

불확실성은 기업 단위 대응차이를 복원추출하는 bootstrap 으로 평가한다. 원 Stage9 의 중심 대비는 PCG64, 기준 seed 20260912, 10,000 회 표본추출을 사용한다. 이번 재집계에서는 원래 행 순서와 정렬된 그룹 순서 및 Oracle 별 난수 소비 순서를 재현하여 기존 평균과 95% bootstrap 구간을 대조하였다. 네 arm 의 해당 구간은 수치오차 범위에서 재현되었다.

표의 tail probability 는 bootstrap 평균분포가 0 의 양쪽에 놓인 빈도에 plus-one 을 적용해 계산한 양측 sign-tail 통계량이다. 이를 정확한 무작위배정 검정의 p 값이나 별도로 귀무가설

아래 중심화한 bootstrap 검정과 동일시하지 않는다. 확정된 산출방식의 재현 가능한 불확실성 지표로 제시하고, 효과크기와 구간 및 방법상 한계를 함께 읽는다.

$$p_tail = \min\{1, 2[\min(n(\mathcal{I}^* \leq 0), n(\mathcal{I}^* \geq 0)) + 1]/(B+1)\}; B=10,000$$

Holm 조정은 모델·Oracle·생성 및 실행 arm 안에서 네 대비×두 예산의 8 개를 하나의 family 로 적용한다. 행동예산 상호작용 네 개는 별도 family 로 둔다. 행동공간의 C4·C4R·C6-E 세 비교 및 정보조건 두 비교도 각각의 사전 정의된 묶음으로 보고한다. 불리한 결과를 제외하거나 유의한 셀만 모아 family 를 다시 만들지 않는다.

이번에 새로 구성한 PP·실행규칙 민감도·추론 상호작용은 대비키를 SHA-256 으로 변환한 결정론적 PCG64 하위 난수열로 10,000 회 계산하였다. 중심 대비의 원래 bootstrap 재현과 추가 재집계의 난수열을 구분하여 분석 명세에 남겼다. 95% 구간은 각 대비의 미조정 구간이고 Holm 열은 tail probability 의 조정값이다. 두 정보를 함께 보여주되 구간 자체가 동시 신뢰구간으로 바뀐 것처럼 해석하지 않는다.

이 불확실성은 최종 표본과 이미 선택된 정책 및 고정 참조배정에 조건부이다. RL configuration 을 탐색한 불확실성, provider 의 장기 모델 변경, 모든 가능한 참조 순열 및 현실에서의 실행오차를 포괄하지 않는다. 유의하지 않다는 사실은 동등성을 뜻하지 않으며, 구형 분석의 MDE 기반 동등성 한계를 새 실험에 자동 적용하지 않는다.

3.9.3 네 종류의 반복성

반복성은 Run1 과 Run2 의 평균 정책가치, 기업별 A0 대비 정책가치 순위, 수정조건의 기업별 증분효과, 구체적 행동벡터의 반복성으로 나누어 측정한다. 절대 Oracle 점수는 기업의 출발 신용상태가 두 실행에 공통으로 포함되므로 매우 높은 상관을 보일 수 있다. 따라서 절대점수 상관만으로 권고가 안정적이라고 판단하지 않는다.

자유작성 행동의 일치율은 실제 여덟 개 행동값으로 계산한다. candidate_id 가 없는 자유작성 행에서 결측값끼리 같다는 이유로 일치했다고 세지 않는다. 두 실행에서 모두 strict usable 인 기업을 연결한 뒤, 벡터 일치와 활성 차원집합 일치 및 정규화 L1 거리를 각각 확인한다. 이 공통 수용집합은 전체 기업과 다르므로 분모를 함께 제시한다.

3.10 실행명세의 불일치, 비용과 재현성

3.10.1 부모 응답 분기규칙의 문서 간 차이

최종 계획서 주식에는 C4가 완료되었더라도 unusable이면 dependent second-pass를 생략하고 해당 branch를 A0로 처리한다는 설명이 남아 있다. 반면 실행 전 pre-live prompt_contract에는 비어 있지 않은 공급자 원문이면 malformed JSON, refusal, truncated partial text도 그대로 JSON-escape하여 초안으로 전달할 수 있다고 명시되어 있다. 실제 요청의 parent lineage는 후자의 raw-draft 분기와 일치한다.

따라서 이 문제를 결과를 본 뒤 임의로 생긴 분기규칙이라고 단정하지 않는다. raw-draft 규칙이 live 전에 존재했다는 해시 증거가 있다. 동시에 계획서와 실행명세 가운데 어느 문서가 우선하는지에 대한 정식 개정·승인 기록은 제공된 자료에서 완결되지 않는다. 본문은 실제 실행(as-executed)을 주 집계로 공개하고, 계획서의 usable-parent gate를 적용한 경우의 결과를 별도 민감도 분석으로 보고한다.

민감도 분석은 원응답을 삭제하거나 실제 호출 이력을 바꾸지 않는다. 부모 C4가 strict unusable인 기업의 후속 결과를 A0로 치환하여 평가집계만 다시 계산한다. 이는 저장된 A0 점수를 사용한 오프라인 비교이며, 해당 게이트 아래에서 새로 생성될 응답을 관찰한 실험은 아니다.

3.10.2 비용과 산출물의 추적

비용은 공급자별로 대시보드의 잠정 귀속가정을 명시하고 분석한다. 요청 1건당 비용, 수용 가능한 행동 1건당 비용, 부모 초안을 포함한 최종 권고 비용은 다르다. C4R·C6-E·C6-EX의 독립적인 2단계 권고에는 C4 생성비가 추가로 필요하지만 실험에서는 C4를 여러 branch가 공유하였다. 따라서 전체 평균 요청단가를 그대로 최종 2단계 권고 단가라고 쓰지 않는다.

재현성은 계약·입력·원응답·평가결과·집계코드의 연결로 관리한다. 최종 결과 패키지는 5개 current-source 파일의 hash drift를 기록한다. metadata와 frozen V4.3 contract의 연결이 통과했다는 사실은 현재 보이는 코드가 과거 결과를 생성한 정확한 코드 스냅샷이라는 증명과 다르다. 본 분석은 집계코드와 입력 해시를 별도로 보존하지만, 과거 실행코드의 완전한 복원까지 완료했다고 주장하지 않는다.

제 4 장 평가기반 검증과 학습 참조정책

평가 하네스의 검증은 ‘높은 점수를 낸 정책이 좋은 정책이다’라는 결론에 선행한다. 본 장은 실제 신용등급과 Oracle 의 정렬성, Simulator 의 재무상태 전파, 최신 행동계약의 실행 일관성 및 현재 참조정책을 순서대로 다룬다. 개발 당시의 검증자료가 남아 있다는 사실과 최종 V4.3 실행환경에서 모든 검증을 다시 수행했다는 주장을 구분한다.

개발 단계 분석기록에는 등급 방향일치율과 회계항등식, Simulator 수준편향 등에 관한 상세한 증거가 존재한다. 그 내용을 삭제하여 검증 우선 문제의식을 잃지는 않되, 금리·상환·차환·CAPEX 의미론을 변경한 최신 계약의 검증으로 자동 승격하지 않는다. 이어지는 최신 후보별 비교와 C3-E 평가는 동결된 V4.3 평가파일을 사용하여 다시 집계한 결과이다.

4.1 Oracle 와 실제 신용등급의 정렬성

Oracle 가 실제 기업의 신용상태와 무관하다면 그 점수를 이용한 권고 비교의 의미도 제한된다. 원 개발 단계에서는 같은 시점의 기업 순서와 다음 해 등급변화의 방향을 구분하여 검토하였다. 같은 시점의 순위 정렬은 높은 신용평점을 받은 기업이 실제로도 우량한 순서에 놓이는지를 묻고, 선행 방향 비교는 전년 대비 신용평점의 변화가 이후 외부등급의 변화와 같은 방향인지를 묻는다.

Spearman 순위상관은 두 순서의 정렬성을 나타내며, 방향일치율은 실제로 등급이 변한 사례 가운데 Oracle 가 같은 방향을 가리킨 비율이다. AUC 는 개선과 악화를 구분하는 점수의 순서 정보를 이용한다. 이들은 권고 실행의 인과적 성공률이 아니다. 특히 방향일치율 72%를 ‘LLM 행동을 적용하면 72% 확률로 신용등급이 개선된다’로 해석할 수 없다.

표 4-1. 개발 단계 Oracle 정렬성 검증기록

Oracle	동시점 ρ	선행 ρ	방향일치율	95% 구간	AUC
α	0.678	0.500	72.0%	[64.7, 78.4]	0.803
β	0.700	0.355	72.0%	[64.7, 78.4]	0.722
γ	0.776	0.361	65.2%	[57.6, 72.1]	0.719

자료: 개발 단계 분석기록 표 4-1 의 개발·시간의 검증기록. 방향일치율은 실제 등급이 이동한 161 개 사례를 대상으로 하며 구간은 Wilson 95%이다. 본 분석에서 최종 Oracle 실행코드로 새로 추정된 값은 아니다.

세 Oracle 는 개발 검증기록에서 실제 등급의 순서 및 변화방향과 양의 정렬성을 보였다. α 는 비교적 단순한 구간형 구조이면서 방향 비교에서 유용한 정보를 제공하였기 때문에 주 평가자로 사용되었다. 그러나 기업의 등급을 정렬하는 능력이 작은 관리행동의 효과까지 동일하게 구분한다는 보장은 없다. 실제 행동별 점수의 동률과 Oracle 간 선호 차이는 제 4.3 절에서 별도로 확인한다.

현재 남아 있는 한계는 원 검증을 산출한 입력·코드·Oracle 스냅샷과 최종 실행파일의 완전한 대응이다. 본 분석은 개발 검증 수치를 보존하고 출처를 명시하지만, 그 숫자가 V4.3 의 모든 변경 이후에도 동일하게 재산출되었다고 선언하지 않는다. 이 구분을 유지하는 것이 검증 결과를 과도하게 넓혀 해석하지 않는 방법이다.

4.2 Simulator 검증의 범위와 최신 실행 점검

4.2.1 회계적 일관성과 과거 상태 재현

개발 단계의 시뮬레이션 검사는 회계항등식과 비정상 값, 행 정렬의 일관성을 확인하였다. 원 기록의 31,590 개 시뮬레이션 상태에서 자산=부채+자본의 최대 상대오차는 $4.66 \times 10^{-1} \%$, 자산=유동자산+비유동자산 오차는 0 으로 보고되었다. 관측전이 3,159 행에서 행 누락 및 비정상 값이 없었다는 결과도 함께 남아 있다.

이 검사는 계산체계가 정해진 항등식을 지키는지에 관한 증거이다. 현실의 재무제표를 정확하게 예측한다거나 자금조달이 실제로 가능하다는 증거는 아니다. 과거 관측행동을 다시 적용한 재현 비교에서는 회사채·장기차입금·단기차입금·총자산을 비교하였고, 총자산 대비 중앙 절대오차가 가장 큰 항목은 총자산의 8.83%였다. 현재 계약은 행동의 정의가 바뀌었으므로 이 전체 검증의 최신 재실행 여부를 별도로 남겨야 한다.

4.2.2 수준, 기업 순위와 변화방향의 분리

원 연구의 초기 B2 는 관측행동을 적용한 Simulator 신용평점의 변화방향을 다음 해 실제 등급이동과 연결한 지표이며, OOT 값은 55.0%였다. 이 하나의 값에는 행동 복원오차, 재무전파오차, Oracle 의 점수화, 분석대상 및 시차의 차이가 섞여 있다. 따라서 Simulator 자체의 검증 성능을 단독으로 나타내는 수치로 사용하지 않는다.

검사 3 은 비교대상을 같은 Oracle 점수로 맞춘 뒤 세 질문을 분리하였다. P1 은 Simulator 상태와 실제 관측상태 사이의 점수 수준차이, P2 는 기업 순위의 일치, P3 는 개발기간의

점수차이를 보정한 후 전년 대비 변화방향의 일치이다. 이 구분은 수준예측에 실패한 모형이 상대비교에는 어떤 정보를 남기는지를 점검한다.

표 4-2. 개발 단계 Simulator 검사 3의 기간별 결과

지표	DEV	OOT	POST
점수차이 중앙값	10.842 (975)	10.700 (925)	11.155 (424)
기업 순위상관 ρ	0.907 (975)	0.903 (925)	0.892 (424)
보정 후 방향일치율	71.2% (698)	71.7% (657)	73.6% (273)
방향일치율 95% 구간	[67.7, 74.4]	[68.1, 75.0]	[68.1, 78.5]

자료: 개발 단계 분석기록 표 4-2. 괄호는 사례 수이다. DEV 도착연도 $\leq$ 2019, OOT=2020-2023, POST=2024이며, P3의 보정값 10.8418은 DEV 중앙값이다. 이 표는 개발 검증기록으로 보존한다.

개발 기록에서 Simulator 점수는 관측 재무상태의 점수보다 중앙값 약 10.8점 높았고, 전체 사례의 97.6%에서 더 높았다. 반면 OOT 기업 순위상관은 0.903, 보정 후 방향일치율은 71.7%였다. 수준오차가 존재하더라도 일부 순위와 방향 정보가 남았다는 해석은 가능하지만, 모든 관리행동의 상대효과가 정확하다는 결론으로 이어지지는 않는다.

cash plug는 자금부족을 신규 단기차입으로 보충하기 때문에 낙관적 상태를 만들 수 있는 구조적 요인이다. 그러나 관측된 약 10.8점의 차이 전체가 cash plug 하나 때문에 발생했다고 확정하려면 다른 가정을 통제할 별도 대조가 필요하다. 본 논문은 구조적 원인 후보와 실제 귀속이 입증된 효과를 구분하며, 전체 수준차이를 임의의 단일 원인으로 설명하지 않는다.

동일 기업의 정책과 A0를 비교하면 공통적인 수준오차는 줄일 수 있다. 다만 상환행동이 자금부족을 바꾸거나 성장성 투자를 줄여 현금경로를 바꾸는 경우처럼, 오차가 행동에 의존한다면 차이에도 잔여오차가 남는다. 이에 따라 본 연구는 실제 다음 해 등급이나 절대 신용평점 예측보다, 명시된 평가환경 안의 정책 차이를 분석대상으로 제한한다.

4.2.3 V4.3 의미론 fixture와 증거의 경계

최신 pre-live 패키지는 실제 Simulator에서 Oracle- $\alpha \cdot \beta \cdot \gamma$ 와 Stage9를 거치는 의미론 fixture를 포함한다. 이 fixture는 제안·수용·ITT·실현의 분리, terminal unusable의 A0 처리, C6-E·C6-EX 조건 및 주요 대비 계산을 연결하여 확인한 실행 점검이다. 저장된 검증결과는 이 경로의 통과를 기록한다.

다만 한 개 기업과 제한된 논리 요청을 사용하는 fixture는 전체 575 개 기업에 대한 과거 상태 재현이나 외부등급 검증을 대신하지 않는다. 통과 여부는 해당 예제와 검사 범위에서의 구현 적합성을 의미한다. 따라서 개발 단계의 empirical validation, 최신 semantic fixture 및 최종 후보별 payoff 진단을 서로 다른 검증층으로 제시한다.

표 4-3. 현재 확보된 검증층과 해석 가능한 범위

검증층	확인하는 내용	확인하지 못하는 내용
개발 실증검증	과거 Oracle 정렬성·상태 재현·수준편향	모든 V4.3 변경 후 같은 수치가 재현됐는지
Pre-live fixture	실제 Simulator→Oracle→집계의 제한 사례 적합성	전체 기업에서의 현실 예측력·실행가능성
동결 9 후보 payoff	575 기업에서 최신 행동별 점수·동률·참조 순위	사후 ceiling 을 실제로 선택할 수 있는지
LLM 결과 무결성	요청카·조건·기업·행동·결과의 연결	자연어 근거의 완전한 사실성·실제 신용개선

자료: 원 검증표, pre-live semantic fixture, 최종 Stage6/Stage9 및 무결성 audit. 검사 범위를 넘어서 PASS 라는 표기를 일반화하지 않는다.

4.3 최신 아홉 행동에서 Oracle 의 구별력

동결된 V4.3 Stage6 에는 575 개 기업에 9 개 후보를 적용한 5,175 개 기업-행동 조합이 존재한다. 이 표면을 사용하여 Oracle 별 최대점수 동률, A0 가 최적인 기업 및 평가자 간 최적행동 일치율을 다시 계산하였다. 구형 후보집합에서 얻은 2.6%의 최적행동 일치율이나 11 개 행동의 동률 수치를 이 표에 재사용하지 않았다.

α 는 일부 재무변화가 같은 점수구간에 머물면 행동을 다르게 적용해도 같은 점수를 줄 수 있다. β 는 연속적인 평가에 가까워 동률이 상대적으로 적고, γ 도 학습된 트리 분할에 따라 동률이 발생한다. 어떤 Oracle 에서 변화가 0 이라는 사실이 모든 재무항목이 동일했다는 뜻은 아니므로 행동값과 평가값을 구분한다.

표 4-4. V4.3 후보별 점수의 동률과 A0 최적 여부

Oracle	복수 최대행동	9 개 전부 동률	A0 가 최대	기업 내 SD 평균
α	348 (60.5%)	164 (28.5%)	187 (32.5%)	0.6013
β	1 (0.2%)	1 (0.2%)	1 (0.2%)	0.1533
γ	257 (44.7%)	88 (15.3%)	173 (30.1%)	0.2493

자료: 최종 Stage6 기업-후보 payoff 재집계, N=575. 복수 최대행동과 A0 최대는 동률을 포함한다. 마지막 열은 기업마다 9 개 점수의 표준편차를 계산한 뒤 평균한 값이며 Oracle 간 척도가 다르다.

동률일 때 canonical 순서의 첫 행동을 택해 세 Oracle 의 argmax 를 비교하면 85 개 기업, 14.8%에서 일치한다. 그러나 세 Oracle 의 최대행동 집합에 적어도 하나의 공통행동이 존재하는 기업은 261 개, 45.4%이다. 이 차이는 평가자 불일치의 일부가 점수 경계와 동률 선택규칙에 민감함을 보여준다. ‘최적행동 일치율’이라는 한 표현으로 두 지표를 섞지 않는다.

이 결과는 서로 다른 평가모형을 유지하는 이유를 뒷받침한다. 한 모형의 높은 평균점수만으로 정책이 보편적으로 우월하다고 판단하면 평가구조의 선호가 정책의 일반적 품질로 오인될 수 있다. 동시에 낮은 argmax 일치율 자체가 모형이 쓸모없다는 의미도 아니다. 어떤 행동 차이를 구분하고 어느 지점에서 동률을 주는지를 공개하는 것이 중요하다.

4.4 최종 비교정책의 공통 평가표면

비교정책은 A0, 각 단일행동의 고정 적용, 균등 무작위 후보의 기대값 C1, 동결된 약점 개선 휴리스틱 C2, 학습 참조 C3-E 및 사후 후보 ceiling 으로 구성한다. C1 은 임의의 한 번 추첨 결과가 아니라 각 기업의 9 개 후보 점수 평균이다. 각 Oracle 의 ceiling 은 그 Oracle 에서 기업별로 최대값을 주는 후보를 선택한 값이므로, 세 Oracle 에서 같은 행동이 선택되었다는 뜻은 아니다.


다음 표는 모든 정책에 같은 575 개 기업과 같은 최신 A0 를 적용하여 계산한 평균 중분가치이다. 구형 학습기간의 관측행동 C_obs 를 2024 년의 실제 관측된 2025 년 성과인 것처럼 추가하지 않았다. 최신 고정정책은 α 기준으로 OE 이며, 구형 후보체계의 MX2 를 그대로 사용하지 않는다.

표 4-5. 최신 비교정책의 A0 대비 평균 정책가치

정책	Oracle- α	Oracle- β	Oracle- γ
A0	+0.0000	+0.0000	+0.0000
C1 (균등기대)	+0.3529	+0.0542	+0.1081
C2	+0.6069	+0.2059	+0.1849
DL	+0.1815	-0.0347	+0.1345
RF	+0.6633	+0.0761	+0.1542
CX	+0.2785	+0.0234	+0.1018
WC1	+0.3253	+0.0102	+0.0645
WC2	+0.2042	+0.0099	+0.0462
OE	+0.7654	+0.2775	+0.1944
MX1	+0.4951	+0.1444	+0.1845
MX2	+0.2630	-0.0188	+0.0932
C3-E	+0.9233	+0.2069	+0.2465
Ceiling	+1.4013	+0.3318	+0.5439

자료: 동결 Stage6 payoff와 C3-E 최종 metrics를 동일 575개 기업에서 재집계. 각 Oracle 내부 비교이며 원점수의 크기를 Oracle 사이에 직접 비교하지 않는다.

그림 4-1. Oracle- α 에서의 최종 비교정책 순위



자료: 표의 A0 대비 증분가치. Ceiling은 후보집합 안의 사후 상한이며 배포정책이 아니다.


α 에서 C3-E의 평균 절대점수는 55.959960, A0 대비 정책가치는 +0.923299이다. 최선 고정정책 OE의 A0 대비 값은 +0.765362, C2는 +0.606941이므로 C3-E-OE는 +0.157936, C3-E-C2는 +0.316358이다. 후보 ceiling은 절대점수 56.437984, A0 대비 +1.401323이다. 이는 현재 표면에서 학습 참조가 고정 OE를 넘는 평균값을 보이지만 여전히 사후 후보 상한과 간격이 있음을 나타낸다.

β 에서는 C3-E의 OE 대비 차이가 -0.070622인 반면 γ 에서는 +0.052025이다. C2 대비 차이는 β 에서 +0.000996으로 매우 작고 γ 에서 +0.061552이다. 따라서 α 에서 OE를 웃도는 결과를 세 평가모형 모두에서 같은 크기와 방향의 우월성으로 확대하지 않는다. 모든 수치는 최종 선택을 거친 정책의 기술통계라는 한계도 함께 갖는다.

4.5 C3-E의 행동분포와 seed 구성

4.5.1 평균가치, 행동다양성과 손실 사례

그림 4-2. 동결 C3-E의 기업별 행동 분포



자료: 최종 deployment metrics, 575 개 기업. OE 232, RF 155, WC1 54, CX 41, WC2 39, MX2 36, MX1 18이며 A0-DL 선택은 0이다.

최종 C3-E는 OE를 232개 기업(40.3%)에 선택하고 RF를 155개 기업(27.0%)에 선택하였다. 나머지는 운전자본, 성장성 CAPEX 및 복합행동으로 나뉜다. 행동빈도의 Shannon entropy는 자연로그 기준 $H=1.594461$ 이며 $\exp(H)$ 는 약 4.93이다. 이는 평가기업 전체에서의 행동선택 분포를 요약하는 값으로, 기업별 확률벡터의 평균 entropy와 다르다.

다양한 행동을 사용했다는 사실이 곧 더 좋은 정책이라는 의미는 아니다. OE와 다른 행동을 선택한 343개 기업 가운데 α 점수가 높아진 기업은 100개, 낮아진 기업은 102개, 같은 기업은 141개이다. 평균이 개선된 이유는 이득 사례의 총 증가폭이 손실 사례의 총 감소폭보다 컸기 때문이지, 이득을 본 기업 수가 압도적으로 많았기 때문은 아니다.

OE 대비 점수 증가의 합은 약 198.04, 감소폭의 합은 약 107.22로 순증가 약 90.81이다. 이를 575개 기업으로 나누면 +0.157936이다. 평균 증가와 개별 손실위험을 함께 제시해야 '평균적으로 더 높은 정책'과 '모든 기업에 더 안전한 정책'을 구분할 수 있다. 이

beneficial/harmful 은 Oracle- α 상 상대평가이며 실제 금융손익이나 부도피해의 관측이 아니다.

표 4-6. 최종 C3-E 의 주요 지표

지표	값	해석
α 절대점수 / A0 대비	55.959960 / +0.923299	같은 575 개 기업에서의 평균
OE / C2 대비 α	+0.157936 / +0.316358	선택된 정책의 개발표면 성과
H / exp(H)	1.594461 / 4.9257	기업별 결정행동의 다양성
OE share	40.3478%	전체 기업 중 OE 를 선택한 비율
OE 대비 gain / loss / tie	100 / 102 / 373	tie 는 OE 를 그대로 선택한 232 개도 포함
MDE75 절대값 / ratio	0.124619 / 1.267354	ratio 는 관측효과 ÷ 해당 MDE
MDE80 절대값 / ratio	0.132525 / 1.191747	표본·비교 정의에 조건부인 검출력 지표

자료: 동결 C3E_metrics.json. MDE ratio 를 MDE 자체로 부르지 않으며, 이 값이 선택편향 또는 외적 타당성 문제를 보정하지 않는다.

4.5.2 matched seed 확장과 민감도

T15 의 부족한 seed 를 추가한 목적은 configuration 마다 같은 일곱 seed 를 갖는 비교 가능한 cohort 를 완성하는 것이었다. 추가 실행으로 seed 2, 11, 12, 13, 16 을 보충하고 기존 14·15 와 함께 구성하였다. 그렇다고 최종 정책의 모든 성과가 개선되었다고 볼 수는 없다.

cohort 완료 보고서에서는 기존 비교 양상블의 α 55.968495, H 1.667468 에 비해 새 matched-cohort 의 α 55.959960, H 1.594461 이 소폭 낮아졌다. $\angle OE \geq 0.20$ 과 $H \geq 1.60$ 이라는 동시 탐색목표도 충족하지 못했다. 보고서의 목표기준 판정과 이후 배포본 동결 결정을 구분하여, 단지 release 이름에 BALANCED 가 있다는 이유로 목표를 달성했다고 쓰지 않는다.

seed 하나를 제거하는 진단에서는 $\angle OE$ 가 대략 +0.1462~+0.1686 범위였고 H는 1.5713~1.6270 이었다. 이는 같은 표면에서 특정 seed 하나에 의해 OE 대비 양의 평균차이가 전부 만들어지지는 않았다는 제한적인 증거이다. 그러나 새로운 기업·시점에서의 성과를 검증한 것은 아니며, 삭제한 seed 를 보고 더 좋은 조합으로 최종 정책을 다시 선택하지 않았다.

configuration 을 하나 제거하는 진단에서도 구성의 역할이 다르다. T15 를 제거하면 OE 비중이 약 49.2%로 높아지고 H 가 약 1.4542 로 낮아진다. 따라서 T15 는 다른 구성과 결합될 때 행동분포에 영향을 주지만, T15 자체의 점수가 가장 높다는 뜻은 아니다. 앙상블의 역할은 개별 구성의 평균점수만으로 판단할 수 없고 기업별 확률과 argmax 경계의 변화에 의존한다.

4.6 학습 참조정책의 사용범위

C3-E 의 역할은 최고 성능의 강화학습 알고리즘을 입증하는 것이 아니라, 재무자료에서 학습하고 재현 가능한 절차로 고정한 외부 행동참조를 제공하는 것이다. LLM 이 이 참조를 보았을 때 무엇을 바꾸는지, 단순 자기 점검토와 어떻게 다른지, 기업-참조 연결을 바꾸면 효과가 달라지는지를 분석하는 실험장치이다.

배포시에는 사후 Oracle 점수로 후보를 다시 정렬하지 않으므로 LLM 에 제공된 참조와 본문에서 평가한 참조가 같은 정책에 연결된다. 다만 encoder 와 configuration 및 배포정책의 선택 과정은 2024 년 평가와 완전히 분리되어 있지 않다. 따라서 C3-E 와 LLM 의 차이를 계산한 bootstrap 구간이 학습 참조 선택의 모든 불확실성을 반영한다고 주장하지 않는다.

학습 참조의 평균품질과 참조를 보여준 뒤 LLM 이 얻는 증분가치는 다른 양이다. 참조가 평균적으로 좋은 행동을 고르더라도 이미 좋은 초안을 가진 기업에서는 도움이 작거나 일부 행동을 대체해 손해가 날 수 있다. 다음 장의 비교는 참조 자체의 순위가 아니라 참조를 포함한 생성·수정 조건의 결과를 평가한다.

4.7 소결

본 장은 평가기반의 검증을 서로 다른 층으로 구분하였다. 개발 단계의 Oracle 정렬성과 Simulator 재현기록은 의미 있는 출발점이지만 최신 계약의 모든 변경을 자동으로 검증하지 않는다. 제한 사례의 semantic fixture 는 실행 의미론을 확인하고, 동결된 575×9 payoff 는 현재 후보집합의 점수 구별력과 비교정책의 위치를 보여준다.

최종 C3-E 는 α 에서 OE 와 C2 보다 높은 평균가치를 보이지만 Oracle 에 따라 상대 순위가 달라지고 개별 손실 사례도 존재한다. matched seed 앙상블은 확률평균에 의해 재현 가능한 참조를 제공하지만 2024 년의 반복 선택이라는 한계가 있다. 이 범위를 전제로 제 5 장에서는 Baseline LLM 정책의 출력 유효성과 운영정책가치를 함께 비교한다.

제 5 장 Baseline 본실험 결과

본 장은 실행 전 동결된 Baseline 의 Main Run1 을 중심으로 정책 하네스의 성과를 제시한다. 먼저 응답이 도착했는지와 행동으로 사용할 수 있는지를 나누어 확인하고, 전체 575 개 기업에 Strict ITT 를 적용한 평균 정책가치를 비교한다. 이어 네 가지 중심 대비, 행동예산, 후보선택과 자유작성, 정보조건 및 반복성의 범위를 살펴본다.

Baseline 에서 오류가 많다는 이유로 해당 조건을 제거하거나 High 또는 Repaired 로 대체하지 않는다. 형식과 행동제약을 지키지 못해 A0 로 처리되는 비율도 운영정책의 관측 결과이다. 다만 실제 실행은 비어 있지 않은 C4 원문을 후속 초안으로 전달한 raw-draft 분기규칙에 따라 이루어졌으므로, 본 장의 주 집계는 이 실행을 반영한다. 계획서의 usable-parent 게이트를 적용한 민감도는 제 6 장에서 따로 제시한다.

5.1 응답 완결성과 사용 가능성

5.1.1 요청 단위와 평가 단위의 구분

최종 실행 패키지인 Baseline 에는 두 공급자 합계 24,150 개의 논리 요청이 존재한다. 이 수는 Main Run1 의 17,250 건과 Stability Run2 의 6,900 건으로 구성된다. 완료·수집된 요청의 식별자와 조건 및 기업키를 연결한 뒤, 본 장의 표에서는 Run1 만 사용하였다. 한 기업의 여러 조건을 독립 기업처럼 더하지 않았고 PP 와 Repaired 분석행을 추가 생성요청으로 세지 않았다.

완료 상태는 공급자가 답을 반환하고 원문이 보존되었음을 의미한다. 그 응답이 정상적인 재무권고라는 뜻은 아니다. JSON 해석, 행동차원, 축별 범위, B1 예산 및 상호배타 조건을 별도로 검사한다. 다음 표의 usable 은 정책평가를 위한 canonical strict action-usability 이며, 진단과 근거 및 설명까지 포함한 전체 schema 검사와 구분된다.

5.1.2 행동 수용률과 전체 응답 형식

표 5-1. Gemini 3.1 Flash-Lite Baseline 자유작성의 수용률

예산	정책	행동 수용 N	행동 수용률	전체 schema 적합 N
B1	C4	88/575	15.3%	88/575
B1	C4R	76/575	13.2%	76/575

예산	정책	행동 수용 N	행동 수용률	전체 schema 적합 N
B1	C5	151/575	26.3%	150/575
B1	C6-E	83/575	14.4%	83/575
B1	C6-EX	72/575	12.5%	72/575
BINF	C4	575/575	100.0%	573/575
BINF	C4R	575/575	100.0%	574/575
BINF	C5	575/575	100.0%	572/575
BINF	C6-E	575/575	100.0%	574/575
BINF	C6-EX	574/575	99.8%	573/575

자료: Run1 canonical action-usability 와 원 요청 outcome 의 full-response/schema audit 를 같은 셀에서 연결. 모든 분모는 575 이며 두 검사는 같은 지표가 아니다.

표 5-2. GPT-5.4-mini Baseline 자유작성의 수용률

예산	정책	행동 수용 N	행동 수용률	전체 schema 적합 N
B1	C4	255/575	44.3%	140/575
B1	C4R	368/575	64.0%	304/575
B1	C5	378/575	65.7%	304/575
B1	C6-E	329/575	57.2%	212/575
B1	C6-EX	294/575	51.1%	193/575
BINF	C4	419/575	72.9%	290/575
BINF	C4R	543/575	94.4%	485/575
BINF	C5	510/575	88.7%	462/575
BINF	C6-E	503/575	87.5%	408/575
BINF	C6-EX	505/575	87.8%	402/575

자료: Run1 canonical action-usability 와 원 요청 outcome 의 full-response/schema audit 를 같은 셀에서 연결. 모든 분모는 575 이며 두 검사는 같은 지표가 아니다.

B1 C4에서 Gemini의 행동 수용률은 15.3%, GPT는 44.3%였다. Gemini는 BINF에서 대부분의 행동이 수용되는 반면 B1에서는 수용률이 크게 낮아졌고, GPT도 BINF보다 B1에서 낮았다. 같은 프롬프트 구조라도 총 행동강도 제약을 지켜야 하는 조건이 출력의 사용 가능성을 크게 바꾼 것이다. 이를 과거 raw L1 실험의 약 98~99% 준수율과 직접 비교해서 모델이 갑자기 퇴보했다고 설명하지 않는다. 행동 의미론과 정규화 예산 및 parser가 달라졌기 때문이다.

또한 GPT의 B1 C4는 행동 수용 255건이지만 전체 schema 적합은 140건이다. 정책행동을 읽어 평가할 수 있는 응답과 진단·근거·설명을 모두 요구한 형태로 작성한 응답 사이에 차이가 있다. 따라서 하나의 usable 비율만으로 보고서 생성의 품질까지 평가해서는 안 된다. 반대로 설명 schema가 완전하지 않다는 이유로 이미 정의된 action mask를 사후에 바꿔 본실험을 다시 선택하지 않는다.

이 결과의 중심은 API가 응답을 전달하는 데 실패했다는 것이 아니라, 생성·출력·검증의 결합이 실행가능한 행동을 얼마나 자주 만들었는가이다. Strict ITT에서 이 차이는 A0 비중으로 이어지고 평균 정책가치를 낮출 수 있다. 따라서 다음 절의 평균값은 성공한 응답의 경제적 효과뿐 아니라 불용 응답의 운영상 결과까지 포함한다.

5.2 Baseline Run1의 정책가치

5.2.1 전체 할당 기업의 A0 대비 가치

표 5-3. Gemini 3.1 Flash-Lite Baseline Strict ITT 정책가치

예산	정책	α 절대평점	$\Delta A0(\alpha)$	$\Delta A0(\beta)$	$\Delta A0(\gamma)$
B1	C4	55.1837	+0.1470	+0.0162	+0.0373
B1	C4R	55.1814	+0.1447	+0.0154	+0.0298
B1	C5	55.2989	+0.2623	+0.0280	+0.0694
B1	C6-E	55.2034	+0.1667	+0.0233	+0.0388
B1	C6-EX	55.1581	+0.1215	+0.0119	+0.0274
BINF	C4	56.5185	+1.4818	+0.3265	+0.3197
BINF	C4R	56.6612	+1.6245	+0.3454	+0.3488

예산	정책	α 절대평점	$\Delta A0(\alpha)$	$\Delta A0(\beta)$	$\Delta A0(\gamma)$
BINF	C5	56.4470	+1.4104	+0.3168	+0.3162
BINF	C6-E	56.6792	+1.6426	+0.3503	+0.3559
BINF	C6-EX	56.6216	+1.5850	+0.3366	+0.3461

자료: V4.3 최종 평가 패키지의 기업별 Stage9 ITT 기록을 재집계. Main Run1, IC-b, 기업 575 개. 표본은 usable subset 이 아니라 각 셀의 전체 575 개 기업이다. 절대평점과 A0 대비 증분가치를 분리하였다.

표 5-4. GPT-5.4-mini Baseline Strict ITT 정책가치

예산	정책	α 절대평점	$\Delta A0(\alpha)$	$\Delta A0(\beta)$	$\Delta A0(\gamma)$
B1	C4	55.3013	+0.2647	+0.0490	+0.0600
B1	C4R	55.4706	+0.4339	+0.0704	+0.1077
B1	C5	55.4973	+0.4606	+0.0972	+0.1131
B1	C6-E	55.5081	+0.4714	+0.0928	+0.1192
B1	C6-EX	55.3339	+0.2973	+0.0714	+0.0792
BINF	C4	55.6313	+0.5946	+0.1194	+0.1724
BINF	C4R	55.7679	+0.7313	+0.1324	+0.2174
BINF	C5	55.7324	+0.6957	+0.1353	+0.1492
BINF	C6-E	55.9151	+0.8785	+0.1825	+0.2395
BINF	C6-EX	55.7882	+0.7515	+0.1597	+0.2199

자료: V4.3 최종 평가 패키지의 기업별 Stage9 ITT 기록을 재집계. Main Run1, IC-b, 기업 575 개. 표본은 usable subset 이 아니라 각 셀의 전체 575 개 기업이다. 절대평점과 A0 대비 증분가치를 분리하였다.

Gemini B1 의 C4 절대평점은 55.183666 이고 A0 대비 정책가치는 +0.147005 이다. C6-E 도 A0 대비 +0.166725 에 머문다. GPT B1 에서는 C4 +0.264654, C4R +0.433916, C6-E +0.471443 으로 높은 값이 나타나지만, 이것만으로 각 수정의 원인을 판단할 수는 없다. C4 와 후속 조건의 수용률이 다르고 원문 분기규칙이 불용 초안의 재검토를 허용하기 때문이다.

BINF 에서는 행동공간의 총 강도 상한이 사라지고 수용률 및 생성된 행동도 달라진다. 더 높은 점수는 더 큰 행동이나 다른 조합을 사용한 결과일 수 있고 실제 비용의 증가를 반영하지

않을 수도 있다. 따라서 BINF의 큰 값으로 B1의 제약을 무시하거나, 제약이 적은 정책을 실제 기업에 더 좋은 권고라고 단정하지 않는다.

세 Oracle에서 A0 대비 점수의 크기를 합산하지 않는다. β 와 γ 는 α 의 결론이 평가구조에 어느 정도 민감한지를 확인하는 별도 축이다. 원점수의 단위가 다른 평가자를 하나의 평균점수로 합치면 어떤 행동이 왜 높게 평가되는지 오히려 불분명해진다.

5.2.2 학습 참조와 비교할 때의 주의점

C3-E의 α 평균 정책가치 +0.923299은 모든 기업에 동결된 후보행동을 적용한 결과이다. B1 free8 Baseline의 평균이 이보다 낮다고 해서 언어모형이 어떤 정상적인 행동도 만들지 못했다는 뜻은 아니다. 이 비교는 확정된 불용 응답을 A0로 처리한 운영정책 전체와, 결정론적 후보출력의 참조정책을 비교한다.

반대로 usable 기업만 고른 LLM의 절대평점이 C3-E 전체 평균보다 높다는 이유로 LLM이 우월하다고 해석할 수 없다. usable 기업의 기초 신용상태가 다르면 절대점수 자체가 높아질 수 있기 때문이다. 비교정책과 같은 기업을 연결한 증분가치 또는 strict 교집합의 대응차이가 필요하다. PP와 실행규칙을 나누어 보는 제6장의 분석은 이 문제를 보완한다.

5.3 자기 재검토, 진단 지시와 참조의 효과

표 5-5. Gemini 3.1 Flash-Lite Baseline의 네 중심 대비

예산	대비	평균 $\Delta \alpha$	95% bootstrap 구간	Holm p
B1	C4R-C4	-0.0023	[-0.0563, +0.0519]	1.0000
B1	C5-C4	+0.1153	[+0.0471, +0.1896]	0.0084
B1	C6-E-C4R	+0.0220	[-0.0241, +0.0665]	1.0000
B1	C6-E-C6-EX	+0.0452	[-0.0155, +0.1059]	0.6489
BINF	C4R-C4	+0.1427	[+0.0891, +0.1993]	0.0016
BINF	C5-C4	-0.0715	[-0.1649, +0.0199]	0.6489
BINF	C6-E-C4R	+0.0180	[-0.0548, +0.0895]	1.0000
BINF	C6-E-C6-EX	+0.0576	[-0.0073, +0.1228]	0.4848

자료: 원 Stage9의 기업별 대응차이, Run1/free8/IC-b/Strict ITT, N=575. p는 제 3.9 절의 bootstrap sign-tail plus-one 통계량에 모델·Oracle 별 8개 family의 Holm 조정을 적용한 값이다. 구간은 미조정이다.

표 5-6. GPT-5.4-mini Baseline의 네 중심 대비

예산	대비	평균 $\Delta \alpha$	95% bootstrap 구간	Holm p
B1	C4R-C4	+0.1693	[+0.1150, +0.2293]	0.0016
B1	C5-C4	+0.1960	[+0.1035, +0.2884]	0.0016
B1	C6-E-C4R	+0.0375	[-0.0548, +0.1273]	0.4036
B1	C6-E-C6-EX	+0.1742	[+0.0751, +0.2767]	0.0020
BINF	C4R-C4	+0.1366	[+0.0775, +0.1985]	0.0016
BINF	C5-C4	+0.1011	[-0.0082, +0.2106]	0.1376
BINF	C6-E-C4R	+0.1472	[+0.0511, +0.2445]	0.0200
BINF	C6-E-C6-EX	+0.1270	[+0.0173, +0.2390]	0.0672

자료: 원 Stage9의 기업별 대응차이, Run1/free8/IC-b/Strict ITT, N=575. p는 제 3.9 절의 bootstrap sign-tail plus-one 통계량에 모델·Oracle 별 8개 family의 Holm 조정을 적용한 값이다. 구간은 미조정이다.

5.3.1 C4R-C4: 다시 검토하는 조건의 가치

B1에서 GPT의 C4R-C4는 +0.010520이며 95% 구간은 [+0.114964, +0.229326]이다. 같은 조건의 Gemini 차이는 -0.002294로 0 부근이고 구간은 양쪽 부호를 포함한다. BINF에서는 두 모델 모두 양의 자기 재검토 차이가 관찰된다. 따라서 ‘자기 재검토는 항상 유익하다’나 ‘아무 도움이 없다’는 하나의 결론으로 정리할 수 없다.

이 차이는 같은 부모 초안을 다시 검토하는 실행조건의 전체 결과이다. GPT B1에서 수용률이 C4 44.3%에서 C4R 64.0%로 높아지므로, 원문이 읽기 어렵거나 예산을 넘은 초안을 더 자주 수용 가능한 행동으로 바꾼 영향도 포함된다. 이것을 경제적 판단의 순수한 개선으로 분리하려면 실행규칙과 분석표본의 역할을 확인해야 한다. Repaired 또는 usable-parent 민감도에서 같은 차이가 유지되는지는 제 6장에서 검토한다.

5.3.2 C5-C4: 프롬프트 진단 유도

B1의 C5-C4는 Gemini +0.115271, GPT +0.195995로 양수이고 각각의 8개 family Holm 조정값도 0.05보다 작다. 따라서 구형 원고의 ‘세 모델 모두 자유작성에서 추론 지시가

정책가치를 낮췄다’는 결론은 최신 Baseline 의 일반 결론으로 유지할 수 없다. 여기서 C5 는 같은 API 추론설정 아래에서 진단 scaffold 를 추가한 조건이라는 점이 중요하다.

BINF 에서는 Gemini -0.071465 , GPT $+0.101118$ 로 방향이 다르고 다중비교 후 명확한 차이로 확정되지 않는다. C5 효과가 B1 과 BINF 에서 달라진다는 사실은 추론 지시의 유용성이 행동제약 및 출력 수용성과 함께 작동한다는 해석과 양립한다. 그러나 C5 가 어떤 내부 추론을 수행했는지를 직접 관찰한 것은 아니므로, 특정 인지기제를 입증했다고 표현하지 않는다.

표 5-7. 진단 유도 전후의 행동강도와 활성 차원

모델	예산	C4 ITT 강도	C5 ITT 강도	C4 활성 축	C5 활성 축
Gemini	B1	0.148	0.255	1.34	1.19
Gemini	BINF	2.499	2.169	4.73	3.42
GPT	B1	0.406	0.625	1.84	1.57
GPT	BINF	0.919	1.013	2.63	1.73

자료: Baseline Run1/free8/IC-b. ITT 강도는 A0 를 포함한 전체 575 개 평균, 활성 축 수는 각 조건에서 strict usable 인 행동의 조건부 평균이다. 후자의 두 표본이 같다는 가정이나 통계적 효과 판정은 하지 않는다.

진단 지시는 수용률뿐 아니라 행동강도와 사용하는 차원의 조합을 바꿀 수 있다. 표의 활성 차원 수는 각 조건의 수용표본에서 계산한 기술통계이므로 동일 기업 교집합의 인과적 변화로 읽지 않는다. H2 는 출력 유효성과 관측 행동의 변화를 함께 확인하는 질문으로 다루며, 구형 후보집합에서의 최근접 거리 수치를 현재 행동공간의 결과로 옮기지 않는다.

5.3.3 C6-E-C4R: 학습참조의 추가 가치

B1 에서 C6-E-C4R 은 Gemini $+0.022015$, GPT $+0.037527$ 이다. 두 구간은 0 을 포함하고 Holm 조정 이후에도 양의 추가효과로 확정되지 않는다. 이는 참조가 모든 기업에서 무의미하다는 뜻이 아니라, 이 Baseline 생성·실행 조건에서 자기 재검토보다 평균적으로 더 높은 가치를 얻었다는 증거가 충분하지 않다는 뜻이다.

BINF 에서는 GPT 의 차이가 $+0.147202$ 이고 95% 구간은 $[+0.051112, +0.244527]$, 이번 재현 방식의 Holm p 는 약 0.0200 이다. 반면 Gemini 는 $+0.018038$ 이며 구간이 양과 음을 포함한다. 따라서 Baseline 에서 학습참조의 추가효과가 두 모델 모두 없었다고 포괄적으로 쓰는 것도 틀리다. 모델과 행동예산을 명시해야 한다.

5.3.4 C6-E-C6-EX: 기업과 참조의 연결

B1 에서 GPT 의 C6-E-C6-EX 는 +0.174192 이며 구간은 [+0.075089, +0.276724]이다. 동일한 참조 주변분포를 유지하면서 기업별 연결을 바꿨을 때보다 원래 연결의 점수가 높았다. Gemini 의 차이는 +0.045249 이나 구간이 0 을 포함한다. 이 결과는 고정된 derangement 아래의 기업-참조 연결 차이이며, 참조의 출처가 언제나 인식되거나 참조를 무비판적으로 수용했다는 증거가 아니다.

GPT BINF 에서도 점추정은 +0.126973 으로 양수이고 미조정 구간은 양의 범위이지만, 8 개 family Holm 조정값은 약 0.0672 이다. 미조정 구간만 보고 본문에 확정적인 별표를 붙이면 다중비교 규칙과 어긋난다. Gemini BINF 도 양의 점추정이지만 조정 후 뚜렷하지 않다. 동일한 표에 추정치, 미조정 구간 및 조정 p 를 함께 남긴 이유이다.

5.4 행동예산과 수정효과의 상호작용

표 5-8. Baseline 대비효과의 B1-BINF 차이

모델	대비	상호작용 $\Delta \alpha$	95% 구간	Holm p
Gemini	C4R-C4	-0.1450	[-0.2206, -0.0727]	0.0008
Gemini	C5-C4	+0.1867	[+0.0750, +0.3017]	0.0012
Gemini	C6-E-C4R	+0.0040	[-0.0786, +0.0859]	1.0000
Gemini	C6-E-C6-EX	-0.0124	[-0.1088, +0.0833]	1.0000
GPT	C4R-C4	+0.0326	[-0.0534, +0.1185]	0.9295
GPT	C5-C4	+0.0949	[-0.0461, +0.2344]	0.5651
GPT	C6-E-C4R	-0.1097	[-0.2405, +0.0229]	0.4480
GPT	C6-E-C6-EX	+0.0472	[-0.0888, +0.1851]	0.9295

자료: 같은 575 개 기업의 예산별 대비 차이. 모델·Oracle 별 상호작용 네 개를 별도 family 로 조정하였다. 음수는 B1 에서 해당 대비가 BINF 보다 작다는 뜻이다.

Gemini 의 자기 재검토 차이는 B1 에서 BINF 보다 -0.145017 낮고, C5-C4 는 오히려 +0.186736 높다. 이 두 상호작용은 각각의 4 개 family 조정에서도 차이가 남는다. 총

행동예산은 모든 수정조건을 같은 방향으로 약화시키는 단순한 스위치가 아니라, 직접생성과 진단·재검토의 상대적인 결과를 바꾸는 조건이다.

GPT에서는 자기 재검토, 진단 유도, 학습참조 및 연결 대비의 B1-BINF 차이가 모두 다중비교 후 뚜렷하지 않다. 특히 BINF에서 참조효과가 유의하고 B1에서 유의하지 않더라도, 그 사실만으로 예산 상호작용이 유의하다고 결론내릴 수 없다. 두 대비의 차이를 직접 계산한 결과와 각각의 조건 안에서 계산한 결과는 다른 질문이다.

5.5 후보선택과 자유작성

표 5-9. Baseline B1의 자유작성-후보선택 대비

모델	정책	평균 $\Delta \alpha$	95% 구간	Holm p
Gemini	C4	-0.7028	[-0.8174, -0.5929]	0.0006
Gemini	C4R	-0.6661	[-0.7779, -0.5584]	0.0006
Gemini	C6-E	-0.6881	[-0.8032, -0.5781]	0.0006
GPT	C4	-0.3372	[-0.4467, -0.2303]	0.0006
GPT	C4R	-0.1928	[-0.2976, -0.0914]	0.0006
GPT	C6-E	-0.2404	[-0.3429, -0.1398]	0.0006

자료: Run1/IC-b/B1/Strict ITT, 동일 575개 기업. 모델별 C4·C4R·C6-E 세 대비를 하나의 family로 처리하였다.

Baseline B1에서는 두 모델 모두 자유작성의 Strict ITT 가치가 후보선택보다 낮다. C4의 차이는 Gemini -0.702799, GPT -0.337179이며 다른 두 정책에서도 음의 차이가 남는다. 따라서 최신 본실험에서 자유작성이 언제나 후보선택보다 우월하다는 주장은 지지되지 않는다.

자유작성은 더 많은 조합을 허용하지만, 그만큼 응답형식과 연속값 및 총 강도를 함께 관리해야 한다. 후보선택은 동결된 ID 하나를 선택하므로 행동수용이 상대적으로 쉽다. 이 비교는 출력공간과 행동제약 준수 및 검증규칙을 포함한 정책 하네스 전체의 차이이다. ‘자유도가 크면 경제적 판단능력이 약해진다’라는 단일 원인으로 해석하지 않는다.

High에서 이 격차가 얼마나 줄어드는지와, 정상 수용집합에서 행동의 차이가 어떠한지는 추가 분석에서 확인한다. 과거 넓은 raw 행동공간의 점수가 높았다는 결과를 가져와 최신 B1의 낮은 운영가치를 덮어쓰지 않는다.

5.6 정보조건: 업종코드와 기업명

표 5-10. Baseline C4/free8/B1 의 정보조건 대비

모델	정보 대비	평균 $\Delta \alpha$	95% 구간	Holm p
Gemini	IC-b-IC-a	-0.0175	[-0.0786, +0.0407]	1.0000
Gemini	IC-c-IC-b	+0.0228	[-0.0556, +0.1040]	1.0000
GPT	IC-b-IC-a	-0.0016	[-0.0940, +0.0885]	0.9771
GPT	IC-c-IC-b	+0.0728	[-0.0201, +0.1661]	0.2524

자료: Main Run1, 전체 575 개 기업, Strict ITT. 모델·Oracle 별 두 정보 대비에 Holm 을 적용하였다. IC-a 에도 연도·규모·시장 필드는 존재하며 IC-b 는 업종코드만 추가한다.

Baseline 에서 업종코드와 기업명 추가의 평균 차이는 두 모델 모두 조정 후 명확한 방향으로 확정되지 않는다. GPT 의 IC-c-IC-b 는 +0.072803 이지만 구간은 음과 양을 포함한다. 이는 현재 코드형 산업정보와 기업명 공개 조건에서의 결과이지 산업연구나 경영진 정보가 본질적으로 쓸모없다는 증거가 아니다.

산업코드는 조회시점의 company-profile 에서 수집했으므로 역사적 시점 정합성에도 한계가 있다. 코드만 제시하는 방식은 업종의 경쟁구도와 공급망, 거시환경을 설명하는 문서를 제공한 것과 다르다. 또한 기업명 공개에 따른 모델의 사전학습 지식 사용 여부를 이번 clean run 에서 직접 확인하지 않았으므로, 정보효과가 작다는 사실을 지식오염이 없었다는 증명으로 쓰지 않는다.

RQ5 는 이 제한된 비교를 통해 ‘어떤 정보를 어떤 형태로 추가했는지’가 실험 정의에 포함되어야 한다는 점을 남긴다. 정보량을 단순히 많음과 적음으로만 구분하지 않고 실제 필드, 시점 및 표현을 함께 공개한다.

5.7 Baseline 반복성과 본실험의 소결

표 5-11. Baseline 의 별도 Run1·Run2 반복 비교

모델	예산	정책	Run1 $\Delta A0$	Run2 $\Delta A0$	$\Delta A0$ 순위 ρ
Gemini	B1	C4	+0.1470	+0.1915	0.754
Gemini	B1	C4R	+0.1447	+0.1830	0.797

모델	예산	정책	Run1 $\Delta A0$	Run2 $\Delta A0$	$\Delta A0$ 순위 ρ
Gemini	B1	C6-E	+0.1667	+0.1810	0.726
Gemini	BINF	C4	+1.4818	+1.4611	0.836
Gemini	BINF	C4R	+1.6245	+1.5761	0.864
Gemini	BINF	C6-E	+1.6426	+1.6348	0.891
GPT	B1	C4	+0.2647	+0.3015	0.495
GPT	B1	C4R	+0.4339	+0.4197	0.526
GPT	B1	C6-E	+0.4714	+0.4762	0.554
GPT	BINF	C4	+0.5946	+0.5592	0.444
GPT	BINF	C4R	+0.7313	+0.7095	0.575
GPT	BINF	C6-E	+0.8785	+0.8206	0.698

자료: 같은 575 개 기업을 Run1 과 Run2 에서 연결. 두 실행을 평균하여 primary 로 사용하지 않는다. 마지막 열은 절대점수가 아니라 A0 대비 기업별 가치의 Spearman 순위상관이다.

반복성 표는 같은 기업과 같은 정책조건을 다시 수행했을 때 평균값과 기업별 가치가 어느 정도 비슷한지를 보여준다. 수용률이 낮은 조건에서는 두 실행 모두 A0 가 많이 포함되어 비슷해 보일 수 있으므로, 평균 및 상관만으로 실행 신뢰성이 충분하다고 판단하지 않는다. 실제 행동벡터와 수정의 증분효과는 제 6 장에서 별도로 비교한다.

Baseline 의 핵심 결과는 세 가지로 정리된다. 첫째, 전승완료와 행동 수용은 다른 지표이며 B1 자유작성의 낮은 수용률은 운영정책가치를 크게 제한하였다. 둘째, C5 와 자기 재검토 및 학습참조의 효과는 모델과 행동예산에 따라 달라졌다. 셋째, 자유작성의 넓은 선택공간만으로 후보선택보다 높은 Strict ITT 가치를 보장할 수 없었다.

이 결과는 Baseline 을 폐기할 이유가 아니라 다음 분석의 동기이다. 추가 추론설정으로 처음부터 더 자주 유효한 행동을 생성할 수 있는지, 같은 원응답에 다른 실행규칙을 적용하면 수정효과의 해석이 달라지는지, 그리고 집단 평균의 개선이 기업별 행동의 안정성까지 의미하는지를 검토할 필요가 있다.

제 6 장 추론 설정과 실행규칙에 대한 추가 분석

Baseline 결과는 LLM의 정책가치를 해석할 때 생성된 내용과 실제 사용할 수 있는 행동을 구분해야 함을 보여주었다. 본 장은 두 개의 추가 질문을 다룬다. 하나는 추론설정을 높인 생성 regime에서 처음부터 수용 가능한 행동과 높은 정책가치를 얻는가이고, 다른 하나는 동일한 원응답에 다른 실행규칙을 적용하면 관측 결과가 어떻게 달라지는가이다.

High와 Repaired는 본실험 이후의 추가 분석이다. 결과가 더 좋다는 이유로 Baseline을 대체하지 않으며, High×Strict, High×Repaired, Baseline×Strict, Baseline×Repaired의 네 조합을 구분한다. PP는 이 네 조합과 별도의 조건부 분석표본이다. 본문의 중심 해석에 High와 Repaired를 충분히 사용하되 최초 실행 전 계획의 지위를 소급 변경하지 않는다.

6.1 추가 분석의 지위와 두 축

표 6-1. 생성 regime와 실행규칙의 2×2 구조

생성	Strict 실행	Repaired 실행
Baseline	먼저 동결된 생성·운영조건의 평가	같은 Baseline 원응답의 별도 결정론적 처리
High	추론·출력상한이 변경된 추가 생성실험	High 원응답과 수리 실행규칙의 결합

새 생성은 Baseline과 High 두 campaign 뿐이다. Repaired는 기존 응답의 오프라인 분석이며 추가 LLM 호출을 만들지 않는다.

High는 추론 effort 또는 thinking level을 high로 높이고 최대 출력 토큰을 4,096에서 32,768로 조정한 regime이다. 특히 후속 응답은 High에서 생성한 자기 C4를 사용하므로, C4R과 C6-E의 High-Baseline 차이는 최초 초안 변화도 포함한다. 이를 추론 토큰 하나만 늘린 순수한 인과효과로 부르지 않는다.

Repaired는 원문에서 읽을 수 있는 행동을 정해진 규칙으로 변환하여 평가하는 실행정책이다. 실제 원응답을 읽은 것이 아니며, unusable이라는 표시는 원문을 지웠다는 뜻도 아니다. 수리된 행동과 strict 행동을 별도로 보존함으로써 출력 유효성과 행동조합의 정책가치를 함께 분석할 수 있다.

6.2 High 에서의 계약준수와 행동강도


6.2.1 B1 자유작성 수용률

표 6-2. Gemini 3.1 Flash-Lite B1 의 추론 regime 별 행동 수용

정책	Baseline N	Baseline 비율	High N	High 비율
C4	88/575	15.3%	570/575	99.1%
C4R	76/575	13.2%	567/575	98.6%
C5	151/575	26.3%	567/575	98.6%
C6-E	83/575	14.4%	566/575	98.4%
C6-EX	72/575	12.5%	568/575	98.8%

자료: Main Run1/free8/IC-b/B1, canonical strict action-usability. 전체 응답 schema 의 완전성과 구분한다.

그림 6-1. Gemini 3.1 Flash-Lite B1 의 행동 수용률 변화




자료: 위 표. 두 regime 가 같은 575 개 기업을 대상으로 하며, High 에는 출력상한의 기술적 변경도 포함된다.

표 6-3. GPT-5.4-mini B1 의 추론 regime 별 행동 수용

정책	Baseline N	Baseline 비율	High N	High 비율
C4	255/575	44.3%	560/575	97.4%
C4R	368/575	64.0%	567/575	98.6%
C5	378/575	65.7%	572/575	99.5%
C6-E	329/575	57.2%	566/575	98.4%
C6-EX	294/575	51.1%	566/575	98.4%

자료: Main Run1/free8/IC-b/B1, canonical strict action-usability. 전체 응답 schema 의 완전성과 구분한다.

그림 6-2. GPT-5.4-mini B1 의 행동 수용률 변화



자료: 위 표. 두 regime 가 같은 575 개 기업을 대상으로 하며, High 에는 출력상한의 기술적 변경도 포함된다.

High B1 C4 의 수용률은 Gemini 570/575(99.1%), GPT 560/575(97.4%)이다. 다른 네 정책도 높은 수용률을 보인다. 따라서 낮은 추론 regime 에서의 높은 불용 비율을 해당 모델의 모든 생성조건에서 불변하는 실패율로 간주할 수 없다. 이번 과제에서는 생성조건을 바꾸었을 때 제약준수가 크게 달라졌다.

수용률이 100%에 가까워지면 C5 또는 자기 재검토가 단순히 불용 응답을 줄여 얻을 수 있는 추가 여지도 작아질 수 있다. 그러나 수용률의 ceiling 과 경제적 판단의 개선은 같은 개념이 아니다. High 에서도 잘못된 재무적 판단, 기업별 손실, 부족한 설명 또는 현실의 실행 불가능성은 남을 수 있다. 높은 수용률은 정해진 수치·형식 계약을 충족했다는 결과일 뿐이다.

6.2.2 실제 사용 강도와 행동의 폭

표 6-4. 직접생성 C4 의 실사용 강도와 활성 차원

모델	예산	Regime	ITT 평균 강도	수용행동 활성 측	수용 N
Gemini	B1	Baseline	0.148	1.34	88
Gemini	B1	High	0.914	2.27	570
Gemini	BINF	Baseline	2.499	4.73	575
Gemini	BINF	High	1.679	3.15	575
GPT	B1	Baseline	0.406	1.84	255
GPT	B1	High	0.923	1.84	560
GPT	BINF	Baseline	0.919	2.63	419
GPT	BINF	High	1.041	1.97	568

자료: Run1/IC-b 의 실제 8 차원 벡터와 canonical strict mask. ITT 강도는 불용 응답을 0 으로 포함한 전체 575 개 평균이고, 활성 측 수는 수용된 행동만의 조건부 평균이다. 서로 다른 분모를 구분한다.

평균 강도는 사용된 분모에 따라 의미가 달라진다. Strict ITT 강도는 A0 fallback 의 0 까지 포함하므로, 낮은 값이 반드시 정상 응답에서 모델이 조심스럽게 작은 행동을 선택했음을 뜻하지는 않는다. 반면 수용행동의 활성 차원 수는 오류 없이 수용된 사례에서 얼마나 많은 재무항목을 조합했는지를 나타낸다.

이 구분은 Baseline 과 High 를 비교할 때 특히 중요하다. High 에서 ITT 강도가 높아졌다면 정상 행동 자체가 커진 영향과 A0 fallback 이 줄어든 영향이 함께 있을 수 있다. 총 예산과 실제 사용 강도를 분리하고, 재무행동의 넓이를 모델의 보편적 우월성으로 바로 해석하지 않는다. 현재 자료로 실행규칙의 역할은 직접 비교할 수 있지만, 각 행동항목의 인과적 기여까지 식별한 것은 아니다.

6.3 결정론적 Repair 의 복구범위와 정책가치

6.3.1 원응답 보존과 정상행동 불변성

표 6-5. Repair 복구와 원래 수용응답의 점수 불변성

모델	Regime	Strict 수용	추가 복구	여전히 불용	기존 수용값 변경
Gemini	Baseline	7,259	4,802	14	0
GPT	Baseline	8,765	3,305	5	0
Gemini	High	11,996	78	1	0
GPT	High	11,904	170	1	0

자료: 두 Run 을 포함한 모델·regime 별 12,075 개 요청을 원 요청키로 연결. 마지막 열은 원래 strict usable 인 응답의 Oracle- α 값이 바뀐 건수이며 최대 절대변화도 모든 집합에서 0 이다.

Baseline 에서는 Gemini 4,802 건, GPT 3,305 건이 Repair 후 추가로 수용 가능해졌다. High 에서는 이미 수용률이 높아 추가 복구가 각각 78 건과 170 건이다. 원래 strict usable 이던 응답의 α 점수는 모두 그대로였다. 이 결과는 정상 응답을 더 유리한 행동으로 바꾸어 평균을 끌어올린 것이 아니라, 불용 출력의 처리규칙 변화가 주된 분석대상임을 확인한다.

하지만 복구된 수가 많다고 모든 응답의 의도를 정확하게 복원했다고 말할 수 없다. 동일한 원문에 같은 규칙을 적용해 재현 가능한 행동을 얻었다는 것과, 그 행동이 원래 모델이 생각한 최선의 판단이었다는 것은 다르다. 특히 예산 rescale 은 원래 제안의 크기를 바꾸고 중복 key 의 last-write-wins 는 가능한 여러 값 가운데 하나를 선택한다. 복구율은 해당 규칙으로 평가 가능한 산출물을 얻은 비율이다.

6.3.2 네 실행조합의 정책가치


표 6-6. Gemini 3.1 Flash-Lite 의 생성·실행 조합별 A0 대비 가치

예산	정책	Base Strict	Base Repair	High Strict	High Repair
B1	C4	+0.1470	+0.7662	+0.8052	+0.8169
B1	C4R	+0.1447	+0.7554	+0.7950	+0.8172
B1	C5	+0.2623	+0.8264	+0.8700	+0.8794
B1	C6-E	+0.1667	+0.8139	+0.8847	+0.8965

예산	정책	Base Strict	Base Repair	High Strict	High Repair
B1	C6-EX	+0.1215	+0.7373	+0.8435	+0.8495
BINF	C4	+1.4818	+1.4818	+1.2742	+1.2742
BINF	C4R	+1.6245	+1.6245	+1.4191	+1.4191
BINF	C5	+1.4104	+1.4104	+1.2090	+1.2090
BINF	C6-E	+1.6426	+1.6426	+1.4622	+1.4622
BINF	C6-EX	+1.5850	+1.5850	+1.4469	+1.4469


자료: V4.3 최종 평가 패키지의 기업별 Stage9 ITT 기록을 재집계. Main Run1, IC-b, 기업 575 개. 모든 열은 N=575 의 ITT 이다. Repair 는 추가 생성이 아니라 동일 원응답의 실행규칙 변경이다.

그림 6-3. Gemini 3.1 Flash-Lite B1 의 네 생성·실행 조합



자료: Run1/IC-b, Oracle- α 의 A0 대비 평균. 점선은 동결 C3-E 의 +0.923299 이다. 각 선은 서로 다른 생성·실행 조합이며 성과의 표본선택 없이 모든 다섯 정책을 표시하였다.

그림 6-4. Gemini 3.1 Flash-Lite BINF 의 네 생성·실행 조합



자료: Run1/IC-b, Oracle- α 의 A0 대비 평균. 점선은 동결 C3-E 의 +0.923299 이다. 각 선은 서로 다른 생성·실행 조합이며 성과의 표본선택 없이 모든 다섯 정책을 표시하였다.


표 6-7. GPT-5.4-mini 의 생성·실행 조합별 A0 대비 가치

예산	정책	Base Strict	Base Repair	High Strict	High Repair
B1	C4	+0.2647	+0.6143	+0.7852	+0.8092
B1	C4R	+0.4339	+0.6191	+0.8116	+0.8197
B1	C5	+0.4606	+0.6930	+0.7981	+0.8033
B1	C6-E	+0.4714	+0.8126	+0.9119	+0.9387
B1	C6-EX	+0.2973	+0.6099	+0.7973	+0.8157
BINF	C4	+0.5946	+0.7330	+0.8875	+0.9069
BINF	C4R	+0.7313	+0.7625	+0.9598	+0.9655
BINF	C5	+0.6957	+0.7743	+0.8195	+0.8243
BINF	C6-E	+0.8785	+0.9694	+1.1740	+1.1867

예산	정책	Base Strict	Base Repair	High Strict	High Repair
BINF	C6-EX	+0.7515	+0.8122	+1.0974	+1.0974


자료: V4.3 최종 평가 패키지의 기업별 Stage9 ITT 기록을 재집계. Main Run1, IC-b, 기업 575 개. 모든 열은 N=575 의 ITT 이다. Repair 는 추가 생성이 아니라 동일 원응답의 실행규칙 변경이다.

그림 6-5. GPT-5.4-mini B1 의 네 생성·실행 조합



자료: Run1/IC-b, Oracle- α 의 A0 대비 평균. 점선은 동결 C3-E 의 +0.923299 이다. 각 선은 서로 다른 생성·실행 조합이며 성과의 표본선택 없이 모든 다섯 정책을 표시하였다.

그림 6-6. GPT-5.4-mini BINF 의 네 생성·실행 조합



자료: Run1/IC-b, Oracle- α 의 A0 대비 평균. 점선은 동결 C3-E 의 +0.923299 이다. 각 선은 서로 다른 생성·실행 조합이며 성과의 표본선택 없이 모든 다섯 정책을 표시하였다.

특히 GPT Baseline B1 에서 자기 재검토의 Strict 차이는 +0.010520 이지만 Repaired 차이는 +0.004748 이다. 직접생성 C4 의 많은 불용 응답을 결정론적으로 사용할 수 있게 바꾸면, 자기 재검토를 한 번 더 수행하여 관측되던 평균상의 이득이 크게 작아진다. 따라서 C4R 의 관측효과를 단순히 ‘생각을 한 번 더 했기 때문에 경제적 판단이 개선되었다’로 귀속하기 어렵다.

이것은 자기 재검토가 무조건 쓸모없다는 결론이 아니다. 실행규칙이 다르면 직접생성과 수정조건의 상대적 출발점도 달라진다는 뜻이다. 또한 Repair 가 행동량을 바꾸므로 Strict 와 Repaired 의 차이를 인과적 mediation 또는 판단능력의 완전한 분해로 부르지 않는다. 수리되지 않은 원응답과 수리된 행동을 함께 보존한 민감도 분석으로 해석한다.

6.4 High 의 수정효과와 Baseline 대비 변화

6.4.1 High regime 안의 네 중심 대비

표 6-8. Gemini 3.1 Flash-Lite High Strict ITT 의 네 대비

예산	대비	평균 $\Delta \alpha$	95% 구간	Holm p
B1	C4R-C4	-0.0102	[-0.0429, +0.0209]	1.0000
B1	C5-C4	+0.0649	[+0.0051, +0.1250]	0.1848
B1	C6-E-C4R	+0.0897	[+0.0408, +0.1405]	0.0028
B1	C6-E-C6-EX	+0.0412	[-0.0134, +0.0986]	0.6899
BINF	C4R-C4	+0.1449	[+0.0914, +0.2009]	0.0016
BINF	C5-C4	-0.0652	[-0.1514, +0.0199]	0.6899
BINF	C6-E-C4R	+0.0431	[-0.0188, +0.1053]	0.6899
BINF	C6-E-C6-EX	+0.0153	[-0.0405, +0.0724]	1.0000

자료: 추가 High 실행의 Main Run1/free8/IC-b. N=575, p는 8개 family의 bootstrap sign-tail Holm 조정값이다. 본실험 primary로 소급 취급하지 않는다.

표 6-9. GPT-5.4-mini High Strict ITT 의 네 대비

예산	대비	평균 $\Delta \alpha$	95% 구간	Holm p
B1	C4R-C4	+0.0264	[-0.0000, +0.0553]	0.1936
B1	C5-C4	+0.0129	[-0.0464, +0.0725]	0.6679
B1	C6-E-C4R	+0.1003	[+0.0368, +0.1631]	0.0120
B1	C6-E-C6-EX	+0.1146	[+0.0443, +0.1864]	0.0084
BINF	C4R-C4	+0.0724	[+0.0290, +0.1189]	0.0016
BINF	C5-C4	-0.0680	[-0.1378, +0.0011]	0.1936
BINF	C6-E-C4R	+0.2142	[+0.1415, +0.2918]	0.0016
BINF	C6-E-C6-EX	+0.0767	[+0.0007, +0.1544]	0.1936

자료: 추가 High 실행의 Main Run1/free8/IC-b. N=575, p는 8개 family의 bootstrap sign-tail Holm 조정값이다. 본실험 primary로 소급 취급하지 않는다.

High B1 에서 학습참조를 포함한 C6-E 와 자기 재검토 C4R 의 차이는 Gemini +0.089722, GPT +0.100324 이다. 각각의 95% 구간은 [+0.040757, +0.140516], [+0.036820, +0.163054] 이며, 이번 재현 방식의 8 개 family 조정값도 0.05 보다 작다. 따라서 높은 수용률의 B1 생성조건에서도 외부 학습참조를 포함한 수정의 양의 증분가치가 관찰된다.

High B1 의 C6-E-C6-EX 는 GPT 에서 +0.114629 로 구간 및 조정값이 양의 차이를 뒷받침하지만, Gemini +0.041223 은 구간이 0 을 포함한다. ‘한 모델만 기업별 정보를 활용한 다’는 기제적 결론 대신, 현재 고정 배정과 표본에서 GPT 의 기업-참조 연결 차이가 더 뚜렷하게 관찰되었다고 기술한다. 모델 간 차이 자체의 검정 없이 두 모델의 효과가 통계적으로 다르다고 쓰지 않는다.

자기 재검토의 B1 차이는 Gemini -0.010172, GPT +0.026394 로 작다. 반면 BINF 에서는 Gemini +0.144888, GPT +0.072365 로 양의 차이가 남는다. 따라서 ‘High 에서는 자기 재검토가 필요 없다’는 결론도 행동예산을 넘어 일반화할 수 없다. C5 지시는 High B1 에서 두 모델 모두 양의 점추정이지만 다중비교 후 명확한 추가가치로 확정되지 않는다.

6.4.2 효과의 크기가 정말 달라졌는가

표 6-10. B1 에서 대비효과와 High-Baseline 차이

모델	대비	차이의 차이	95% 구간	Holm p
Gemini	C4R-C4	-0.0079	[-0.0652, +0.0529]	1.0000
Gemini	C5-C4	-0.0504	[-0.1387, +0.0376]	1.0000
Gemini	C6-E-C4R	+0.0677	[+0.0028, +0.1344]	0.3232
Gemini	C6-E-C6-EX	-0.0040	[-0.0827, +0.0772]	1.0000
GPT	C4R-C4	-0.1429	[-0.2052, -0.0842]	0.0016
GPT	C5-C4	-0.1831	[-0.2900, -0.0770]	0.0042
GPT	C6-E-C4R	+0.0628	[-0.0490, +0.1743]	0.9807
GPT	C6-E-C6-EX	-0.0596	[-0.1722, +0.0501]	0.9807

자료: 같은 기업의 네 관련 셀로 계산한 직접 상호작용. 각 모델·Oracle 안에서 네 대비×두 예산의 8 개 추가 비교를 조정하였다. High 에서 유의하다는 사실과 High-Baseline 이 유의하다는 사실은 다르다.

GPT B1 에서 High-Baseline 의 자기 재검토 대비 차이는 -0.142868 이고 C5-C4 의 차이는 -0.183082 이다. 두 값의 구간은 음의 범위이며 조정 후에도 차이가 남는다. High 에서 첫 생성의 수용성과 가치가 높아진 상태에서는 추가 프롬프트 또는 재검토가 제공하던 이득이 작아진 패턴이다. 그러나 이 패턴을 내부 추론의 중복이라는 직접 증거로 단정하지 않는다.

학습참조의 대비는 High B1 에서 양의 차이가 관찰되지만, 그 효과가 Baseline 보다 커졌다는 차이의 차이는 Gemini +0.067707, GPT +0.062797 이고 다중비교 후 확정되지 않는다. 특히 Gemini 의 미조정 구간이 양수라도 8 개 family 의 조정 p 는 0.05 를 넘는다. 따라서 ‘High 가 외부참조의 효과를 통계적으로 강화했다’와 ‘High 에서도 참조가 양의 증분가치를 보였다’를 구분한다.

Regime 비교는 현재 실험의 범위에서만 유효하다. 최대 출력 토큰, 부모 초안의 내용, 생성시점이 함께 바뀌었다는 사실을 감안하면, high 라는 이름 하나를 완전한 처치변수로 볼 수는 없다. 본 연구의 기여는 이 변화를 숨기지 않고 전체 하네스의 조건으로 보고하는 데 있다.

6.5 행동예산, 행동공간과 평가모형

6.5.1 BINF 에서의 비단조성

표 6-11. 정책별 High-Baseline 변화: Strict ITT

모델	예산	정책	평균 $\Delta \alpha$	95% 구간	조정 p
Gemini	B1	C4	+0.6582	[+0.5524, +0.7695]	0.0020
Gemini	B1	C4R	+0.6503	[+0.5476, +0.7520]	0.0020
Gemini	B1	C6-E	+0.7180	[+0.6074, +0.8345]	0.0020
Gemini	BINF	C4	-0.2076	[-0.3074, -0.1101]	0.0020
Gemini	BINF	C4R	-0.2054	[-0.3051, -0.1076]	0.0020
Gemini	BINF	C6-E	-0.1804	[-0.2727, -0.0866]	0.0020
GPT	B1	C4	+0.5205	[+0.4121, +0.6298]	0.0020
GPT	B1	C4R	+0.3777	[+0.2758, +0.4845]	0.0020
GPT	B1	C6-E	+0.4405	[+0.3444, +0.5393]	0.0020

모델	예산	정책	평균 $\Delta \alpha$	95% 구간	조정 p
GPT	BINF	C4	+0.2928	[+0.1879, +0.3967]	0.0020
GPT	BINF	C4R	+0.2286	[+0.1278, +0.3321]	0.0020
GPT	BINF	C6-E	+0.2956	[+0.2003, +0.3950]	0.0020

자료: Main Run1/IC-b의 같은 기업. 이 표는 추가 regime 비교이며 C4R과 C6-E는 각 regime의 자기 C4에서 생성되었다. free8의 다섯 정책×두 예산에 대한 모델별 조정을 사용한다.

B1에서는 두 모델 모두 High의 주요 정책가치가 Baseline보다 높다. 낮은 수용률이 크게 개선된 조건에서 나타난 운영상 이득이다. 그러나 BINF에서는 같은 패턴이 항상 나타나지 않는다. Gemini는 Baseline의 수용률이 이미 높았고, High의 직접생성 및 수정결과가 모든 셀에서 더 높은 α 값을 주지는 않는다. 추론 증가가 제한된 평가모형의 점수를 언제나 단조롭게 올리는 수단은 아니다.

High의 B1-BINF 자기 재검토 차이는 Gemini에서 -0.155060이다. GPT의 학습참조 대비는 BINF에서 더 크지만 그 예산 상호작용의 조정 p는 약 0.0512로 경계에 있다. 이 결과에서 유의수준을 사후에 바꾸거나 반올림으로 0.05 미만처럼 표시하지 않는다. 행동예산의 역할은 점추정과 불확실성을 함께 보고 해석한다.

6.5.2 후보선택과 자유작성 격차의 변화

표 6-12. High B1의 자유작성-후보선택 대비

모델	정책	평균 $\Delta \alpha$	95% 구간	Holm p
Gemini	C4	+0.0111	[-0.0599, +0.0851]	1.0000
Gemini	C4R	+0.0212	[-0.0525, +0.0932]	1.0000
Gemini	C6-E	+0.0739	[-0.0001, +0.1471]	0.1518
GPT	C4	+0.0185	[-0.0454, +0.0801]	1.0000
GPT	C4R	+0.0053	[-0.0506, +0.0608]	1.0000
GPT	C6-E	+0.0963	[+0.0388, +0.1560]	0.0024

자료: Run1/IC-b/B1/Strict ITT. 모델별 세 대비 family. Baseline에서의 큰 음의 격차와 비교하되 모든 정책이 자유작성 우위를 입증한 것으로 해석하지 않는다.

High 에서는 자유작성과 후보선택의 격차가 크게 줄었다. GPT C6-E 의 자유작성-후보선택 차이는 +0.096273 으로 양의 구간과 조정값이 관찰된다. 그러나 C4와 C4R, Gemini 의 세 비교는 같은 방식의 명확한 자유작성 우위로 확정되지 않는다. 따라서 출력공간의 성과는 생성 regime 와 실행규칙에 의존한다는 해석이 적절하다.

이 결과는 자유작성의 넓은 조합능력이 어떤 조건에서는 가치를 가질 수 있으나, 그 전에 제약을 지키는 행동으로 변환되어야 한다는 점을 보여준다. 한편 구형 10 차원 분석의 mean/shuffle/nearest 및 Shapley 결과를 최신 8 차원에서 다시 계산한 증거는 이번 산출물에 포함하지 않았다. 따라서 높은 점수의 원인을 ‘공통 방향이 대부분이고 맞춤효과는 얼마’라고 구형 수치로 확정하지 않는다.

6.5.3 다른 Oracle 에서의 참조 대비

표 6-13. High Strict 의 참조 대비: Oracle 별 방향

모델	예산	대비	α	β	γ
Gemini	B1	C6-E-C4R	+0.0897	+0.0156	+0.0222
Gemini	B1	C6-E-C6-EX	+0.0412	+0.0043	+0.0114
Gemini	BINF	C6-E-C4R	+0.0431	+0.0120	+0.0427
Gemini	BINF	C6-E-C6-EX	+0.0153	-0.0002	+0.0228
GPT	B1	C6-E-C4R	+0.1003	+0.0231	+0.0196
GPT	B1	C6-E-C6-EX	+0.1146	+0.0084	+0.0286
GPT	BINF	C6-E-C4R	+0.2142	+0.0425	+0.0709
GPT	BINF	C6-E-C6-EX	+0.0767	+0.0108	+0.0412

자료: 각 Oracle 에서 독립적으로 계산한 같은 기업의 평균차이. 원점수 단위가 다르므로 열 사이 크기는 직접 비교하지 않는다. 전체 구간과 조정값은 부록 E 에 제공한다.

평가모형을 바꾸면 차이의 크기뿐 아니라 일부 방향과 통계적 판정도 달라질 수 있다. α 의 결과를 중심으로 서술하되 $\beta \cdot \gamma$ 를 동일 단위의 반복측정처럼 합치지 않는다. 같은 행동의 경제적 결과에 대한 직접 관측이 없으므로, 세 Oracle 의 비교는 평가구조 민감도이지 실제 기업성과에 대한 외부 재현실험이 아니다.

6.6 PP 와 부모 응답 게이트의 민감도

6.6.1 Strict 수용 교집합에서의 비교

표 6-14. Baseline B1 의 strict 교집합 PP 대비

모델	대비	PP N	평균 $\Delta \alpha$	95% 구간	Holm p
Gemini	C4R-C4	45	-0.0068	[-0.0205, +0.0000]	1.0000
Gemini	C5-C4	51	+0.0563	[-0.0121, +0.1548]	0.9975
Gemini	C6-E-C4R	44	+0.1405	[+0.0000, +0.3547]	0.9975
Gemini	C6-E-C6-EX	39	+0.1805	[+0.0000, +0.4293]	0.6061
GPT	C4R-C4	246	+0.0000	[+0.0000, +0.0000]	1.0000
GPT	C5-C4	175	+0.1575	[+0.0052, +0.3125]	0.1704
GPT	C6-E-C4R	235	+0.1918	[+0.0764, +0.3216]	0.0070
GPT	C6-E-C6-EX	193	+0.2265	[+0.0659, +0.4004]	0.0330

자료: 각 대비의 두 조건 모두에서 strict usable 인 동일 기업만 사용. 서로 다른 대비의 PP N 은 다르므로 그 평균차이를 임의로 합산하지 않는다. Repaired usable 로 N 을 확대하지 않았다.

Baseline B1 에서 Gemini 의 PP N 은 대비에 따라 39~51 개로 매우 작다. 전체 575 개의 평균과 이 집합의 평균은 같은 질문에 답하지 않는다. GPT 의 C4R-C4 는 246 개 공통 수용기업에서 α 차이가 모두 0 이었다. 이 결과와 전체 ITT +0.010520 를 함께 보면, 실제 실행에서 자기 재검토의 평균상 이득이 정상 초안의 점수변화만으로 만들어진 것이 아님을 알 수 있다.

GPT 의 다른 PP 대비는 양의 차이를 보이기도 하지만, PP 의 선택과 표본 크기를 고려해야 한다. 수용률이 다른 정책에서 서로 다른 기업을 남겨 계산한 값을 비교해 ‘순수한 판단능력’을 추정했다고 부르지 않는다. 원래 strict usable 의 점수가 Repair 로 바뀌지 않았기 때문에 같은 strict 교집합을 적용한 repaired PP 는 새로운 표본이나 별개의 복구성과가 아니다.

6.6.2 계획서와 pre-live 분기명세의 차이

부모 C4 가 불용이어도 후속 원문이 생성된 사례는 실제 실행자료에서 확인된다. Baseline 의 전체 후속 요청 13,800 건 가운데 strict unusable C4 에서 시작한 후속 요청은 4,839 건이며,

그중 1,413 건은 후속 행동이 strict usable 이었다. 이는 단순히 ‘최종 응답의 parser 만 엄격했다’는 설명으로는 드러나지 않는 호출 구조의 특성이다.

여기에는 실행 전 문서증거가 존재한다. pre-live prompt_contract 는 비어 있지 않은 원문을 후속 초안으로 사용할 수 있다고 명시하고, 해당 파일은 live 이전 패키지의 해시에 연결된다. 따라서 이 현상을 실행 후 성과를 높이기 위해 새로 만든 규칙으로 단정할 수 없다. 문제는 usable-parent 생략 규칙이 적힌 계획서와 raw-draft 규칙이 적힌 실행명세의 불일치 및 공식 우선순위 기록의 미완결이다.

본 논문은 실제 생성된 후속 응답을 삭제하지 않는다. 실제 raw-draft 정책을 평가하고, 계획서 게이트의 영향을 보기 위해 불용 부모의 후속 결과만 A0 로 치환하는 별도 오프라인 분석을 제시한다. C5 는 부모가 없는 첫 생성이므로 이 게이트의 직접 대상이 아니다.

표 6-15. B1 의 부모 수용 게이트 민감도

Regime	모델	대비	실제 실행	게이트 적용	부모 불용 N
Baseline	Gemini	C4R-C4	-0.0023	-0.0615	487
Baseline	Gemini	C6-E-C4R	+0.0220	+0.0204	487
Baseline	Gemini	C6-E-C6-EX	+0.0452	+0.0386	487
Baseline	GPT	C4R-C4	+0.1693	-0.0018	320
Baseline	GPT	C6-E-C4R	+0.0375	+0.0209	320
Baseline	GPT	C6-E-C6-EX	+0.1742	+0.1016	320
High	Gemini	C4R-C4	-0.0102	-0.0102	5
High	Gemini	C6-E-C4R	+0.0897	+0.0823	5
High	Gemini	C6-E-C6-EX	+0.0412	+0.0503	5
High	GPT	C4R-C4	+0.0264	+0.0024	15
High	GPT	C6-E-C4R	+0.1003	+0.1003	15
High	GPT	C6-E-C6-EX	+0.1146	+0.1059	15

자료: 저장된 부모-자식 요청기와 A0 평가값. N=575. 게이트 적용은 불용 부모의 후속결과를 A0 로 바꾼 오프라인 민감도이며 원응답·실제 요청 이력은 보존하였다.

GPT Baseline B1의 C4R-C4는 실제 실행 +0.010520에서 게이트 적용 -0.001830으로 바뀐다. BINF에서도 +0.136642가 -0.001594로 작아진다. 이 민감도는 자기 재검토의 이득을 해석할 때 불용 초안을 다시 읽을 기회가 있었는지 반드시 밝혀야 함을 보여준다. 작은 음의 값 자체를 중요한 경제적 손실이라고 과장하지 않는다.

High B1의 학습참조 대비는 이 게이트에서 Gemini +0.082291, GPT +0.100324로 양의 차이를 유지한다. High의 불용 부모가 각각 5개와 15개로 적기 때문에, B1 참조 대비의 주된 패턴이 Baseline 자기 재검토처럼 크게 바뀌지는 않는다. 다만 이 분석은 호출을 실제로 생략한 새로운 운영실험이 아니며, 비용절감이나 다른 응답의 생성 변화까지 관찰한 것은 아니다.

부모 게이트와 Repair는 서로 다른 민감도이다. 게이트는 후속 호출 대상의 정의를 바꾸고, Repair는 이미 생성된 결과의 실행규칙을 바꾼다. 둘 다 baseline 자기 재검토 해석에 영향을 주지만 같은 기제를 측정했다고 합쳐서는 안 된다.

6.7 평균, 기업별 효과와 행동의 반복성

6.7.1 절대점수와 증분가치의 구분

같은 기업의 절대 신용평점은 두 실행에서 매우 높은 상관을 보일 수 있다. 기업의 규모, 부채구조 및 기초 신용상태가 반복되기 때문이다. 이 상관을 LLM이 같은 행동을 골랐다는 증거로 제시하면 정책생성의 안정성을 과대평가한다. 본 연구는 A0 대비 정책가치와 수정조건의 증분효과를 별도로 비교한다.

High B1에서 기업별 A0 대비 가치의 Run1-Run2 순위상관은 C4·C4R·C6-E에 걸쳐 Gemini 약 0.796~0.817, GPT 약 0.807~0.879이다. 그러나 학습참조의 추가효과가 큰 기업의 순서는 훨씬 덜 안정적이다. 같은 기업에서 재검토와 참조조건을 뺀 차이는 절대점수보다 잡음과 경계효과에 민감한 지표이다.

표 6-16. 학습참조 증분효과 C6-E-C4R의 반복성

Regime	모델	예산	Run1 평균	Run2 평균	증분효과 ρ
Baseline	Gemini	B1	+0.0220	-0.0020	0.270
Baseline	Gemini	BINF	+0.0180	+0.0586	0.286
Baseline	GPT	B1	+0.0375	+0.0566	0.198

Regime	모델	예산	Run1 평균	Run2 평균	증분효과 ρ
Baseline	GPT	BINF	+0.1472	+0.1111	0.216
High	Gemini	B1	+0.0897	+0.0653	0.064
High	Gemini	BINF	+0.0431	-0.0022	0.059
High	GPT	B1	+0.1003	+0.0978	0.210
High	GPT	BINF	+0.2142	+0.1889	0.294

자료: 각 Run의 자기 C4에서 분기한 결과를 같은 575개 기업으로 연결. ρ 는 절대 Oracle 점수가 아니라 기업별 C6-E-C4R의 Spearman 상관이다.

High B1의 학습참조 평균효과는 Gemini에서 +0.089722와 +0.065302, GPT에서 +0.100324와 +0.097807이다. 평균의 양의 방향은 반복되지만 기업별 증분효과 순위상관은 각각 약 0.064와 0.210이다. 따라서 집단 평균에서 도움이 된다는 사실과 어떤 기업이 더 도움을 받는지 안정적으로 예측할 수 있다는 주장은 다르다.

Gemini BINF의 참조 평균은 +0.043085에서 -0.002234로 바뀌고 증분효과 순위상관도 약 0.059이다. GPT BINF는 +0.214199와 +0.188950, 순위상관 약 0.294이다. 작은 순효과가 부호를 바꾼 경우와 비교적 큰 양의 평균이 반복된 경우를 모두 남겨 조건별 차이를 보여준다. Run2를 더 좋은 값만 선택하는 용도로 사용하지 않는다.

6.7.2 실제 행동벡터의 반복성

표 6-17. High 자유작성의 실제 8차원 행동 반복성

모델	예산	정책	공통 수용 N	벡터 일치율	평균 거리
Gemini	B1	C4	561	7.5%	0.553
Gemini	B1	C4R	559	6.3%	0.525
Gemini	B1	C6-E	554	11.2%	0.477
Gemini	BINF	C4	575	9.2%	0.787
Gemini	BINF	C4R	575	8.2%	0.831
Gemini	BINF	C6-E	575	6.8%	0.706
GPT	B1	C4	543	48.6%	0.438

모델	예산	정책	공통 수용 N	벡터 일치율	평균 거리
GPT	B1	C4R	560	48.8%	0.436
GPT	B1	C6-E	556	57.6%	0.356
GPT	BINF	C4	565	27.1%	0.537
GPT	BINF	C4R	574	30.8%	0.542
GPT	BINF	C6-E	561	47.1%	0.411

자료: 두 Run 모두 strict usable 인 기업의 raw action vector. 벡터 일치는 각 축 절대오차 $\leq 10^{-9}$, 거리 = $\sum |a_{Run1} - a_{Run2}| / s_j$ 이다. free8 의 결측 candidate_id 일치를 행동일치로 세지 않았다.

High B1 에서 실제 행동벡터의 일치율은 Gemini C4 7.5%, C4R 6.3%, C6-E 11.2%인 반면 GPT 는 각각 48.6%, 48.8%, 57.6%이다. 높은 수용률과 비슷한 평균가치가 반드시 같은 기업에 같은 수치행동을 생성한다는 뜻은 아니다. 활성 차원집합이 같더라도 강도가 다를 수 있으므로 벡터 일치와 차원집합 일치도 구분한다.

이 비교 역시 정상응답 교집합에 조건부이다. 불용 응답을 모두 0 으로 바꾼 뒤 두 0 이 같다는 이유로 안정성이 높다고 계산하지 않았다. 또한 소수점 값의 정확일치는 엄격한 지표이므로 작은 수치차이까지 다른 행동으로 분류할 수 있다. 따라서 일치율과 함께 연속적인 정규화 거리를 제공한다.

두 번의 반복은 제한적인 반복성 진단이다. 장기간의 모델 업데이트나 프롬프트 수정, 새로운 기업으로 확장한 안정성을 입증하지 않는다. 본 연구에서는 평균적 정책평가와 개별 권고의 반복성을 별도의 검증단계로 두어야 한다는 근거로 사용한다.

6.8 API 비용과 운영적 비용효율

6.8.1 대시보드 귀속가정

비용분석은 이번 실행에서 확인한 대시보드 지출을 다음과 같이 귀속한다는 가정에 따른다. OpenAI 총액 \$128.85 중 Baseline \$19.57, High \$109.28 로 나누고, Gemini 는 먼저 보인 약 ₩12,900 을 Baseline, 누적 ₩54,730 에서 이를 뺀 약 ₩41,830 을 High 로 둔다. Gemini 의 posting delay 때문에 화면상 금액이 서로 다른 시점에 반영되었다는 사용자 제공 가정을 명시적으로 사용한 것이다.

이 값은 요청별 완결된 청구명세와 모두 대사한 확정 회계원장이 아니다. 다른 기간·호출이 포함되어 있을 가능성, 세금과 표시단위의 반올림 및 지연 반응을 고려해야 한다. 공급자별 원통화를 유지하고 임의의 환율로 합계나 직접 가격비율을 만들지 않았다.

표 6-18. 가정에 따른 공급자·regime 별 지출과 단가

모델	Regime	총 귀속비용	요청 수	요청당 비용	수용행동당 비용
Gemini	Baseline	₩12,900	12,075	₩1.0683	₩1.7771
Gemini	High	₩41,830	12,075	₩3.4642	₩3.4870
GPT	Baseline	\$19.57	12,075	\$0.001621	\$0.002233
GPT	High	\$109.28	12,075	\$0.009050	\$0.009180

자료: 사용자 제공 대시보드 귀속가정과 최종 canonical strict usable 수. 분모는 Main 과 Stability 를 포함한 모델·regime 별 전체 요청이다. 수용행동당 단가는 전체 응답 schema 적합 또는 최종 2 단계 권고 단가와 다르다.

동일한 요청 수를 기준으로 High 의 평균 요청단가는 GPT 에서 Baseline 의 약 5.58 배, Gemini 에서 약 3.24 배이다. GPT 는 요청당 약 \$0.001621 에서 \$0.009050 으로, Gemini 는 약 ₩1.0683 에서 ₩3.4642 로 증가한다. 이는 공급자 안의 regime 비용비교이며 서로 다른 통화의 공급자 간 직접 단가비율이 아니다.

Strict 수용행동당 비용은 GPT Baseline 약 \$0.002233, High 약 \$0.009180 이며 Gemini 는 약 ₩1.7771 와 ₩3.4870 이다. High 에서는 비용이 늘지만 불용 응답도 줄어드므로 요청당 비용배수와 수용행동당 비용배수는 다르다. 같은 평균 API 단가로 더 많은 usable 행동을 얻었다는 사실과, 더 높은 정책가치를 얻었다는 사실도 별도로 보아야 한다.

6.8.2 요청 한 건과 최종 권고 하나의 비용

C4 는 한 번의 생성으로 직접 권고를 만든다. C4R 또는 C6-E 를 처음부터 독립적으로 만들려면 C4 초안과 두 번째 응답이 모두 필요하다. 따라서 최종 권고비용은 부모 초안 생성비와 해당 후속 호출비의 합이다. 실험에서는 같은 C4 를 여러 branch 에서 공유하므로 셀별 비용을 정확히 배분하려면 부모 비용을 어떤 기준으로 나눌지 정해야 한다.

$$\text{Cost}(\text{final C6-E}) = \text{Cost}(\text{parent C4}) + \text{Cost}(\text{C6-E call})$$

전체 평균 요청단가만으로는 각 정책의 input 길이, 재검토 초안의 토큰 수 및 reasoning output 이 얼마나 달랐는지 알 수 없다. 모든 호출의 단가가 같다고 단순 가정하면 두 요청의

비용이 필요하다는 근사만 가능하며, 이를 실제 C6-E 청구단가로 보고하지 않는다. 이번 표의 행동당 비용은 처리된 요청 한 건에서 나온 수용행동의 비용이다.

Repaired 는 저장된 응답에 적용하므로 추가 API 생성비는 0 이다. 그렇다고 구현·검증·컴퓨팅·사람의 감사비용까지 0 이라는 뜻은 아니다. 금융업무에 도입할 때에는 잘못된 수리와 검토시간 및 운영리스크를 포함해야 한다. 본 실험에서는 실제 금융편익이나 심사역의 시간절감이 관측되지 않았으므로 경제적 ROI 를 계산하지 않는다.

6.8.3 토큰당 비용을 해석하는 한계

OpenAI 화면에는 두 regime 합계 요청 24,150 건과 약 98,577,154 개의 표시 입력토큰이 제시되어 있다. 총 지출을 이 표시 토큰으로 나누면 약 \$1.3071/백만 표시 입력토큰이라는 혼합 지출밀도가 나온다. 하지만 총액에는 출력 및 추론 관련 과금이 포함될 수 있으므로 이것은 입력토큰의 공시단가가 아니다. Baseline 과 High 의 입력·출력·추론·캐시 토큰을 분리한 완결 usage ledger 가 없으면 실제 종류별 토큰단가를 역산할 수 없다.

Gemini 는 같은 범위의 완전한 토큰 분해자료가 이 비용분석에 확보되지 않았다. 따라서 지출에서 추론 토큰 수를 역산해 실제 관측한 thinking token 처럼 표기하지 않는다. 논문이 직접 보고할 수 있는 것은 대시보드 귀속가정 아래의 전체 지출과 요청당·수용행동당 비용, 그리고 실제 관찰된 정책가치와 수용률의 차이이다.

6.9 소결

High 생성조건에서는 B1 행동 수용률이 크게 개선되었고, 같은 B1 에서 학습참조를 포함한 C6-E 의 자기 재검토 대비 양의 증분가치가 관찰되었다. 그러나 High 가 모든 BINF 점수를 높이지는 않았으며, 참조효과가 High 에서 유의하다는 사실이 Baseline 보다 효과가 유의하게 커졌음을 자동으로 의미하지는 않는다.

동일한 원응답에 Repaired 실행규칙을 적용하거나 부모 수용 게이트를 가정하면 Baseline 자기 재검토의 해석이 크게 달라진다. 따라서 관측된 평균차이는 모델의 경제적 판단만이 아니라 불용 초안의 처리와 후속 기회 및 실행규칙에 의존한다. 이는 정책 하네스 전체를 평가단위로 두어야 한다는 실증적 근거이다.

평균가치, 기업별 증분효과와 행동의 반복성은 다르며 비용도 regime 에 따라 변한다. 실무에서는 생성·검증·실행 조합을 사용목적과 함께 명시해야 한다.

제 7 장 종합 논의와 결론

7.1 연구결과의 요약

본 연구는 LLM 이 생성한 기업 신용등급 개선권고의 실제 효과를 직접 관찰하기 어려운 상황에서, 어떤 평가기반과 생성·실행 조건 아래에서 권고를 비교할 수 있는지를 검토하였다. 평가 하네스와 정책 하네스를 구분하고, 평가기반의 증거 범위를 먼저 정한 뒤 동일한 기업과 행동 의미론에서 정책을 비교하는 검증 우선 접근을 유지하였다.

평가기반에서는 개발 단계의 Oracle 정렬성과 Simulator 재현·편향 기록, 최신 의미론 fixture 및 동결된 9 후보 payoff 를 서로 다른 증거로 나누었다. 회계적 일관성과 제한적인 실제 등급 정렬성이 존재하더라도, 권고를 실제 실행하면 같은 효과가 발생한다는 결론은 얻을 수 없다. 같은 기업의 A0 대비 차이는 공통 수준오차를 줄이는 데 유용하지만 행동에 따라 달라지는 오차까지 자동으로 없애지는 않는다.

학습 참조정책 C3-E 는 네 configuration 과 일곱 matched seed 의 28 개 actor 를 확률평균으로 결합하였다. α 에서 평균 절대점수 55.959960, A0 대비 +0.923299, OE 대비 +0.157936 을 기록하였다. 그러나 평가모형에 따라 상대가치가 달라지고 개별 손실 사례도 존재한다. 개별 actor 의 학습목표와 달리 최종 정책 선택은 2024 년의 반복적인 개발·평가와 연결되므로, 선택과정까지 완전히 독립적인 검증정책이라고 주장하지 않았다.

Baseline B1 에서는 자유작성의 낮은 행동 수용률이 중요한 운영결과였다. C4 수용률은 Gemini 15.3%, GPT 44.3%였으며, 같은 B1 에서 후보선택보다 Strict ITT 가치가 낮았다. 진단 지시 C5 는 이 Baseline B1 에서 양의 효과를 보였지만, 자기 재검토와 학습참조의 증분효과는 모델과 예산에 따라 달랐다. 따라서 구형 원고의 ‘추론 지시는 항상 해롭다’ 또는 ‘자유작성은 항상 우월하다’는 포괄 결론을 유지하지 않았다.

High 에서는 B1 C4 수용률이 Gemini 99.1%, GPT 97.4%로 높아졌다. High B1 의 C6-E-C4R 은 각각 +0.0897 과 +0.1003 으로 양의 증분가치가 관찰되었다. 그러나 High 가 BINP 의 점수를 항상 높이지 않았고, High 의 참조효과가 유의하다는 사실만으로 Baseline 보다 효과가 유의하게 커졌다고 결론내릴 수 없었다. C5 프롬프트 유도과 API 추론설정도 다른 변수로 남겼다.

결정론적 Repair 또는 부모 수용 게이트를 적용한 민감도에서는 Baseline 자기 재검토의 해석이 크게 달라졌다. GPT B1의 Strict C4R-C4는 +0.1693이지만 Repaired에서는 +0.0047이었다. 이는 자기 재검토의 관측상 이득에 형식·행동제약 위반과 후속 기회 및 실행규칙이 관여함을 보여준다. 다만 이러한 비교는 모델의 숨겨진 의도를 완전하게 복원하거나 내부 판단기제를 인과적으로 분해한 결과가 아니다.

마지막으로 평균 정책가치, 기업별 가치의 순서, 수정의 증분효과 및 구체적인 행동은 서로 다른 정도로 반복되었다. High B1의 학습참조 평균효과는 두 Run에서 양수였지만 기업별 증분효과의 순위상관은 낮았고, 행동벡터도 항상 같지 않았다. 비용은 High에서 증가했으나 수용률과 가치의 변화는 단순 비용배수와 같지 않았다. 따라서 정책의 실용성은 평균점수 하나가 아니라 유효성, 효과, 반복성과 비용을 함께 평가해야 한다.

7.2 연구질문과 가설의 회수

연구질문은 원래의 다섯 축을 유지한다. 다만 구형 실행의 가설 판정을 그대로 최신 실험에 옮기지 않고, 실제 실행한 대비와 결과의 범위에 맞추어 회수한다. H1의 프롬프트 추론 유도와 High regime의 추가 계산실험은 같은 가설이 아니며, High-Repaired의 결과는 별도 추가 분석으로 보고한다.

표 7-1. 연구질문·가설별 증거와 결론의 범위

질문·가설	이번 결과의 회수	해석의 제한
RQ1 평가기반	개발 검증기록과 현재 의미론·후보평가를 분리하여 제시	현실적 실행효과 및 모든 V4.3 변경 후의 실증 재검증까지 입증하지 않음
RQ2 행동가치·순위	C3-E α 의 OE 대비 +0.1579; 같은 표면의 최신 비교정책 복원	선택된 정책의 기술통계; 모든 Oracle·기업에서 우월하지 않음
RQ3-H1 진단 유도	Baseline B1 C5-C4는 두 모델에서 양수; BINF 및 High에서는 다름	조건부 지지이며 언제나 유익하거나 해롭다는 결론 아님
RQ3-H2 행동 변화	생성 regime와 예산에 따라 수용률·강도·활성 차원 차이 확인	구형 nearest-candidate 거리 결과를 최신 정량 근거로 재사용하지 않음
RQ3-H3 참조 연결	GPT B1에서 C6-E-C6-EX의 양의 차이; Gemini는 불확실	균등 무작위 후보가 아닌 고정 derangement 대조; 모델 간 차이의 직접 검정과 구분

질문·가설	이번 결과의 회수	해석의 제한
RQ4-H4-a Oracle	동물·최적행동·참조 대비가 평가자에 따라 달라짐	원점수 통합 금지; 보편적 순위 강건성 주장 불가
RQ4-H4-b 행동공간	Baseline B1 free8 은 candidate9 보다 낮음; High 에서 격차 축소	자유작성의 무조건적 우위는 지지되지 않음
RQ5-H5 정보조건	C4/free8/B1 의 코드·기업명 추가효과는 명확하지 않음	정보가 무가치하거나 사전학습 개입이 없다는 증명 아님

자료: 제 4-6 장의 최종 계약 및 Run1 결과. H1-H5 의 문제의식과 추가 regime 분석의 시간적 지위를 구분하였다.

RQ1 은 단순한 통과·실패 판정으로 끝나지 않는다. 평가체계가 어떤 사실을 검증했고 어떤 사실을 검증하지 못했는지를 범위로 정리하는 것이 답이다. RQ2 역시 가장 높은 하나의 숫자만을 고르는 문제가 아니라, 같은 행동집합과 평가자에서 비교정책의 역할을 명확히 하는 문제이다.

RQ3 에서 확인된 중요한 점은 자기 재검토, 진단 지시, 참조의 존재와 기업별 연결이 서로 다른 비교라는 것이다. C6-E-C4 를 모두 외부참조의 효과라고 부를 수 없고 C5 와 API High 를 같은 추론 조건으로 부를 수도 없다. RQ4 와 RQ5 는 이 결과가 행동예산과 출력공간, 평가자 및 제한된 정보표현에 조건부임을 보여준다. 이처럼 연구질문의 범위를 명확히 하는 것이 결과를 과장하지 않으면서 의미를 남기는 방법이다.

7.3 학술적 기여

첫째, 권고의 생성능력과 평가기반의 측정범위를 함께 검토하는 절차를 제시하였다. 기존의 신용상태 예측력만으로 관리행동 비교의 타당성을 가정하지 않고, 실제 등급 정렬, 회계적 전파, 수준오차 및 행동별 점수 구별력을 나누었다. 현실의 권고 실행결과가 없는 상황에서 관측된 정책가치가 어떤 가정과 평가함수에 종속되는지를 공개한 점에 의미가 있다.

둘째, 정책 하네스를 모델명 이상의 평가단위로 구체화하였다. 같은 모델에서도 API 추론설정, 진단 프롬프트, 초안의 후속 검토, 참조 배정 및 행동예산이 달라지면 다른 출력과 수용률 및 정책가치가 나타났다. 특히 proposed·accepted·ITT·realized 를 구분함으로써 자연어 응답이 경제적 행동으로 전환되는 경로를 평가대상에 포함하였다.

셋째, 원응답의 유효성과 실행규칙이 수정효과의 해석에 관여함을 실제 자료로 보여주었다. Baseline 자기 재검토의 큰 ITT 차이가 Repair와 부모 게이트에서 작아지는 현상은, 출력검증을 단순한 전처리로 숨겨서는 안 된다는 근거이다. 이러한 효과를 모델의 순수한 판단능력으로 자동 귀속하지 않고 별도의 실행정책 민감도로 분리하였다.

넷째, 평균적인 성과와 개별 권고의 반복성을 다른 수준의 검증으로 다루었다. 기업의 절대 신용평점이 잘 반복된다는 사실과 학습참조의 증분효과가 큰 기업을 안정적으로 식별한다는 사실은 다르다. 실제 자유작성 벡터를 연결하여 결측 후보 ID의 가짜 일치가 아니라 수치행동 자체의 반복성을 측정한 점도 이 구분을 뒷받침한다.

이 기여는 새로운 최적화 알고리즘의 보편적 우월성이나 실제 신용등급 개선의 인과적 입증에 있지 않다. 오히려 동일한 연구자료에서도 평가·생성·실행·분석의 정의에 따라 결론이 달라질 수 있음을 구체적인 산출물과 비교절차로 보여준 데 있다.

7.4 결과의 이론적 해석

7.4.1 추론과 재검토는 같은 개입이 아니다

프롬프트로 진단을 유도하는 C5는 첫 번째 응답의 작성방식을 바꾼다. 자기 재검토 C4R은 이미 생성한 구체적인 초안을 다시 읽는 기회를 준다. API High는 공급자 안의 추론 regime와 관련된 생성조건을 바꾼다. 이 셋을 모두 ‘더 많이 생각함’이라는 하나의 설명으로 묶으면 각각의 처리 경로와 증거를 잃는다.

High B1에서 C5와 자기 재검토의 추가 평균차이가 작아지는 패턴은 최초 생성의 유효성이 높아졌다는 결과와 함께 해석할 수 있다. 하지만 출력의 유효성이 좋아진 이유가 어떤 내부 탐색이나 계산 때문인지 직접 측정하지 않았으므로, 특정 심리적 또는 추론 기제가 확인되었다고 주장하지 않는다. 본 연구의 확실한 관측은 설정과 출력 및 정책가치의 관계이다.

7.4.2 참조의 평균품질과 참조를 쓰는 가치

C3-E가 OE보다 높은 α 평균을 가진다는 사실과, C3-E를 보여주면 LLM의 점수가 반드시 높아진다는 사실은 다르다. 참조는 기존 초안과 만나는 정보이며, 제한된 행동예산 안에서는 유리한 새 행동을 넣기 위해 다른 행동을 줄여야 할 수 있다. 또한 LLM은 참조를 그대로 따르거나 일부만 반영하거나 거절할 수 있다.

따라서 참조의 가치는 참조정책 자체, 기업별 연결, 최초 초안, 생성 regime 와 실행규칙의 결합에서 관찰된다. High B1 의 양의 C6-E-C4R 은 이 결합의 유용성을 보여주는 제한적 증거이며, 모든 기업에서 참조를 채택하는 것이 최적이라는 결론이 아니다. 정답 정책이나 사후 Oracle 최고값을 제공했다고 설명하지 않는 것도 같은 이유이다.

7.4.3 실패 처리도 정책의 일부이다

자연어 모델의 응답을 실제 행동으로 바꾸는 시스템에서는 오류를 어떻게 처리하는지가 최종 성과를 바꾼다. 같은 원문을 A0 로 처리하는 Strict 와 규칙적으로 수리하는 Repaired 는 다른 실행정책이다. 평균점수의 차이를 오로지 모델의 금융지식으로 돌리면 이 부분이 사라진다.

검증규칙을 엄격하게 하는 것은 오류를 숨기지 않는 장점이 있지만 사용할 수 있었던 일부 행동도 배제할 수 있다. 수리규칙은 더 많은 응답을 활용할 수 있지만 선택·축소·추출의 임의성을 새로 도입할 수 있다. 두 규칙 중 어느 것이 항상 옳다고 정하기보다, 실제로 구현한 규칙과 변경된 행동 및 실패비용을 공개하고 목적에 맞게 평가해야 한다.

7.5 실무적·감독적 시사점

7.5.1 검토·변경관리의 단위

실무의 검토대상은 파운데이션 모델만이 아니라 그 모델이 권고를 만들어 실제 행동값으로 확정하는 전체 구성이다. 같은 모델 ID 를 유지해도 추론설정, 최대 출력 토큰, 정보표현, prompt, 참조정책 및 배정, action schema, parser 와 fallback 또는 Repair 가 달라지면 다른 정책 시스템이 될 수 있다.

변경관리에서는 어느 요소가 바뀌었는지와 그 변경이 수용률·정책가치·기업별 손실 및 반복성에 미치는 영향을 함께 확인해야 한다. 모델의 일반 벤치마크가 높다는 사실만으로 특정 여신 또는 기업 신용개선 작업의 실행 신뢰성이 확보되었다고 볼 수 없다. 반대로 한 구성의 높은 오류율을 모델 전체의 영구적인 한계로 단정하지 않는다.

표 7-2. 정책 하네스의 변경요소와 필요한 검증

변경요소	먼저 확인할 자료	함께 비교할 결과
모델·추론·출력상한	정확한 모델 ID, 요청 manifest, usage	행동 수용률, 정책가치, 비용
정보·프롬프트	실제 렌더링 필드, 시점, 부모 원문	결측·정보누출, 행동분포, 정보조건 효과
참조정책·배정	C3-E hash, donor mapping, 표시내용	참조 대비, 기업별 손실, 배정 민감도
행동·검증·실행규칙	bounds·scale·mutex, raw/accepted/ITT 연결	Strict/Repaired 차이, 수리사례, 실현효과
평가기반	Oracle·Simulator 버전과 검증범위	행동별 동물, 평가자 민감도, 현실 타당성

본 연구의 관측 결과에 근거한 운영적 제안이다. 특정 규제기관의 법적 승인요건을 대신하는 표는 아니다.

7.5.2 집단 정책평가와 개별 기업 검토

정형화된 후보 가운데 하나를 고르는 방식은 출력검증과 일관된 적용이 상대적으로 쉽다. 자유작성은 더 다양한 조합을 제안할 수 있지만 행동제약과 수용률을 함께 확인해야 한다. High 나 Repair 가 사용 가능한 행동을 늘렸더라도 최종 권고를 사람의 검토 없이 자동으로 확정할 근거가 되지는 않는다.

개별 기업에서는 산업환경, 고객·공급업체 관계, 시장상황, 사업계획, 차입약정, 자금조달 여건 및 실행기간을 검토해야 한다. 같은 채고 감축이나 매출채권 회수 권고라도 안정적인 수요가 있는 기업과 공급망 충격을 겪는 기업에서 실행비용과 위험이 다르다. 회계항등식을 지켰다고 사업상 실행가능성까지 확보되는 것은 아니다.

집단 수준에서는 평균 정책가치와 손실 분포 및 반복성을 비교하고, 개별 기업 수준에서는 구체적인 제안행동과 근거 및 실현조건을 확인한다. 본 연구의 증거 범위에서 LLM은 최종 처방을 자동 확정하는 체계라기보다 분석가가 검토할 행동조합을 생성하는 도구로 보는 것이 타당하다. 결과를 설명할 때에는 어떤 조건이 최초 초안과 최종 행동을 만들었는지를 추적할 수 있어야 한다.

7.6 연구의 한계

첫째, 실제 기업이 권고를 실행한 뒤 재무상태와 외부등급이 어떻게 바뀌었는지 관찰하지 못하였다. Simulator 와 Oracle 의 점수차이는 대리 평가이다. 금리·조달·거래관계·경영진의 의사결정 및 외생 충격이 현실에서 미치는 영향을 충분히 반영하지 못하므로, 관측한 α 차이를 실제 등급 상승이나 금전적 편익으로 바꿔 읽을 수 없다.

둘째, 평가표면을 반복적으로 검토하여 최종 C3-E 를 선택하였다. 따라서 2024 년 575 개 기업은 untouched holdout 이 아니다. 기업 bootstrap 은 선택된 정책의 표본평균 불확실성을 요약하지만 encoder·configuration 탐색의 불확실성까지 포함하지 않는다. LLM 과의 상대성결과를 외부 기업과 미래 시점의 일반적 우월성으로 확대하지 않는다.

셋째, 개발 검증자료와 최종 실행코드의 대응이 완전히 닫히지 않았다. 개발 단계 분석기록의 Oracle·Simulator 실증검증은 보존하였으나, 모든 V4.3 의미론 변경 후에 같은 검증을 재수행했다는 증거는 분리되어야 한다. 최종 패키지에 기록된 5 개 current-source hash drift 도 실제 결과 생성코드와 현재 파일의 동일성에 한계를 남긴다. 본 분석의 재집계 재현과 과거 전 실행의 완전재현을 혼동하지 않는다.

넷째, 계획서와 pre-live prompt 명세의 부모 응답 게이트가 다르다. raw-draft 규칙이 실행 전에 존재했다는 증거는 있지만 정식 우선순위·개정 기록이 완결되어 있지 않다. 실제 결과를 보존하고 게이트 민감도를 추가하였으나, 이를 통해 문서관리의 불일치 자체가 없어진 것은 아니다.

다섯째, High 와 Repair 는 Baseline 결과를 본 뒤 추가한 분석이다. High 의 출력 토큰 상한과 부모 초안도 바뀌었으므로 순수한 추론 설정 하나의 처치효과가 아니다. Repair 도 원래 의도의 완전한 복원이 아니라 추가 실행규칙이다. PP 는 strict 수용조건에 따라 선택된 기업집합이므로 무조건부 판단능력을 나타내지 않는다.

여섯째, 통계분석은 저장된 대응차이의 bootstrap 과 정해진 family 조정을 사용하였다. 본문의 sign-tail 통계량은 정확한 무작위배정 p 값과 같지 않으며, 미조정 구간은 동시 구간이 아니다. 한 번의 참조 derangement 와 두 번의 반복실행, 두 모델 및 제한된 정보표현은 배정·시간·모델의 모든 불확실성을 포괄하지 못한다.

일곱째, API 비용은 대시보드의 잠정 귀속가정에 따른다. 요청별 완전한 token usage 와 청구명세, 사람의 검토비용 및 실제 금융편익을 모두 관찰한 것이 아니다. 따라서 비용효율 표는

이번 실행의 운영지표로 제한되며 투자수익률이나 공급자별 보편적 가성비 순위를 입증하지 않는다.

7.7 향후 연구

후속 연구의 첫 단계는 새 생성실험을 늘리기보다 현재 평가기반과 실행기록의 증거 연결을 닫는 일이다. 생성 당시 코드 스냅샷을 최종 계약과 대조하고, V4.3의 상환·차환·CAPEX 의미론에 따라 Simulator의 과거 재현 및 조달계약 민감도를 다시 확인해야 한다.

새로운 평가연도나 독립 기업집합에서는 고정된 C3-E와 LLM 하네스를 변경하지 않고 비교해야 한다. 기업명과 산업정보의 시점을 실제 평가시점에 맞추고, 코드형 산업정보와 설명형 산업정보의 효과도 구분할 수 있다.

생성 유효성과 판단효과를 분리하려면 구조화 출력, 결정론적 수리규칙 및 부모 게이트를 사전에 명시하여 비교할 필요가 있다. 유리한 결과만 선택하지 않고 수리된 행동의 크기와 의미 및 실패사례를 공개해야 한다. 추론설정과 출력상한을 분리한 비교도 현재 regime 분석의 해석을 보완한다.

실제 심사역과 기업 실무자의 판단을 연결하는 것도 필요하다. 재무적 일관성과 높은 대리점수만으로 권고의 실행가치를 알 수는 없다. 산업·자금조달·계약·실행기간에 대한 사람의 평가와 장기 실행자료를 통해 평가환경과 현실 사이의 두 번째 간극을 줄여야 한다.

7.8 결론

LLM의 기업 신용등급 개선권고를 평가한다는 것은 가장 높은 평균점수의 모델명을 찾는 일만이 아니다. 어떤 자료와 행동공간에서 권고가 생성되고, 어떤 오류가 수용 또는 배제되며, 어떤 실행규칙과 평가모형을 통해 가치로 변환되는지를 검증하는 일이다.

Baseline의 낮은 유효성, High에서의 개선, Repair와 부모 게이트의 민감도 및 제한적인 기업별 반복성은 정책 하네스 전체를 평가해야 함을 보여준다. 다만 선택된 2024년 평가표면과 Oracle-Simulator 안의 결과는 실제 신용등급 상승이나 기업별 최적 권고의 증거가 아니다. 본 연구가 제시하는 것은 자동 처방의 보장이 아니라, 분석가가 검토할 권고를 어떤 조건에서 생성하고 어떤 증거로 비교해야 하는지에 관한 검증 프레임워크이다.

참고문헌

- Altman, E. I. (1968). Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. *Journal of Finance*, 23(4), 589–609. <https://doi.org/10.1111/j.1540-6261.1968.tb00843.x>
- Basel Committee on Banking Supervision. (2022). CRE36: IRB approach: minimum requirements to use IRB approach. Bank for International Settlements.
- Bean, A. M., Kearns, R. O., Romanou, A., et al. (2025). Measuring what matters: Construct validity in large language model benchmarks. *NeurIPS 2025 Datasets and Benchmarks Track*. arXiv:2511.04703.
- Beaver, W. H. (1966). Financial ratios as predictors of failure. *Journal of Accounting Research*, 4, 71–111. <https://doi.org/10.2307/2490171>
- Dong, W., Zhang, J., Fu, S., Lin, H., Wang, D., & Hu, L. (2026). Algorithmic recourse of in-context learning for tabular data. arXiv:2605.31272.
- Financial Services Commission [금융위원회]. (2026, June 18). Guidelines on artificial intelligence in the financial sector, revised proposal [금융분야 인공지능 가이드라인 개정안] and AI risk-management framework (effective June 22, 2026). FSC. <https://www.fsc.go.kr/no010101/87142>
- Financial Stability Board. (2024). The financial stability implications of artificial intelligence. FSB.
- Financial Stability Board. (2026, June 10). Sound practices for responsible adoption of artificial intelligence (AI): Consultation report. FSB. <https://www.fsb.org/2026/06/sound-practices-for-responsible-adoption-of-artificial-intelligence-ai-consultation-report/>
- Framework Act on the Development of Artificial Intelligence and the Establishment of a Foundation of Trust [인공지능 발전과 신뢰 기반 조성 등에 관한 기본법], Act No. 21311 (amended January 20, 2026; effective January 22, 2026). <https://www.law.go.kr/lsInfoP.do?ancYnChk=0&lsId=014820>
- Fujimoto, S., Meger, D., & Precup, D. (2019). Off-policy deep reinforcement learning without exploration. *ICML*.

- Golec, M., & Alabduljalil, M. (2026). Interpretable LLMs for credit risk: A systematic review and taxonomy. *Expert Systems with Applications*, 306, 130941. <https://doi.org/10.1016/j.eswa.2025.130941>
- Huang, J., Chen, X., Mishra, S., Zheng, H. S., Yu, A. W., Song, X., & Zhou, D. (2024). Large language models cannot self-correct reasoning yet. *ICLR*. arXiv:2310.01798.
- Huang, L., Yu, W., Ma, W., Zhong, W., Feng, Z., Wang, H., Chen, Q., Peng, W., Feng, X., Qin, B., & Liu, T. (2023). A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions. arXiv:2311.05232.
- Jacobs, A. Z., & Wallach, H. (2021). Measurement and fairness. *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*, 375 – 385. <https://doi.org/10.1145/3442188.3445901>
- Jarrow, R. A., & Turnbull, S. M. (1995). Pricing derivatives on financial securities subject to credit risk. *Journal of Finance*, 50(1), 53 – 85. <https://doi.org/10.1111/j.1540-6261.1995.tb05167.x>
- Kamoi, R., Zhang, Y., Zhang, N., Han, J., & Zhang, R. (2024). When can LLMs actually correct their own mistakes? A critical survey of self-correction of LLMs. *Transactions of the Association for Computational Linguistics*, 12, 1417 – 1440. https://doi.org/10.1162/tacl_a_00713
- Kang, H., & Liu, X.-Y. (2023). Deficiency of large language models in finance: An empirical examination of hallucination. arXiv:2311.15548.
- Kapoor, S., et al. (2025). Holistic Agent Leaderboard: The missing infrastructure for AI agent evaluation. arXiv:2510.11977.
- Karimi, A.-H., Barthe, G., Balle, B., & Valera, I. (2020a). Model-agnostic counterfactual explanations for consequential decisions. *AISTATS*.
- Karimi, A.-H., von Kügelgen, J., Schölkopf, B., & Valera, I. (2020b). Algorithmic recourse under imperfect causal knowledge: A probabilistic approach. *NeurIPS*, 33, 265 – 277.
- Karimi, A.-H., Schölkopf, B., & Valera, I. (2021). Algorithmic recourse: From counterfactual explanations to interventions. *ACM FAccT*. <https://doi.org/10.1145/3442188.3445899>
- Kealhofer, S. (2003). Quantifying credit risk I: Default prediction. *Financial Analysts Journal*, 59(1), 30 – 44. <https://doi.org/10.2469/faj.v59.n1.2501>

- Kidambi, R., Rajeswaran, A., Netrapalli, P., & Joachims, T. (2020). MOREL: Model-based offline reinforcement learning. *NeurIPS*.
- Kostrikov, I., Nair, A., & Levine, S. (2022). Offline reinforcement learning with implicit Q-learning. *ICLR*.
- Kumar, A., Fu, J., Tucker, G., & Levine, S. (2019). Stabilizing off-policy Q-learning via bootstrapping error reduction. *NeurIPS*.
- Kumar, A., Zhou, A., Tucker, G., & Levine, S. (2020). Conservative Q-learning for offline reinforcement learning. *NeurIPS*.
- Lashkevich, E., & Zelenkov, Y. (2026). Designing an AI-based financial advisor for distressed firms: A decision support framework for actionable and accounting-consistent algorithmic recourse. *IEEE Access*, 14, 20084 – 20099.
- Levine, S., Kumar, A., Tucker, G., & Fu, J. (2020). Offline reinforcement learning: Tutorial, review, and perspectives on open problems. *arXiv:2005.01643*.
- Liang, P., Bommasani, R., Lee, T., et al. (2022). Holistic evaluation of language models. *arXiv:2211.09110*.
- Madaan, A., Tandon, N., Gupta, P., Hallinan, S., Gao, L., Wiegrefe, S., Alon, U., Dziri, N., Prabhume, S., Yang, Y., Gupta, S., Majumder, B. P., Hermann, K., Welleck, S., Yazdanbakhsh, A., & Clark, P. (2023). Self-Refine: Iterative refinement with self-feedback. *Advances in Neural Information Processing Systems*, 36.
- Merton, R. C. (1974). On the pricing of corporate debt: The risk structure of interest rates. *Journal of Finance*, 29(2), 449 – 470. <https://doi.org/10.1111/j.1540-6261.1974.tb03058.x>
- National Institute of Standards and Technology. (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0) (NIST AI 100-1).
- National Institute of Standards and Technology. (2024). Artificial Intelligence Risk Management Framework: Generative Artificial Intelligence Profile (NIST AI 600-1).
- Ohlson, J. A. (1980). Financial ratios and the probabilistic prediction of bankruptcy. *Journal of Accounting Research*, 18(1), 109 – 131. <https://doi.org/10.2307/2490395>
- Pearl, J. (2009). *Causality: Models, reasoning, and inference* (2nd ed.). Cambridge University Press.

- Pitis, S., Creager, E., & Garg, A. (2020). Counterfactual data augmentation using locally factored dynamics. *NeurIPS*.
- Schall, M., & de Melo, G. (2025). The hidden cost of structure: How constrained decoding affects language model performance. *Proceedings of RANLP 2025*, 1074 – 1084.
- Sprague, Z., Yin, F., Rodriguez, J. D., Jiang, D., Wadhwa, M., Singhal, P., Zhao, X., Ye, X., Mahowald, K., & Durrett, G. (2024). To CoT or not to CoT? Chain-of-thought helps mainly on math and symbolic reasoning. *arXiv:2409.12183*.
- Tam, Z. R., Wu, C.-K., Tsai, Y.-L., Lin, C.-Y., Lee, H., & Chen, Y.-N. (2024). Let me speak freely? A study on the impact of format restrictions on performance of large language models. *arXiv:2408.02442*.
- Ustun, B., Spangher, A., & Liu, Y. (2019). Actionable recourse in linear classification. *ACM FAT**. <https://doi.org/10.1145/3287560.3287566>
- Wachter, S., Mittelstadt, B., & Russell, C. (2017). Counterfactual explanations without opening the black box: Automated decisions and the GDPR. *Harvard Journal of Law & Technology*, 31(2), 841 – 887.
- Wang, D., Chen, Z., Florescu, I., & Wen, B. (2023). A sparsity algorithm for finding optimal counterfactual explanations: Application to corporate credit rating. *Research in International Business and Finance*, 64, 101869. <https://doi.org/10.1016/j.ribaf.2022.101869>
- Wang, X., Wei, J., Schuurmans, D., Le, Q., Chi, E., Narang, S., Chowdhery, A., & Zhou, D. (2023). Self-consistency improves chain-of-thought reasoning in language models. *ICLR*.
- Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E., Le, Q., & Zhou, D. (2022). Chain-of-thought prompting elicits reasoning in large language models. *NeurIPS*.
- Wu, H., Sharma, S., Patra, S., & Gopalakrishnan, S. (2024). SafeAR: Safe algorithmic recourse by risk-aware policies. *Proceedings of the AAAI Conference on Artificial Intelligence*, 38(14), 15915 – 15923.
- Xuan, Y., Sokol, K., Sanderson, M., & Chan, J. (2025). Perfect counterfactuals in imperfect worlds: Modelling noisy implementation of actions in sequential algorithmic recourse. *Machine Learning*. <https://doi.org/10.1007/s10994-025-06821-1>

- Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., & Cao, Y. (2023). ReAct: Synergizing reasoning and acting in language models. ICLR.
- Yehudai, A., Eden, L., Li, A., Uziel, G., Zhao, Y., Bar-Haim, R., Cohan, A., & Shmueli-Scheuer, M. (2025; v2 2026). Survey on evaluation of LLM-based agents. arXiv:2503.16416.
- Yu, T., Kumar, A., Rafailov, R., Rajeswaran, A., Levine, S., & Finn, C. (2021). COMBO: Conservative offline model-based policy optimization. NeurIPS.
- Yu, T., Thomas, G., Yu, L., Ermon, S., Zou, J., Levine, S., Finn, C., & Ma, T. (2020). MOPO: Model-based offline policy optimization. NeurIPS.
- Zhu, P., Sun, L., Yu, P. S., & Su, S. (2026). The necessity of a unified framework for LLM-based agent evaluation. arXiv:2602.03238.

부록 A. 최종 행동·입력 명세

A.1 행동 필드, 단위와 실제 계산값

이 부록은 최신 8차원 계약의 원 필드명과 기준을 보존한다. 본문에서는 읽기 쉬운 한글 이름을 사용하고 실제 계산은 아래 순서와 동결 float64 값으로 수행한다. 문서의 반올림 숫자로 원래 입력파일을 덮어쓰지 않는다.

A.1.1 성장성 CAPEX 축소율

growth_capex_reduction_pct

정규화 기준 $s=0.6310184441953189$; 허용범위 $[0, 1]$.

A.1.2 이자부부채 상환율

deleveraging_total_debt_pct

정규화 기준 $s=0.3469549324277901$; 허용범위 $[0, 1]$.

A.1.3 단기차입 차환율

refinancing_short_debt_pct

정규화 기준 $s=0.4741061962838509$; 허용범위 $[0, 1]$.

A.1.4 재고 회전을 변화

inv_turnover_chg

정규화 기준 $s=1.398376123199908$; 허용범위 $[-3, 3]$.

A.1.5 매출채권 회전을 변화

ar_turnover_chg

정규화 기준 $s=0.9341039044455588$; 허용범위 $[-3, 3]$.

A.1.6 매입채무 회전을 변화

ap_turnover_chg

정규화 기준 $s=2.453574198113573$; 허용범위 $[-3, 3]$.

A.1.7 매출원가율 변화

cogs_ratio_chg

정규화 기준 $s=0.02688260661233544$; 허용범위 $[-0.03, 0.03]$.

A.1.8 판매관리비율 변화

sga_ratio_chg

정규화 기준 $s=0.01716946739071251$; 허용범위 $[-0.02, 0.02]$.

DL 과 RF 는 두 값이 동시에 양수인 제안을 허용하지 않는다. 모든 값은 유한수여야 하며 추가 차원은 허용하지 않는다. B1 은 $\sum |a_j|/s_j \leq 1$ 의 조건이고, BINF 는 이 총량 조건만 제거한다. 숫자 문자열과 실제 JSON number 의 구분, 동일 key 의 중복 및 설명값과 행동값의 구분은 응답 검증단계에서 관리한다.

A.2 아홉 후보의 실제 행동벡터

표 A-1. CAPEX·부채·재고 부분

후보	CAPEX	DL	RF	INV
A0	0.000000	0.000000	0.000000	0.000000
DL	0.000000	0.346955	0.000000	0.000000
RF	0.000000	0.000000	0.474106	0.000000
CX	0.631018	0.000000	0.000000	0.000000
WC1	0.000000	0.000000	0.000000	0.699188
WC2	0.000000	0.000000	0.000000	0.466125
OE	0.000000	0.000000	0.000000	0.000000
MX1	0.000000	0.173477	0.000000	0.000000
MX2	0.000000	0.173477	0.000000	0.279675

자료: 동결 action_contract.catalog. 여덟 차원을 두 표로 나누어 제시했으며, 각 행은 두 표를 이어 하나의 벡터로 읽는다. A0 외 모든 후보의 정규화 강도는 1 이다.

표 A-2. 매출채권·매입채무·비용 부분

후보	AR	AP	COGS	SG&A
A0	0.000000	0.000000	0.000000	0.000000
DL	0.000000	0.000000	0.000000	0.000000
RF	0.000000	0.000000	0.000000	0.000000
CX	0.000000	0.000000	0.000000	0.000000
WC1	0.467052	0.000000	0.000000	0.000000
WC2	0.311368	-0.817858	0.000000	0.000000
OE	0.000000	0.000000	-0.013441	-0.008585
MX1	0.000000	0.000000	-0.006721	-0.004292
MX2	0.186821	-0.245357	0.000000	0.000000

자료: 동결 action_contract.catalog. 여덟 차원을 두 표로 나누어 제시했으며, 각 행은 두 표를 이어 하나의 벡터로 읽는다. A0 외 모든 후보의 정규화 강도는 1 이다.

A.3 LLM 입력특징의 의미

표 A-3. 재무특징과 제공정보의 정확한 정의

특징 묶음	정의·주의사항
부채/자산	총부채 ÷ 총자산. 이자부부채만의 비율이 아님
자본/자산	자기자본 ÷ 총자산
유동비율 / 현금비율	유동자산 ÷ 유동부채 / 현금·현금성자산 ÷ 유동부채
영업 / 총 / 순이익률	영업이익 / 매출총이익 / 당기순이익을 각각 매출액으로 나눔
ROA 대리변수	당기순이익 ÷ 기말 총자산. 평균 총자산 기준과 다름
원가율 / 판매관비율	매출원가 / 판매관리비를 각각 매출액으로 나눔
금융비용/매출	광의 금융비용 ÷ 매출. 순수 이자비용과 동일하지 않음
CAPEX/매출	canonical CAPEX ÷ 매출. 임의 추정 proxy 로 대체하지 않음

특징 묶음	정의·주의사항
유형자산/자산	순유형자산÷총자산
단기차입 구성비	단기차입금÷이자부 총부채
장기차입 구성비	(유동성 장기부채+비유동 장기차입)÷이자부 총부채
사채 구성비	사채÷이자부 총부채
운전자본/매출	재고·매출채권·매입채무를 각각 매출액으로 나눔
전년 대비 네 변화	영업이익률·부채/자산·유동비율·ROA 의 가산 차이. 상대 증가율 아님
공통 보조필드	fiscal_year, log_assets, market. IC-a 부터 포함
IC-b / IC-c 추가	industry_class / firm_name. 각각 1 개 필드 추가

자료: feature_dictionary.csv 및 prompt_contract 의 visible_dictionary. 재무특징은 총 23 개이다. log_assets 는 canonical 통화단위 총자산의 부호를 보존한 $\log(1+|\text{자산}|)$ 변환이다.

결측값은 null 로 전달하고, 없는 재무값을 이름이나 업종에서 추정해 채우지 않는다. 동일한 경제적 이름이라도 분자와 분모가 다르면 다른 특징이므로 원 필드 사전을 기준으로 대조한다. 업종코드 바인딩은 평가연도 당시 snapshot 이 아니라 조회시점 company-profile 이라는 시점 한계를 유지한다.

부록 B. 평가기반의 개발 검증기록

아래 계수와 예측성능은 개발 단계 분석기록의 개발 검증자료를 보존한 것이다. 최종 V4.3 실행 스냅샷으로 새로 적합하거나 추정한 결과로 제시하지 않는다. 기존 연구의 평가기반을 이해하기 위한 증거이며, 최신 실행경로의 동일성 확인은 별도의 재현성 과제이다.

표 B-1. Oracle 공통 입력변수

영역	변수	방향·정의
수익성	R006 세전이익률	높을수록 우량한 방향
안정성	R064 이익잉여금/총자산	높을수록 우량한 방향
부채상환	R085 금융비용부담률	낮을수록 우량한 방향
유동성	R133 FCF/유동부채	높을수록 우량한 방향
활동성	R157 자본금회전율	높을수록 우량한 방향
성장성	R182 비유동자산증가율	기존 Oracle 의 정의에 따라 평가
산업	전기 업종평균등급	자사 제외, 등급부호 체계와 함께 해석
경영	최근 3 년 자본금 변동 횟수	회수 기반 대리변수
영업	ln(총자산)	규모 대리변수; LLM log_assets 와 별도 정의
재무	최근 3 년 영업손실 빈도	낮을수록 우량한 방향
신뢰도	재무비율 결측률	자료 누락 비중

자료: 개발 단계 분석기록 부록 A. Oracle 의 비재무 대리변수와 LLM 에 전달한 입력필드 집합은 동일하지 않다.

표 B-2. 개발 단계 Oracle- α 항목 가중치

변수	사전 가중치	최적화 가중치
R006	.186	.257
R064	.187	.234
R085	.188	.113
R133	.116	.093

변수	사전 가중치	최적화 가중치
R157	.196	.194
R182	.128	.108
업종 평균등급	.139	.225
자본금 변동 횟수	.239	.278
ln(총자산)	.239	.299
영업손실 빈도	.215	.145
결측률	.168	.052

자료: 개발 단계 분석기록 표 B-1. 원래 재무·비재무 묶음의 가중치이며 이 열 전체를 하나의 가중합으로 새로 구성하지 않았다.

표 B-3. 개발 단계 Oracle- β 계수

변수	계수	z
R006	-.035	-0.7
R064	-.945	-13.7
R085	-.189	-3.7
R133	-.097	-2.2
R157	-.195	-4.3
R182	-.001	-0.0
업종 평균등급	+.334	+7.8
자본금 변동 횟수	+.178	+3.6
ln(총자산)	-.942	-18.8
영업손실 빈도	+.394	+8.1
결측률	-.073	-1.7

자료: 개발 단계 분석기록 표 B-2. 순서형 종속변수의 등급 부호와 연계되는 계수이므로 부호만으로 현재의 정책효과를 판단하지 않는다.

표 B-4. 개발 단계 실제 등급 대비 예측성능

Oracle·기간	N	정확일치	Within-1	MAE	$ \rho $
α DEV	2032	.470	.911	.656	.662
α OOT	1790	.482	.921	.634	.699
β DEV	2032	.468	.920	.650	.676
β OOT	1790	.522	.936	.579	.729
γ DEV	2032	.586	.961	.550	.799
γ OOT	1790	.546	.962	.555	.750

자료: 개발 단계 분석기록 표 B-3, 제 4 장 등급이동 방향일치율의 표본 및 지표와 다르므로 숫자를 직접 대체하지 않는다.

부록 C. C3-E 배포와 학습 구성

C.1 최종 배포 식별과 정책의 정의

표 C-1. 배포정책의 동결값

항목	값
Release	C3E_E2_7SEED_BALANCED_DFEBafa6
Encoder / actor 수	E2 / 28
Configuration	B27, M2_S0935, DT06, T15_REWARD_S088
Matched seed	2, 11, 12, 13, 14, 15, 16
확률결합	같은 configuration 의 7 seed 평균 → 4 configuration 동일평균
최종 행동	canonical 순서 argmax; Q/Oracle 사후 재정렬 없음
α / β / γ 평균	55.959960 / 63.197863 / 65.902886
OE 대비 α / H	+0.157936 / 1.594461

자료: rl_contract.json, C3E_metrics.json, member_provenance.csv. 최종 배포 산출물의 값이며 추가 재학습이나 사후 재정렬을 하지 않았다.

Release hash

1100b62b5523e6d96f6a6711f0f07c15
9d6d7e889600905d6021205ee437aefd

Decision hash

dfebafa6b50e55c2f5019766e0e540af
9964b2a9ab7d4e49805d03e8011b792e

Action contract hash

f722e189a265e111c018341254a648dd
b9cecc05aa8c12c3547a023ea4c458c0

C.2 최종 configuration 의 Stage5 설정

표 C-2. 구성별 주요 Stage5 설정

Configuration	τ / β	Q 학습률	Q 감쇠	Epoch	Critic 비율
B27	.70 / 4	5×10^{-5}	.02	180	1
M2_S0935	.70 / 4	5×10^{-5}	.02	180	1
DT06	.70 / 4	4.5×10^{-5}	.03	200	2
T15_REWARD_S088	.70 / 4	5×10^{-5}	.02	180	1

자료: 실행 마스터 카탈로그의 최종 family 및 T15 검증기록. $\gamma=0$, CQL=0, sector shaping=0; actor 학습률 8×10^{-4} . 예전 공통 $\gamma=.6$ 11-class 명세를 최종 28 actor 의 설정으로 재사용하지 않았다.

가중치와 학습률을 평균하여 하나의 새로운 actor 를 학습한 것이 아니라, 각 configuration 에서 이미 학습한 확률출력을 결합한다. predecessor hash 가 같아야 같은 encoder/BC 경로로 해석할 수 있으며, 폴더명이나 seed 번호만으로 계보를 판단하지 않는다. 전체 설정과 가중치는 source manifest 및 실행 카탈로그에 연결한다.

C.3 28 개 actor 의 checkpoint 연결

표 C-3. 최종 구성원의 checkpoint 해시 접두어

Config	Seed	Stage3	Stage4	Stage5
B27	2	fd1164cd5918	855da469144e	6ea4cb707057
B27	11	ee6c82a66bfb	29555efde053	38d12a3393b5
B27	12	37031e713d6f	6c86baadb413	141f9519d86c
B27	13	de56bfd12bdf	ee003af1a3a1	f64897cac612
B27	14	8049552b9548	a494becded26	972d6bc6b8a8
B27	15	e87beb0ef6b2	9e585088ef41	41277b216d59
B27	16	cf90b760c7cc	ff135a368d16	d5f0bf77eed4
DT06	2	fd1164cd5918	855da469144e	52064ba3ea7f
DT06	11	ee6c82a66bfb	29555efde053	89be19c952cd

Config	Seed	Stage3	Stage4	Stage5
DT06	12	37031e713d6f	6c86baadb413	d010a69d5b07
DT06	13	de56bfd12bdf	ee003af1a3a1	700009a85fcb
DT06	14	8049552b9548	a494becded26	a96d899eb900
DT06	15	e87beb0ef6b2	9e585088ef41	4461b4620be8
DT06	16	cf90b760c7cc	ff135a368d16	6ff7fec53bb7
M2_S0935	2	fd1164cd5918	855da469144e	5f98aadd2c86
M2_S0935	11	ee6c82a66bfb	29555efde053	8e85e8c44958
M2_S0935	12	37031e713d6f	6c86baadb413	45b1b37db6e0
M2_S0935	13	de56bfd12bdf	ee003af1a3a1	40c462e3cf0b
M2_S0935	14	8049552b9548	a494becded26	ab7334b20329
M2_S0935	15	e87beb0ef6b2	9e585088ef41	b1ced2cbebf7
M2_S0935	16	cf90b760c7cc	ff135a368d16	377c9b08c697
T15	2	fd1164cd5918	855da469144e	c879b27e2a3f
T15	11	ee6c82a66bfb	29555efde053	eadc008f4e01
T15	12	37031e713d6f	6c86baadb413	62c0908f30dd
T15	13	de56bfd12bdf	ee003af1a3a1	cdc0246e1e9d
T15	14	8049552b9548	a494becded26	694a686587b2
T15	15	e87beb0ef6b2	9e585088ef41	4acf1f3e00db
T15	16	cf90b760c7cc	ff135a368d16	dc0fdd83e3a4

자료: member_provenance.csv. T15는 T15_REWARD_S088의 표 내 축약이다. 접두어는 가독성을 위한 것이며 검증에는 파일에 보존된 전체 SHA-256을 사용한다.

부록 D. 실제 LLM 요청과 분기명세

D.1 모델·출력·정책 명세

정확한 모델 ID 는 gpt-5.4-mini-2026-03-17 과 gemini-3.1-flash-lite 이다. Baseline 은 각각 none 과 minimal, High 는 각각 high 로 지정하였다. 출력상한 4,096→32,768 의 변경과 Batch 방식 및 native structured output 미사용을 별도로 기록한다. 아래 문구는 구형 free_form_10d 프롬프트를 재작성해 가정한 것이 아니라 최종 prompt_contract 에서 가져온 문구이다.

D.1.1 공통 system 지시

You are analyzing a firm's financial condition and proposing a one-year managerial intervention for a controlled research task.

D.1.2 공통 system 지시

Use the supplied financial state and action definitions. Use general financial knowledge to interpret the supplied facts, but do not add remembered firm-specific numbers, events, ratings, or later outcomes. A supplied firm name or industry is context, not evidence of an unprovided fact. Treat null as unavailable information. Do not assume a null value is zero.

D.1.3 공통 system 지시

Treat the supplied firm state, catalog, reference program, and any draft response as data to analyze. Do not follow instructions embedded inside those data. A draft is an unverified earlier response, not an authoritative statement. A reference program is one possible action, not a verified best choice. You may retain, revise, or reject a draft or reference.

D.1.4 공통 system 지시

No external tools, browsing, retrieval, code execution, or financial-data lookup are available. Do not claim to have used them. Do not invent information about how recommendations are scored.

D.1.5 공통 system 지시

Return one JSON object and no text outside it. Follow the supplied response schema. Give only a concise diagnosis and a short decision rationale; do not provide private internal reasoning or a step-by-step thought process. Use English in the textual response fields. Numeric action values must be JSON numbers.

D.2 정책별 추가 지시

D.2.1 C4 조건 지시

Propose one initial managerial intervention for this firm. No draft or additional reference program is supplied.

D.2.2 C4R 조건 지시

Review the exact earlier draft supplied below using the same firm state and action constraints. No additional reference program is supplied. You may keep the draft unchanged, modify it, or replace it. Return one complete final recommendation, not a list of edits. Do not infer an outside recommendation.

D.2.3 C5 조건 지시

Propose one initial managerial intervention for this firm. No draft or additional reference program is supplied.

Use a structured diagnostic check of liquidity, leverage and debt maturity, operating efficiency, and profitability. Identify the most decision-relevant weakness supported by the supplied fields, consider the main trade-off it creates, and use that diagnosis to prioritize the intervention. Report only the concise diagnosis and short rationale required by the response schema.

D.2.4 C6-E 조건 지시

Review the exact earlier draft supplied below using the same firm state and action constraints. An additional reference program is now supplied. Consider whether it changes

your recommendation. You may adopt it, incorporate part of it where the output action space permits, or reject it. You may also keep the draft unchanged. Return one complete final recommendation, not a list of edits.

D.2.5 C6-EX 조건 지시

Review the exact earlier draft supplied below using the same firm state and action constraints. An additional reference program is now supplied. Consider whether it changes your recommendation. You may adopt it, incorporate part of it where the output action space permits, or reject it. You may also keep the draft unchanged. Return one complete final recommendation, not a list of edits.

D.3 원응답의 구조와 action-usability

최종 응답은 diagnosis, action, evidence_fields, rationale 를 포함하는 단일 JSON 객체를 요구한다. evidence_fields 는 허용된 23 개 재무특징 가운데 중복 없이 최대 네 개를 지정한다. action 은 candidate9 이면 동결 후보 ID 에 연결되고 free8 이면 여덟 차원의 수치를 갖는다. 설명문은 짧은 영어 진단과 근거를 요구하며, 내부 추론과정의 공개를 요구하지 않는다.

전체 응답 schema 와 action-validity 의 기준은 분리되어 있다. 단일 모호하지 않은 JSON object, 정확한 action schema, 유한수, 범위, 상호배타와 예산을 검사한다. policy_usable 은 action-validity 와 비어 있지 않은 완료응답 및 refusal/output-limit 종료 여부를 함께 반영한다. 영어 여부나 권장 설명길이 및 내용 품질의 일부 검사는 별도의 prose QC 로 관리한다

D.4 부모 원문을 전달하는 pre-live 규칙

Any nonempty provider-returned raw visible text, including malformed JSON, refusal and truncated partial text; copy verbatim as JSON-escaped draft.

위 문구는 비어 있지 않은 원문을 그대로 JSON-escape 하여 후속 초안으로 사용할 수 있다는 실행 전 명세이다. 계획서의 unusable-parent 생략 설명과 다르다. 두 자료를 합쳐 하나의 완전히 일치된 규칙이었다고 쓰지 않고, 본문 제 3.10 절과 제 6.6 절에서 실제 실행 및 대체 게이트 민감도를 공개하였다.

Pre-live prompt_contract SHA-256

0ce383553d8135c0df116f993b342be1
fd88b4b0f6d356990ae5075c9f38492c

D.5 재현 경로

최종 runtime 의 canonical 진입점은 `python -m credit_recourse.final_release` 이다. 구형 Stage7 전용 경로를 현재의 실행방법으로 제시하지 않는다. 다만 이 진입점의 현재 파일과 이미 생성된 Stage8/9 의 정확한 source snapshot 이 항상 같다는 증거는 아니므로, 실제 실행의 release binding 과 해시를 함께 확인해야 한다.

본 분석의 재집계는 저장된 CSV 와 JSON 을 읽고 표·bootstrap·그림·Word 문서를 생성한다. 신규 API 요청과 Simulator 재실행은 하지 않는다. 개발 단계 분석기록, raw response, 동결 RL/LLM 배포파일을 덮어쓰지 않으며, 추가된 분석은 별도 파생파일로 기록한다.

부록 E. 최종 대비의 전체 Oracle 결과

본문의 α 중심표에 대응하는 전체 Oracle 결과를 아래에 제시한다. 모든 표는 Main Run1/free8/IC-b의 각 셀 575개 기업에 대한 ITT이며, 같은 생성·실행 arm 안에서 모델·Oracle 별 네 대비×두 예산의 8개 family로 조정한다. 구간은 미조정 bootstrap 95%이며 p는 제 3.9 절의 sign-tail 방식이다. 긴 모델 ID와 원시 float 문자열을 직접 붙여 넣지 않고 별도의 패널과 반올림으로 표시하였다.

E.1 Baseline · Strict / Gemini 3.1 Flash-Lite

표 E-1. Baseline · Strict / Gemini / Oracle- α

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	-0.0023	[-0.0563, +0.0519]	1.0000
B1	C5-C4	+0.1153	[+0.0471, +0.1896]	0.0084
B1	C6-E-C4R	+0.0220	[-0.0241, +0.0665]	1.0000
B1	C6-E-C6-EX	+0.0452	[-0.0155, +0.1059]	0.6489
BINF	C4R-C4	+0.1427	[+0.0891, +0.1993]	0.0016
BINF	C5-C4	-0.0715	[-0.1649, +0.0199]	0.6489
BINF	C6-E-C4R	+0.0180	[-0.0548, +0.0895]	1.0000
BINF	C6-E-C6-EX	+0.0576	[-0.0073, +0.1228]	0.4848

자료: 기업별 Stage9와 production bootstrap 순서 재현. 표의 반올림 전 값과 family는 동봉 분석 CSV에서 추적한다.

표 E-2. Baseline · Strict / Gemini / Oracle- β

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	-0.0008	[-0.0069, +0.0045]	1.0000
B1	C5-C4	+0.0119	[+0.0048, +0.0187]	0.0154
B1	C6-E-C4R	+0.0080	[-0.0013, +0.0199]	0.4510
B1	C6-E-C6-EX	+0.0114	[+0.0020, +0.0240]	0.0660

예산	대비	평균차	95% 구간	Holm p
BINF	C4R-C4	+0.0189	[+0.0143, +0.0237]	0.0016
BINF	C5-C4	-0.0097	[-0.0555, +0.0339]	1.0000
BINF	C6-E-C4R	+0.0049	[-0.0149, +0.0237]	1.0000
BINF	C6-E-C6-EX	+0.0137	[-0.0022, +0.0304]	0.4510

자료: 기업별 Stage9와 production bootstrap 순서 재현. 표의 반올림 전 값과 family는 동봉 분석 CSV에서 추적한다.

표 E-3. Baseline · Strict / Gemini / Oracle- γ

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	-0.0075	[-0.0254, +0.0089]	1.0000
B1	C5-C4	+0.0321	[+0.0052, +0.0597]	0.1386
B1	C6-E-C4R	+0.0090	[-0.0083, +0.0272]	1.0000
B1	C6-E-C6-EX	+0.0114	[-0.0098, +0.0330]	1.0000
BINF	C4R-C4	+0.0291	[+0.0149, +0.0450]	0.0032
BINF	C5-C4	-0.0034	[-0.0409, +0.0343]	1.0000
BINF	C6-E-C4R	+0.0072	[-0.0176, +0.0323]	1.0000
BINF	C6-E-C6-EX	+0.0098	[-0.0157, +0.0356]	1.0000

자료: 기업별 Stage9와 production bootstrap 순서 재현. 표의 반올림 전 값과 family는 동봉 분석 CSV에서 추적한다.

E.2 Baseline · Strict / GPT-5.4-mini

표 E-4. Baseline · Strict / GPT / Oracle- α

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	+0.1693	[+0.1150, +0.2293]	0.0016
B1	C5-C4	+0.1960	[+0.1035, +0.2884]	0.0016
B1	C6-E-C4R	+0.0375	[-0.0548, +0.1273]	0.4036

예산	대비	평균차	95% 구간	Holm p
B1	C6-E-C6-EX	+0.1742	[+0.0751, +0.2767]	0.0020
BINF	C4R-C4	+0.1366	[+0.0775, +0.1985]	0.0016
BINF	C5-C4	+0.1011	[-0.0082, +0.2106]	0.1376
BINF	C6-E-C4R	+0.1472	[+0.0511, +0.2445]	0.0200
BINF	C6-E-C6-EX	+0.1270	[+0.0173, +0.2390]	0.0672

자료: 기업별 Stage9 와 production bootstrap 순서 재현. 표의 반올림 전 값과 family 는 동봉 분석 CSV 에서 추적한다.

표 E-5. Baseline · Strict / GPT / Oracle- β

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	+0.0214	[+0.0026, +0.0413]	0.1608
B1	C5-C4	+0.0482	[+0.0179, +0.0799]	0.0168
B1	C6-E-C4R	+0.0224	[-0.0049, +0.0503]	0.5209
B1	C6-E-C6-EX	+0.0214	[-0.0046, +0.0466]	0.5209
BINF	C4R-C4	+0.0130	[-0.0088, +0.0341]	0.5633
BINF	C5-C4	+0.0159	[-0.0146, +0.0473]	0.5633
BINF	C6-E-C4R	+0.0501	[+0.0219, +0.0799]	0.0032
BINF	C6-E-C6-EX	+0.0228	[-0.0113, +0.0577]	0.5633

자료: 기업별 Stage9 와 production bootstrap 순서 재현. 표의 반올림 전 값과 family 는 동봉 분석 CSV 에서 추적한다.

표 E-6. Baseline · Strict / GPT / Oracle- γ

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	+0.0478	[+0.0255, +0.0721]	0.0016
B1	C5-C4	+0.0531	[+0.0213, +0.0867]	0.0084
B1	C6-E-C4R	+0.0114	[-0.0271, +0.0502]	1.0000

예산	대비	평균차	95% 구간	Holm p
B1	C6-E-C6-EX	+0.0400	[+0.0014, +0.0813]	0.2130
BINF	C4R-C4	+0.0450	[+0.0229, +0.0686]	0.0016
BINF	C5-C4	-0.0233	[-0.0681, +0.0201]	1.0000
BINF	C6-E-C4R	+0.0220	[-0.0189, +0.0632]	1.0000
BINF	C6-E-C6-EX	+0.0196	[-0.0212, +0.0586]	1.0000

자료: 기업별 Stage9 와 production bootstrap 순서 재현. 표의 반올림 전 값과 family 는 동봉 분석 CSV 에서 추적한다.

E.3 Baseline · Repaired / Gemini 3.1 Flash-Lite

표 E-7. Baseline · Repaired / Gemini / Oracle- α

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	-0.0109	[-0.0358, +0.0139]	0.7623
B1	C5-C4	+0.0602	[+0.0020, +0.1218]	0.2120
B1	C6-E-C4R	+0.0585	[+0.0092, +0.1082]	0.1320
B1	C6-E-C6-EX	+0.0765	[+0.0211, +0.1339]	0.0588
BINF	C4R-C4	+0.1427	[+0.0881, +0.2004]	0.0016
BINF	C5-C4	-0.0715	[-0.1644, +0.0194]	0.3648
BINF	C6-E-C4R	+0.0180	[-0.0549, +0.0894]	0.7623
BINF	C6-E-C6-EX	+0.0576	[-0.0061, +0.1228]	0.2872

자료: 기업별 Stage9 와 production bootstrap 순서 재현. 표의 반올림 전 값과 family 는 동봉 분석 CSV 에서 추적한다.

표 E-8. Baseline · Repaired / Gemini / Oracle- β

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	-0.0003	[-0.0036, +0.0028]	1.0000
B1	C5-C4	+0.0200	[+0.0083, +0.0342]	0.0020

예산	대비	평균차	95% 구간	Holm p
B1	C6-E-C4R	+0.0253	[+0.0106, +0.0431]	0.0016
B1	C6-E-C6-EX	+0.0269	[+0.0121, +0.0464]	0.0016
BINF	C4R-C4	+0.0189	[+0.0143, +0.0237]	0.0016
BINF	C5-C4	-0.0097	[-0.0558, +0.0338]	1.0000
BINF	C6-E-C4R	+0.0049	[-0.0153, +0.0240]	1.0000
BINF	C6-E-C6-EX	+0.0137	[-0.0028, +0.0305]	0.3896

자료: 기업별 Stage9와 production bootstrap 순서 재현. 표의 반올림 전 값과 family는 동봉 분석 CSV에서 추적한다.

표 E-9. Baseline · Repaired / Gemini / Oracle- γ

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	-0.0033	[-0.0198, +0.0118]	1.0000
B1	C5-C4	+0.0396	[+0.0088, +0.0715]	0.0624
B1	C6-E-C4R	+0.0187	[-0.0016, +0.0409]	0.3720
B1	C6-E-C6-EX	+0.0310	[+0.0102, +0.0537]	0.0238
BINF	C4R-C4	+0.0291	[+0.0148, +0.0443]	0.0016
BINF	C5-C4	-0.0034	[-0.0395, +0.0348]	1.0000
BINF	C6-E-C4R	+0.0072	[-0.0165, +0.0317]	1.0000
BINF	C6-E-C6-EX	+0.0098	[-0.0161, +0.0360]	1.0000

자료: 기업별 Stage9와 production bootstrap 순서 재현. 표의 반올림 전 값과 family는 동봉 분석 CSV에서 추적한다.

E.4 Baseline · Repaired / GPT-5.4-mini

표 E-10. Baseline · Repaired / GPT / Oracle- α

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	+0.0047	[+0.0000, +0.0122]	0.5303
B1	C5-C4	+0.0787	[-0.0115, +0.1691]	0.2496
B1	C6-E-C4R	+0.1936	[+0.1222, +0.2656]	0.0016
B1	C6-E-C6-EX	+0.2027	[+0.1120, +0.2949]	0.0016
BINF	C4R-C4	+0.0295	[+0.0025, +0.0602]	0.1216
BINF	C5-C4	+0.0414	[-0.0551, +0.1409]	0.5303
BINF	C6-E-C4R	+0.2070	[+0.1276, +0.2892]	0.0016
BINF	C6-E-C6-EX	+0.1572	[+0.0623, +0.2550]	0.0080

자료: 기업별 Stage9와 production bootstrap 순서 재현. 표의 반올림 전 값과 family는 동봉 분석 CSV에서 추적한다.

표 E-11. Baseline · Repaired / GPT / Oracle- β

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	+0.0007	[+0.0001, +0.0016]	0.0240
B1	C5-C4	+0.0308	[+0.0050, +0.0584]	0.0980
B1	C6-E-C4R	+0.0504	[+0.0300, +0.0741]	0.0016
B1	C6-E-C6-EX	+0.0281	[-0.0047, +0.0608]	0.2706
BINF	C4R-C4	+0.0050	[-0.0030, +0.0160]	0.5691
BINF	C5-C4	+0.0111	[-0.0187, +0.0408]	0.5691
BINF	C6-E-C4R	+0.0569	[+0.0309, +0.0843]	0.0016
BINF	C6-E-C6-EX	+0.0323	[-0.0014, +0.0663]	0.2360

자료: 기업별 Stage9와 production bootstrap 순서 재현. 표의 반올림 전 값과 family는 동봉 분석 CSV에서 추적한다.

표 E-12. Baseline · Repaired / GPT / Oracle- γ

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	+0.0000	[-0.0007, +0.0009]	0.9617
B1	C5-C4	+0.0206	[-0.0186, +0.0600]	0.5611
B1	C6-E-C4R	+0.0734	[+0.0385, +0.1106]	0.0016
B1	C6-E-C6-EX	+0.0642	[+0.0272, +0.1031]	0.0042
BINF	C4R-C4	+0.0092	[-0.0013, +0.0214]	0.2676
BINF	C5-C4	-0.0414	[-0.0844, +0.0005]	0.2510
BINF	C6-E-C4R	+0.0489	[+0.0146, +0.0848]	0.0456
BINF	C6-E-C6-EX	+0.0355	[+0.0000, +0.0714]	0.2510

자료: 기업별 Stage9 와 production bootstrap 순서 재현. 표의 반올림 전 값과 family 는 동봉 분석 CSV 에서 추적한다.

E.5 High · Strict / Gemini 3.1 Flash-Lite

표 E-13. High · Strict / Gemini / Oracle- α

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	-0.0102	[-0.0429, +0.0209]	1.0000
B1	C5-C4	+0.0649	[+0.0051, +0.1250]	0.1848
B1	C6-E-C4R	+0.0897	[+0.0408, +0.1405]	0.0028
B1	C6-E-C6-EX	+0.0412	[-0.0134, +0.0986]	0.6899
BINF	C4R-C4	+0.1449	[+0.0914, +0.2009]	0.0016
BINF	C5-C4	-0.0652	[-0.1514, +0.0199]	0.6899
BINF	C6-E-C4R	+0.0431	[-0.0188, +0.1053]	0.6899
BINF	C6-E-C6-EX	+0.0153	[-0.0405, +0.0724]	1.0000

자료: 기업별 Stage9 와 production bootstrap 순서 재현. 표의 반올림 전 값과 family 는 동봉 분석 CSV 에서 추적한다.

표 E-14. High · Strict / Gemini / Oracle- β

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	-0.0013	[-0.0041, +0.0013]	1.0000
B1	C5-C4	+0.0140	[-0.0048, +0.0348]	0.9095
B1	C6-E-C4R	+0.0156	[+0.0060, +0.0283]	0.0056
B1	C6-E-C6-EX	+0.0043	[-0.0021, +0.0105]	0.9095
BINF	C4R-C4	+0.0302	[+0.0141, +0.0513]	0.0016
BINF	C5-C4	-0.0008	[-0.0338, +0.0327]	1.0000
BINF	C6-E-C4R	+0.0120	[-0.0157, +0.0389]	1.0000
BINF	C6-E-C6-EX	-0.0002	[-0.0192, +0.0149]	1.0000

자료: 기업별 Stage9와 production bootstrap 순서 재현. 표의 반올림 전 값과 family는 동봉 분석 CSV에서 추적한다.

표 E-15. High · Strict / Gemini / Oracle- γ

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	+0.0036	[-0.0087, +0.0163]	1.0000
B1	C5-C4	+0.0144	[-0.0153, +0.0437]	1.0000
B1	C6-E-C4R	+0.0222	[+0.0019, +0.0444]	0.2226
B1	C6-E-C6-EX	+0.0114	[-0.0108, +0.0344]	1.0000
BINF	C4R-C4	+0.0122	[-0.0019, +0.0272]	0.4760
BINF	C5-C4	-0.0185	[-0.0549, +0.0167]	1.0000
BINF	C6-E-C4R	+0.0427	[+0.0221, +0.0646]	0.0016
BINF	C6-E-C6-EX	+0.0228	[+0.0019, +0.0452]	0.2226

자료: 기업별 Stage9와 production bootstrap 순서 재현. 표의 반올림 전 값과 family는 동봉 분석 CSV에서 추적한다.

E.6 High · Strict / GPT-5.4-mini

표 E-16. High · Strict / GPT / Oracle- α

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	+0.0264	[-0.0000, +0.0553]	0.1936
B1	C5-C4	+0.0129	[-0.0464, +0.0725]	0.6679
B1	C6-E-C4R	+0.1003	[+0.0368, +0.1631]	0.0120
B1	C6-E-C6-EX	+0.1146	[+0.0443, +0.1864]	0.0084
BINF	C4R-C4	+0.0724	[+0.0290, +0.1189]	0.0016
BINF	C5-C4	-0.0680	[-0.1378, +0.0011]	0.1936
BINF	C6-E-C4R	+0.2142	[+0.1415, +0.2918]	0.0016
BINF	C6-E-C6-EX	+0.0767	[+0.0007, +0.1544]	0.1936

자료: 기업별 Stage9와 production bootstrap 순서 재현. 표의 반올림 전 값과 family는 동봉 분석 CSV에서 추적한다.

표 E-17. High · Strict / GPT / Oracle- β

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	-0.0026	[-0.0141, +0.0044]	1.0000
B1	C5-C4	+0.0052	[-0.0130, +0.0203]	1.0000
B1	C6-E-C4R	+0.0231	[+0.0006, +0.0474]	0.3080
B1	C6-E-C6-EX	+0.0084	[-0.0159, +0.0310]	1.0000
BINF	C4R-C4	+0.0106	[-0.0050, +0.0270]	0.9119
BINF	C5-C4	+0.0048	[-0.0163, +0.0250]	1.0000
BINF	C6-E-C4R	+0.0425	[+0.0258, +0.0617]	0.0016
BINF	C6-E-C6-EX	+0.0108	[-0.0035, +0.0256]	0.8519

자료: 기업별 Stage9와 production bootstrap 순서 재현. 표의 반올림 전 값과 family는 동봉 분석 CSV에서 추적한다.

표 E-18. High · Strict / GPT / Oracle- γ

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	+0.0012	[-0.0057, +0.0088]	1.0000
B1	C5-C4	+0.0010	[-0.0239, +0.0268]	1.0000
B1	C6-E-C4R	+0.0196	[-0.0049, +0.0430]	0.4632
B1	C6-E-C6-EX	+0.0286	[+0.0011, +0.0578]	0.2050
BINF	C4R-C4	+0.0179	[+0.0075, +0.0303]	0.0056
BINF	C5-C4	-0.0062	[-0.0361, +0.0242]	1.0000
BINF	C6-E-C4R	+0.0709	[+0.0398, +0.1054]	0.0016
BINF	C6-E-C6-EX	+0.0412	[+0.0084, +0.0744]	0.0816

자료: 기업별 Stage9와 production bootstrap 순서 재현. 표의 반올림 전 값과 family는 동봉 분석 CSV에서 추적한다.

E.7 High · Repaired / Gemini 3.1 Flash-Lite

표 E-19. High · Repaired / Gemini / Oracle- α

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	+0.0003	[-0.0281, +0.0292]	1.0000
B1	C5-C4	+0.0625	[+0.0038, +0.1205]	0.2064
B1	C6-E-C4R	+0.0793	[+0.0371, +0.1244]	0.0028
B1	C6-E-C6-EX	+0.0470	[-0.0039, +0.0999]	0.3650
BINF	C4R-C4	+0.1449	[+0.0918, +0.2004]	0.0016
BINF	C5-C4	-0.0652	[-0.1526, +0.0198]	0.5351
BINF	C6-E-C4R	+0.0431	[-0.0188, +0.1041]	0.5453
BINF	C6-E-C6-EX	+0.0153	[-0.0401, +0.0728]	1.0000

자료: 기업별 Stage9와 production bootstrap 순서 재현. 표의 반올림 전 값과 family는 동봉 분석 CSV에서 추적한다.

표 E-20. High · Repaired / Gemini / Oracle- β

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	-0.0022	[-0.0070, +0.0015]	1.0000
B1	C5-C4	+0.0148	[-0.0037, +0.0359]	0.6959
B1	C6-E-C4R	+0.0176	[+0.0075, +0.0307]	0.0028
B1	C6-E-C6-EX	+0.0049	[-0.0013, +0.0108]	0.6959
BINF	C4R-C4	+0.0302	[+0.0138, +0.0513]	0.0016
BINF	C5-C4	-0.0008	[-0.0329, +0.0336]	1.0000
BINF	C6-E-C4R	+0.0120	[-0.0163, +0.0388]	1.0000
BINF	C6-E-C6-EX	-0.0002	[-0.0197, +0.0147]	1.0000

자료: 기업별 Stage9와 production bootstrap 순서 재현. 표의 반올림 전 값과 family는 동봉 분석 CSV에서 추적한다.

표 E-21. High · Repaired / Gemini / Oracle- γ

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	+0.0074	[-0.0061, +0.0216]	0.8459
B1	C5-C4	+0.0115	[-0.0175, +0.0409]	0.8459
B1	C6-E-C4R	+0.0166	[-0.0045, +0.0387]	0.6359
B1	C6-E-C6-EX	+0.0147	[-0.0071, +0.0371]	0.6807
BINF	C4R-C4	+0.0122	[-0.0018, +0.0273]	0.5399
BINF	C5-C4	-0.0185	[-0.0553, +0.0167]	0.8459
BINF	C6-E-C4R	+0.0427	[+0.0219, +0.0641]	0.0016
BINF	C6-E-C6-EX	+0.0228	[+0.0022, +0.0445]	0.2016

자료: 기업별 Stage9와 production bootstrap 순서 재현. 표의 반올림 전 값과 family는 동봉 분석 CSV에서 추적한다.

E.8 High · Repaired / GPT-5.4-mini

표 E-22. High · Repaired / GPT / Oracle- α

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	+0.0105	[-0.0005, +0.0293]	0.1556
B1	C5-C4	-0.0059	[-0.0646, +0.0552]	0.8473
B1	C6-E-C4R	+0.1190	[+0.0703, +0.1715]	0.0016
B1	C6-E-C6-EX	+0.1230	[+0.0642, +0.1849]	0.0016
BINF	C4R-C4	+0.0586	[+0.0208, +0.0996]	0.0120
BINF	C5-C4	-0.0827	[-0.1478, -0.0181]	0.0488
BINF	C6-E-C4R	+0.2212	[+0.1516, +0.2940]	0.0016
BINF	C6-E-C6-EX	+0.0893	[+0.0169, +0.1632]	0.0510

자료: 기업별 Stage9와 production bootstrap 순서 재현. 표의 반올림 전 값과 family는 동봉 분석 CSV에서 추적한다.

표 E-23. High · Repaired / GPT / Oracle- β

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	+0.0006	[-0.0011, +0.0021]	1.0000
B1	C5-C4	+0.0027	[-0.0154, +0.0178]	1.0000
B1	C6-E-C4R	+0.0235	[+0.0069, +0.0435]	0.0308
B1	C6-E-C6-EX	+0.0126	[-0.0079, +0.0337]	1.0000
BINF	C4R-C4	+0.0095	[-0.0066, +0.0258]	1.0000
BINF	C5-C4	+0.0039	[-0.0169, +0.0245]	1.0000
BINF	C6-E-C4R	+0.0438	[+0.0271, +0.0628]	0.0016
BINF	C6-E-C6-EX	+0.0120	[-0.0022, +0.0270]	0.6167

자료: 기업별 Stage9와 production bootstrap 순서 재현. 표의 반올림 전 값과 family는 동봉 분석 CSV에서 추적한다.

표 E-24. High · Repaired / GPT / Oracle- γ

예산	대비	평균차	95% 구간	Holm p
B1	C4R-C4	+0.0015	[-0.0029, +0.0077]	1.0000
B1	C5-C4	+0.0037	[-0.0203, +0.0293]	1.0000
B1	C6-E-C4R	+0.0264	[+0.0047, +0.0481]	0.1000
B1	C6-E-C6-EX	+0.0262	[+0.0037, +0.0512]	0.1000
BINF	C4R-C4	+0.0143	[+0.0051, +0.0254]	0.0042
BINF	C5-C4	-0.0098	[-0.0396, +0.0193]	1.0000
BINF	C6-E-C4R	+0.0715	[+0.0401, +0.1054]	0.0016
BINF	C6-E-C6-EX	+0.0418	[+0.0088, +0.0744]	0.0636

자료: 기업별 Stage9 와 production bootstrap 순서 재현. 표의 반올림 전 값과 family 는 동봉 분석 CSV 에서 추적한다.

부록 F. PP·반복성·비용과 증거 연결

F.1 주요 PP 표본의 구성

아래 표는 각 대비가 사용하는 strict 수용 교집합 N을 보여준다. Repaired 에서도 같은 strict 마스크를 적용하며 repaired usable 집합으로 분모를 넓히지 않는다. 같은 기업의 두 조건에서 평가하므로, 조건별 절대평점을 서로 다른 집합에서 빼는 표가 아니다.

표 F-1. 대비별 strict PP 교집합 N

Regime·모델	예산	C4R-C4	C5-C4	C6-E-C4R	C6-E-C6-EX
Baseline Gemini	B1	45	51	44	39
Baseline Gemini	BINF	575	575	575	574
Baseline GPT	B1	246	175	235	193
Baseline GPT	BINF	409	370	483	458
High Gemini	B1	567	562	561	559
High Gemini	BINF	575	575	575	575
High GPT	B1	552	557	558	557
High GPT	BINF	567	566	567	565

자료: canonical strict mask 재구성. 완전한 PP 효과·구간은 strict_intersection_pp_contrasts.csv 에 보존한다.

F.2 비용 계산식과 귀속 범위

요청단가= $C_{\text{assumed}}/N_{\text{requests}}$, 수용행동단가= $C_{\text{assumed}}/N_{\text{usable}}$ 로 계산하였다. 수용행동 수는 각 공급자·regime 의 전체 12,075 개 요청에서 strict mask 를 합산한 수이다. Repaired 단가를 계산할 때에도 총 API 지출은 같은 값을 사용하고, 추가 수용행동만 분모에 반영한다. 이렇게 계산한 값은 동일 원응답의 후처리 비용효율이지 추가 호출의 청구단가가 아니다.

OpenAI 의 Baseline/High 귀속은 \$19.57/\$109.28, Gemini 는 약 ₩12,900/₩41,830 이다. High 를 추가 수행한 총지출과 동일한 수를 Baseline 대신 High 로 생성했을 때의 비용

프리미엄은 구분한다. 후자의 금액차이는 GPT \$89.71, Gemini 약 ₩28,930 이며, 통화 사이 합산이나 금전적 ROI 는 계산하지 않았다.

F.3 재집계 산출물과 자료 출처

표 F-2. 본문 표와 파생파일의 대응

내용	재집계 파일
Run1 정책가치	cell_summary_run1.csv
Run1/Run2 분리 점검	cell_summary_all_runs.csv
네 중심 대비·Holm	〈ARM〉_primary_run1.csv
행동예산 상호작용	〈ARM〉_interaction_run1.csv
Strict 교집합 PP	strict_intersection_pp_contrasts.csv
추론 regime / 기제 대비	reasoning_regime_run1.csv / reasoning_mechanism_run1.csv
행동공간·정보조건	action_space_information_run1.csv
평균·기업별 반복성	repeatability.csv / increment_repeatability.csv
실제 벡터 반복성	action_repeatability.csv
부모 게이트 / 계보	parent_gate_sensitivity.csv / parent_lineage_audit.csv
수리 불변성 / 비용	repair_invariance_audit.csv / dashboard_cost_analysis.csv
RL 비교정책·동률	reference_ladder.csv / reference_diagnostics.json

ARM 은 BASELINE_STRICT_ITT, BASELINE_REPAIRED_ITT, HIGH_STRICT_ITT, HIGH_REPAIRED_ITT 가운데 하나이다. 일반 repeatability 파일의 free8 candidate_match_rate 열은 행동일치로 사용하지 않는다.

상기 분석은 LLM_FINAL_OFFLINE_EVALUATION_20260914 패키지의 Stage9 기업별 평가행, 완료된 Baseline 요청 outcome, High 원행동 기록, pre-live contracts 와 C3-E 배포 산출물을 연결하였다. 원 단계별 결과와 재집계의 경계, 실행 전 분기규칙 증거 및 재현된 bootstrap 구간은 별도 JSON 과 변경기록에 남긴다.

원 평가파일의 첫 usability 표에 실제로 점수 요약이 들어 있던 문제, Run1 과 Run2 를 혼합하던 평균표, repaired usability 를 사용한 PP, 50:50 비용배분 및 긴 float 를 그대로 삽입한

표는 이 개정의 본문 표에 사용하지 않았다. 다만 집계수정으로 실행 source hash drift 나 개발 검증의 최신 재실행 증거가 자동으로 해결되는 것은 아니다.

F.4 아직 남는 증거상 제한

표 F-3. 편집과 재집계로 없앨 수 없는 제한

항목	이번 개정에서 한 조치	남는 확인사항
생성코드 hash drift	현재 집계코드와 입력해시 별도 보존	Stage8/9 를 실제 생성한 source snapshot 과 변경이력
Simulator 실증 재검증	개발 검증과 최신 fixture 를 분리	변경된 V4.3 의미론으로 과거 재현·조달제약 검증
부모 게이트 문서 차이	pre-live raw 규칙의 선행 증거와 대체게이트 민감도 공개	계획서 개정 및 실행명세 우선순위의 정식 기록
비용·토큰 회계	사용자 가정을 명시하고 동일 기준으로 산출	완전한 공급자별 usage·청구명세 대사

자료의 공백은 실제 결과를 삭제하거나 임의의 값으로 채우는 방식으로 해결하지 않는다.

부록 G. 구형 실험의 개발 이력과 분리 원칙

개발 단계 분석기록의 10 차원 자유행동·11 후보, raw L1 0.75·1.27·2.00, 단일 seed 2 C3, C7·C8, 구형 C6X 및 기업명 인식 프로브는 최종 V4.3 의 현재 결과와 다른 계약에 속한다. 이 내용은 연구가 어떤 문제를 발견하고 설계를 변경했는지 이해하는 개발 이력으로 남기되, 최신 본실험의 가설을 입증하는 수치로 사용하지 않는다.

특히 구형 원고의 자유작성 우위, 추론 유도의 음의 효과, mean/shuffle/nearest 에 따른 가치분해 및 Shapley 결과는 그 당시의 행동공간과 실행규칙 아래의 결과이다. 최종 8 차원 계약에서 재평가한 자료 없이 이 수치를 새 결론에 옮기면 연구대상이 바뀐 것을 숨기게 된다. 최신 본문은 동일한 문제의식을 살리되 실제 계산된 V4.3 결과로 교체하였다.

기존 원문 파일은 변경 없이 보존한다. 따라서 과거 실험의 세부 표나 프롬프트를 역사적 비교로 확인할 수 있지만, 이를 현재 runtime 또는 현재 하이퍼파라미터로 해석하지 않는다. 모든 연구 이력을 현재 논문 본문에 반복 삽입하는 대신 아래 전환표로 핵심 차이를 명시한다.

표 G-1. 개발계약에서 최종계약으로의 주요 전환

과거 정의	최종 V4.3 정의	변경의 의미
10 차원 재무변화	8 차원 관리행동	상환·차환·성장 CAPEX 의미론 재정의
11 개 후보	9 개 canonical 후보	비-A0 총 강도 1 로 통일
원값의 raw L1	P50 정규화 B1/BINF	과거 준수율과 최신 준수율 직접 비교 금지
단일 seed 2	4 configuration×7 matched seed	계층적 확률평균 및 선택과정 공개
균등 무작위 C6X	고정 derangement C6-EX	주변분포 보존·기업연결 대비
C4~C8·여러 탐색	다섯 정책의 Main / Stability	실행한 셀만 보고; 미실행조건 결과 없음
허용범위 보정 후 비교	Strict 와 Repaired 별도	운영정책과 수리 실행규칙의 구분
정상응답 위주의 비교	ITT 전체 N 와 strict PP 교집합	실패와 선택표본을 명시적으로 분리

자료: 개발 단계 분석기록과 최종 frozen contracts 의 정의 차이. 구형 수치의 단순 이름 치환이 아니라 분석대상의 변경이다.

V1.3 재현성 통계 계약 및 보조분석 동결

본 버전의 primary 분석은 frozen Stage8 firm-level observations 에 대한 Strict ITT 이며, terminal unusable 응답은 사전 실행계약에 따라 A0 fallback 으로 처리한다. Primary production bootstrap stream 은 변경하지 않았다.

Supplemental 분석의 과거 SHA-256 substream 구현은 복구되지 않았으므로, V1.3 에서는 canonical JSON(UTF-8, sort_keys=True, no whitespace) → SHA-256 첫 8 바이트 unsigned big-endian → 독립 PCG64 → 10,000 회 paired firm bootstrap → linear percentile CI → plus-one sign-tail → Holm 을 명시적으로 동결했다. 과거 supplemental 수치는 역사적 비정보으로 보존하며, 현재의 inferential claim 은 V1.3 결과를 따른다.

GPT Baseline B1 C4R-C4 의 primary Strict ITT 는 +0.1692620467(N=575)이며, frozen production fullstream 과 row-level N·mean 교차검증으로 유지된다. +0.0105196562 는 High-Repaired supplemental cell 의 값으로서 Baseline-Strict primary 값을 대체하지 않는다.

V1.3 보조분석 대표 결과

Analysis	Model	Oracle	LHS	RHS	N	Estimate	CI Low	CI High	Holm p
RQ4	Gemini	α	C4	Candidate9	575	-0.702799	-0.812901	-0.594852	0.000600
RQ4	Gemini	α	C4R	Candidate9	575	-0.666136	-0.779248	-0.555447	0.000600
RQ4	Gemini	α	C6-E	Candidate9	575	-0.688085	-0.804121	-0.577134	0.000600
RQ4	Gemini	β	C4	Candidate9	575	-0.179005	-0.222048	-0.139807	0.000600
RQ4	Gemini	β	C4R	Candidate9	575	-0.159313	-0.201965	-0.120535	0.000600
RQ4	Gemini	β	C6-E	Candidate9	575	-0.158351	-0.198100	-0.121575	0.000600
RQ4	Gemini	γ	C4	Candidate9	575	-0.170484	-0.217059	-0.125395	0.000600
RQ4	Gemini	γ	C4R	Candidate9	575	-0.164942	-0.211959	-0.119771	0.000600
RQ4	Gemini	γ	C6-E	Candidate9	575	-0.187014	-0.234642	-0.141486	0.000600
RQ4	GPT	α	C4	Candidate9	575	-0.337179	-0.447931	-0.229916	0.000600
RQ4	GPT	α	C4R	Candidate9	575	-0.192836	-0.295607	-0.094909	0.000600
RQ4	GPT	α	C6-E	Candidate9	575	-0.240362	-0.344634	-0.139982	0.000600
RQ4	GPT	β	C4	Candidate9	575	-0.095559	-0.133936	-0.061278	0.000600
RQ4	GPT	β	C4R	Candidate9	575	-0.081622	-0.114145	-0.052861	0.000600
RQ4	GPT	β	C6-E	Candidate9	575	-0.075509	-0.111867	-0.039969	0.000600
RQ4	GPT	γ	C4	Candidate9	575	-0.100200	-0.141275	-0.060155	0.000600
RQ4	GPT	γ	C4R	Candidate9	575	-0.055896	-0.095193	-0.015552	0.005599
RQ4	GPT	γ	C6-E	Candidate9	575	-0.067498	-0.109795	-0.026219	0.002400
RQ5	Gemini	α	IC-b	IC-a	575	-0.017540	-0.079219	0.041384	1.000000
RQ5	Gemini	α	IC-c	IC-b	575	0.022761	-0.056158	0.101581	1.000000
RQ5	Gemini	β	IC-b	IC-a	575	-0.003031	-0.016796	0.007627	0.688731

Analysis	Model	Oracle	LHS	RHS	N	Estimate	CI Low	CI High	Holm p
RQ5	Gemini	β	IC-c	IC-b	575	0.007554	-0.003148	0.021501	0.393161
RQ5	Gemini	γ	IC-b	IC-a	575	0.006395	-0.012747	0.025709	0.521148
RQ5	Gemini	γ	IC-c	IC-b	575	0.017183	-0.010610	0.046033	0.453955
RQ5	GPT	α	IC-b	IC-a	575	-0.001592	-0.092690	0.089050	0.980502
RQ5	GPT	α	IC-c	IC-b	575	0.072803	-0.016842	0.166242	0.232777
RQ5	GPT	β	IC-b	IC-a	575	-0.005862	-0.024088	0.010873	0.515748
RQ5	GPT	β	IC-c	IC-b	575	0.018272	-0.006923	0.044705	0.309969
RQ5	GPT	γ	IC-b	IC-a	575	-0.016574	-0.051325	0.017386	0.564744
RQ5	GPT	γ	IC-c	IC-b	575	0.019366	-0.014948	0.054883	0.564744

표의 전체 V1.3 결과와 firm-level 재계산 경로는 THESIS_REPRO_KIT_v1.3/canonical_v13/V13_SUPPLEMENTAL_RESULTS.csv 및 contracts/V13_STATISTICAL_CONTRACT.md 에 보존한다. PP는 strict usable 교집합으로만 보고하며, RQ4와 RQ5는 575개 ITT로 계산한다.