10/19(월) 18:00 교수님 미팅 · 개인 참고용 보여 드릴 자료: LLM – Human baseline 비교 (2쪽) · 근거: 종합자료 15쪽

LLM과 RL 참조 LLM은 실제 기업 계획보다 평균 점수는 높았지만 통계적 우위는 확인되지 않았고, 행동의 성격은 달랐다. RL 참조도 기업 계획과의 일치를 뚜렷하게 높이지 못했다.

→ AI 권고는 평가 점수와 실제 경영 의사결정과의 정합성을 함께 검증해야 한다.

발표 순서 **1·2번** → **3번 점수** → **4번 행동** → **5번 일치** → **6번 참조** → **7번 요약** (2쪽 문서를 위에서 아래로)

세 비교 대상 (같은 기업)

C4 직접 작성 LLM · **C6-E** 해당 기업 RL 참조를 받아 고친 LLM · **Human baseline** 신용평가사·증권사 문서 236건에 적힌 기업의 경영·재무계획(대부분 회사 방침, 명시적 권고 15건). **같은 과제를 전문가가 푼 것이 아님** — 처음에 한 번만 말하기.

표본: 문서 236건 · 161개 기업 → 행동 비교 56개 → 점수 주 비교 53개 (+ OE 하나에 정확히 대응한 3개는 별도)

① 정책가치 — 53개 기업, Oracle-α 1년 뒤 점수 (문서 3번)

	GPT	Gemini
LLM 직접 권고 (C4)	+0.857	+0.762
RL 참조 LLM (C6-E)	+0.820	+0.776
Human baseline	**+0.638**	

C4 − HB: GPT +0.219 [−0.138, +0.607], Gemini +0.124 [−0.341, +0.586] → **구간이 0 포함, 절반 이상 기업 동점**. 우위 미확인일 뿐 "같다"는 증명 아님.

② 행동 종류 — 56개 기업 (문서 4번)

	문서	LLM / 참조 LLM
단기차입 장기 전환	**0**	23~28
투자 축소	20	0~3
투자 확대 (LLM 목록 밖)	32	—

만기연장·재조달(18) ≠ RF

③ 기업별 일치 — 다섯 종류 (문서 5번)

	실제	무작위 짝짓기
LLM GPT / Gemini	.250 / .339	.269 / .329
참조 GPT / Gemini	.196 / .339	.236 / .329

상환 적힌 9개 기업 → GPT 9/9 장기 전환

④ RL 참조 — 두 비교를 섞지 말 것 (문서 6번 ↔ 3번)

전체 자유 작성 실험 (575개)	HB 비교 53개 (후보 선택)
C6-E − C4R = 같은 초안에서 자기 재검토 대비 참조정보 추가의 증분 24/24 양수 · 추론 높음·B1·α: GPT **+0.100**, Gemini **+0.090**	C4 → C6-E: GPT +0.857 → +0.820, Gemini +0.762 → +0.776 문서와의 일치 변화도 확인되지 않음 → **대상·행동공간·표본이 달라 모순 아님**

교수님께 확인할 3가지

1. **비교 기준** — 기업 경영·사업계획과 전문가 문서로 만든 Human baseline이 요청하신 인간 비교의 방향에 맞는가?
2. **해석** — 점수와 실제 기업 계획의 차이를 외부 비교로 평가 범위를 점검한 결과로 봐도 되는가?
3. **진행** — 지금의 7장으로 학위심사 준비를 진행해도 되는가?

같은 과제의 전문가 비교를 뜻하셨다면 → 새 실험을 약속하지 말고 필요한 범위부터 여쭙기