검증 우선 평가 프레임워크를 통한 LLM 생성 기업 신용등급 개선권고 평가

신용평가모형–강화학습–LLM 파이프라인

2026 년 12 월

서강대학교 AI·SW 대학원

데이터사이언스·인공지능 전공

조 종 선

검증 우선 평가 프레임워크를 통한 LLM 생성 기업 신용등급 개선권고 평가

신용평가모형–강화학습–LLM 파이프라인

지도교수 최 준 석

이 논문을 공학석사 학위논문으로 제출함

2026 년 12 월 일

서강대학교 AI·SW 대학원

데이터사이언스·인공지능 전공

조 종 선

논 문 인 준 서

조 종 선의 공학석사 학위논문을 인준함

2026 년 12 월 일

주 심 (인)

부 심 (인)

부 심 (인)

차 례

Abstract.....vii

초록.....ix

제 1 장 서론.....1
- 제 1 절 연구의 배경.....1
- 제 2 절 문제 제기와 평가 기준.....2
- 제 3 절 연구 목적과 연구질문.....3
- 제 4 절 주요 발견과 연구의 기여.....4
- 제 5 절 논문의 구성.....6

제 2 장 관련 연구.....7
- 제 1 절 기업 신용위험의 측정과 신용평가모형.....7
- 제 2 절 알고리즘적 권고와 반사실적 설명.....8
- 제 3 절 오프라인 강화학습.....9
- 제 4 절 정책으로서의 LLM.....9
- 제 5 절 평가의 타당성과 외부 비교 기준.....10
- 제 6 절 선행연구의 한계와 본 연구의 위치.....11

제 3 장 연구 설계.....12
- 제 1 절 연구의 전체 구조.....12
- 제 2 절 자료와 표본.....13
- 제 3 절 행동공간.....13
  - (1) 8 개 관리 행동 축.....13
  - (2) 9 개 표준 후보행동.....14
  - (3) 자유 작성, 후보 선택, 행동크기 조건.....15
- 제 4 절 평가 장치: 재무 Simulator 와 Oracle.....15
  - (1) 재무 Simulator.....15
  - (2) 세 신용평가모형(Oracle).....16
  - (3) 정책가치.....17
- 제 5 절 비교 기준선.....17
- 제 6 절 LLM 실험 설계.....17
  - (1) 모델과 생성 설정.....17
  - (2) 입력 정보.....18
  - (3) 권고 방식.....18
  - (4) 실행 행렬.....20
  - (5) 응답의 판정과 실행 규칙.....20
- 제 7 절 통계 분석.....21

제 4 장 평가 장치의 검증.....22
- 제 1 절 Oracle 과 실제 신용등급의 정렬.....22
- 제 2 절 재무 Simulator 의 회계 일관성과 실제 재무 재현.....23
- 제 3 절 같은 기업 안에서 후보행동의 구별.....24
- 제 4 절 소결: 평가 장치의 사용 범위.....25

제 5 장 강화학습 참조정책 C3-E 27
제 1 절 학습 자료와 보상 27
제 2 절 학습 단계와 최종 구성 28
제 3 절 기준선 대비 정책가치 29
제 4 절 행동 분포와 기업별 손익 29
제 5 절 소결 31
제 6 장 LLM 권고 실험 32
제 1 절 비교의 기준 32
제 2 절 수용률과 정책가치 32
제 3 절 권고 방식의 효과 35
(1) 참조정보 추가 패키지의 증분 35
(2) 기업과 참조의 연결 37
(3) 자기 재검토와 실행 규칙 37
(4) 진단 유도 38
제 4 절 행동공간, 행동크기 조건, 평가모형 39
(1) 자유 작성과 후보 선택 39
(2) 행동크기 조건 39
(3) 평가모형 39
제 5 절 정보조건 39
제 6 절 반복 실행에서의 안정성 40
제 7 절 소결 41
제 7 장 Human baseline 과의 대조 43
제 1 절 비교의 설계와 가설 43
제 2 절 Human baseline 의 구성 44
(1) 문서의 수집 44
(2) 코딩 44
(3) 비교 대상 기업 46
제 3 절 LLM 권고와 전문가 문서의 대응 (H1, H2) 47
(1) 같은 종류의 행동을 고른 비율 47
(2) 만기 차입금에 대한 대응의 차이 49
(3) 참조정보 추가 패키지의 증분 (H2) 50
(4) 문서에 기재된 행동과 LLM 이 권한 행동의 종류 51
제 4 절 Human baseline 행동에 대한 평가 장치의 점수 (H3) 52
제 5 절 해석 53
제 6 절 소결 55
제 8 장 결론 56
제 1 절 연구 결과의 요약 56
제 2 절 논의 57
(1) 평가 장치의 구축과 한계 57
(2) 실행 가능성과 정책 하네스 58
(3) 생성 방식과 강화학습 참조 58
(4) 기업별 권고의 부가가치와 안정성 59
(5) 기업의 실제 경영·사업계획과의 차이 59

제 3 절 실무적 시사점 61
제 4 절 연구의 한계 61
제 5 절 향후 연구 63
제 6 절 맺음말 63
참고문헌 64
부록 68
부록 A. Oracle 의 입력변수와 모형 구성 68
부록 B. 9 개 후보행동의 벡터와 고정 정책의 가치 69
부록 C. C3-E 의 학습 설정 70
부록 D. LLM 입력 정보와 프롬프트 72
부록 E. 주 분석 96 개 결과 74
부록 F. Human baseline 의 재점검과 기업별 행동 78
부록 G. LLM 의 행동 선택과 반복성 83
부록 H. 재현 방법 85

표 차례

<표 1-1> 정답이 관측되지 않을 때 쓰는 세 가지 비교 기준.....2
<표 1-2> 연구질문과 분석 범위.....3
<표 1-3> 주요 발견의 요약.....4
<표 1-4> 주요 용어.....6
<표 2-1> 선행연구의 공백과 본 연구의 설계.....11
<표 3-1> 자료의 구분과 용도.....13
<표 3-2> 8 개 관리 행동 축의 정의와 허용 범위.....14
<표 3-3> 9 개 표준 후보행동.....15
<표 3-4> 모델과 생성 설정.....18
<표 3-5> 권고 방식과 비교하려는 효과.....19
<표 3-6> 모델·생성 설정 하나당 실행 행렬.....20
<표 4-1> Oracle 의 실제 신용등급 정렬 검증.....22
<표 4-2> Simulator 가 계산한 재무상태와 실제 재무상태의 점수 비교.....23
<표 4-3> 575 개 기업에서 9 개 후보행동의 점수 구별.....24
<표 4-4> 평가 장치 검증의 범위.....25
<표 5-1> C3-E 의 학습과 평가 구성.....27
<표 5-2> 기준선과 C3-E 의 정책가치(575 개 기업, 무행동 대비).....29
<표 5-3> 학습 자료의 행동 표지와 C3-E 의 선택.....30
<표 6-1> 직접 작성(C4)의 수용률과 정책가치(Oracle-α, B1).....33
<표 6-2> 직접 작성(C4)과 기준선의 대응 비교(Oracle-α, B1, 575 개 기업).....34
<표 6-3> 권고 방식 사이의 차이: 방향과 유의성.....35
<표 6-4> 참조정보 추가 패키지의 증분(C6-E − C4R): 자유 작성 조합별 평균 차이.....36
<표 6-5> 참조정보 추가 패키지의 증분(C6-E − C4R): 후보 선택 조건별 평균 차이.....37
<표 6-6> 실행 규칙에 따른 대비의 변화(GPT · 추론 낮음 · 자유 작성 · B1 · Oracle-α).....38
<표 6-7> 정보조건의 효과(추론 낮음 · 자유 작성 · B1 · 직접 작성).....40
<표 6-8> 반복 실행 사이 권고 행동의 일치(자유 작성, 추론 높음, B1).....41
<표 7-1> Human baseline 비교의 가설과 결과.....43
<표 7-2> Human baseline 자료의 구성.....46
<표 7-3> Human baseline 과 같은 종류의 행동을 고른 기업의 비율(56 개 기업).....48
<표 7-4> 만기연장·재조달 서술을 장기 전환으로 본 민감도와 단기차입 부담을 통제한 겹침..49
<표 7-5> 강화학습 참조 수정과 참조 없는 재검토의 겹침 차이(C6-E − C4R, 56 개 기업).....50
<표 7-6> 단일 후보 라벨이 없는 53 개 기업의 점수(무행동 대비).....52

<표 8-1> 연구질문별 결과 요약.....56
<표 8-2> 네 가지 행동에 대한 기준별 평가와 선택.....60
<표 A-1> Oracle 의 입력변수, Oracle-α 부문 내 가중치, Oracle-β 계수, Oracle-γ 변수 중요도...68
<표 B-1> 9 개 후보행동의 8 개 축 값.....69
<표 B-2> 고정 정책과 기준선의 정책가치(575 개 기업, 무행동 대비).....69
<표 C-1> C3-E 학습 구성별 보조 보상 가중치와 학습 설정.....70
<표 C-2> 시드·구성 하나를 뺀 C3-E 의 결과(Oracle-α).....71
<표 D-1> LLM 에 제공한 23 개 재무 특징.....72
<표 E-1> 진단 유도(C5 − C4).....74
<표 E-2> 자기 재검토(C4R − C4).....75
<표 E-3> 참조정보 추가 패키지의 증분(C6-E − C4R).....76
<표 E-4> 기업과 참조의 연결(C6-E − C6-EX).....77
<표 F-1> Human baseline 라벨의 재점검.....78
<표 F-2> 만기연장·재조달 서술의 세부 유형(확정 라벨의 앞으로의 행동 67 개).....78
<표 F-3> 재점검 전후와 민감도 라벨의 주요 결과.....79
<표 F-4> 단일 후보 라벨이 없는 53 개 기업의 기업별 행동.....80
<표 F-5> 단일 후보 라벨이 있는 3 개 기업의 기업별 행동.....82
<표 G-1> 후보 선택의 직접 작성(C4)에서 고른 후보의 분포와 참고 분포(%).....83
<표 G-2> 자유 작성의 직접 작성(C4, B1)에서 각 행동 축을 사용한 기업의 비율(%).....83
<표 G-3> 반복 실행 사이 권고 행동의 일치(자유 작성, 추론 높음).....84

그림 차례

<그림 3-1> 연구 전체 구조..... 12
<그림 3-2> 권고 방식의 분기 구조..... 19
<그림 6-1> 자유 작성 B1 의 권고 방식별 수용률: 추론 낮음과 추론 높음..... 33
<그림 6-2> 참조정보 추가 패키지의 증분(C6-E − C4R)의 조합별 점추정과 95% 구간..... 36
<그림 7-1> 문서에 기재된 행동과 LLM(직접 작성)·C3-E 가 권한 행동의 종류(56 개 기업)..... 51

Abstract

A Validation-First Evaluation Framework for LLM-Generated Corporate Credit-Rating Recourse: An Oracle–RL–LLM Pipeline

The quality of the credit-improvement actions that large language models (LLMs) prescribe for firms is hard to judge because the outcome of advice that was never executed cannot be observed. This thesis builds a validation-first framework that turns each recommendation into a one-year counterfactual financial state with an accounting-consistent simulator and scores it with three structurally different credit-scoring models (Oracles). For 575 Korean listed firms in fiscal year 2024, two LLMs (GPT-5.4-mini, Gemini 3.1 Flash-Lite) under 21 conditions and two generation settings (48,300 requests) were compared with baselines, a reinforcement-learning reference policy (C3-E), and a human baseline of firms' business and financial plans stated in 236 rating opinions and research reports.

In validating the apparatus, the Oracles followed the order of actual ratings in out-of-time data (rank correlation 0.69–0.75), yet the primary scorecard could not distinguish the nine candidate actions for 28.5% of firms, and the three Oracles shared a top candidate for only 45.4%. The main results obtained with this apparatus are as follows. First, policy value depended largely on whether the answer could be executed: with low reasoning, only 15–44% of free-form recommendations generated directly under the unit cap on total action size (B1) obeyed the action rules, and their value fell below random choice; with high reasoning, the acceptance rate exceeded 97% and value matched a rule recommending cost cuts to every firm. Second, revising a draft with the firm's C3-E action as a reference scored higher than self-review in all 24 free-form comparisons (7–9 significant after Holm correction), while part of the self-review gain came from repairing unexecutable drafts. Third, within this action space and evaluation setting, there was no evidence that the LLMs used firm-specific information to produce policy value reliably above a fixed simple rule: in none of the eight B1 settings did direct recommendations clearly exceed that rule. The LLMs did vary their choices across firms, but their choices concentrated on cost efficiency and term-out (moving short-term into long-term debt). Rerunning high-reasoning free-form generation under B1 reproduced the identical action for 7.5–48.6% of firms and the same set of axes for 38.0–65.6%. Against the human baseline, the LLMs' recommendations (α +0.762 to +0.857 on 53 firms) and the RL-referenced LLMs' recommendations (+0.776 to +0.820) had higher average one-year policy value than the actions stated in the documents (+0.638), but paired differences were not statistically significant. The two differed in kind: the LLMs mostly chose cost efficiency and term-out (about 70% of candidate choices), whereas the documents mostly described business decisions, cutting investment (20 of 56 firms) or expanding it (32 firms, outside the action space), and never described term-out. Under the five-kind classification there was no statistical evidence that the LLMs matched the firm's own

documents more often than random pairing. Because the two serve different goals, this is not a ranking of LLMs against corporate judgment. The quality of credit-improvement recommendations cannot be judged from the model alone; the validity of the evaluation apparatus, the configuration of the policy harness, and consistency with actual business decisions must be verified together.

Keywords: large language model; corporate credit rating; algorithmic recourse; offline reinforcement learning; model validation; policy harness; human baseline

초록

검증 우선 평가 프레임워크를 통한 LLM 생성 기업 신용등급 개선권고 평가: 신용평가모형–강화학습–LLM 파이프라인

대규모 언어모형(LLM)이 기업에 처방한 신용개선 행동은 실행되지 않으면 결과가 관측되지 않아 품질을 판단하기 어렵다. 본 연구는 모든 권고를 회계적으로 일관된 재무 Simulator 로 1 년 뒤 재무상태로 바꾸고 구조가 다른 세 신용평가모형(Oracle)으로 채점하는 검증 우선 평가 틀을 구축하였다. 2024 회계연도 한국 상장기업 575 개에서 두 LLM(GPT-5.4-mini, Gemini 3.1 Flash-Lite)의 21 개 조건과 두 생성 설정(48,300 건)을 기준선, 강화학습 참조정책(C3-E), 신용평가사·증권사 문서 236 건에 기재된 기업의 경영·재무 행동(Human baseline)과 대조하였다.

평가 장치를 먼저 검증한 결과, Oracle 은 기간외 자료에서 실제 등급의 순서를 따랐지만(순위상관 0.69~0.75), 주 평가모형은 기업의 28.5%에서 9 개 후보행동을 구별하지 못했고 세 Oracle 의 최고점 후보가 겹치는 기업은 45.4%였다. 첫째, 정책가치는 행동 규칙을 지킨 응답의 비율에 크게 좌우되었다. 추론 수준을 낮게 두면 총 행동크기 상한(B1) 아래 자유 작성 직접 권고의 15~44%만 행동 규칙을 지켜 정책가치가 무작위보다 낮았고, 추론 수준을 높게 두면 수용률이 97%를 넘어 모든 기업에 비용 절감을 권하는 단순 규칙 수준에 이르렀다. 둘째, 그 기업의 C3-E 행동을 참조로 보여준 수정은 참조 없는 재검토보다 자유 작성 24 개 조합 모두에서 높았고(7~9 개 조합은 Holm 보정 후 유의), 자기 재검토의 이득 일부는 실행할 수 없던 초안을 고친 효과였다. 셋째, 본 연구의 행동공간과 평가 조건에서는 LLM 이 기업별 정보로 고정된 단순 정책보다 높은 정책가치를 안정적으로 만든다는 증거를 확인하지 못했다. B1 직접 작성은 8 개 설정 어디에서도 단순 규칙을 뚜렷이 넘지 못했고, LLM 은 기업에 따라 행동을 달리 고르기도 했으나 선택이 비용 효율화와 장기 전환에 집중되었다. 같은 조건을 다시 실행하면 행동이 완전히 같은 기업은 7.5~48.6%, 사용한 행동 축이 같은 기업은 38.0~65.6%였다.

Human baseline 과 대조하면 53 개 기업의 1 년 뒤 신용점수에서 LLM 의 권고(α +0.762~+0.857)와 강화학습 참조 LLM 의 권고(+0.776~+0.820)는 문서에 기재된 행동(+0.638)보다 평균이 높았지만 대응 비교에서 통계적 차이를 확인하지 못했다. 행동의 성격도 달랐다. 문서는 투자를 줄이거나(56 개 기업 중 20 개) 늘리는(32 개, 행동공간 밖) 사업 결정을 주로 담았고 단기차입의 장기 전환은 없었다. 다섯 행동 분류에서 LLM 권고가 해당 기업의 문서와 무작위 짝짓기보다 높은 일치를 보인다는 통계적 증거는 확인되지 않았다. 두 행동은 목표와 의사결정의 성격이 다르므로 이 결과를 우열로 해석할 수는 없다. 기업 신용개선 권고의 품질은 LLM 모델 하나만으로 판단할 수 없으며, 평가 장치의 타당성과 정책 하네스의 구성, 실제 경영 의사결정과의 정합성을 함께 검증해야 한다.

주제어: 대규모 언어모형, 기업 신용등급, 알고리즘적 권고, 오프라인 강화학습, 모형 검증, 정책 하네스, Human baseline

제 1 장 서론

제 1 절 연구의 배경

신용등급은 기업의 자금조달 비용과 금융기관의 여신 판단에 직접 영향을 주는 정보이다. 기업과 금융기관은 신용등급을 예측하는 데서 그치지 않고, 어떤 재무 행동을 하면 신용상태가 나아질지를 묻는다. 차입금을 갚을 것인가, 단기차입을 장기로 바꿀 것인가, 성장 투자를 늦출 것인가, 원가와 판매관리비를 줄일 것인가와 같은 질문이다. 이 질문에 답하는 일은 등급을 맞히는 예측 문제가 아니라, 여러 재무 항목 가운데 무엇을 얼마나 바꿀지 정하는 처방 문제이다.

예를 들어 단기차입금이 많은 기업에 "단기차입금의 절반가량을 장기 차입으로 바꾸라"는 권고가 주어졌다고 하자. 만기를 늘리면 1 년 안에 갚아야 할 빚이 줄어 유동성 지표가 좋아진다. 그러나 빚의 총액은 그대로이고, 금융기관이 그런 전환에 응할지도 알 수 없다. "원가와 판매관리비를 줄이라"는 권고는 이익을 늘리지만, 그만큼 줄일 수 있는지는 기업마다 다르다. 두 권고 가운데 어느 쪽이 더 나은지는 무엇을 기준으로 보느냐에 따라 달라질 수 있다. 실제로 본 연구에서 LLM 과 강화학습 정책은 이러한 단기차입의 장기 전환을 자주 권했다. 반면 같은 시기의 신용평가사·증권사 문서 236 건 가운데 단기차입을 장기로 바꾸는 행동을 앞으로의 행동으로 서술한 문서는 없었다. 단기차입이 많은 기업에 대해 신용평가사 문서가 서술한 것은 차입금의 상환이나, 만기가 돌아오는 차입금을 만기연장·재조달로 넘기는 일이었다(제 7 장).

대규모 언어모형(Large Language Model, 이하 LLM)은 재무제표를 읽고 위험 요인을 설명하는 업무에 쓰이기 시작하였다[1, 2]. 신용 분야에서도 LLM 을 활용한 연구가 빠르게 늘고 있으나, 그 대부분은 부도 예측, 등급 분류, 텍스트에서 위험 신호를 찾는 일과 같은 예측·진단 과제에 머물러 있다[3]. LLM 이 재무정보를 해석하고 자연어로 근거를 제시할 수 있다는 점은 개별 기업에 구체적인 개선 행동을 제안하는 처방에도 쓰일 수 있음을 시사한다. 그러나 LLM 이 생성한 처방이 얼마나 좋은지를 판단하는 방법은 아직 정립되어 있지 않다.

처방은 예측보다 검증하기 어렵다. 권고가 실제로 실행되면 기업의 자금조달, 투자, 유동성, 비용구조가 함께 바뀌고, 잘못된 권고의 비용은 기업과 금융기관 모두에게 돌아간다. 금융 분야의 모형 관리 기준과 인공지능 관련 지침이 모형을 사용하기 전에 독립적인 검증, 문서화, 사람의 책임 있는 판단을 요구하는 이유가 여기에 있다[4–9]. LLM 의 신용개선 권고 역시 업무에 쓰기 전에 그 품질을 재현 가능한 절차로 판단할 수 있어야 한다.

본 연구는 이 판단의 방법을 다룬다. LLM 이 2024 회계연도 재무정보를 보고 제안한 1 년 동안의 재무 행동을 공통의 평가 장치에서 신용점수로 바꾸고, 그 점수를 여러 기준선, 강화학습으로 학습한 참조정책, 그리고 신용평가사·증권사 문서에 기재된 기업의 경영·재무 행동과 대조한다. 본 연구는 특정 LLM 의 우열을 가리기보다, 같은 모델이라도 권고를 받는 절차 행동을 표현하는 방식, 행동의 크기에 대한 제약, 참고 정보, 응답을 처리하는 규칙에 따라 결과가 어떻게 달라지는지와 그 결과를 어떤 기준으로 해석해야 하는지를 밝히는 데 중점을 둔다.

제 2 절 문제 제기와 평가 기준

기업별 정답 행동은 자료로 존재하지 않는다. 한 기업은 한 해에 하나의 행동 경로만 실행하므로, 실행되지 않은 행동의 결과는 관측되지 않는다. 기업이 우연히 LLM 의 권고와 비슷하게 행동했더라도 그 결과에는 업황, 금리, 환율, 다른 경영 판단이 함께 섞인다. 재무 행동이 재무제표에 반영되고 다시 신용등급에 반영되기까지의 시차도 길다. 따라서 LLM 의 권고를 실제 결과로 바로 채점할 수는 없다.

실행하지 않은 선택의 결과를 다루어야 하는 문제는 신용 분야에만 있는 것이 아니다. 의학의 치료효과 추정, 추천 시스템의 오프라인 평가, 강화학습의 정책 평가는 모두 같은 어려움을 안고 있다[10]. 본 연구는 이러한 분야에서 쓰이는 세 가지 비교 방법을 함께 사용한다(<표 1-1>). 첫째, 모든 권고를 같은 재무 Simulator 와 신용평가모형에 넣어 같은 계산환경 안에서 비교한다. 둘째, 아무것도 하지 않는 경우, 무작위로 고르는 경우, 모든 기업에 같은 행동을 적용하는 경우, 기업마다 사후적으로 가장 좋은 후보를 고르는 경우와 같은 기준선을 두어 권고의 가치가 어느 정도인지 가늠한다. 셋째, 같은 시점의 신용평가사·증권사 문서에 기재된 그 기업의 경영·사업계획과 전문가의 전망·권고를 평가 장치 밖의 기준으로 둔다.

<표 1-1> 정답이 관측되지 않을 때 쓰는 세 가지 비교 기준

비교 기준	본 연구에서의 형태	답하는 질문
같은 계산환경	모든 권고를 같은 재무 Simulator 와 세 Oracle 에 넣어 점수로 바꾼다	이 환경 안에서 어느 권고가 더 나은가
기준선	무행동(A0), 무작위, 고정 행동(OE), 기업별 사후 최선 후보(상한), 강화학습 참조정책(C3-E)	어느 기준선보다 얼마나 나은가
평가 장치 밖의 기준	기업 경영·사업계획 및 전문가 문서 기반 비교 기준 (Human baseline): 비슷한 시점의 신용평가사·증권사 문서에 기재된 기업의 경영·재무 행동	실제 기업의 계획과 어디서 대응하고 어디서 다른가

주: 세 기준은 모두 정답이 아니며 서로를 보완한다. 실제 신용등급은 Oracle 개발(2007~2019 년)과 기간외 검증(2020~2023 년), 강화학습의 학습 신호(2023 년까지의 등급 변동)에 쓰였고, 2024 년 권고를 채점하는 정답으로는 쓰이지 않았다. 다만 차입 금리가 관측되지 않은 평가 기업 37 개 가운데 31 개는 Simulator 사업계획의 금리를 등급에 따라 추정하였고, 6 개는 전체 중앙값을 사용하였다.

첫째 기준은 평가 장치가 실제 신용상태와 관련이 있을 때에만 의미가 있다. 신용평가모형의 점수가 실제 신용등급과 무관하거나, 재무 Simulator 가 회계적으로 일관되지 않다면, 그 위에서 계산한 정책 간 차이는 평가 장치의 특성일 뿐이다. 이 때문에 본 연구는 정책을 비교하기 전에 평가 장치를 먼저 검증하는 검증 우선(validation-first) 원칙을 따른다.

이 원칙 아래에서 두 가지 간극을 구분한다. 첫째 간극은 평가 장치 내부의 문제이다. 신용평가모형의 점수가 실제 등급의 순서와 변화 방향에 정렬되는지, 재무 Simulator 가 정해진 행동을 회계적으로 일관되게 반영하는지, 그리고 평가 장치가 같은 기업 안에서 서로 다른 행동을 구별하는지를 묻는다. 둘째 간극은 평가 장치와 현실 사이의 문제이다. 평가 장치에서 높은 점수를 받은 행동을 실제로 실행했을 때 신용등급이 오르는지는 별개의 질문이다. 본

연구는 첫째 간극을 개발 단계의 검증 기록과 현재 평가 경로의 재계산으로 점검하고, 둘째 간극은 전문가 문서에 기재된 기업의 계획과 대조하여 일부를 살피되 입증하지는 않는다.

따라서 본 연구는 LLM 의 권고가 실제 신용등급을 개선하는지를 직접 묻지 않는다. 본 연구가 다루는 질문은 실제 신용등급과의 정렬이 확인된 평가 장치에서 측정할 때 LLM 에게 권고를 받는 여러 방식과 비교 정책의 상대적 가치가 어떠하며, 그 권고가 실제 기업의 경영·사업계획과 어떻게 대응하는가이다.

제 3 절 연구 목적과 연구질문

본 연구의 목적은 세 가지이다. 첫째, 정책 비교에 사용하는 평가 장치가 무엇을 검증했고 어디까지 사용할 수 있는지를 밝힌다. 둘째, 학습된 강화학습 참조정책과 LLM 정책을 같은 기업, 같은 행동 정의, 같은 평가 경로에서 비교하고, 권고를 받는 절차와 조건이 정책가치를 어떻게 바꾸는지 분해한다. 셋째, LLM 권고를 평가 장치 밖의 기준인 기업의 경영·사업계획 및 전문가 문서와 대조하여 그 해석 범위를 정한다. 이를 위해 <표 1-2>의 여섯 연구질문을 둔다.

<표 1-2> 연구질문과 분석 범위

구분	연구질문	해당 장
RQ1 평가기반	신용평가모형(Oracle)과 재무 Simulator 를 정책 행동의 비교에 사용할 수 있는 범위는 어디까지인가	제 4 장
RQ2 정책 비교	강화학습 참조정책(C3-E)과 LLM 정책은 무행동·무작위·고정 행동·사후 상한과 비교해 어디에 위치하는가	제 5 장, 제 6 장
RQ3 생성·참조	직접 작성, 진단 유도, 자기 재검토, 강화학습 참조를 본 수정은 정책가치를 바꾸는가	제 6 장
RQ4 강건성	신용평가모형, 행동공간, 행동크기 조건을 바꾸어도 효과의 방향이 유지되는가	제 6 장
RQ5 정보조건	업종과 기업명 정보를 추가하면 권고의 정책가치가 달라지는가	제 6 장
RQ6 외부 기준	LLM 권고는 실제 기업의 경영·사업계획과 전문가 문서에 기재된 경영·재무 행동과 얼마나 대응하고, 어떤 점에서 다른가	제 7 장

주: RQ2~RQ5 의 분석 단위는 2024 회계연도의 같은 575 개 상장기업이다. RQ1 은 Oracle 의 개발·기간외 자료(3,804 기업-연도)와 Simulator 검증 기록을, RQ6 은 문서가 있는 161 개 기업 가운데 비교 가능한 56 개 기업을 사용한다.

RQ1 은 이후 모든 결과를 읽는 범위를 정한다. RQ2 부터 RQ5 까지는 평가 장치 안에서 정책을 비교하는 질문이고, RQ6 은 평가 장치 밖의 기준과 대조하는 질문이다. RQ6 은 평가 장치가 높게 평가한 권고가 실제 기업이 세운 경영·재무 계획과 어떤 관계에 있는지를 다룬다. 평가 장치 안의 비교만으로는 장치의 기준이 현실의 의사결정과 얼마나 떨어져 있는지 알 수 없기 때문이다. 이 비교는 사람과 LLM 이 같은 조건에서 같은 문제를 푸는 경쟁이 아니다. 문서에 기재된 행동의 대부분은 전문가의 직접 권고가 아니라 기업이 추진한다고 밝힌 방침이었다(제 7 장).

제 4 절 주요 발견과 연구의 기여

결과를 미리 요약하면 <표 1-3>과 같다. 각 발견은 제 4 장부터 제 7 장에서 근거와 함께 제시하고, 제 8 장에서 종합한다.

<표 1-3> 주요 발견의 요약

구분	발견	의미
평가 장치의 구축과 한계(RQ1)	Oracle 은 실제 등급의 순서를 따르지만(순위상관 0.69~0.75), 주 평가모형은 기업의 28.5%에서 9 개 후보를 구별하지 못하고, 세 Oracle 의 최고점 후보가 겹치는 기업은 45.4% 이다	등급 예측의 정렬과 행동 채점의 타당성은 따로 확인해야 한다. 결과는 1 년 뒤 점수에 기초한 상대 비교로 해석한다
실행 가능성과 정책 하네스(RQ2)	추론 수준을 낮게 두면 B1 자유 작성의 직접 작성에서 규칙을 지킨 답이 15~44%에 그쳐 정책가치가 무작위보다 낮고, 추론 수준을 높게 두면 모든 기업에 비용 절감을 권하는 단순 규칙 수준에 이른다	정책가치의 차이는 상당 부분 규칙을 지킨 응답의 비율과 실패한 응답의 처리 방식에서 나왔다
생성 방식과 강화학습 참조(RQ3·RQ4)	강화학습 정책의 답을 참조로 보여준 수정은 참조 없는 재검토보다 자유 작성 24 개 조합 모두에서 높았다(네 비교 가운데 유일). 자기 재검토의 이득 일부는 실행할 수 없던 초안을 고친 효과였다	참조정보를 주는 수정이 자기 재검토보다 일관된 효과를 보였다. 실패한 응답의 처리 규칙도 결과에 영향을 준다
정보조건(RQ5)	추론 낮음 설정에서 업종 코드나 기업명을 더해도 12 개 비교 모두에서 보정 후 유의한 차이가 없었다	짧은 식별 정보의 효과는 확인되지 않았다. 더 풍부한 정보의 효과는 별도 검토가 필요하다
기업별 권고의 부가가치와 안정성	B1 직접 작성은 8 개 설정 어디에서도 고정 OE 를 뚜렷이 넘지 못했다. LLM 은 기업에 따라 다른 후보를 고르기도 했으나(C3-E 와 같은 후보를 고른 비율 GPT 42.4%, Gemini 37.7%로 후보 비율에서 기대되는 26.5%, 25.3%보다 높음) 비용 효율화와 장기 전환에 선택이 집중되었다. 다시 실행했을 때 행동이 완전히 같은 기업은 7.5~48.6%, 사용한 행동 축이 같은 기업은 38.0~65.6%였다	LLM 이 기업별 정보를 활용하여 고정된 단순 정책보다 높은 정책가치를 안정적으로 만든다는 증거는 확인되지 않았다
기업의 실제 경영·사업계획과의 차이(RQ6)	53 개 기업의 1 년 신용점수에서 LLM 과 강화학습 참조 LLM 의 권고는 문서에 기재된 기업의 경영·재무 행동보다 평균이 높았으나(α +0.76~+0.86 대 +0.64) 대응 비교에서 통계적 차이를 확인하지 못했다. 문서는 투자 축소·확대 같은 사업 결정을 주로 기재했고, 단기차입의 장기 전환은 없었다. 다섯 행동 분류에서 LLM 권고가 해당 기업의 문서와 무작위 짝짓기보다 높은 일치를 보인다는 통계적 증거는 확인되지 않았다	두 행동은 목표와 의사결정의 성격이 달라, 점수의 차이를 LLM 과 기업 경영 판단의 우열로 해석할 수 없다

주: 수치는 주 평가모형(Oracle-α) 기준이다. C3-E 와의 후보 일치는 후보 선택·추론 높음의 직접 작성, 반복 실행의 일치율은 추론 높음·B1 설정의 자유 작성 직접 작성에서 두 모델의 값이다.

이 발견에 근거한 본 연구의 기여는 다음과 같다.

첫째, 정답이 관측되지 않는 처방을 평가할 때 평가 장치부터 검증하는 절차를 기업 신용 영역에 구체화하고, 등급 예측의 정렬과 행동 채점의 타당성이 다르다는 것을 수치로 보였다. 신용평가모형과 실제 신용등급의 정렬, 재무 Simulator 의 회계 일관성과 실제 재무 재현, 같은 기업 안에서 후보행동을 구별하는 능력을 서로 다른 검증으로 나누어 보고하였다. 그 결과 구간형 점수표는 기업의 28.5%에서 9 개 후보행동에 모두 같은 점수를 주었고, 구조가 다른 세 평가모형은 최선 행동과 정책의 순위에서 자주 엇갈렸다.

둘째, 같은 두 LLM 에서도 권고를 받는 절차와 조건에 따라 정책가치가 무작위보다 낮은 수준부터 강화학습 정책에 가까운 수준까지 달라진다는 것을 2 개 모델, 2 개 생성 설정, 21 개 조건, 575 개 기업의 48,300 건 요청으로 보였다. 그 차이의 상당 부분은 규칙에 맞는 행동을 만들었는지와 규칙을 어긴 응답을 어떻게 처리했는지에서 나왔다. 이 결과에 근거하여 본 연구는 모델 이름보다 모델과 권고 절차, 제약, 참조, 응답 처리 규칙의 결합, 즉 정책 하네스(policy harness)를 평가 단위로 삼을 것을 제안한다.

셋째, 학습된 강화학습 정책을 LLM 의 정답이 아닌 외부 참조로 사용하는 설계를 제시하였다. 같은 초안에서 갈라지는 자기 재검토, 참조 수정, 다른 기업 참조 수정을 비교하여 재검토 자체의 효과와 새 정보를 받는 효과, 그리고 참조가 주어진다는 사실의 효과와 그 기업에 맞는 참조의 효과를 구분하였다.

넷째, 기업별 권고가 단순 정책을 넘는 가치를 만드는지를 따로 살폈다. 본 연구의 행동공간과 평가 조건에서는 LLM 이 기업별 정보를 활용하여 고정된 단순 정책보다 높은 정책가치를 안정적으로 만들어낸다는 증거를 확인하지 못했다. LLM 은 기업 상태에 따라 행동을 달리 선택하기도 했으나 비용효율화와 단기차입 장기 전환에 선택이 집중되었고, 같은 조건을 다시 실행하면 기업별 권고가 자주 달라졌다.

다섯째, 신용평가 의견서와 리서치 보고서 236 건에 기재된 기업의 경영·사업계획과 전문가의 전망·권고로 평가 장치 밖의 비교 기준(Human baseline)을 만들고, LLM 권고와 대조하였다. 평가 장치에서 LLM 권고의 평균 정책가치는 문서에 기재된 기업의 경영·재무 행동보다 높았지만 대응 비교에서 통계적 차이를 확인하지 못했다. 문서는 투자 축소·확대 같은 사업 결정을 주로 담았고, LLM 권고와의 대응은 제한적이었다. 두 행동은 목표와 의사결정의 성격이 다르므로, 이 비교는 우열이 아니라 LLM 권고와 실제 경영 의사결정 사이의 거리를 보여 준다.

여섯째, 주요 결과를 다시 계산할 수 있는 공개 재현 키트를 함께 제공한다. 주요 결과는 유료 API 호출이나 GPU 학습 없이 보존된 기업 단위 관측값에서 다시 계산되어 914 개 행의 원래 결과 등록부와 대조된다(주 분석 96 개 행은 표본 수와 평균을, 보조 결과 722 개 행은 구간과 p 값까지 대조한다).

이 결과들은 하나의 결론으로 모인다. 기업 신용개선 권고의 품질은 LLM 모델 하나만으로 판단할 수 없으며, 평가 장치의 타당성과 정책 하네스의 구성, 실제 경영 의사결정과의 정합성을 함께 검증해야 한다. 다만 본 연구는 LLM 의 권고가 실제 신용등급을 높인다는 것을 입증하지 않으며, 특정 모델이 보편적으로 우월하다고 주장하지도 않는다. 결과는 정해진 평가 장치와 표본, 실행 조건 안에서의 비교이다.

제 5 절 논문의 구성

제 2 장은 기업 신용위험 측정, 알고리즘적 권고, 오프라인 강화학습, 정책으로서의 LLM, 평가의 타당성에 관한 선행연구를 검토한다. 제 3 장은 연구의 전체 구조와 자료, 행동공간, 평가 장치, 비교 기준선, LLM 실험 설계, 통계 분석 방법을 정의한다. 제 4 장은 평가 장치를 검증하고(RQ1), 제 5 장은 강화학습 참조정책 C3-E 의 구성과 성과를 기준선과 비교한다(RQ2). 제 6 장은 LLM 실험의 결과를 수용률과 정책가치, 권고 방식, 행동공간과 행동크기 조건, 정보조건, 반복 실행의 안정성 순서로 제시한다(RQ2~RQ5). 제 7 장은 LLM 권고를 신용평가사·증권사 문서에 기재된 기업의 경영·재무 행동(Human baseline)과 대조한다(RQ6). 제 8 장은 결과를 종합하여 여섯 가지 논점을 논의하고, 실무적 시사점, 한계와 향후 연구를 정리한다.

이 분야에 익숙하지 않은 독자를 위해 본문에서 자주 쓰는 용어를 <표 1-4>에 정리하였다.

<표 1-4> 주요 용어

용어	뜻
Oracle(α·β·γ)	재무제표를 받아 0~100 의 신용점수를 내는 신용평가모형. α 는 스코어카드(주 평가모형), β 는 순서형 로짓, γ 는 그래디언트 부스팅이다
재무 Simulator	기업의 재무상태에 행동을 반영하여 1 년 뒤 재무제표를 계산하는 도구
평가 장치	Simulator 와 Oracle 의 결합. 모든 권고를 같은 방식으로 채점한다
정책가치	권고를 실행했을 때의 1 년 뒤 점수에서 아무것도 하지 않았을 때(A0)의 점수를 뺀 값의 기업 평균
후보행동	표준 크기로 정한 9 개 행동. A0 무행동, DL 상환, RF 단기차입의 장기 전환, CX 설비투자 축소, WC1·WC2 운전자본 개선, OE 비용 절감, MX1·MX2 복합
기준선	무작위(9 개 후보 점수의 평균), 고정 OE(모든 기업에 비용 절감), 상한(기업마다 사후적으로 가장 좋은 후보)
C3-E	과거 재무 자료와 신용등급 변화로 학습한 강화학습 참조정책
자유 작성 / 후보 선택	8 개 행동 축의 크기를 직접 쓰는 방식 / 9 개 후보 가운데 하나를 고르는 방식
행동크기 조건(B1 / BINF)	정규화한 총 행동크기를 후보 하나의 크기(1) 이하로 제한하는 조건 / 총 행동크기 무지시 조건
생성 설정	모델이 답하기 전에 쓰는 추론의 양과 출력 한도. 추론 낮음(Baseline)과 추론 높음(High)
권고 방식	C4 직접 작성, C5 진단 유도, C4R 참조 없는 자기 재검토, C6-E 해당 기업의 강화학습 참조를 제공한 수정, C6-EX 다른 기업의 참조를 제공한 수정
수용률 / 엄격 규칙	행동 규칙을 모두 지킨 응답의 비율 / 규칙을 어긴 응답을 무행동으로 처리하고 모든 기업을 평가하는 규칙
정책 하네스	모델, 생성 설정, 권고 방식, 행동공간, 행동크기 조건, 참조, 응답 처리 규칙의 결합. 본 연구의 평가 단위
Human baseline	기업 경영·사업계획 및 전문가 문서 기반 비교 기준. 신용평가사·증권사 문서에 기재된 기업의 향후 경영·재무 행동(회사 방침, 전문가의 전망과 권고)으로 구성

제 2 장 관련 연구

이 장은 본 연구가 기대는 다섯 갈래의 선행연구를 검토한다. 기업 신용위험의 측정, 알고리즘적 권고와 반사실적 설명, 오프라인 강화학습, 정책으로서의 LLM, 그리고 평가의 타당성과 외부 비교 기준이다. 각 절은 선행연구가 무엇을 해결했고 무엇을 남겼는지 확인한 뒤, 남은 문제가 본 연구의 어떤 설계로 이어지는지를 정리한다.

제 1 절 기업 신용위험의 측정과 신용평가모형

기업 신용위험의 계량화는 세 흐름으로 발전하였다. 첫째는 회계정보에 기반한 흐름이다. Beaver[11]는 개별 재무비율이 부도 기업과 건전 기업을 부도 수년 전부터 구분할 수 있음을 보였고, Altman[12]은 다섯 개 재무비율의 판별함수로 이를 다변량 문제로 확장하였다. Ohlson[13]은 판별분석의 분포 가정을 비판하고 로지스틱 회귀로 부도확률을 직접 추정하였으며, 이 확률적 접근은 이후 순서형 모형을 이용한 신용등급 예측으로 이어졌다.

둘째는 시장정보에 기반한 구조모형이다. Merton[14]은 자기자본을 기업가치에 대한 콜옵션으로 보고, 기업가치가 부채가치 아래로 떨어지는 사건을 부도로 정의하였다. 이 구조에서 나온 부도거리(distance-to-default)는 KMV 모형을 통해 실무의 부도 예측 지표로 자리 잡았다[15]. 셋째는 기계학습의 흐름으로, 트리 앙상블과 신경망은 재무비율 사이의 비선형성과 상호작용을 반영하여 예측력을 높였다[16].

세 흐름은 모두 기업의 신용상태가 얼마나 위험한지를 측정하고 예측하는 문제를 다룬다. 본 연구는 이 세 흐름의 대표 구조를 평가 장치로 차용한다. 회계 비율을 구간 점수로 바꾸어 합산하는 스코어카드(Oracle-α), 등급의 순서를 확률적으로 모형화하는 순서형 로짓(Oracle-β), 비선형 관계를 학습하는 그래디언트 부스팅 트리(Oracle-γ)이다. 또한 강화학습 참조정책의 보조 보상에는 Merton 모형의 부도거리를 회계자료로 근사한 부채부담 항목이 포함된다.

금융 실무에서 신용평가모형은 예측력만으로 쓰이지 않는다. 바젤 내부등급법의 최소 요건은 모형의 개발, 검증, 문서화, 지속적인 사용을 요구하고[5], 모형위험 관리 지침은 모형을 쓰기 전에 개념적 타당성과 성과를 독립적으로 검증할 것을 요구한다[4]. 본 연구는 이러한 요구를 두 가지 방식으로 반영한다. 주 평가모형인 Oracle-α 를 실무에서 널리 쓰이는 스코어카드 구조로 구성하고, 정책을 비교하기 전에 평가모형이 개발에 쓰지 않은 기간(out-of-time, OOT)에서도 실제 신용등급과 정렬되는지를 먼저 확인한다. 다만 본 연구의 검증이 감독상 모형 승인 요건 전체를 충족한다는 뜻은 아니다.

최근에는 LLM 을 신용 분야에 적용하려는 연구가 빠르게 늘고 있다. Golec 과 Alabduljalil[3]의 체계적 문헌검토는 이 연구들을 해석가능성 중심으로 분류하면서, 대부분이 여전히 부도 예측, 등급 분류, 텍스트 기반 위험 신호 추출과 같은 분류·예측 과제에 LLM 을 투입하고 있음을 보였다. 재무제표 분석에서 LLM 이 이익의 방향을 예측하는 데 전문 분석가와 견줄 만한 성과를 보였다는 보고도 있다[1]. 반면 LLM 이 기업에 구체적인 재무 행동을 처방하고 그 처방을 검증

가능한 방식으로 평가한 연구는 드물다. 본 연구는 예측·진단의 활용과 구분하여, 처방으로 생성된 재무 행동을 어떤 평가 장치와 실행 규칙 아래에서 비교할지를 연구문제로 삼는다.

제 2 절 알고리즘적 권고와 반사실적 설명

설명가능한 기계학습에서 반사실적 설명(counterfactual explanation)은 “입력이 어떻게 달라졌다면 모형의 결과가 바뀌었을 것인가”를 제시하는 접근이다[17]. Ustun 등[18]은 이를 실행가능성(actionability)의 문제로 바꾸었다. 결과를 뒤집는 입력의 변화가 존재한다는 것과 그 변화를 사람이 실제로 실행할 수 있다는 것은 다르다는 지적이다. 이후 실행가능한 권고(actionable recourse) 연구는 바꿀 수 있는 특성의 구분, 변화 방향의 제약, 감당할 수 있는 변화량의 상한을 표준 구성요소로 삼았다[19].

Karimi 등[20]은 권고를 개입(intervention)의 관점에서 다시 정의하였다. 특성 사이에 인과구조가 있다면 한 특성의 변경은 다른 특성으로 전파되므로, 권고는 특성값의 나열이 아니라 인과모형 위의 개입이어야 한다는 것이다[21]. 인과 지식이 불완전할 때 권고의 성공이 확률적일 수밖에 없다는 점[22], 권고를 실행하는 과정에서 생기는 위험을 정책 차원에서 관리해야 한다는 점[23]도 후속 연구에서 다루어졌다.

권고를 채점하는 모형 자체의 역할을 다룬 연구도 있다. 예측 성능이 거의 같은 여러 모형이 개별 사례에서는 서로 다른 예측을 낼 수 있다는 예측 다중성(predictive multiplicity)[24]은 권고에도 이어진다. 한 모형에서 찾은 반사실적 설명이 성능이 비슷한 다른 모형에서는 유효하지 않을 수 있기 때문이다[25]. 또한 모형의 점수를 올리는 변화가 실제 결과를 개선하는 변화인지, 점수에 쓰이는 지표만 바꾸는 변화인지를 구분하려면 인과적 지식이 필요하다는 지적이 있다[26]. 두 문제는 예측 성능이 좋은 모형이 권고도 타당하게 채점하는지에 대한 의문으로 이어진다. 본 연구가 하나의 평가모형 대신 구조가 다른 세 신용평가모형을 함께 보고하고 평가 장치 밖에 별도의 비교 기준을 두는 것은 이 때문이다.

권고 연구는 주로 개인의 대출 심사와 같은 단일 시점의 판단을 대상으로 발전하였다. 기업 신용등급을 대상으로 한 연구는 비교적 최근에 나타났다. Wang 등[27]은 기업 신용등급 모형에 대해 가장 적은 수의 재무비율 변경으로 등급을 바꾸는 반사실적 설명을 찾는 알고리즘을 제안하였다. Dong 등[28]은 LLM 의 문맥 내 학습(in-context learning)으로 만든 표 형식 자료의 예측기에 대해 권고를 계산하는 방법을 제안하여, LLM 이 판단에 쓰이는 상황으로 권고 연구를 넓혔다.

개인 권고에서 기업 권고로 대상을 옮기면 문제의 구조가 바뀐다. 첫째, 기업의 재무 행동은 부채, 투자, 운전자본, 비용에 걸친 다차원 벡터이며, 여러 항목을 함께 바꾸는 조합 자체가 하나의 전략이 된다. 둘째, 한 항목의 변화는 회계항등식을 통해 다른 항목으로 전파된다. 부채 상환은 현금을 줄이고, 원가 절감은 이익과 현금을 늘린다. 셋째, 행동과 등급 반영 사이에 결산과 정기평가의 시차가 있다. 따라서 기업 권고는 단일 시점의 특성 변경보다 행동을 반영한 1 년 뒤 재무상태를 기준으로 평가해야 한다.

본 연구의 행동공간과 재무 Simulator 는 이 세 가지 차이를 반영한다. “부채비율을 낮추라” 는 결과 목표 대신 상환, 단기차입의 장기 전환, 성장 투자 유예, 운전자본 회전, 비용률과 같이 재무제표에 적용할 수 있는 관리 행동을 먼저 정하고, 이 행동을 회계항등식을 지키는 Simulator 로 1 년 뒤 재무상태에 반영한 다음 신용평가모형으로 채점한다. 다만 1 년의 비교 기간은 장기 성장과 투자 능력의 손실까지 평가하지 못한다. 이 한계는 제 7 장에서 기업의 실제 경영·사업계획과 대조할 때 다시 다룬다.

제 3 절 오프라인 강화학습

기업의 재무 행동은 매년 재무상태에서 경영계획을 실행하고, 그 결과가 결산을 거쳐 다음 재무상태로 이어지는 순차적 과정이다. 이 과정은 상태, 행동, 보상, 전이로 이루어진 마르코프 결정과정으로 형식화할 수 있다. 그러나 기업에 임의의 재무 결정을 시행하고 등급 변화를 관측할 수는 없으므로, 환경과 직접 상호작용한다는 강화학습의 표준 전제가 성립하지 않는다. 이러한 상황에서 과거 자료만으로 정책을 학습하는 방법이 오프라인 강화학습이다[10].

오프라인 강화학습의 핵심 난점은 분포 이동(distribution shift)이다. 학습된 정책이 자료에 거의 없던 행동을 고르면, 가치함수가 그 행동을 학습한 적이 없어 임의로 높은 값을 줄 수 있고 정책이 잘못된 방향으로 향한다. 이에 대한 대응은 두 갈래이다. 한 갈래는 보수적 방법으로, 학습 정책을 자료의 행동 분포 가까이에 묶어 두거나[29, 30], 분포 밖 행동의 가치에 벌점을 주어 보수적으로 추정한다[31]. Implicit Q-Learning(IQL)은 자료 안의 행동만으로 가치를 추정하여 분포 밖 행동을 직접 평가하지 않는다[32]. 다른 갈래는 자료 증강으로, 전이모형을 학습해 합성 경험을 만들되 불확실한 영역을 억제하거나[33–35], 국소적인 인과구조를 이용해 반사실적 전이를 만든다[36].

본 연구의 강화학습 참조정책은 두 갈래를 함께 쓴다. 관측된 기업-연도에서 행동만 표준 후보로 바꾼 반사실적 전이를 회계항등식 기반의 결정론적 Simulator 로 생성하고, 가치 학습은 IQL 로 수행한다. 확률적 전이모형을 학습할 때 생기는 불확실성은 줄일 수 있지만, Simulator 자체의 모형위험은 남으므로 제 4 장에서 따로 검증한다. 또한 본 연구의 학습은 할인계수 0 의 한 해 행동 선택 문제로, 장기 누적보상을 학습하는 완전한 다기간 문제라기보다 맥락형 밴딧(contextual bandit)에 가까운 한 단계 오프라인 의사결정이다. 따라서 본 연구는 강화학습 정책을 주된 연구 대상이 아니라, 도메인 자료로 학습한 외부 참조로 사용한다.

제 4 절 정책으로서의 LLM

LLM 을 행동을 생성하는 정책으로 볼 때 관련되는 연구는 추론 유도, 자기 수정, 외부 참조의 세 흐름이다. 추론 유도 연구는 중간 추론을 쓰게 하는 지시가 일부 과제의 성능을 높일 수 있음을 보였다[37–39]. 추론에 더 많은 계산을 쓰게 하면 성능이 오를 수 있다는 결과도 보고되었다[40]. 반면 그 이득이 수학·기호 추론에 집중되어 있거나[41], 응답 형식의 제약이 강할수록 성능이 떨어질 수 있다는 결과도 있다[42, 43]. 엄격한 형식의 8 차원 행동 벡터를 작성해야 하는 본

연구의 과제에서 진단을 유도하거나 추론 설정을 높이는 것이 정책가치를 높이는지는 경험적으로 확인해야 하는 문제이다.

본 연구는 추론에 관한 개입을 두 수준으로 나눈다. 하나는 같은 모델과 추론 설정에서 유동성, 레버리지와 만기구조, 영업효율, 수익성을 먼저 진단하도록 지시하는 프롬프트 조건(C5)이다. 다른 하나는 공급자가 제공하는 추론 설정을 높이고 출력 한도를 늘린 생성 설정(추론 높음, High)이다. 두 조건은 서로 다른 개입이며, 후자는 추론 설정과 출력 한도가 함께 바뀐 묶음 변경이다.

자기 수정 연구에서 Self-Refine 은 모델이 자기 출력에 피드백을 주고 다시 고치는 절차가 여러 과제에서 유효할 수 있음을 보였다[44]. 그러나 외부 피드백이 없는 자기 수정은 정답률을 높이지 못하거나 오히려 낮출 수 있고[45], 성공 사례의 상당수는 두 번째 단계에서 들어온 외부 정보나 의도적으로 약하게 만든 첫 응답의 영향을 포함한다는 비판이 있다[46]. 따라서 수정 후 결과가 좋아졌다면, 다시 검토했기 때문인지 새로운 정보가 들어왔기 때문인지를 구분해야 한다 본 연구의 자기 재검토(C4R)는 외부 정보 없이 같은 초안을 다시 보게 하는 조건이고, 참조 수정(C6-E)은 같은 초안에 강화학습 참조정책의 행동을 추가로 보여주는 조건이다. 두 조건은 같은 초안에서 각각 갈라지므로 둘의 차이가 참조정보 추가 패키지의 증분을 나타낸다.

LLM 을 정책으로 볼 때에는 출력의 유창성과 행동의 품질을 구분해야 한다. LLM 은 금융 영역에서 수치, 계산, 시점에 관한 오류를 그럴듯한 문장으로 제시할 수 있다[47, 48]. 설명이 자연스럽더라도 필요한 행동 값을 읽을 수 없거나, 허용 범위를 벗어나거나, 행동의 크기 제한을 지키지 않으면 그 권고는 그대로 실행할 수 없다. 본 연구는 행동 규칙을 지켜 실행 가능한 응답의 비율(수용률)과, 실행 가능한 행동의 정책가치를 구분하여 측정하고, 규칙을 어긴 응답을 무행동으로 처리하는 운영 규칙 전체의 가치를 함께 평가한다.

제 5 절 평가의 타당성과 외부 비교 기준

측정 타당성 연구는 평가 점수가 측정하려는 개념을 실제로 반영하는지를 먼저 확인해야 한다고 본다[49]. HELM 은 정확도 하나가 아니라 평가 시나리오와 여러 평가 항목을 함께 명시해야 함을 강조했고[50], 최근 연구는 LLM 벤치마크의 상당수가 구성 타당성을 충분히 갖추지 못했다고 지적하였다[51]. 에이전트 평가 연구도 평가 대상이 모델 하나가 아니라 프롬프트, 도구, 후처리가 결합된 하네스이며, 그 조합을 명시하지 않으면 비교와 재현이 어렵다고 보았다[52, 53]. 본 논문은 모델, 생성 설정, 권고 방식, 행동공간, 행동크기 조건, 참조, 응답 처리 규칙의 결합을 정책 하네스(policy harness)라 부르고, 이를 평가의 단위로 삼는다. 반면 행동을 재무상태에 반영하고 점수로 바꾸는 재무 Simulator 와 신용평가모형의 결합은 평가 장치라 부른다.

평가 장치 안의 비교는 장치가 정한 기준에 따른 상대 비교이다. 장치의 기준이 현실의 판단과 얼마나 떨어져 있는지 보려면 장치 밖의 기준이 필요하다. 사람의 판단은 이러한 외부 기준으로 자주 쓰이지만, 사람 판단 역시 정답은 아니며, 같은 정보를 받은 사람인지, 어떤 목적의 문서인지에 따라 성격이 달라진다. 본 연구의 Human baseline 은 같은 시점에 공개된 신용평가

의견서와 리서치 보고서에 기재된 기업의 경영·사업계획과 전문가의 전망·권고로 구성한 비교 기준으로, LLM 과 같은 정보를 받은 전문가 설문이 아니라 실무 문서에 나타난 기업의 경영·재무 행동이다.

문서의 서술을 행동으로 옮기는 과정에는 해석이 들어가므로, 코딩 지침과 라벨 확정 절차를 함께 밝혀 둘 필요가 있다. 본 연구는 지침에 따라 문서마다 진술 유형과 행동을 기록하고, 라벨을 확정하기 전에 236 건 전체를 원문과 다시 대조하였다(제 7 장).

제 6 절 선행연구의 한계와 본 연구의 위치

앞의 검토는 기업 신용개선 권고를 평가할 때 필요한 네 가지 요구로 정리된다(<표 2-1>). 권고의 점수를 실제 신용성과와 구분하고 평가 장치부터 검증해야 하며, 점수화 이전에 어떤 행동이 실제로 실행 가능한 형태로 만들어졌는지를 밝혀야 한다. 자기 재검토와 외부 참조는 같은 출발점에서 비교해야 하고, 평가 장치의 기준이 실무 관점과 얼마나 다른지를 장치 밖에서 확인해야 한다.

<표 2-1> 선행연구의 공백과 본 연구의 설계

선행연구의 흐름	남은 문제	본 연구의 설계
신용위험 측정	예측력이 처방의 타당성을 보장하지 않음	평가 장치를 먼저 검증하고, 행동 간 구별력까지 보고
알고리즘적 권고	기업의 다차원 행동과 회계적 전파, 시차를 다룬 연구가 적음	8 개 관리 행동 축, 회계항등식을 지키는 1 년 Simulator
오프라인 강화학습	상호작용 없이 학습한 정책의 지위가 불명확함	학습 정책을 정답이 아닌 LLM 의 외부 참조로 사용
정책으로서의 LLM	추론 유도·자기 수정·외부 정보의 효과가 뒤섞임	같은 초안에서 갈라지는 자기 재검토·참조 수정·다른 기업 참조 수정
평가의 타당성	모델 단위 평가, 장치 내부 비교에 머묾	정책 하네스 단위 평가, 공개 문서에 기재된 기업의 경영·재무 행동과의 대조 (Human baseline)

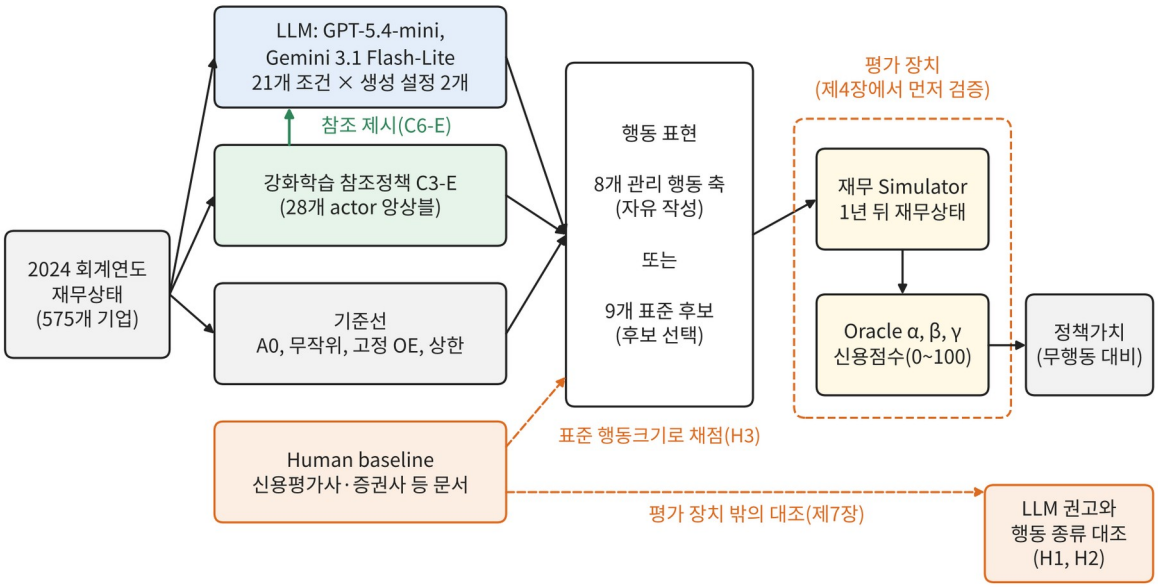
본 연구는 새로운 파운데이션 모델이나 최적화 알고리즘을 제안하지 않는다. 대신 기업 재무 행동의 생성에서 관측되는 정책가치가 평가 장치와 정책 하네스에 어떻게 의존하는지를 재현 가능한 자료로 보여주고, 그 가치를 평가 장치 밖의 기준과 대조한다.

제 3 장 연구 설계

이 장은 실제로 실행한 실험을 기준으로 연구의 전체 구조, 자료와 표본, 행동공간, 평가 장치, 비교 기준선, LLM 실험 설계, 통계 분석 방법을 정의한다. 같은 이름의 조건이라도 행동의 정의나 응답 처리 규칙이 다르면 결과를 합칠 수 없으므로, 각 조건의 입력, 허용되는 행동, 실패의 처리, 참조의 배정을 명시한다. Human baseline(제 7 장)을 제외한 모든 정의와 수치는 공개 재현 키트에 동결된 계약 파일과 결과 등록부를 따른다. 등록부에 없는 후보 선택·추론 낮음 설정의 Holm 보정 결과는 같은 기업 단위 관측값에서 같은 방법으로 별도 계산하였다.

제 1 절 연구의 전체 구조

본 연구는 기업 신용개선 권고를 평가하는 틀을 만들고, 이를 이용해 LLM 에게 권고를 받는 방식들을 비교한다(<그림 3-1>). 권고의 주체는 네 가지이다. LLM, 강화학습 참조정책 C3-E, 기준선, 그리고 신용평가사·증권사 문서에 기재된 기업의 경영·재무 행동(Human baseline)이다. 모든 주체의 권고는 같은 형식의 행동, 즉 8 개 관리 행동 축의 크기(자유 작성) 또는 9 개 표준 후보행동 가운데 하나(후보 선택)로 표현된다.



<그림 3-1> 연구 전체 구조

표현된 행동은 같은 경로로 채점된다. 재무 Simulator 가 기업의 2024 회계연도 재무상태에 행동을 반영하여 1 년 뒤의 재무제표를 계산하고, 구조가 다른 세 신용평가모형(Oracle α·β·γ)이 그 재무제표에 0~100 의 신용점수를 매긴다. 정책가치는 행동을 적용했을 때의 점수에서 아무 행동도 하지 않았을 때(A0)의 점수를 뺀 값이다. 모든 정책이 같은 기업, 같은 Simulator, 같은 Oracle 을 쓰므로 정책 간 차이는 같은 계산환경 안의 상대적 비교로 해석된다.

평가 장치 자체의 타당성은 RQ1 에서 따로 검증한다. Simulator 가 계산한 1 년 뒤 재무상태를 실제 다음 해 재무상태와 비교하고, Oracle 의 점수를 실제 신용등급과 비교한다. 이 검증이 이후 모든 정책 비교를 읽는 범위를 정한다.

제 2 절 자료와 표본

재무제표와 외부 신용등급은 상장폐지 기업을 포함한 한국 상장기업 재무 데이터베이스(KIS-VALUE 등)에서 구축하였다. 상장폐지 기업을 포함한 것은 존속 기업만 남기는 생존 편향을 줄이기 위해서이다. 자료는 쓰임에 따라 시점을 나누었다(<표 3-1>).

<표 3-1> 자료의 구분과 용도

구분	기간	규모	용도
Oracle 개발	2007~2019 사업연도	2,015 기업-연도	외부 신용등급에 맞추어 세 Oracle 을 적합
Oracle 기간외 검증	2020~2023 사업연도	1,789 기업-연도	개발에 쓰지 않은 기간에서 등급 정렬 확인
강화학습 학습	의사결정 2022 이하, 결과 2023 이하	가치학습 2,642 전이 (의사결정 2008~2022)	C3-E 학습. 표현학습·행동복제는 등급이 없는 기업을 포함한 상장기업 패널을 함께 사용
정책 평가	2024 사업연도(도착 2025)	575 개 기업	모든 정책의 권고와 채점
Human baseline	2025.1.1~2025.6.30 공개 문서	236 건, 161 개 기업	평가 장치 밖의 비교 기준

주: 강화학습 학습 전이 2,642 건 가운데 다음 해 외부 신용등급이 관측된 전이는2,080 건이다. 정책 평가의 도착 시점(2025)은 Simulator 가 계산한 가상의 재무상태이며 실제 관측된 실행 성과가 아니다.

정책 평가의 대상은 2024 회계연도 재무상태를 Simulator 와 세 Oracle 에 모두 입력할 수 있도록 구성된 상장기업 575 개로, 재현 키트의 평가 코호트로 고정되어 있다. 2024 년 말 기준으로 코스닥 기업이 401 개, 코스피 기업이 152 개이며 나머지 22 개는 해당 시점의 시장 정보가 확인되지 않았다. 575 개 기업은 외부 신용등급과 필요한 재무 항목이 있는 기업으로 범위가 좁아진 집합이므로 한국 기업 전체의 무작위 표본이 아니다.

강화학습 학습 자료는 의사결정 연도를 2022 년 이하, 결과 관측 연도를 2023 년 이하로 제한하였다. 평가 연도인 2024 년의 자료는 학습에 쓰지 않았다. 최종 참조정책의 구성 선정에 2024 년 평가 결과를 사용한 경위는 제 5 장 제 2 절에 밝힌다.

제 3 절 행동공간

(1) 8 개 관리 행동 축

권고는 경영진이 1 년 안에 직접 결정할 수 있는 8 개 관리 행동 축으로 표현한다(<표 3-2>). 축은 재무제표에 직접 적용할 수 있는 행동으로 정하였고, “부채비율을 낮춘다” 와 같은 결과

목표는 축으로 쓰지 않았다. 매출 성장, 자산 매각, 유상증자처럼 경영진이 단독으로 정하기 어렵거나 외생적 사업계획에 속하는 항목은 축에서 제외하였다.

<표 3-2> 8 개 관리 행동 축의 정의와 허용 범위

축	의미	허용 범위	정규화 척도
성장 투자 축소	성장성 설비투자 가운데 미룰 비율. 유지·보수 투자는 보존하며 자산 매각이 아님	0 ~ 1	0.631
총차입금 상환	기초 이자부부채 가운데 상환을 요청하는 비율. 실제 상환은 상환 가능 현금과 유동성 여유에 따라 제한	0 ~ 1	0.347
단기차입 장기전환	기초 단기차입금 가운데 장기 차입으로 옮기는 비율. 원금 총액은 바뀌지 않음	0 ~ 1	0.474
재고 회전	재고자산회전율(매출원가/재고)의 가산적 변화	−3 ~ 3	1.398
매출채권 회전	매출채권회전율(매출/매출채권)의 가산적 변화	−3 ~ 3	0.934
매입채무 회전	매입채무회전율(매출원가/매입채무)의 가산적 변화. 음수는 지급 기간 연장	−3 ~ 3	2.454
매출원가율	매출원가/매출의 가산적 변화. −0.01 은 1% 포인트 하락	−0.03 ~ 0.03	0.0269
판매관리비율	판매관리비/매출의 가산적 변화	−0.02 ~ 0.02	0.0172

주: 이자부부채는 단기차입금, 유동성 장기부채, 비유동 장기차입금, 사채의 합이며 매입채무를 포함한 총부채와 다르다. 총차입금 상환과 단기차입 장기전환은 한 행동에서 동시에 양수일 수 없다. 정규화 척도는 학습 기간(기준연도 2022 년 이하)의 실제 재무 변화에서 축별 개선 방향 크기의 중앙값 (P50)으로 정해 동결한 값이며, 평가 대상 기업과 Oracle 점수는 쓰지 않았다.

축마다 단위가 다르므로 행동의 크기는 각 축의 절댓값을 정규화 척도로 나누어 합한 정규화 총 행동크기로 잰다.

$$\mathrm{I}(\mathrm{a}) = \Sigma_{\mathrm{j}=1}{}^{8}\ |\mathrm{a_j}| \ / \ \mathrm{s_j} \qquad (3.1)$$

여기서 a_j 는 j 번째 축의 행동 값이고 s_j 는 그 축의 정규화 척도이다. 이 값은 서로 다른 단위의 행동을 같은 기준으로 비교하기 위한 연구용 크기이며, 기업이 부담하는 원화 비용이나 자금조달 한도를 뜻하지 않는다.

(2) 9 개 표준 후보행동

8 개 축 위에 9 개의 표준 후보행동을 정의하였다(<표 3-3>). A0 를 제외한 8 개 후보의 정규화 총 행동크기는 모두 1 이다. 복합 후보도 행동크기는 1 이며, 이를 여러 축에 나누어 배분한다. 예를 들어 OE 는 매출원가율과 판매관리비율에 0.5 씩, MX1 은 총차입금 상환에 0.5, 두 비용 축에 0.25 씩 배분한다. 강화학습 참조정책과 후보 선택형 LLM 은 이 9 개 가운데 하나를 고르며, 고정 OE 와 같은 기준선도 이 후보로 정의된다.

<표 3-3> 9 개 표준 후보행동

후보	내용	적용 행동크기(축별 정규화 척도 기준)
A0 무행동	기존 사업계획 유지	없음
DL 부채상환	이자부부채 원금 축소	이자부부채의 34.70% 상환
RF 장기 전환	단기차입금을 장기차입금으로 전환(원금 유지)	단기차입금의 47.41% 전환
CX 설비투자 축소	유지·보수 투자는 보존, 성장 설비투자 축소	성장 설비투자의 63.10% 축소
WC1 운전자본 회수	재고·매출채권 회전 개선	재고 +0.699 회, 매출채권 +0.467 회
WC2 공급자금융	WC1 과 매입채무 지급기간 연장	재고 +0.466 회, 매출채권 +0.311 회, 매입채무 −0.818 회
OE 비용효율화	매출원가·판매관리비 절감	매출원가율 −1.344%p, 판매관리비율 −0.858%p
MX1 상환·비용 복합	DL 과 OE 의 결합	부채 17.35% 상환, 원가율 −0.672%p, 판관비율 −0.429%p
MX2 상환· 운전자본 복합	DL 과 운전자본 개선의 결합	부채 17.35% 상환, 재고 +0.280 회, 매출채권 +0.187 회, 매입채무 −0.245 회

주: 후보의 행동크기가 같아도 실제 재무 효과는 기업의 부채, 매출, 재고 규모에 따라 다르다. 후보 벡터의 정확한 값은 부록 B 에 제시한다.

(3) 자유 작성, 후보 선택, 행동크기 조건

LLM 은 두 가지 행동공간에서 권고한다. 자유 작성(free8)은 8 개 축의 크기를 직접 쓰는 방식으로 본 연구의 주 분석 대상이다. 후보 선택(candidate9)은 9 개 후보 가운데 하나를 고르는 방식이다. 두 방식 모두 같은 9 개 후보의 정의를 프롬프트에서 보여주므로, 자유 작성에서도 LLM 은 후보를 참고하거나 그대로 옮겨 쓸 수 있다.

자유 작성에는 두 가지 행동크기 조건을 둔다. 기본(B1)은 정규화 총 행동크기를 1 이하로 제한하여 9 개 후보와 같은 크기 안에서 행동을 배분하게 한다. 총 행동크기 무지시 조건(BINF)은 총 행동크기의 상한만 없앤 조건으로, 축별 허용 범위와 상환·전환의 동시 양수 금지는 그대로 유지되므로 제약이 전혀 없는 조건은 아니다. 행동크기 조건은 생성 전에 프롬프트로 제시되며, 생성된 행동을 사후에 줄이는 것과는 다르다.

제 4 절 평가 장치: 재무 Simulator 와 Oracle

(1) 재무 Simulator

재무 Simulator 는 기업의 사업계획에 행동을 반영하여 1 년 뒤 재무제표를 계산하는 결정론적 도구이다. 사업계획은 기업의 과거 추세로 정한 매출 성장률, 비용률, 투자율, 차입 금리 등으로 구성되며, 행동이 없을 때(A0)에도 이 사업계획을 1 년 연장한 결과를 계산하므로, A0 의 재무상태는 현재 재무제표와 같지 않다. 차입 금리는 기업별로 관측된 값을 쓰고, 관측되지 않은 경우에는 대체값을 쓴다. 단기차입, 장기차입, 사채에는 같은 금리를 적용하므로, 단기차입을 장기로 바꾸는 장기 전환은 Simulator 에서 이자와 현금, 총자산을 바꾸지 않고 부채의 유동·

비유동 구분만 바꾼다. 평가 기업 575 개 가운데 31 개는 신용등급에 따라 추정한 금리를, 6 개는 전체 중앙값을 사용하였다.

행동은 회계 규칙에 따라 전파된다. 부채 상환은 현금과 차입금을 함께 줄이고(실제 상환액에 대한 이자 절감은 1 년치 전액으로 반영), 단기차입의 장기 전환은 원금을 바꾸지 않은 채 만기 구성만 바꾼다. 운전자본 회전의 변화는 재고, 매출채권, 매입채무와 현금을 함께 바꾸고, 비용률의 변화는 영업이익과 이익잉여금, 현금으로 이어진다. 계산 후에는 자산이 부채와 자본의 합과 같은지를 확인한다. 현금이 모자라면 단기차입으로 보충하고(cash plug), 부도나 금융시장의 반응은 가정하지 않는다. 이것은 모형의 처리 규칙이며, 실제로 필요한 자금조달이 항상 가능하다고 본 것은 아니다.

LLM 이 제안한 행동과 Simulator 가 실제로 반영한 행동은 다를 수 있다. 예를 들어 상환 요청 비율이 커도 상환 가능한 현금이 부족하면 실제 상환액은 줄어든다. 이 단계는 재무적 실행 가능성을 계산할 뿐 응답 자체를 고치지는 않으며, 모든 정책에 같은 규칙이 적용된다.

(2) 세 신용평가모형(Oracle)

Oracle 은 재무제표를 입력받아 0~100 의 신용점수를 내는 신용평가모형이다. 점수가 높을수록 신용이 우량하다. 구조가 다른 세 모형을 같은 9 개 변수(재무 6 개, 비재무 3 개)로 개발하였다(부록 A).

- Oracle-α(스코어카드): 각 변수를 구간별 점수로 바꾸고, 재무 부문과 비재무 부문의 가중합을 7:3 으로 결합한다. 실무에서 쓰이는 평가표 구조와 가장 가까워 주 평가모형으로 사용한다.
- Oracle-β(순서형 로짓): 10 단계 신용등급을 순서형 로짓으로 모형화하고, 기대 등급을 0~100 점수로 바꾼다.
- Oracle-γ(그래디언트 부스팅): 트리 부스팅 회귀모형으로 등급 단계를 예측하고 이를 0~100 점수로 바꾼다.

세 모형은 2007~2019 년 자료로 개발하고 2020~2023 년 자료로 기간외 검증하였다. 같은 입력을 쓰더라도 구간 경계, 연속성, 비선형 결합이 다르므로 같은 행동에 대한 점수 변화도 다르다. 구간형인 α 는 변화가 같은 구간 안에 머물면 점수를 바꾸지 않으며, β 는 입력이 바뀌면 작은 변화에도 연속적으로 반응한다. 세 Oracle 의 점수는 단위가 다르므로 서로 더하거나 평균하지 않고, 각 Oracle 안에서만 비교한다.

9 개 변수는 수익성(세전이익률), 안정성(이익잉여금/총자산), 부채상환능력(금융비용/매출), 유동성(당좌비율), 활동성(자본금회전율), 성장성(비유동자산증가율)과 자본금 변동 횟수, 자산 규모, 영업손실 빈도이다. 부채비율은 변수에 직접 들어 있지 않으며, 부채의 영향은 금융비용부담률과 세전이익률(이자비용), 이익잉여금 비율과 자산 규모(총자산), 당좌비율(유동부채)을 통해 간접적으로 반영된다. 이 구성은 등급을 예측하기 위해 통계적으로 고른 것이지만, 행동에 대한 점수의 반응을 정하는 구조이기도 하므로 제 4 장과 제 7 장에서 행동의 점수를 해석할 때 다시 중요해진다.

(3) 정책가치

기업 i 의 2024 회계연도 상태를 x_i, 정책 p 가 그 기업에 권고한 행동을 a_i^p, Simulator 를 S, Oracle j 를 R_j라 하면, 기업 i 에서 정책 p 의 정책가치는 다음과 같다.

$$V_{ij}(p) = R_j(\ S(x_i,\ a_i^p)\ ) - R_j(\ S(x_i,\ A0)\ ) \tag{3.2}$$

두 정책 p 와 q 의 차이는 같은 기업 안에서 먼저 계산한 뒤 575 개 기업에서 평균한다.

$$\Delta_j(p,\ q) = (1/N)\ \Sigma_i\ [\ V_{ij}(p) - V_{ij}(q)\ ],\ \ N = 575 \tag{3.3}$$

같은 기업의 A0 점수를 빼면 Simulator 의 공통적인 수준 오차는 상쇄된다. 그러나 특정 행동에서만 생기는 자금조달, 영업, 회계 전파의 오차는 차이 안에 남는다. 따라서 정책가치의 차이는 공통 가정 아래의 상대적 비교로 해석하며, 실제 신용등급의 상승이나 금전적 편익으로 직접 바꾸어 읽지 않는다.

정책가치의 크기는 0~100 점 척도의 점수 차이로 읽는다. 예를 들어 Oracle-α 에서 정책가치 +0.9 는 1 년 뒤 신용점수가 무행동보다 기업 평균 0.9 점 높다는 뜻이며, Oracle-α 에서 무행동의 평균 점수는 55.0 점이다. Oracle-α 에서 B1 정책의 정책가치는 대체로 1 점 안팎(+0.12~+1.40)이고 정책 사이의 차이는 그보다 작으며, Oracle-β 와 Oracle-γ 에서는 더 작다.

제 5 절 비교 기준선

정답 행동이 관측되지 않으므로 LLM 과 강화학습 정책의 위치는 다음 기준선과의 비교로 정한다. 모든 기준선은 같은 575 개 기업, 같은 Simulator, 같은 Oracle 에서 계산한다.

- 무행동(A0): 행동 없이 사업계획만 1 년 연장한 경우이다. 모든 정책가치의 기준점(0)이다.
- 무작위: 9 개 후보를 같은 확률로 고를 때의 기대값으로, 기업마다 9 개 후보 점수의 평균이다. 한 번의 무작위 추첨 결과가 아니다.
- 고정 OE: 모든 기업에 비용효율화(OE)를 권하는 단순 규칙이다. 9 개 후보 가운데 하나를 모든 기업에 같이 적용하는 고정 정책 중 Oracle-α 기준으로 가장 높다.
- 상한: 기업마다 9 개 후보 가운데 그 Oracle 에서 가장 높은 점수를 주는 후보를 사후적으로 고른 값이다. 후보 집합 안에서 도달할 수 있는 상한으로, 실제로 배포할 수 있는 정책은 아니다.
- 강화학습 참조정책(C3-E): 제 5 장에서 설명하는 학습 정책이다.

제 6 절 LLM 실험 설계

(1) 모델과 생성 설정

GPT-5.4-mini 와 Gemini 3.1 Flash-Lite 의 두 모델을 사용하였다(<표 3-4>). 먼저 기본 생성 설정(추론 낮음, Baseline)으로 본실험을 수행하고, 같은 실험 행렬을 추론 설정과 출력 한도를 높인 생성 설정(추론 높음, High)으로 한 번 더 실행하였다. High 는 추론 설정과 최대 출력 토큰이

함께 바뀐 묶음 변경이므로, 추론 설정 하나만 바꾼 통제 실험으로 해석하지 않는다. 또한 High 는 Baseline 의 결과를 확인한 뒤 추가한 실행이다.

<표 3-4> 모델과 생성 설정

항목	GPT-5.4-mini	Gemini 3.1 Flash-Lite
모델 식별자	gpt-5.4-mini-2026-03-17	gemini-3.1-flash-lite
호출 방식	Responses Batch API	Gemini Batch API
추론 설정: 추론 낮음 (Baseline)	reasoning effort none	thinking level minimal
추론 설정: 추론 높음(High)	reasoning effort high	thinking level high
최대 출력 토큰	4,096(Baseline), 32,768(High)	4,096(Baseline), 32,768(High)
도구·구조화 출력 기능	사용하지 않음	사용하지 않음

주: 응답 형식(JSON)은 프롬프트로 요구하였고 공급자의 구조화 출력 강제 기능은 사용하지 않았다. 다른 모델로의 자동 대체는 허용하지 않았다.

(2) 입력 정보

LLM 에게는 2024 회계연도의 재무비율 23 개와 연도, 자산 규모(로그), 시장 구분을 공통으로 제공하였다. 재무비율에는 부채·자본·유동성 비율, 영업·총·순이익률, 총자산이익률, 매출원가율과 판매관리비율, 금융비용과 설비투자의 매출 대비 비율, 차입금의 구성, 운전자본 항목의 매출 대비 비율, 주요 비율의 전년 대비 변화가 포함된다(부록 D). 값이 없는 항목은 0 이 아니라 null 로 전달하였고, Oracle 의 점수는 입력에 포함하지 않았다.

정보조건은 세 가지이다. IC-a 는 위 26 개 항목, IC-b 는 여기에 업종 코드를 더한 27 개 항목, IC-c 는 기업명을 더한 28 개 항목이다. 본 분석은 IC-b 를 기본으로 하고, IC-a 와 IC-c 는 정보조건 비교(RQ5)에만 사용한다. 업종 코드는 평가 대상 575 개 기업 모두에서 확보되었다.

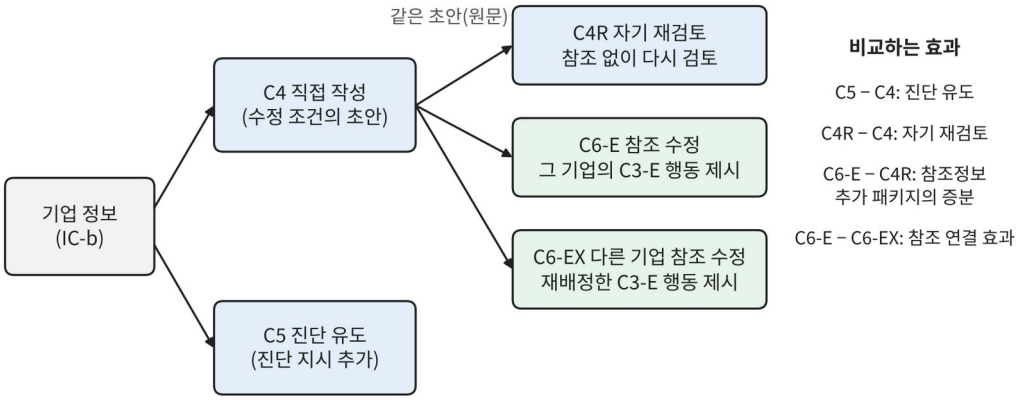
(3) 권고 방식

권고 방식은 다섯 가지이다(<표 3-5>, <그림 3-2>). C4 는 기업 정보만 보고 처음부터 권고를 작성한다. C5 는 C4 와 같은 최초 작성이지만 유동성, 레버리지와 만기구조, 영업효율, 수익성을 먼저 진단하도록 지시한다. C4R, C6-E, C6-EX 는 모두 같은 실행의 C4 응답 원문을 초안으로 받아 수정하는 조건이며, 세 조건은 차례로 이어지지 않고 같은 C4 초안에서 각각 갈라진다.

<표 3-5> 권고 방식과 비교하려는 효과

권고 방식	무엇을 하는가	비교하려는 효과
C4 직접 작성	기업 정보만 보고 처음부터 권고 작성	직접 작성의 기준
C5 진단 유도	C4 와 같은 최초 작성에 진단 지시 추가	진단 유도의 증분(C5 − C4)
C4R 참조 없는 자기 재검토	같은 C4 초안을 참조 없이 다시 검토	자기 재검토의 증분(C4R − C4)
C6-E 해당 기업의 강화학습 참조를 제공한 수정	같은 C4 초안에 그 기업의 C3-E 행동을 참조로 제시	참조정보 추가 패키지의 증분(C6-E − C4R)
C6-EX 다른 기업의 참조를 제공한 수정	같은 C4 초안에 다른 기업에 배정된 C3-E 행동을 제시	기업과 참조의 연결 효과(C6-E − C6-EX)

주: C6-E 와 C6-EX 의 참조는 출처, 가치 추정치, Oracle 점수 없이 8 차원 행동 벡터로만 제시하였고, “적합성이 보장되지 않은 하나의 가능한 프로그램” 이라고 안내하였다.



<그림 3-2> 권고 방식의 분기 구조

C6-EX 에서는 무작위 행동을 새로 만들지 않았다. C3-E 가 575 개 기업에 배정한 행동의 분포는 그대로 두고, 어느 기업이 어떤 행동을 받는지만 고정된 순열(자기 자신에게 돌아가지 않는 순열)로 바꾸었다. 여러 기업이 같은 후보를 받으므로, 순열 뒤에도 원래와 같은 후보를 받은 기업이 141 개(24.5%) 있다. 이 순열은 모델, 생성 설정, 행동크기 조건에 걸쳐 고정하였다. 따라서 C6-E − C6-EX 는 참조의 유무가 아니라 그 기업에 맞게 연결된 참조의 효과를 하나의 고정 순열 아래에서 추정한다.

수정 조건이 받는 초안은 C4 응답의 원문 그대로이다. 실험 명세에 따라, 비어 있지 않은 응답이면 형식이 깨졌거나 규칙을 어긴 응답도 초안으로 전달하였다. 따라서 수정 조건은 규칙을 어긴 초안을 실행 가능한 행동으로 고칠 기회도 갖는다. 실험 계획 문서에는 실행 가능한 초안만 수정 조건에 넘기는 방식(초안 수용 게이트)이 적혀 있었으나, 프롬프트·분기 명세는 비어 있지 않은 원문을 그대로 넘기도록 하였고, 실험은 이 명세대로 수행되었다. 두 방식의 차이가 결과 해석에 주는 영향은 제 6 장에서 별도의 민감도 분석으로 확인한다.

모든 조건의 프롬프트는 같은 시스템 지시를 공유한다. 시스템 지시는 주어진 재무상태와 행동 정의를 사용하되 일반적인 재무 지식으로 해석하도록 하고, 기억하고 있는 개별 기업의 수치나 사건, 등급, 이후의 결과를 덧붙이지 말며, 초안과 참조를 검증되지 않은 자료로 다루라고 요구한다. 응답은 진단, 행동, 근거 항목(최대 4 개), 근거 설명으로 이루어진 하나의 JSON 객체로 요구하였다(부록 D).

(4) 실행 행렬

한 모델과 한 생성 설정에서 21 개 조건을 실행하였다(<표 3-6>). 본실험(Run1)은 자유 작성의 B1 과 BINF 에서 다섯 권고 방식, 후보 선택의 B1 에서 C4·C4R·C6-E, 정보조건 비교의 IC-a·IC-c 로 구성된다. 반복 실행(Run2)은 자유 작성의 C4·C4R·C6-E 를 B1 과 BINF 에서 다시 실행한 것으로, Run2 의 수정 조건은 Run2 의 C4 에서 갈라진다.

<표 3-6> 모델·생성 설정 하나당 실행 행렬

묶음	조건	조건 수	요청 수
본실험 B1	자유 작성, IC-b, B1 × C4·C5·C4R·C6-E·C6-EX	5	2,875
본실험 BINF	자유 작성, IC-b, BINF × 같은 다섯 방식	5	2,875
행동공간	후보 선택, IC-b, B1 × C4·C4R·C6-E	3	1,725
정보조건	자유 작성, B1, C4 × IC-a·IC-c	2	1,150
반복(Run2)	자유 작성, IC-b, B1·BINF × C4·C4R·C6-E	6	3,450
합계	각 조건 575 개 기업	21	12,075

주: 두 모델을 합하면 한 생성 설정에서 24,150 건이고, Baseline 과 High 를 합한 전체 생성 요청은 48,300 건이다. Repaired 실행 규칙은 새 요청이 아니라 같은 응답의 재처리이다.

(5) 응답의 판정과 실행 규칙

도착한 응답이 모두 실행 가능한 행동은 아니므로 각 응답을 다음 순서로 검사하였다. 하나의 모호하지 않은 JSON 객체인지, 요구한 행동 형식을 정확히 따르는지, 모든 값이 유한한 수이며 허용 범위 안에 있는지, 상환과 전환을 동시에 양수로 두지 않았는지, B1 에서 정규화 총 행동크기가 1 이하인지(허용 오차 10^{-9}), 후보 선택에서는 유효한 후보 하나를 골랐는지이다. 이 검사를 모두 통과한 응답의 비율을 수용률이라 한다.

주 분석의 실행 규칙은 엄격(Strict) 규칙이다. 응답은 완료되었으나 검사를 통과하지 못한 경우 그 기업의 행동을 무행동(A0)으로 처리하고, 575 개 기업 전체를 그대로 평가한다(intention-to-treat, ITT). 따라서 정책가치에는 실행 가능한 행동의 효과뿐 아니라 실행할 수 없는 응답이 무행동으로 처리된 결과까지 포함된다. 전송 장애처럼 응답이 완료되지 않은 요청은 처음 요청을 포함해 최대 세 번까지 요청하였으며, 이를 무행동으로 바꾸지 않았다.

보조 분석으로 같은 응답 원문에 결정론적 보정을 적용한 Repaired 규칙을 두었다. 쉼표 오류와 같은 형식 문제를 고치고, 중복된 키는 마지막 값을 쓰며, 행동 부분만 추출하고, B1 을 넘는 행동은 비례적으로 줄이는 규칙이다. Repaired 는 모델의 본래 의도를 복원한다고 보지 않고 또 하나의 실행 규칙으로 다루며, 새로운 생성 요청을 만들지 않는다.

제 7 절 통계 분석

정책 간 비교는 같은 575 개 기업에서 계산한 기업 단위의 대응 차이로 한다. 불확실성은 기업을 복원추출하는 부트스트랩 10,000 회로 평가하였다[54]. 난수 생성기는 PCG64 이며, 주 분석은 기준 시드 20260912 에서 시작하는 생성 설정별 난수열을, 보조 결과는 결과 행마다 식별 정보의 SHA-256 값에서 정한 시드를 사용하였다. 95% 구간은 부트스트랩 평균 분포의 2.5·97.5 백분위이다. p 값은 부트스트랩 평균이 0 의 양쪽에 놓인 빈도를 이용한 양측 부호 꼬리 확률로 계산하였다.

$$\mathrm{p} = \min\{\,1,\; 2 \times [\,\min(\mathrm{n}(\Delta^{*} \le 0),\; \mathrm{n}(\Delta^{*} \ge 0)) + 1\,] \,/\, (\mathrm{B}+1)\,\}\,, \quad \mathrm{B} = 10{,}000 \tag{3.4}$$

이 값은 정해진 계산 방식에 따른 불확실성 지표로, 정확한 무작위배정 검정의 p 값과는 다르다. 주 분석 96 개 행의 구간과 p 값은 실험 당시의 계산 결과를 동결해 사용한다. 당시의 부트스트랩 추출 순서는 보존되지 않았으므로 재현 키트는 이 행들의 표본 수와 평균을 다시 계산해 대조하며, 보조 결과는 구간과 p 값까지 다시 계산한다.

다중비교는 Holm 방법으로 조정하였다[55]. 주 분석에서는 모델, Oracle, 생성 설정마다 네 대비(C5 − C4, C4R − C4, C6-E − C4R, C6-E − C6-EX)와 두 행동크기 조건(B1, BINF)의 8 개 비교를 하나의 묶음으로 조정하였다. 이에 따라 주 분석의 결과는 2 개 모델 × 3 개 Oracle × 2 개 생성 설정 × 2 개 행동크기 조건 × 4 개 대비의 96 개 행이다. 다만 추론 높음 설정은 추론 낮음 설정의 결과를 확인한 뒤 추가한 실행이므로, 결과 등록부는 이 설정의 48 개 대비를 후보 선택 대비 12 개와 함께 60 개 비교의 보조 묶음으로 다시 조정한 값도 보고한다. 이 보수적인 조정에 따른 차이는 제 6 장에서 함께 제시한다. 수용 교집합 분석(per-protocol), Repaired 규칙의 대비, 반복 실행, 추론 높음 설정의 보조 묶음, Repaired 와 Strict 의 차이, 생성 설정 상호작용, 행동공간, 정보조건, 행동크기 조건 상호작용은 보조 결과 722 개 행으로 따로 조정하였고, 초안 처리 규칙에 대한 민감도 96 개 행은 기술 통계로 보고한다. 이 914 개 행이 결과 등록부를 이루며, 기반이 되는 기업 단위 관측값은 96,600 행(48,300 건 × 2 개 실행 규칙)이다.

유의하지 않은 차이는 두 조건이 같다는 뜻이 아니며, 한 조건에서 유의하고 다른 조건에서 유의하지 않다는 사실만으로 두 조건의 효과가 다르다고 판단하지 않는다. 조건 간 효과의 차이는 같은 기업에서 차이의 차이를 직접 계산하여 판단한다. 또한 이 불확실성은 선택된 정책과 고정된 참조 배정에 조건부이며, 강화학습 구성 탐색이나 모든 가능한 참조 순열의 불확실성을 포함하지 않는다.

제 4 장 평가 장치의 검증

높은 점수를 받은 정책을 좋은 정책으로 보려면 먼저 평가 장치를 검증해야 한다. 이 장은 RQ1에 답하기 위해 세 가지를 차례로 확인한다. Oracle 의 점수가 실제 신용등급과 정렬되는가, 재무 Simulator 가 계산한 1 년 뒤 재무상태가 실제와 어느 정도 맞는가, 그리고 평가 장치가 같은 기업 안에서 서로 다른 행동을 구별하는가이다. 각 검증이 어떤 자료에서 나왔는지를 함께 밝혀, 검증 자료가 존재한다는 사실과 그 자료가 현재의 주장에 적용되는 범위를 구분한다.

제 1 절 Oracle 과 실제 신용등급의 정렬

세 Oracle 은 2007~2019 년 2,015 개 기업-연도로 개발하고, 개발에 쓰지 않은 2020~2023 년 1,789 개 기업-연도로 검증하였다(<표 4-1>). 기간외 자료에서 Oracle 이 매긴 등급이 실제 등급과 정확히 일치한 비율은 50.1~55.8%, 1 등급 이내로 일치한 비율은 92.6~95.8%였다. 점수와 실제 등급의 순위상관은 0.69~0.75 였다. 세 모형 모두 기업의 신용 순서를 상당 부분 반영한다고 볼 수 있다.

<표 4-1> Oracle 의 실제 신용등급 정렬 검증

Oracle	기간외 등급 정확일치	기간외 1 등급 이내	기간외 순위상관	등급 변화 방향 일치율 [95% 구간]	AUC
α 스코어카드	50.08%	92.96%	0.690	72.0% [64.7, 78.4]	0.803
β 순서형 로짓	51.20%	92.57%	0.709	72.0% [64.7, 78.4]	0.722
γ 그래디언트 부스팅	55.79%	95.75%	0.746	65.2% [57.6, 72.1]	0.719

주: 정확일치, 1 등급 이내, 순위상관은 배포된 Oracle 의 기간외 검증 산출물(2020~2023 년, 1,789 개 기업-연도)에서 계산한 값이며, 순위상관은 점수와 10 단계 등급의 Spearman 상관계수의 절댓값이다. 방향일치율과 AUC 는 개발 단계 검증기록의 값으로, 실제 등급이 바뀐 161 개 사례에서 전년 대비 점수 변화의 방향이 다음 해 등급 변화의 방향과 같은 비율이며 구간은 Wilson 95% 구간이다[56]. AUC 는 등급 상향 기업과 하향 기업을 점수 변화로 구별하는 정도이다. 배포된 Oracle 산출물로 기간외 기간의 방향 일치율과 AUC 를 같은 정의(전년 대비 점수 변화와 다음 해 등급 변화의 방향 비교)로 다시 계산하면 등급 변경 143 건에서 α 72.7%(AUC 0.802), β 75.5%(0.766), γ 68.5%(0.790)였다. 표본 구성이 개발 단계 기록과 다르므로 본문에는 개발 단계 기록의 값을 제시한다.

정책 비교에는 같은 시점의 순서보다 변화의 방향을 맞히는 능력이 더 중요하다. 권고의 가치는 같은 기업의 점수가 행동에 따라 오르는지 내리는지로 측정되기 때문이다. 개발 단계 검증기록에서 실제 등급이 바뀐 161 개 사례 가운데 Oracle-α 와 Oracle-β 의 점수 변화가 다음 해 등급 변화와 같은 방향이었던 비율은 72.0%였고, Oracle-γ 는 65.2%였다. α 를 주 평가모형으로 삼은 것은 이처럼 방향 정보가 비교적 좋으면서 실무의 평가표 구조와 가장 가깝기 때문이다.

세 Oracle 은 서로 높은 상관을 보이지만 같지는 않다. 기간외 자료에서 α 와 β 점수의 순위상관은 0.791, α 와 γ 는 0.868 이었고, 등급이 정확히 같은 비율은 각각 57.9%와 62.9%였다. 같은 기업의 신용 순서에는 대체로 동의하지만, 어느 행동이 점수를 얼마나 바꾸는지에 대해서는 다르게 반응할 수 있으므로, 본 연구는 세 Oracle 의 결과를 각각 보고하고 점수를 합치지 않는다.

이 결과를 “LLM 행동을 적용하면 72%의 확률로 신용등급이 개선된다”로 읽을 수는 없다. 방향일치율은 실제 재무상태의 변화와 실제 등급 변화 사이의 관계이며, 권고 실행의 인과적 성공률이 아니다. 또한 기업의 등급 순서를 맞히는 능력이 작은 관리 행동의 효과까지 같은 정밀도로 구별한다는 보장도 없다. 이 문제는 제 3 절에서 따로 확인한다.

제 2 절 재무 Simulator 의 회계 일관성과 실제 재무 재현

Simulator 는 두 가지 측면에서 검증하였다. 하나는 회계적 일관성이다. 개발 단계 검사에서 31,590 개의 시뮬레이션 상태에 대해 자산이 부채와 자본의 합과 같은지를 확인한 결과, 최대 상대오차는 4.66×10^{-16} 으로 계산상의 반올림 수준이었다. 이 검사는 계산 체계가 정해진 항등식을 지키는지에 관한 증거이며, 현실의 재무제표를 정확히 예측한다는 증거는 아니다.

다른 하나는 실제 재무 재현이다. 과거 기업-연도에 실제 관측된 재무 변화를 행동으로 바꾸어 Simulator 에 넣고, Simulator 가 계산한 1 년 뒤 재무상태와 실제 1 년 뒤 재무상태를 같은 Oracle-α 로 채점하여 비교하였다(<표 4-2>).

<표 4-2> Simulator 가 계산한 재무상태와 실제 재무상태의 점수 비교

지표	개발(DEV)	기간외(OOT)	평가 이후(POST)
점수 차이의 중앙값	10.842	10.700	11.155
기업 순위상관	0.907	0.903	0.892
보정 후 방향일치율	71.2%	71.7%	73.6%
방향일치율의 95% 구간	[67.7, 74.4]	[68.1, 75.0]	[68.1, 78.5]

주: 개발 단계 검증기록. DEV 는 도착 연도 2019 년 이하, OOT 는 2020~2023 년, POST 는 2024 년에서 2025 년으로의 전이이다. 기업 순위상관의 사례 수는 975, 925, 424 개, 방향일치율의 사례 수는 698, 657, 273 개이다. 점수 차이는 0~100 척도이며, 방향일치율은 개발 기간의 점수 차이 중앙값(10.842)을 보정한 뒤 전년 대비 점수 변화의 방향이 같은 비율이다.

Simulator 가 계산한 상태의 점수는 실제 상태의 점수보다 중앙값으로 약 10.8 점 높았고, 전체 사례의 97.6%에서 더 높았다. Simulator 는 점수의 수준을 체계적으로 높게 계산한다. 현금 부족을 단기차입으로 메우는 처리 규칙처럼 낙관적인 상태를 만들 수 있는 구조적 요인이 있지만, 이 차이 전체가 하나의 원인 때문이라고 확정하려면 다른 가정을 통제한 대조가 필요하다.

반면 기업 간 순서와 변화의 방향은 상당 부분 남았다. 기간외 기간의 기업 순위상관은 0.903, 수준 차이를 보정한 뒤의 방향일치율은 71.7%였고, 평가 이후 기간에서도 비슷하였다. 수준 오차가 크더라도 상대 비교에 필요한 정보는 일부 보존되므로, 본 연구는 정책의 절대 점수 대신 같은 기업의 무행동 대비 차이(정책가치)를 쓴다. 같은 기업에서 무행동 점수를 빼면 공통적인 수준 오차는 상쇄된다. 다만 상환이 현금 부족을 바꾸거나 성장 투자의 축소가 현금 경로를 바꾸는 경우처럼 오차가 행동에 따라 달라진다면, 그 오차는 정책가치에도 남는다.

이 절의 검증은 개발 단계의 기록이다. 최종 실험에서는 상환, 단기차입 전환, 성장 투자 축소의 정의를 다듬었으므로, 위 수치가 최종 행동 정의 이후에도 같게 재현된다고 단정하지 않는다. 최종 행동 정의에 대해서는 한 기업과 제한된 요청으로 제안, 수용, 무행동 처리, 실제

반영, 세 Oracle 채점, 결과 집계까지의 경로를 확인하는 실행 점검을 거쳤다. 또한 평가 경로를 독립적으로 다시 호출하여 575 개 기업 × 9 개 후보의 점수표를 재계산한 결과는 동결된 점수표와 완전히 일치하였다(최대 절대 차 0). 다만 이것은 구현의 재현성을 확인한 것이고 현실 예측력을 확인한 것은 아니다.

제 3 절 같은 기업 안에서 후보행동의 구별

정책을 비교하려면 평가 장치가 같은 기업에서 서로 다른 행동에 서로 다른 점수를 주어야 한다. 575 개 기업에 9 개 후보를 각각 적용한 5,175 개의 점수로 이를 확인하였다(<표 4-3>).

<표 4-3> 575 개 기업에서 9 개 후보행동의 점수 구별

Oracle	최고점 후보가 여럿인 기업	9 개 후보가 모두 동점인 기업	무행동(A0)이 최고점인 기업	기업 내 점수 표준편차의 평균
α	348 (60.5%)	164 (28.5%)	187 (32.5%)	0.601
β	1 (0.2%)	1 (0.2%)	1 (0.2%)	0.153
γ	257 (44.7%)	88 (15.3%)	173 (30.1%)	0.249

주: 동점은 점수 차이 10^{-9} 이하이다. 무행동이 최고점인 기업은 다른 후보와 동점인 경우를 포함한다. 표준편차는 기업마다 9 개 후보 점수의 표준편차를 구한 뒤 평균한 값이며, Oracle 마다 점수 척도가 달라 Oracle 사이에 직접 비교하지 않는다.

구간형 점수표인 α 는 재무 변화가 같은 점수 구간 안에 머물면 점수를 바꾸지 않는다. 그 결과 164 개 기업(28.5%)에서는 9 개 후보가 모두 같은 점수를 받았고, 187 개 기업(32.5%)에서는 어떤 후보도 무행동보다 높은 점수를 받지 못했다. 무행동을 제외한 8 개 후보의 기업별 정책가치 가운데 73.3%가 정확히 0 이었다. 후보별로 보면 α 점수를 바꾼 기업의 비율은 비용효율화(OE) 52.9%, 상환·비용 복합(MX1) 38.8%, 단기차입의 장기 전환(RF) 28.9%의 순으로 높았고, 나머지 후보는 16.9~20.7%였다. 특히 장기 전환은 α 점수를 낮춘 기업이 한 곳도 없었다. 장기 전환은 원금을 줄이지 않고 단기차입을 장기로 옮기므로 유동부채가 줄어 유동성 비율이 개선되기 때문이다. 이 특성은 이후 장에서 정책의 행동 선택을 해석할 때 다시 다룬다.

연속형인 β 는 574 개 기업에서 최고점 후보를 하나로 정하였지만, 행동이 Oracle 의 입력을 바꾸지 못하면 점수도 그대로였다. 무행동을 제외한 후보 값의 15.2%가 정확히 0 이었고(예: 부채상환은 53.6%의 기업에서 β 점수를 바꾸지 못함), 9 개 후보의 점수가 모두 다른 기업은 154 개(26.8%)였다. 기업 내 점수의 퍼짐도 작았다. γ 는 그 중간이었다. 세 Oracle 이 기업마다 가장 높은 점수를 준 후보를 비교하면, 동점일 때 정해진 순서의 첫 후보를 고르는 규칙에서 세 Oracle 의 선택이 모두 같은 기업은 85 개(14.8%)였고, 세 Oracle 의 최고점 후보 집합에 공통 후보가 하나라도 있는 기업은 261 개(45.4%)였다. 세 Oracle 사이의 불일치 가운데 일부는 점수 구간의 경계와 동점 처리 규칙에서 비롯된다.

평가모형 사이의 차이는 행동마다 모든 기업에 같은 후보를 적용한 고정 정책의 값에서도 드러난다(부록 B). 비용효율화(OE)는 세 Oracle 모두에서 고정 정책 가운데 가장 높았다. 반면 부채상환(DL)은 Oracle-α 에서 +0.181 로 8 개 후보 가운데 가장 낮았고, Oracle-β 에서는 −0.035 로 무행동보다도 낮았다. 세 Oracle 사이에서 고정 정책 값의 부호가 갈린 후보는 DL 과 상환·

운전자본 복합(MX2) 두 개뿐이며, 둘 다 신용 실무에서 대표적인 개선 수단으로 꼽히는 차입금 상환을 포함한다.

이 차이는 변수의 구성과 일치한다. 9 개 변수에는 부채비율이 직접 들어 있지 않고, 자산 규모가 Oracle-β 의 계수와 Oracle-γ 의 변수 중요도에서 가장 크다(부록 A). 차입금을 갚으면 금융비용은 줄지만 현금과 총자산도 함께 줄어들므로, 상환의 점수는 이 효과들이 어떻게 상쇄되는지에 달려 있고 그 방식이 모형마다 다르다. 반대로 장기 전환은 총자산을 바꾸지 않고 유동부채만 줄이므로, 앞에서 보았듯이 Oracle-α 에서 점수를 낮춘 기업이 없었다. 평가모형은 비용 절감처럼 방향이 분명한 행동에는 일관되게 반응하지만, 부채·유동성·규모가 함께 바뀌는 행동에서는 서로 다르게 판단한다. 다만 이 설명은 변수 구성과 결과가 맞아떨어진다는 관찰이며, 변수별로 점수 변화를 분해하여 확인한 것은 아니다.

이 결과는 세 가지를 함의한다. 첫째, α 로 측정한 정책가치의 차이는 점수가 실제로 움직이는 일부 기업에서 만들어진다. 평균 정책가치가 비슷한 두 정책이라도 기업별로는 다른 행동을 골랐을 수 있다. 둘째, 한 Oracle 에서의 우위를 정책의 보편적 우위로 일반화해서는 안 된다. 본 연구가 α 를 주 평가모형으로 쓰면서 β 와 γ 를 함께 보고하는 이유이다. 셋째, 평가 장치는 어떤 행동을 유리하게 보는 나름의 기준을 갖는다. 정책이 그 행동을 자주 고른다면, 그것이 좋은 판단 때문인지 평가 장치의 기준에 맞기 때문인지를 구분해서 읽어야 한다.

제 4 절 소결: 평가 장치의 사용 범위

<표 4-4>는 이 장의 검증이 무엇을 확인했고 무엇을 확인하지 못했는지 정리한 것이다.

<표 4-4> 평가 장치 검증의 범위

검증	확인한 내용	확인하지 못한 내용
Oracle 과 실제 등급	기간외 기간의 등급 순서 정렬(순위상관 0.69~0.75), 등급 변화 방향(개발 단계 기록 65~72%)	작은 관리 행동이 실제 등급에 미치는 효과의 크기
Simulator 와 실제 재무	회계항등식, 기업 순위(0.90)와 변화 방향(약 72%)의 정렬, 수준 편향의 크기(약 10.8 점)	자금조달의 가능성, 실행 비용, 최종 행동 정의 이후의 전면 재검증
후보 간 구별	Oracle 별 동점 비율과 무행동 최적 비율, 평가모형 간 최고점 후보의 일치, 고정 정책 값의 순서와 부호	동점 기업에서 행동의 실제 우열, 행동에 대한 점수 반응이 실제 등급의 반응과 같은지
평가 경로의 재현	575 개 기업 × 9 개 후보 점수표의 독립 재계산 일치	현실의 예측력

종합하면 평가 장치는 실제 신용등급의 순서와 변화 방향을 상당 부분 반영하고 회계적으로 일관되므로, 같은 기업에서 행동 간 상대 비교에 쓸 수 있다. 다만 이 비교는 평가모형의 구조에 조건부이며(세 Oracle 의 최고점 후보 집합에 공통 후보가 있는 기업은 45.4%, 제 3 절), 특정 행동이 실제 등급에 미치는 효과의 타당성은 검증하지 않았다. 또한 점수 수준은 체계적으로

높게 계산되고, 주 평가모형인 α 는 행동의 차이를 거칠게 구별하며, 평가 기간은 1 년이다. 따라서 이후 장의 정책가치는 이 평가 장치에서 1 년 뒤 신용점수를 얼마나 높이는지에 대한 상대 비교이며, 장기적인 기업 가치나 실제 등급 상승을 뜻하지 않는다.

요약하면, 기업의 신용 순서를 맞히는 능력은 검증할 수 있었지만 어떤 행동이 신용을 얼마나 바꾸는지에 대한 판단은 모형의 변수 구성과 구간에 따라 달라졌다. 평가 장치가 유리하게 보는 행동을 미리 확인해 두어야 이후 장에서 LLM 과 강화학습 정책이 어떤 행동을 고르고 그것이 어떻게 채점되는지를 올바르게 읽을 수 있다. 이 기준이 실무 관점과 어떻게 다른지는 제 7 장에서 다시 다룬다.

제 5 장 강화학습 참조정책 C3-E

이 장은 LLM 의 권고를 수정하는 조건(C6-E)에서 참조로 제시되는 강화학습 정책 C3-E 의 구성과 성과를 다룬다. C3-E 는 한국 기업의 재무 자료와 신용등급 변화라는 좁은 영역의 과거 자료로 학습하여, 기업마다 9 개 후보행동 가운데 하나를 고르는 정책이다. C3-E 는 도메인 자료에서 학습하고 재현 가능한 절차로 고정한 외부 참조로 쓰이며, 최고 성능의 강화학습 알고리즘을 제시하려는 것은 아니다. 이 장에서는 그 성과와 한계를 함께 밝힌다.

제 1 절 학습 자료와 보상

C3-E 의 학습과 평가는 시점을 나누어 구성하였다(<표 5-1>). 가치학습에는 외부 신용등급이 연결된 기업-연도 전이 2,642 건(의사결정 연도 2008~2022 년, 결과 관측 연도 2023 년 이하)을 사용하였고, 그 앞 단계인 표현학습과 행동복제에는 등급이 없는 기업을 포함한 상장기업 패널을 같은 시점 제한(의사결정 2022 년 이하, 결과 2023 년 이하) 아래에서 사용하였다. 평가에는 학습에 쓰지 않은 2024 회계연도 575 개 기업을 사용하였다.

<표 5-1> C3-E 의 학습과 평가 구성

구분	학습	평가
대상	가치학습: 외부 신용등급이 연결된 기업-연도 전이 2,642 건(다음 해 등급이 관측된 전이 2,080 건). 표현학습·행동복제: 등급 유무와 무관한 상장기업 패널	2024 회계연도 575 개 기업
기간	의사결정 2022 년 이하, 결과 관측 2023 년 이하	2024 결산 상태
Simulator 사용	전이마다 9 개 후보행동을 적용해 23,778 개의 반사실 전이 생성	후보·LLM 행동의 1 년 뒤 재무 계산
보상 / 채점	실제 신용등급 변화(기본) + 부채부담·투자 후 현금흐름·영업수익성·단기 유동성(보조)	Oracle α·β·γ
최종 구성 선택	2024 년 평가자료 기준: 고정 OE 대비 α 차이(목표 0.20, 최종 0.158)와 행동 다양성(엔트로피 목표 1.60, 최종 1.594)	—

주: 보조 보상의 정규화 기준은 학습 자료(2022 년 이하 의사결정, 2023 년 이하 결과)에서 산출하였다. Oracle 의 점수는 학습 보상에 쓰지 않았다.

재무제표에는 경영진이 어떤 전략을 택했는지가 기록되지 않는다. 따라서 관측된 재무 변화를 8 개 축의 행동으로 바꾸고, 정규화 척도로 잰 거리가 가장 가까운 후보를 그 전이의 행동 표지로 붙였다. 2,642 건의 표지는 A0 668 건, CX 637 건, WC1 371 건, DL 318 건, OE 285 건, WC2 261 건 MX2 46 건, MX1 45 건, RF 11 건이었다. 이 표지는 실제 재무 변화를 표준 후보와 연결한 분석용 표현으로, 경영진이 그 전략을 의도적으로 선택했다는 뜻은 아니다.

학습 보상은 기본 보상과 보조 보상으로 이루어진다. 기본 보상은 실제 외부 신용등급의 변화로, 다음 해 등급이 관측된 전이 가운데 실제 재무 변화가 가장 가까운 후보와 두 번째 후보를

뚜렷이 구별할 수 있는 1,271 건에서 그 후보에 부여하였다. 관측되지 않은 후보행동에 실제 다음 해 등급을 임의로 붙이지는 않았다. 보조 보상은 Simulator 로 계산한 반사실 전이에서 얻는 네 가지 재무 신호이다. 부채부담은 Merton/KMV 부도거리의 회계 대리변수로서 단기차입금, 유동성 장기부채, 비유동 장기차입금의 절반, 사채를 합한 금액의 총자산 대비 감소이다. 투자 후 현금흐름은 FCFF 의 대리변수로서 영업현금흐름에서 설비투자지출을 뺀 금액의 총자산 대비 증가이고, 영업수익성은 행동을 반영한 영업이익과 실제 영업이익의 차이를 총자산으로 나눈 값이며, 단기 유동성은 현금과 단기금융자산의 총자산 대비 증가이다. 각 항목은 학습 기간의 분포로 정규화하고 범위를 제한한 뒤 구성별 가중치로 합하였다(부록 C).

$$r = r_{\text{rating}} + w_M \cdot r_M + w_F \cdot r_F + w_P \cdot r_P + w_L \cdot r_L \tag{5.1}$$

Oracle 의 점수는 학습 보상에 쓰지 않았다. 다만 기본 보상의 신호인 실제 등급 변화와 평가에 쓰는 Oracle 은 모두 신용등급을 향하므로, 학습 목표와 평가 기준이 완전히 무관하다고 볼 수는 없다. 업종 재무비율에 기반한 보상 항목은 코드에 구현되어 있으나 최종 학습에서는 계수를 0 으로 두어 쓰지 않았다.

제 2 절 학습 단계와 최종 구성

학습은 세 단계로 구성하였다. 첫째, 재무제표의 여러 비율과 범주 정보를 잠재 표현으로 압축하는 표현학습 단계에서 Transformer 기반 인코더[57]를 자기지도 방식으로 학습하였다. 둘째, 관측된 재무 변화의 행동 표지를 따라 하는 행동복제 단계에서 출발 정책을 만들었다. 자주 나타나는 행동이 학습을 지배하지 않도록 불균형을 보정하였다. 셋째, Implicit Q-Learning[32]으로 관측 전이와 반사실 전이의 보상을 이용해 행동의 가치를 학습하고 정책을 갱신하였다. 할인계수는 0 으로 두었으므로, 이 학습은 기업 상태에 조건부인 한 해의 행동 선택 문제이며 장기 누적보상을 최적화하지 않는다. 보수적 Q 학습의 벌점 항목은 사용하지 않았다.

최종 정책 C3-E 는 네 가지 학습 구성(B27, M2_S0935, DT06, T15_REWARD_S088)을 각각 같은 7 개 시드(2, 11, 12, 13, 14, 15, 16)로 학습한 28 개 정책(actor)을 결합한 앙상블이다. 먼저 같은 구성 안에서 7 개 시드의 행동 확률을 평균하고, 네 구성의 평균을 다시 25%씩 같은 비중으로 평균한 뒤, 가장 높은 확률의 후보를 기업의 행동으로 정한다. 배포 단계에서는 가치함수나 Oracle 점수로 후보를 다시 정렬하지 않으므로, LLM 에게 제시한 참조와 본문에서 평가한 C3-E 는 같은 정책이다.

최종 구성은 다음 경위로 정하였다. 개별 정책의 학습 보상에는 Oracle 점수가 들어가지 않았다. 최종 인코더와 학습 구성, 앙상블은 2024 년 평가자료의 Oracle-α 성과(고정 OE 대비 차이)와 행동 다양성을 기준으로 골랐으며, 탐색 목표였던 고정 OE 대비 0.20 과 엔트로피 1.60 에 대해 최종 정책의 값은 각각 0.158 과 1.594 였다. 따라서 2024 년 575 개 기업은 C3-E 에 대해 독립된 검증 표본이 아니며, 이후 C3-E 와 기준선의 차이에 붙는 불확실성은 이 선택의 불확실성을 포함하지 않는다. 본 연구에서 C3-E 의 역할은 최고 성능의 정책이 아니라, LLM 의 정책 하네스를 비교하기 위해 재현 가능한 절차로 고정한 학습된 참조정책이다.

제 3 절 기준선 대비 정책가치

<표 5-2>는 같은 575 개 기업에서 기준선과 C3-E 의 정책가치를 비교한 것이다. Oracle-α 에서 C3-E 의 정책가치는 +0.923 으로, 무작위(+0.353)와 고정 OE(+0.765)보다 높았다. 고정 OE 에 대한 차이는 +0.158(기업 단위 대응 t 95% 구간 [0.065, 0.251])이다. 기업별 사후 최선 후보로 정의한 상한은 +1.401 이므로, C3-E 는 상한까지의 거리 가운데 약 66%에 도달하였다.

<표 5-2> 기준선과 C3-E 의 정책가치(575 개 기업, 무행동 대비)

정책	Oracle-α	Oracle-β	Oracle-γ
무작위(9 개 후보 균등 기대값)	+0.353	+0.054	+0.108
고정 OE(모든 기업 비용효율화)	+0.765	+0.278	+0.194
C3-E(강화학습 참조정책)	+0.923	+0.207	+0.246
상한(기업별 사후 최선 후보)	+1.401	+0.332	+0.544
참고: 무행동(A0)의 평균 점수	55.037	62.991	65.656

주: 정책가치는 각 Oracle 안에서 같은 기업의 무행동 점수를 뺀 값의 평균이며 Oracle 사이의 크기는 직접 비교하지 않는다. 상한은 Oracle 마다 따로 고른 값이므로 세 Oracle 에서 같은 행동이 선택된 것은 아니다. 단일 후보를 모든 기업에 적용한 고정 정책 전체의 값은 부록 B 에 제시한다.

그러나 C3-E 의 우위는 평가모형에 따라 달라졌다. Oracle-γ 에서는 C3-E(+0.246)가 고정 OE(+0.194)보다 높았지만, Oracle-β 에서는 C3-E(+0.207)가 고정 OE(+0.278)보다 낮았다. 고정 OE 에 대한 C3-E 의 차이는 α 에서 +0.158, β 에서 −0.071, γ 에서 +0.052 이다. 따라서 C3-E 가 단순 규칙보다 좋다는 판단은 주 평가모형 α 에서의 결과이며, 세 평가모형 모두에 같은 크기와 방향으로 일반화할 수 없다. 이 결과 역시 최종 선택을 거친 정책의 기술통계라는 한계를 갖는다.

제 4 절 행동 분포와 기업별 손익

C3-E 는 575 개 기업 가운데 232 개(40.3%)에 비용효율화(OE), 155 개(27.0%)에 단기차입의 장기 전환(RF)을 골랐고, 나머지는 운전자본 회수(WC1) 54 개, 설비투자 축소(CX) 41 개, 공급자금융(WC2) 39 개, 상환·운전자본 복합(MX2) 36 개, 상환·비용 복합(MX1) 18 개였다. 무행동(A0)과 부채상환(DL)은 한 번도 고르지 않았다. 행동 빈도의 Shannon 엔트로피는 1.594 로, 약 4.9 개의 행동을 고르게 쓰는 것과 같은 다양성이다.

이 선택은 학습 자료에 나타난 재무 변화와 크게 다르다(<표 5-3>). 학습 전이 2,642 건의 행동 표지에서 장기 전환은 0.4%(11 건)에 불과했지만 C3-E 는 27.0%의 기업에 장기 전환을 골랐다. 반대로 표지의 25.3%였던 무행동과 12.0%였던 상환은 한 번도 고르지 않았고, 24.1%였던 설비투자 축소는 7.1%에 그쳤다. 행동 표지는 재무 변화를 가장 가까운 후보에 대응시킨 분석용 표현이며, 과거 자료에서 장기 전환은 차입 총액이 거의 변하지 않은 채 만기만 바뀐 경우에만 식별되므로 표지에서 적게 잡힐 수 있다(부록 G). 따라서 이 비교를 기업들의 실제 전략 분포로 읽을 수는 없지만, C3-E 의 선택이 학습 자료의 행동 표지 분포를 그대로 따르지 않았다는 것은 확인할 수 있다.

<표 5-3> 학습 자료의 행동 표지와 C3-E 의 선택

후보	학습 자료의 행동 표지(2,642 건)	C3-E 의 선택(575 개 기업)
A0 무행동	25.3%	0.0%
DL 부채상환	12.0%	0.0%
RF 장기 전환	0.4%	27.0%
CX 설비투자 축소	24.1%	7.1%
WC1 운전자본 회수	14.0%	9.4%
WC2 공급자금융	9.9%	6.8%
OE 비용효율화	10.8%	40.3%
MX1 상환·비용 복합	1.7%	3.1%
MX2 상환·운전자본 복합	1.7%	6.3%

주: 행동 표지는 의사결정 2008~2022 년의 실제 재무 변화에 가장 가까운 후보이며, 경영진이 그 전략을 의도했다는 뜻이 아니다. C3-E 의 선택은 2024 회계연도 평가 기업에 대한 것이다.

C3-E 가 장기 전환을 선호한 것은 보상의 구조와 일치한다. 보조 보상 가운데 가중치가 가장 큰 부채부담 항목(구성별 0.449~0.606, 부록 C)은 단기차입금, 유동성 장기부채, 사채를 전액, 비유동 장기차입금을 절반으로 센다. 따라서 장기 전환은 원금을 줄이지 않고도 이 항목을 개선하며, Simulator 에서는 단기·장기 금리가 같으므로 이자와 현금, 영업이익도 바꾸지 않는다. 반면 상환은 부채부담을 줄이는 대신 현금을 줄여 단기 유동성 항목을 낮춘다. 학습된 정책의 선호는 경영진의 과거 선택보다는 학습 신호를 어떻게 정의했는지를 반영한다고 보는 것이 자연스럽다. 장기 전환은 제 4 장에서 보았듯이 평가 장치(Oracle-α)에서도 점수를 낮춘 적이 없는 행동이다. 보상과 평가 장치가 같은 행동을 유리하게 보는 구조이므로, C3-E 가 평가 장치에서 높은 가치를 보인 이유의 일부도 여기에 있을 수 있다. 또한 최종 구성을 Oracle-α 의 성과를 보며 골랐으므로, 장기 전환을 불리하게 평가하지 않는 α 의 구조가 선택 과정에서 장기 전환의 비중을 높였을 가능성도 있다.

행동의 다양성과 기업별 손익은 따로 확인해야 한다. C3-E 가 고정 OE 와 다른 행동을 고른 343 개 기업 가운데 Oracle-α 점수가 높아진 기업은 100 개, 낮아진 기업은 102 개, 점수가 변하지 않은 기업은 141 개였다. 평균이 개선된 것은 높아진 기업의 증가폭 합계(약 198.0)가 낮아진 기업의 감소폭 합계(약 107.2)보다 컸기 때문이며, 점수가 오른 기업의 수는 내린 기업과 비슷하였다.

C3-E 의 결과가 특정 시드나 구성 하나에 좌우되는지도 확인하였다. 시드 하나를 뺀 일곱 가지 경우에 고정 OE 대비 α 차이는 +0.146~+0.169, 엔트로피는 1.571~1.627 의 범위에 있었다. 구성 하나를 뺀 네 가지 경우에는 고정 OE 대비 차이가 +0.136~+0.158 이었고, T15_REWARD_S088 구성을 빼면 OE 의 비중이 49.2%로 높아지고 엔트로피가 1.454 로 낮아졌다. 고정 OE 에 대한 양의 평균 차이가 시드나 구성 하나에서 비롯되지는 않았다고 볼 수 있으나, 증거는 제한적이다. 다만 이 진단은 같은 2024 년 평가 자료에서 한 것이며, 다른 기업이나 시점에서의 성과를 검증한 것은 아니다.

제 5 절 소결

C3-E 는 2008~2022 년의 기업 재무 자료와 실제 신용등급 변화로 학습한 강화학습 정책으로, 주 평가모형 α 에서 무작위와 고정 OE 보다 높고 사후 상한보다 낮은 위치에 있다. 상한과 고정 OE 의 차이(0.636)를 기업마다 다른 행동을 골라서 얻을 수 있는 몫으로 보면, C3-E 는 그 가운데 약 4 분의 1(+0.158)을 얻었다. 이 위치는 LLM 정책을 해석하는 기준이 된다.

다만 이 결과에는 세 가지 단서가 붙는다. 첫째, C3-E 의 우위는 평가모형에 따라 달라져 β 에서는 고정 OE 보다 낮았다. 둘째, 고정 OE 와 다른 행동을 고른 기업에서 점수가 오른 기업과 내린 기업의 수가 비슷하여, 평균의 우위가 개별 기업의 우위로 이어지지는 않았다. 셋째, C3-E 가 자주 고른 장기 전환은 학습 자료의 행동 표지에서는 드물었고(엄격한 식별 규칙 때문에 2,642 건 가운데 11 건에서만 장기 전환이 관측됨), 보상과 평가 장치가 함께 유리하게 보는 행동이다. 따라서 다음 장에서는 C3-E 를 LLM 이 따라야 할 정답이 아니라 학습된 외부 참조로 두고, 이 참조가 LLM 의 수정에 무엇을 더하는지를 살펴본다.

제 6 장 LLM 권고 실험

이 장은 LLM 실험의 결과를 제시한다. 먼저 LLM 이 규칙에 맞는 행동을 얼마나 만들었는지(수용률)와 그 정책가치를 기준선과 비교하고(RQ2), 권고 방식 사이의 차이를 강화학습 참조, 기업과 참조의 연결, 자기 재검토, 진단 유도의 순서로 살핀다(RQ3). 이어 행동공간과 행동크기 조건, 평가모형을 바꾸었을 때의 결과(RQ4)와 정보조건의 효과(RQ5)를 다루고, 마지막으로 반복 실행에서 권고가 얼마나 안정적인지를 본다. 별도로 밝히지 않으면 결과는 본실험(Run1), IC-b, 엄격(Strict) 실행 규칙, 575 개 기업 전체(ITT), Oracle-α 기준이다.

제 1 절 비교의 기준

기업별 정답 행동은 관측되지 않는다. 한 기업은 한 해에 한 가지 행동 경로만 실행하므로 실행되지 않은 행동의 결과는 자료에 없다. 따라서 행동별 정책가치는 제 4 장의 평가 장치로 계산하고, LLM 의 위치는 무행동, 무작위, 고정 OE, C3-E, 상한과 함께 비교한다. 이 장의 비교는 모두 같은 575 개 기업에서 계산한 대응 차이이다. 평가 장치 밖의 기준과의 비교는 제 7 장에서 다룬다.

제 2 절 수용률과 정책가치

LLM 의 권고는 그럴듯한 설명을 쓰는 단계, 규칙에 맞아 실제로 실행할 수 있는 행동을 만드는 단계, 그 행동이 가치를 갖는 단계로 나누어 볼 수 있다. 설명이 자연스러워도 행동의 값이 허용 범위를 벗어나거나 크기 제한을 넘으면 그 권고는 실행할 수 없다. 이 절은 둘째 단계(수용률)와 셋째 단계(정책가치)를 함께 본다.

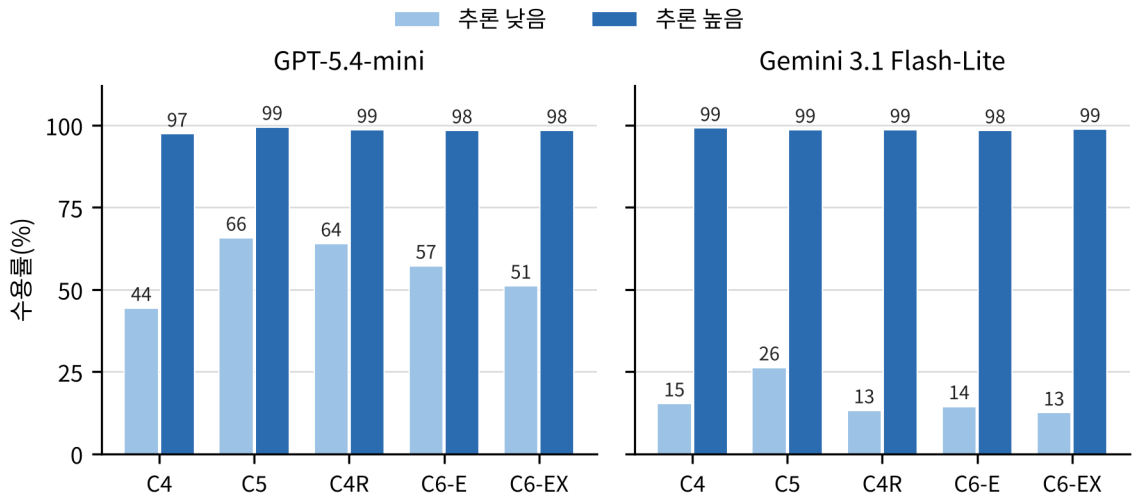
<표 6-1>은 직접 작성(C4)의 수용률과 정책가치를 생성 설정별로 정리한 것이다. 추론 낮음(Baseline) 설정에서 자유 작성의 수용률은 Gemini 15.3%, GPT 44.3%에 그쳤다. 응답의 대부분이 B1 의 총 행동크기 상한이나 형식 규칙을 지키지 못했고, 엄격 규칙에서 이 응답들은 무행동으로 처리되었다. 그 결과 자유 작성의 정책가치는 Gemini +0.147, GPT +0.265 로 무작위(+0.353)보다도 낮았다. 추론 높음(High) 설정에서는 수용률이 각각 99.1%와 97.4%로 높아졌고, 정책가치도 +0.805 와 +0.785 로 크게 올랐다.

<표 6-1> 직접 작성(C4)의 수용률과 정책가치(Oracle-α, B1)

모델 · 생성 설정	자유 작성 수용률	자유 작성 정책가치	후보 선택 수용률	후보 선택 정책가치
GPT · 추론 낮음(Baseline)	44.3%	+0.265	95.1%	+0.602
Gemini · 추론 낮음(Baseline)	15.3%	+0.147	100.0%	+0.850
GPT · 추론 높음(High)	97.4%	+0.785	96.7%	+0.767
Gemini · 추론 높음(High)	99.1%	+0.805	100.0%	+0.794

주: 수용률은 형식, 축별 범위, 상환·전환 동시 양수 금지, 총 행동크기 상한을 모두 지킨 응답의 비율이다. 정책가치는 규칙을 어긴 응답을 무행동으로 처리한 575 개 기업 전체의 평균이다. 같은 기준의 기준선은 무작위 +0.353, 고정 OE +0.765, C3-E +0.923, 상한 +1.401 이다(<표 5-2>).

수용률의 차이는 직접 작성에만 있지 않았다(<그림 6-1>). 추론 낮음 설정의 B1 자유 작성에서 Gemini 의 수용률은 다섯 권고 방식 모두 12.5~26.3%였고, GPT 는 44.3~65.7%였다. 반면 같은 설정에서 총 행동크기를 지시하지 않는 BINF 의 수용률은 Gemini 가 99.8% 이상, GPT 가 72.9~94.4%였다. 같은 프롬프트 구조에서도 총 행동크기 1 이하라는 수치 제약이 있는지에 따라 실행 가능한 행동의 비율이 크게 달라졌다. 후보 선택은 정해진 후보 하나를 고르면 되므로 두 생성 설정 모두에서 수용률이 95% 이상이었다.



<그림 6-1> 자유 작성 B1 의 권고 방식별 수용률: 추론 낮음과 추론 높음

<표 6-2>는 직접 작성의 정책가치를 기준선과 대응 비교한 것이다. 추론 높음 설정의 자유 작성은 두 모델 모두 무작위보다 분명히 높았고(GPT +0.432, Gemini +0.452), 고정 OE 와는 구별되지 않았으며(+0.020, +0.040, 95% 구간이 0 을 포함), C3-E 보다는 낮았다(C3-E − C4: +0.138, +0.118). 후보 선택에서도 추론 높음 설정의 두 모델은 고정 OE 와 구별되지 않았다. 추론 낮음 설정의 후보 선택에서는 GPT 가 고정 OE 보다 낮았고(−0.164), Gemini 는 고정 OE 와 구별되지 않았다.

<표 6-2> 직접 작성(C4)과 기준선의 대응 비교(Oracle-α, B1, 575 개 기업)

행동공간	모델 · 생성 설정	정책가치	C4 − 무작위	C4 − 고정 OE	C3-E − C4
자유 작성	GPT · 추론 낮음	+0.265	−0.088 [−0.160, −0.014]	−0.501 [−0.600, −0.404]	+0.659 [0.546, 0.776]
자유 작성	Gemini · 추론 낮음	+0.147	−0.206 [−0.276, −0.137]	−0.618 [−0.725, −0.509]	+0.776 [0.659, 0.895]
자유 작성	GPT · 추론 높음	+0.785	+0.432 [0.344, 0.520]	+0.020 [−0.067, 0.108]	+0.138 [0.048, 0.233]
자유 작성	Gemini · 추론 높음	+0.805	+0.452 [0.373, 0.536]	+0.040 [−0.045, 0.126]	+0.118 [0.031, 0.204]
후보 선택	GPT · 추론 낮음	+0.602	+0.249 [0.171, 0.326]	−0.164 [−0.258, −0.065]	+0.321 [0.223, 0.421]
후보 선택	Gemini · 추론 낮음	+0.850	+0.497 [0.408, 0.587]	+0.084 [−0.010, 0.180]	+0.073 [0.001, 0.146]
후보 선택	GPT · 추론 높음	+0.767	+0.414 [0.326, 0.504]	+0.001 [−0.077, 0.082]	+0.157 [0.076, 0.243]
후보 선택	Gemini · 추론 높음	+0.794	+0.441 [0.354, 0.530]	+0.029 [−0.058, 0.116]	+0.129 [0.039, 0.220]

주: 괄호는 기업 단위 대응 부트스트랩(10,000 회) 95% 구간이며 다중비교 보정을 하지 않았다.

추론 높음 설정의 LLM 권고는 무작위보다 높았고, 모든 기업에 비용효율화를 권하는 단순 규칙과 비슷하였으며, 강화학습 참조정책보다는 낮았다. 추론 낮음 설정에서 자유 작성의 정책가치가 낮았던 것은 경제적 판단보다는 실행 가능한 행동을 만들지 못한 데서 비롯된 것으로 보인다. 자유 작성의 직접 작성에서 생성 설정만 바꾸어도 정책가치는 GPT +0.265 에서 +0.785 로, Gemini +0.147 에서 +0.805 로 움직였지만, 같은 생성 설정에서 두 모델의 차이는 0.118 과 0.020 이었다. 이 점은 다음 절에서 자기 재검토의 효과를 해석할 때 다시 다룬다.

기업마다 다른 행동을 고르는 데서 얻을 수 있는 몫으로 보아도 결과는 같다. 상한(+1.401)과 고정 OE(+0.765)의 차이 0.636 이 그 몫이다. C3-E 는 그 가운데 약 4 분의 1 을 얻었지만, LLM 의 직접 작성은 B1 의 8 개 설정 가운데 어느 것도 고정 OE 보다 유의하게 높지 않았고 3 개는 유의하게 낮았다. 이 평가 장치에서는 LLM 이 기업마다 달리 판단하여 더한 가치를 확인할 수 없었다.

LLM 이 실제로 고른 행동도 이와 일치한다(부록 G). 추론 높음 설정의 후보 선택에서 두 모델은 575 개 기업의 약 40%(GPT 40.2%, Gemini 39.5%)에 비용효율화(OE)를, 30~34%에 단기차입의 장기 전환(RF)을 골랐고, 설비투자 축소(CX)와 부채상환(DL)은 각각 3% 미만이었다. 자유 작성의 추론 높음·B1 직접 작성에서도 원가율이나 판매관리비율을 낮춘 권고가 56~73%, 장기 전환을 포함한 권고가 37~46%였던 반면, 성장 투자 축소를 포함한 권고는 4~10%였다. 후보 선택의 분포는 C3-E(OE 40.3%, RF 27.0%)와 비슷하고, 자유 작성에서도 비용 절감, 장기 전환, 투자 축소의 순서는 같다. 같은 기업에 C3-E 와 같은 후보를 고른 비율은 GPT 42.4%, Gemini 37.7%로, 두 정책의 행동 비율만으로 기대되는 일치(약 26%, 25%)보다 높았지만 절반에 미치지 못했다.

제 3 절 권고 방식의 효과

<표 6-3>은 네 가지 권고 방식 대비와 정보조건 대비의 결과를 방향과 유의성으로 요약한 것이다. 네 대비 가운데 방향이 가장 일관된 것은 참조정보 추가 패키지의 증분(C6-E − C4R)이었다. 자유 작성의 24 개 조합 모두에서 점추정이 양수였고, 그 가운데 9 개 조합에서 Holm 보정 후에도 차이가 확인되었다. 자기 재검토(C4R − C4)와 진단 유도(C5 − C4)는 모델과 행동크기 조건에 따라 방향과 크기가 달랐다.

<표 6-3> 권고 방식 사이의 차이: 방향과 유의성

대비	질문	자유 작성: 앞쪽이 높은 조합	자유 작성: Holm p<.05	후보 선택: 앞쪽이 높은 조합	후보 선택: Holm p<.05
C6-E − C4R	학습된 참조를 추가하면 바뀌는가	24 / 24	9 / 24	11 / 12	2 / 12
C6-E − C6-EX	기업에 맞는 참조인지가 차이를 만드는가	23 / 24	2 / 24	—	—
C4R − C4	참조 없이 다시 검토하면 바뀌는가	18 / 24	11 / 24	6 / 12	4 / 12
C5 − C4	진단을 먼저 유도하면 바뀌는가	15 / 24	5 / 24	—	—
정보 추가	업종·기업명 정보를 추가하면 바뀌는가	7 / 12	0 / 12	—	—

주: 자유 작성 24 개 조합은 2 개 모델 × 3 개 Oracle × 2 개 생성 설정 × 2 개 행동크기 조건이고, 후보 선택 12 개 조합은 2 개 모델 × 3 개 Oracle × 2 개 생성 설정(B1)이다. Holm 보정 단위는 자유 작성에서 모델·Oracle·생성 설정마다 4 개 대비 × 2 개 행동크기 조건, 후보 선택에서 모델·Oracle·생성 설정마다 2 개 대비이다. 정보 추가는 추론 낮음·B1 의 직접 작성에서 모델·Oracle 마다 두 비교(업종 추가, 기업명 추가)이다. “—”는 실행하지 않은 조건이다. 나중에 추가한 추론 높음 설정을 결과 등록부의 60 개 비교 보조 묶음으로 조정하면 자유 작성의 유의한 조합은 C6-E − C4R 7 개, C6-E − C6-EX 1 개가 되고, 후보 선택의 C4R − C4 는 2 개가 된다. 나머지 수는 같다.

(1) 참조정보 추가 패키지의 증분

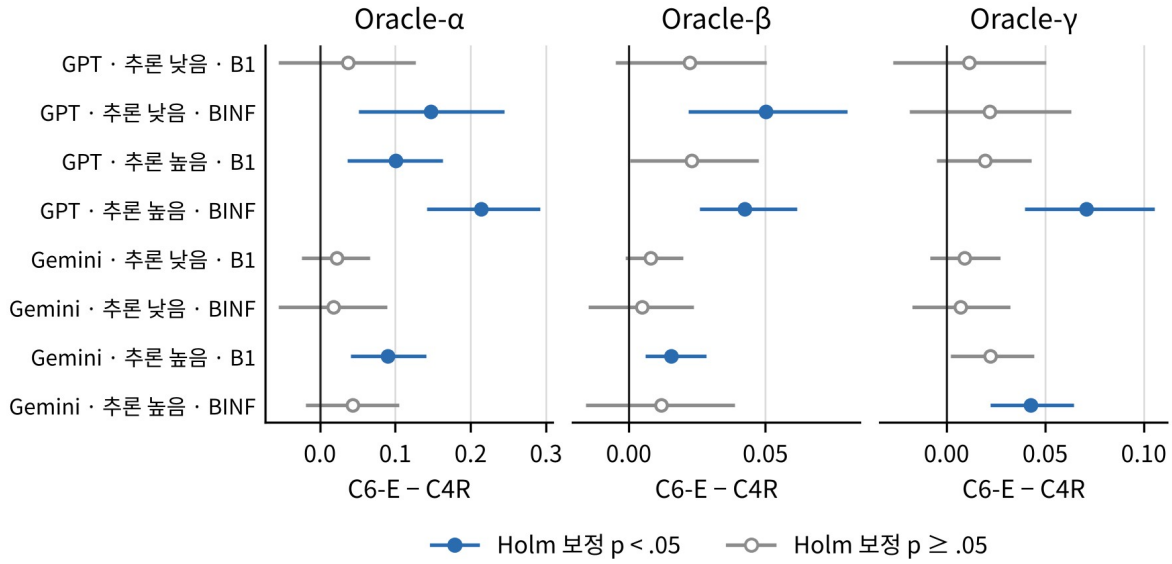
C6-E 와 C4R 은 같은 C4 초안에서 갈라진다. C4R 은 참조 없이 초안을 다시 검토하고, C6-E 는 같은 초안에 그 기업의 C3-E 행동을 참조로 받는다. 두 조건 모두 초안을 다시 볼 기회를 가지므로, 둘의 차이는 재검토 기회를 공통으로 둔 상태에서 참조가 더한 효과이다. C6-E 는 C4R 을 거쳐 생성된 것이 아니므로 이 차이를 순차적 효과로 해석하지는 않는다.

<표 6-4>와 <그림 6-2>는 자유 작성의 24 개 조합별 결과이다. 모든 조합에서 C6-E 가 C4R 보다 높았다. Holm 보정 후에도 차이가 남은 9 개 조합 가운데 7 개가 추론 높음 설정이었다. 추론 높음·B1 에서는 두 모델 모두 Oracle-α 에서 차이가 확인되었다(GPT +0.100, 95% 구간 [0.037, 0.163]; Gemini +0.090, [0.041, 0.141]). GPT 의 추론 높음·BINF 에서는 +0.214([0.142, 0.292])로 가장 컸다. 최초 응답의 수용률이 거의 100%인 상태에서도 학습된 참조를 보여준 수정이 참조 없는 재검토보다 높은 조합이 있었다. 다만 추론 높음 설정은 나중에 추가한 실행이므로 이를 60 개 비교의 보조 묶음으로 다시 조정하면 추론 높음·B1 의 두 α 결과는 유의하지 않고(보정 p = .078, .061), 유의한 조합은 9 개에서 7 개로 줄어든다. 추론 낮음 설정에서는 GPT 의 BINF(α +0.147, β +0.050)에서만 차이가 확인되었다.

<표 6-4> 참조정보 추가 패키지의 증분(C6-E − C4R): 자유 작성 조합별 평균 차이

모델 · 생성 설정	α · B1	α · BINF	β · B1	β · BINF	γ · B1	γ · BINF
GPT · 추론 낮음	+0.038	**+0.147***	+0.022	**+0.050***	+0.011	+0.022
Gemini · 추론 낮음	+0.022	+0.018	+0.008	+0.005	+0.009	+0.007
GPT · 추론 높음	**+0.100***	**+0.214***	+0.023	**+0.042***	+0.020	**+0.071***
Gemini · 추론 높음	**+0.090***	+0.043	**+0.016***	+0.012	+0.022	**+0.043***

주: * Holm 보정 p < .05(주 분석 묶음). 추론 높음 설정을 60 개 비교의 보조 묶음으로 조정하면 추론 높음·B1 의 α(GPT, Gemini)는 유의하지 않다. 각 Oracle 의 점수 척도가 달라 열 사이의 크기는 직접 비교하지 않는다. 95% 구간과 보정 p 는 부록 E 에 제시한다.



<그림 6-2> 참조정보 추가 패키지의 증분(C6-E − C4R)의 조합별 점추정과 95% 구간

후보 선택에서도 12 개 조합 가운데 11 개에서 C6-E 가 C4R 보다 높았으나, 보정 후 차이가 확인된 조합은 2 개였다(<표 6-5>). LLM 은 참조를 본 뒤에도 대부분의 기업에서 선택을 바꾸지 않았다. 참조 없는 재검토(C4R)와 참조 수정(C6-E)의 선택이 다른 기업의 비율은 추론 낮음 설정에서 GPT 30.3%, Gemini 25.0%였고, 추론 높음 설정에서 GPT 14.6%, Gemini 12.3%였다. 최초 작성(C4)과 비교하면 추론 높음 설정에서 선택이 바뀐 기업은 11.0~17.0%였다. 참조를 받은 뒤 C3-E 와 같은 후보를 고른 기업도 추론 높음 설정에서 GPT 53.6%, Gemini 43.7%로, 직접 작성(42.4%, 37.7%)보다 늘었지만 절반 안팎에 머물렀다(부록 G). LLM 은 참조를 일부 기업에서만 받아들였고, 평균 차이는 이들 기업에서 바뀐 선택에서 나온 것으로 볼 수 있다.

<표 6-5> 참조정보 추가 패키지의 증분(C6-E − C4R): 후보 선택 조건별 평균 차이

모델 · 생성 설정	α	β	γ	C4R 과 선택이 다른 기업
GPT · 추론 낮음	**+0.085***	+0.016	+0.023	30.3%
Gemini · 추론 낮음	+0.044	+0.007	**+0.031***	25.0%
GPT · 추론 높음	+0.009	−0.002	+0.018	14.6%
Gemini · 추론 높음	+0.037	+0.009	+0.008	12.3%

주: * Holm 보정 p < .05(모델·Oracle·생성 설정마다 C6-E − C4R 과 C4R − C4 의 두 대비). 575 개 기업, Strict ITT, B1.

참조정보 추가 패키지의 증분이 반복 실행에서도 유지되는지는 제 6 절에서 다룬다.

(2) 기업과 참조의 연결

C6-EX 는 C6-E 와 같은 참조 분포를 쓰되 기업과 참조의 연결만 바꾼 조건이다. C6-E − C6-EX 는 자유 작성 24 개 조합 가운데 23 개에서 양수였으나, 보정 후 차이가 확인된 조합은 GPT 의 추론 낮음·B1(α +0.174, [0.075, 0.277])과 추론 높음·B1(α +0.115, [0.044, 0.186])의 2 개였다(후자는 60 개 비교 보조 묶음에서는 보정 p = .078). 기업에 맞게 연결된 참조가 대체로 더 높은 가치를 보였고 평균 크기도 참조정보 추가 패키지의 증분과 비슷하였지만(α 8 개 조합 평균 +0.081 대 +0.084), 조합에 따라 크게 달라져 보정 후 차이가 남은 경우는 적었다.

이 결과를 읽을 때 두 가지를 고려해야 한다. 첫째, C6-EX 는 하나의 고정 순열에 조건부이며, 모든 가능한 재배정에 대한 평균 효과의 불확실성을 포함하지 않는다. 둘째, 같은 후보를 받는 기업이 많아 575 개 기업 가운데 141 개는 재배정 뒤에도 원래와 같은 후보를 받았다. 이 기업들에서는 두 조건의 참조가 같으므로, C6-E − C6-EX 는 연결의 효과를 작게 추정하는 쪽으로 치우칠 수 있다.

(3) 자기 재검토와 실행 규칙

참조 없이 같은 초안을 다시 검토하게 한 C4R − C4 는 자유 작성 24 개 조합 가운데 18 개에서 양수, 11 개에서 보정 후 유의하였다. 그러나 이 효과는 행동크기 조건에 따라 크게 달랐다. BINF 에서는 두 생성 설정과 두 모델 모두 α 에서 양의 효과가 확인되었지만(Gemini +0.143 과 +0.145, GPT +0.137 과 +0.072), B1 에서는 GPT 의 추론 낮음 설정(+0.169)을 제외하면 0 에 가까웠다.

GPT 의 추론 낮음·B1 에서 관측된 자기 재검토의 이득은 실행 규칙에 크게 의존하였다(<표 6-6>). 이 조건에서 C4 초안 575 개 가운데 320 개는 규칙을 어겨 실행할 수 없었다. 수정 조건은 이렇게 실행할 수 없는 초안도 원문 그대로 받아 다시 쓸 수 있었으므로, 재검토의 이득에는 판단의 개선뿐 아니라 실행할 수 없던 초안이 실행 가능한 행동으로 바뀐 효과가 섞인다. 같은 원응답에 결정론적 보정(Repaired)을 적용하면 C4R − C4 는 +0.169 에서 +0.005 로 거의 사라졌다. 실행할 수 없는 초안의 후속 응답을 무행동으로 바꾼 민감도 분석에서도 −0.002 가 되었고, 같은 설정의 BINF 에서도 +0.137 이 −0.002 로 사라졌다. 반대로 C6-E − C4R 은 보정 규칙에서 +0.038 에서 +0.194 로 커졌다.

<표 6-6> 실행 규칙에 따른 대비의 변화(GPT · 추론 낮음 · 자유 작성 · B1 · Oracle-α)

대비	엄격(Strict)	보정(Repaired)	실행할 수 없는 초안의 후속 응답을 무행동으로 처리
C4R − C4	+0.169	+0.005	−0.002
C5 − C4	+0.196	+0.079	+0.196
C6-E − C4R	+0.038	+0.194	+0.021
C6-E − C6-EX	+0.174	+0.203	+0.102

주: C4 초안 575 개 가운데 255 개가 실행 가능했고 320 개는 실행할 수 없었다. 오른쪽 열은 C4 가 실행할 수 없었던 기업의 후속 조건 결과를 무행동으로 바꾸어 다시 집계한 기술 통계이며, 새로운 생성 요청을 관찰한 것은 아니다. C5 는 초안을 받지 않으므로 이 처리의 대상이 아니다.

이 결과로 자기 재검토에 효과가 없다고 할 수는 없지만, 관측된 재검토의 효과를 모두 경제적 판단의 개선으로 보기도 어렵다. 응답의 검증과 실패 처리 규칙도 권고 절차의 평가 결과를 바꾸기 때문이다. 보정 규칙도 원래 의도를 복원하는 절차라기보다 행동의 크기를 줄이거나 값을 골라내는 또 하나의 실행 규칙이므로, 어느 쪽이 참값이라고 정할 수 없다. 추론 높음 설정에서는 최초 응답의 수용률이 거의 100%이므로 실행 규칙에 따른 차이가 작았고(보정과 엄격 규칙의 차이 −0.019~+0.019), 참조정보 추가 패키지의 증분도 두 규칙에서 비슷하게 유지되었다.

후보 선택에서 자기 재검토의 효과는 혼합적이었다. 12 개 조합 가운데 6 개가 양수였고, 보정 후 유의한 4 개 가운데 2 개는 양수(GPT 추론 낮음 α +0.025, 추론 높음 α +0.040), 2 개는 음수(Gemini β −0.020, −0.004)였다. 추론 높음 설정의 두 결과는 60 개 비교 보조 묶음으로 조정하면 유의하지 않다.

(4) 진단 유도

C5 − C4 는 자유 작성 24 개 조합 가운데 15 개에서 양수였고, 보정 후 유의한 5 개는 모두 추론 낮음·B1 조건이었다(GPT α +0.196, β +0.048, γ +0.053; Gemini α +0.115, β +0.012). 진단 지시가 낮은 수용률을 높인 효과(B1 수용률이 Gemini 15.3%에서 26.3%로, GPT 44.3%에서 65.7%로 상승)가 함께 작용했을 가능성이 있다. 추론 높음 설정이나 BINF 에서는 보정 후 유의한 효과가 없었고, 일부 조합은 음수였다(추론 높음·BINF 의 α: GPT −0.068, Gemini −0.065).

생성 설정과의 상호작용을 같은 기업에서 직접 계산하면, GPT 의 B1 에서 진단 유도와 자기 재검토가 주던 이득은 추론 높음 설정에서 줄었다. C5 − C4 의 차이는 추론 높음에서 추론 낮음보다 0.183 작았고, C4R − C4 는 0.143 작았다(두 값 모두 Holm 보정 $p < .01$). 반면 참조정보 추가 패키지의 증분(C6-E − C4R)의 차이는 GPT +0.063, Gemini +0.068 로 보정 후 유의하지 않았다. 최초 응답이 이미 실행 가능한 형태로 만들어지는 상태에서는 추가 지시나 재검토가 메울 수 있는 몫이 줄지만, 외부 참조가 주는 정보는 그대로 남는다는 해석과 맞는다. 다만 이 결과로 특정한 내부 추론 기제를 확인한 것은 아니다.

제 4 절 행동공간, 행동크기 조건, 평가모형

(1) 자유 작성과 후보 선택

추론 낮음·B1 에서는 자유 작성의 정책가치가 후보 선택보다 일관되게 낮았다. 2 개 모델 × 3 개 Oracle × 3 개 권고 방식(C4, C4R, C6-E)의 18 개 비교 모두에서 자유 작성 − 후보 선택이 음수였고, 18 개 모두 보정 후 유의하였다. Oracle-α 의 직접 작성에서 그 차이는 Gemini −0.703, GPT −0.337 이었다. 표현할 수 있는 행동공간이 넓어도, 그 안에서 규칙에 맞고 가치가 높은 행동을 실제로 구성하지 못하면 정책가치는 오히려 낮았다.

추론 높음 설정에서는 이 격차가 거의 사라졌다. α 에서 자유 작성 − 후보 선택의 평균은 직접 작성에서 GPT +0.018, Gemini +0.011, 자기 재검토에서 +0.005, +0.021, 참조 수정에서 +0.096, +0.074 였다. 수용률이 두 행동공간 모두에서 거의 100%가 되면 자유 작성은 후보 선택과 비슷하거나 약간 높은 가치를 보였고, 참조 수정에서는 자유 작성의 값이 더 높았다. 두 행동공간 사이의 우열은 생성 설정과 실행 규칙에 따라 달랐다.

(2) 행동크기 조건

BINF 에서는 총 행동크기 상한이 없으므로 행동의 크기가 커지고 정책가치의 절대 수준도 높아졌다. 예를 들어 추론 낮음 설정의 Gemini 직접 작성은 B1 에서 +0.147 이었으나 BINF 에서 +1.482 로, 행동크기 1 의 후보 안에서 정의한 상한(+1.401)을 넘었다. 이 값을 B1 의 결과와 같은 기준으로 비교하거나, 제약이 적은 정책을 실제 기업에 더 좋은 권고라고 읽어서는 안 된다. 큰 행동은 실제로 더 큰 비용과 실행 부담을 수반하지만 평가 장치는 그 비용을 측정하지 않는다.

행동크기 조건은 권고 방식의 효과도 바꾸었다. 추론 낮음 설정에서 같은 기업의 B1 효과와 BINF 효과의 차이를 직접 계산하면, Gemini 의 자기 재검토(C4R − C4)는 B1 에서 BINF 보다 0.145 작았고, 진단 유도(C5 − C4)는 0.187 컸다(두 값 모두 보정 후 유의). GPT 에서는 네 대비 모두 행동크기 조건 사이의 차이가 보정 후 유의하지 않았다. 따라서 행동크기 조건은 어떤 권고 절차가 유리하게 나타나는지를 바꾸는 실험 조건으로 다루어야 한다.

(3) 평가모형

참조정보 추가 패키지의 증분은 세 Oracle 모두에서 같은 방향이었다. 자유 작성의 C6-E − C4R 은 α, β, γ 각각의 8 개 조합 모두에서 양수였다(후보 선택에서는 GPT 추론 높음의 β 가 −0.002 였다). 반면 자기 재검토와 진단 유도의 효과는 Oracle 에 따라 방향이 달라진 조합이 있었다. 예를 들어 Gemini 의 B1 자기 재검토는 α 와 β 에서 음수였고, γ 에서는 생성 설정에 따라 부호가 갈리며 0 부근이었다. 정책가치의 크기는 Oracle 의 점수 척도에 따라 다르므로, 본 연구는 세 Oracle 의 결과를 합치지 않고 방향의 일관성을 강건성의 기준으로 삼는다.

제 5 절 정보조건

추론 낮음·B1 의 직접 작성에서 업종 코드(IC-b − IC-a)와 기업명(IC-c − IC-b)을 하나씩 추가하였다(<표 6-7>). 정보조건 비교는 결과 등록부의 비교 범위인 추론 낮음 설정에서

수행하였으며, 이 설정은 규칙을 지킨 응답의 비율이 낮아 정보의 효과가 작게 측정되었을 수 있다. Oracle-α 에서 업종 코드 추가의 효과는 Gemini −0.018, GPT −0.002, 기업명 추가의 효과는 Gemini +0.023, GPT +0.073 이었고, 세 Oracle 을 포함한 12 개 비교 가운데 보정 후 유의한 것은 없었다.

<표 6-7> 정보조건의 효과(추론 낮음 · 자유 작성 · B1 · 직접 작성)

모델	업종 추가(IC-b − IC-a), α	기업명 추가(IC-c − IC-b), α	업종 추가, β·γ	기업명 추가, β·γ
Gemini	−0.018 [−0.079, 0.041]	+0.023 [−0.056, 0.102]	−0.003, +0.006	+0.008, +0.017
GPT	−0.002 [−0.093, 0.089]	+0.073 [−0.017, 0.166]	−0.006, −0.017	+0.018, +0.019

주: 괄호는 95% 부트스트랩 구간이다. 12 개 비교 모두 Holm 보정 $p \geq .05$ 이다. IC-a 에도 연도, 자산 규모, 시장 구분은 포함된다. 업종은 조회 시점의 공시 업종 코드이며 2024 년 당시의 업종 분류라고 단정하지 않는다.

이 실험에서 업종 코드 하나나 기업명 하나를 추가하는 것만으로 평균 정책가치가 일관되게 높아지는 모습은 나타나지 않았다. 다만 이는 코드 형태의 업종 정보와 기업명이라는 제한된 정보를 더한 결과이므로, 업종 분석 보고서나 경영진 정보처럼 풍부한 정보의 효과는 따로 확인해야 한다. 또한 기업명을 공개하면 모델이 사전학습에서 얻은 기업 지식을 쓸 수 있으나, 본 실험은 그 사용 여부를 따로 측정하지 않았으므로 효과가 작다는 사실을 지식 개입이 없었다는 증거로 쓰지 않는다.

제 6 절 반복 실행에서의 안정성

반복 실행에서는 평균적인 결과의 반복성과 기업별 권고의 반복성을 나누어 살폈다. 같은 실험을 다시 실행한 반복 실행(Run2)에서 평균의 방향은 대체로 유지되었다. 추론 높음·B1 에서 C6-E − C4R 의 α 평균은 GPT 가 +0.100 에서 +0.098 로, Gemini 가 +0.090 에서 +0.065 로 비슷하였다. 그러나 어느 기업이 참조에서 더 큰 이득을 보는지는 거의 반복되지 않았다. Oracle-α 기준으로 두 실행에서 기업별 C6-E − C4R 차이의 순위상관은 0.06~0.29 로, 같은 기업의 C4 정책가치의 순위상관(0.44~0.86)보다 훨씬 낮았다.

권고 행동 자체도 자주 달라졌다(<표 6-8>). 행동 완전 일치는 8 개 축의 값이 모두 같아야 하는 엄격한 기준이다. 추론 높음·B1 의 직접 작성에서 두 실행 모두 규칙을 지킨 기업 가운데 이 기준을 충족한 비율은 GPT 48.6%, Gemini 7.5%였다. 값의 크기는 다르더라도 같은 축을 썼는지만 보면 일치율은 65.6%와 38.0%였고, 두 권고 사이의 평균 정규화 거리는 0.438 과 0.553 이었다(B1 에서 한 권고의 정규화 총 행동크기는 1 이하). Gemini 의 낮은 완전 일치율에는 같은 축을 쓰면서 크기만 달라진 경우가 포함되지만, 사용한 축이 같은 기업도 절반에 미치지 못했다. 참조를 받은 수정(C6-E)에서는 일치율이 조금 높아지고 거리는 줄었다(57.6%와 11.2%, 0.356 과 0.477). 이처럼 개별 기업의 권고가 달라져도 평균 정책가치와 정책 간 차이의 방향은 대체로 유지되었다. 반복 실행에서 흔들린 것은 집단의 평균보다 개별 기업에 대한 권고였다.

<표 6-8> 반복 실행 사이 권고 행동의 일치(자유 작성, 추론 높음, B1)

모델	권고 방식	두 실행 모두 수용된 기업	행동 완전 일치	사용 축 일치	평균 정규화 거리
GPT	C4 직접 작성	543	48.6%	65.6%	0.438
GPT	C4R 자기 재검토	560	48.8%	64.3%	0.436
GPT	C6-E 참조 수정	556	57.6%	67.6%	0.356
Gemini	C4 직접 작성	561	7.5%	38.0%	0.553
Gemini	C4R 자기 재검토	559	6.3%	35.4%	0.525
Gemini	C6-E 참조 수정	554	11.2%	39.9%	0.477

주: 행동 완전 일치는 8 개 축의 값이 모두 같은 경우(차이 10^{-9} 이하), 사용 축 일치는 값이 0 이 아닌 축의 조합이 같은 경우이며, 정규화 거리는 축별 차이의 절댓값을 정규화 척도로 나누어 더한 값이다. 반복 실행의 수정 조건은 각 실행의 C4 에서 갈라진다. BINF 의 결과는 부록 G 에 제시한다.

따라서 집단 평균에서 어떤 방식이 낫다는 결과를 한 기업에 대한 권고를 믿고 쓸 근거로 삼기는 어렵다. 기업 단위로 권고를 쓰려면 같은 요청을 여러 번 반복해 일치 여부를 확인하는 것과 같은 별도의 안정성 점검이 필요하다. 두 번의 실행은 제한적인 반복성 진단이며, 모델의 갱신이나 프롬프트 변경 이후의 안정성을 보여주지는 않는다.

제 7 절 소결

이 장의 결과는 다섯 가지로 정리된다.

첫째, 정책가치는 먼저 규칙에 맞는 응답을 만들었는지에 좌우되었다. 추론 낮음 설정의 B1 직접 작성은 수용률이 15~44%에 그쳐 정책가치가 무작위보다 낮았다. 추론 높음 설정에서는 수용률이 97% 이상으로 오르면서 직접 작성이 고정 OE 와 비슷한 수준까지 올라갔으나 두 모델 모두 C3-E 보다는 낮았다. B1 자유 작성에서는 같은 모델의 생성 설정에 따른 차이가 같은 설정에서 두 모델 사이의 차이보다 훨씬 컸다.

둘째, 권고 방식 가운데 효과의 방향이 일관된 것은 강화학습 참조를 보여준 수정이었다. 이 수정은 자유 작성의 24 개 조합 모두에서 참조 없는 재검토보다 높았고, 9 개 조합(나중에 추가한 실행을 보조 묶음으로 조정하면 7 개)에서 보정 후에도 차이가 남았다. 이 효과는 최초 응답의 수용률이 높은 추론 높음 설정에서도 유지되었고 세 Oracle 에서 같은 방향이었다. 반면 자기 재검토와 진단 유도의 효과는 모델, 행동크기 조건, 생성 설정, 실행 규칙에 따라 달라졌고, 일부는 실행할 수 없던 초안을 실행 가능하게 바꾼 효과와 구별되지 않았다. 규칙을 어긴 응답의 처리 방식에 따라서도 결과가 달라졌다.

셋째, 본 연구의 행동공간과 평가 조건에서는 LLM 이 기업별 정보를 활용하여 고정된 단순 정책보다 높은 정책가치를 안정적으로 만들어낸다는 증거를 확인하지 못했다. B1 의 직접 작성은 8 개 설정 어디에서도 고정 OE 를 유의하게 넘지 못했고, 업종 코드와 기업명을 더한 효과도 확인되지 않았다. LLM 은 기업 상태에 따라 행동을 달리 선택하기도 했으나(C3-E 와 같은 후보를 고른 비율이 후보 비율로 기대되는 값보다 높음), 비용효율화와 단기차입의 장기 전환에 선택이 집중되었다.

넷째, 행동공간과 행동크기 조건은 결과의 수준뿐 아니라 어떤 절차가 유리한지를 바꾸었다. 총 행동크기를 지시하지 않으면 정책가치가 상한을 넘기도 하였는데, 상한은 행동크기 1 의 후보 안에서 정의한 값이고 평가 장치는 큰 행동에 따르는 비용을 세지 않으므로 이를 더 좋은 권고로 읽어서는 안 된다.

다섯째, 평균 결과는 반복 실행에서 대체로 유지되었으나 기업 단위의 권고는 자주 달라졌다. 참조에서 이득을 보는 기업은 반복 실행에서 거의 재현되지 않았고, 추론 높음·B1 의 직접 작성에서 두 번 모두 규칙을 지킨 기업 가운데 행동이 완전히 같은 비율은 GPT 48.6%, Gemini 7.5%, 사용한 축이 같은 비율은 65.6%와 38.0%였다.

같은 두 모델에서도 생성 설정, 권고 방식, 행동공간, 행동크기 조건, 참조의 배정, 실행 규칙을 바꾸면 관측되는 정책가치가 크게 달라졌으므로, LLM 권고의 가치는 모델 이름만으로 설명하기 어렵다. 다음 장은 이 권고를 평가 장치 밖의 기준인 기업의 경영·사업계획 및 전문가 문서와 대조한다.

제 7 장 Human baseline 과의 대조

제 6 장까지의 비교는 모두 같은 평가 장치 안에서 이루어졌다. 평가 장치 안의 비교만으로는 장치가 높게 평가하는 권고가 실제 기업의 의사결정과 어떤 관계에 있는지 알 수 없다. 이 장은 비슷한 시점에 신용평가사와 증권사 등이 해당 기업에 대해 작성한 문서에서 앞으로의 경영·재무 행동을 추출하여 기업 경영·사업계획 및 전문가 문서 기반 비교 기준(Human baseline)으로 삼고, LLM 및 강화학습 참조 LLM 의 신용개선 권고를 이에 대조한다(RQ6). 문서에 기재된 행동은 대부분 기업이 추진한다고 밝힌 방침이며 전문가의 직접 권고는 일부이므로, 이 비교는 사람과 LLM 이 같은 조건에서 같은 문제를 푸는 경쟁이 아니다. 이 장이 묻는 것은 LLM 의 신용개선 권고가 실제 기업의 경영·사업계획 및 전문가가 문서에 기술한 행동과 얼마나 일치하고, 어떤 점에서 다른가이다.

제 1 절 비교의 설계와 가설

LLM 권고와 평가 장치가 문서에 나타난 기업의 경영·재무 판단에 가깝다면 세 가지가 관찰될 것이다(<표 7-1>). 첫째, LLM 이 고른 행동은 같은 기업의 Human baseline 과, 기업 사이에서 무작위로 짝지은 경우보다 자주 같은 종류여야 한다(H1). 둘째, 강화학습 참조를 본 수정(C6-E)이 문서의 방향을 반영한다면, 참조 없는 재검토(C4R)보다 Human baseline 과 같은 종류를 더 자주 골라야 한다(H2). 셋째, 평가 장치가 문서에 나타난 판단과 정렬되어 있다면 문서에 기재된 행동을 기준선이나 LLM 권고보다 높게 평가해야 한다(H3).

<표 7-1> Human baseline 비교의 가설과 결과

가설	반영한다면 관찰되어야 할 것	결과	절
H1. LLM 권고는 해당 기업의 문서에 기재된 행동과 대응한다	같은 기업의 Human baseline 과 같은 종류의 행동을 고른 비율이 기업 간 무작위 짝짓기보다 높다	확인되지 않음(네 LLM 비교 모두 무작위 짝짓기보다 높다는 통계적 증거 없음). 문서 라벨에 상환이 있는 기업에 LLM 은 장기 전환을 권함	제 3 절
H2. 강화학습 참조는 권고를 문서의 행동 쪽으로 옮긴다	강화학습 참조 수정(C6-E)이 참조 없는 재검토(C4R)보다 같은 종류를 더 자주 고른다	확인되지 않음(네 조합 모두 0 과 구별되지 않음)	제 3 절
H3. 평가 장치는 문서에 기재된 행동을 높게 평가한다	Human baseline 행동의 점수가 기준선·LLM 보다 높다	지지되지 않음(α 에서 무작위보다는 높으나 고정 OE·C3-E·LLM 과 구별되지 않음)	제 4 절

이 장의 LLM 조건은 후보 선택, 추론 높음(High), B1, 기본 정보조건 IC-b(재무 항목과 업종 코드), 본실험(Run1), 엄격 규칙으로 통일하였다(H2 는 두 생성 설정을 모두 보고한다). 후보 선택으로 통일한 것은 문서에 행동의 크기가 거의 없어 Human baseline 행동을 점수로 비교하려면 후보행동의 표준 행동크기가 필요하고, 같은 표준 행동크기를 쓰는 조건끼리 비교해야 공정하기 때문이다. 추론 높음 설정을 주 비교로 둔 것은 이 설정에서만 두 모델의 후보

선택과 자유 작성 수용률이 모두 95% 이상이어서(제 6 장), 규칙 위반에 따른 무행동 처리가 비교를 흐리지 않고 자유 작성의 보조 결과도 같은 설정에서 볼 수 있기 때문이다. 참조 없는 LLM 은 한 번에 작성하는 직접 작성(C4)으로 비교하였다. 문서의 작성 과정에는 본 연구의 재검토 지시나 참조 제시에 해당하는 단계가 없기 때문이다.

제 2 절 Human baseline 의 구성

(1) 문서의 수집

이상적인 비교 기준은 신용을 아는 사람이 LLM 과 같은 결정 시점에 2024 회계연도 재무를 보고 그 기업의 신용개선을 위해 제시한 행동일 것이다. 이에 가장 가까운 공개 자료로 두 종류의 문서를 사용하였다. 첫 번째 출처는 신용평가사의 평가의견으로, 한국신용평가의 평가의견과 NICE 신용평가의 평가의견서 요지이다. 한국기업평가의 평가의견은 본문이 공개되지 않아 사용하지 못하였고, 은행 지급보증 사채처럼 보증기관의 신용으로 평가된 문서는 제외하였다. 두 번째 출처는 증권사 등의 리서치 보고서로, 증권사 기업분석 보고서와 NICE 평가정보·서울평가정보의 기업 리서치 보고서이다. NICE 평가정보의 보고서에는 NICE 평가정보 연구원이 작성하고 한국 IR 협의회가 발간한 기술분석보고서가 포함된다. 자동 생성 보고서, 뉴스 요약, 다른 기업(계열사·지주사)에 관한 문서는 제외하였다.

수집 기간은 두 출처 모두 2025 년 1 월 1 일부터 6 월 30 일까지이다. 신용평가사 문서는 기간 안의 해당 기업 평가의견을 모두 사용하였고, 리서치 보고서는 기업마다 2024 년 실적을 다룬 보고서 가운데 가장 이른 것 한 건을 사용하였다. LLM 이 받은 정보(2024 년 결산)와 시점이 가장 가까운 문서를 고르기 위해서이다. 이 규칙에 따라 더 이른 날짜의 보고서 86 건은 2024 년 실적을 다루지 않은 것으로 판단되어 제외되었고, 뒤에서 설명하는 재점검에서도 86 건 모두 같은 판단이 나왔다. 수집은 미리 정한 개수에서 멈추지 않고, 575 개 기업 전체를 신용평가사 공시 목록과 리서치 보고서 목록에 대조하는 작업을 모두 마친 뒤 종료하였다. 그 결과 161 개 기업에 대해 236 건의 문서를 얻었다(신용평가사 문서 95 건·47 개 기업, 리서치 보고서 141 건·141 개 기업, 두 출처 모두 있는 기업 27 개). 문서 원문은 저작권 때문에 재현 키트에 포함하지 않는다.

(2) 코딩

문서마다 앞으로의(또는 진행 중인) 경영 행동을 하나씩 기록하고, 각 행동에 진술 유형과 8 개 행동 축의 방향을 붙였다. 진술 유형은 작성자가 권고한 행동(권고), 회사가 추진한다고 작성자가 전한 행동(회사 방침), 작성자가 앞으로의 경로로 제시한 행동(개선 경로), 이미 실행된 행동(실현 행동) 등으로 구분하였고, 앞의 세 유형만 앞으로의 행동으로 사용하였다. 축의 방향은 행동공간이 표현하는 방향(+, 예: 성장 투자 축소, 차입금 상환, 원가 절감)과 그 반대 방향(−, 예: 증설·신규 투자 확대, 차입 확대)으로 기록하였다. 축으로 표현되지 않는 행동은 자산 매각 증자, 인수합병, 주주환원, 매출 성장, 판가·제품 구성, 신사업, 구조조정으로 따로 기록하였다. 또한 문서가 그 기업의 재무·신용 경로로 중요하게 다룬 행동, 즉 등급 논거·핵심 검토사항·

요약에 나오거나 결론을 좌우하는 행동을 핵심 행동으로 표시하였다. 문서에 행동의 크기가 적혀 있어도 라벨에는 쓰지 않았고, 문서에 없는 크기를 만들지 않았다.

차입금에 관한 서술에는 용어의 구별이 필요하다. 본 연구에서 RF 는 단기차입금을 장기차입금으로 바꾸는 단기차입의 장기 전환(원금 유지)을 뜻한다(제 3 장). 그런데 문서에서 차환이라는 말은 만기가 돌아오는 차입금을 다시 빌려 갚는 일을 넓게 가리키는 경우가 많다. 이 장에서는 둘을 구별하기 위해 RF 를 장기 전환이라 부르고, 문서가 서술한 만기 차입금의 만기연장과 재차입은 만기연장·재조달이라 부른다. 차입금에 관한 앞으로의 서술은 세 가지로 나누어 기록하였다. 총차입을 줄이는 상환(총차입금 상환 축 +), 단기차입을 장기로 바꾸어 만기를 늘리는 장기 전환(단기차입 장기전환 축 +), 그리고 만기가 돌아오는 차입금을 만기연장이나 재차입으로 넘기는 만기연장·재조달이다. 만기연장·재조달은 총차입을 줄이지 않고 단기차입을 장기로 바꾼다는 내용도 없으므로 본 연구의 행동공간으로 표현되지 않으며, 행동공간 밖의 행동으로 기록하였다. “미사용 여신한도와 담보 여력으로 대응할 수 있다”처럼 감당할 능력만 평가한 서술은 상환으로 보지 않았다.

비교는 행동을 다섯 종류로 나누어 수행하였다. 상환(총차입금 상환), 장기 전환(단기차입 장기전환), 투자(성장 투자 축소), 운전자본(재고·매출채권·매입채무), 영업(원가율·판관비율)이다. 상환과 장기 전환은 같은 차입금을 다루지만 하나는 빚을 줄이고 다른 하나는 빚을 유지한 채 만기만 늘리는 행동이므로 따로 셌다. 기재된 + 방향 축 집합이 9 개 후보 가운데 하나와 정확히 대응하고, 핵심 행동 가운데 반대 방향이나 행동공간 밖의 행동이 없으면 그 후보를 문서의 후보 라벨(단일 후보)로 두었다. 같은 출처에 속한 한 기업의 문서들은 앞으로의 행동을 합쳐 기업 단위 라벨로 만들었다.

코딩에는 문서 본문, 코딩 지침, 기업명만 사용하였고, LLM 과 C3-E 가 고른 행동이나 Oracle 점수는 참고하지 않았다. 라벨을 확정하기 전에 236 건 전체를 원문과 다시 대조하였다. 재점검에서는 문서마다 원문을 처음부터 끝까지 읽어 앞으로의 행동 목록을 먼저 만든 뒤 기존 라벨과 비교하였고, 앞에서 설명한 차입금 서술의 세 구분을 지침에 명시하였다. 재점검에서는 기존 행동 1,302 개 가운데 318 개에 대해 진술 유형·축·핵심 여부 등의 수정안이 나왔고(가장 많은 것은 핵심 여부의 변경 220 개), 12 개의 제외안(행동이 아닌 것 10 개, 중복 1 개, 생성형 AI 답변 상자에만 근거한 것 1 개)과 157 개의 추가안이 나왔다. 이 가운데 비교에 쓰이는 값, 즉 행동 축의 방향, 기업 후보 라벨의 성립 여부, 문서의 대표 진술 유형을 바꾸는 89 건은 원문을 다시 확인하여 48 건만 변경하였다(기존 라벨이 원문에 더 맞는 28 건과 어느 쪽이 맞는지 가를 수 없는 13 건은 기존 라벨 유지). 변경하지 않은 경우의 상당수는 “상환에 대응할 수 있다”는 능력 평가를 상환 행동으로 보거나(6 건), 기존 차입 구성의 설명이나 수주·판가의 결과 전망을 회사의 행동으로 본 경우처럼 문서의 서술을 넘어서는 해석이었다. 비교에 쓰이는 값을 바꾸지 않는 나머지 변경은 재점검 결과를 그대로 반영하였다. 생성형 AI 답변 상자는 리서치 보고서 7 건(한국 IR 협의회 발간 기술분석보고서)에서 확인되었으며, 상자 안의 문장은 사람의 서술이 아니므로 근거로 쓰지 않았다. 재점검 전후의 결과는 부록 F 에 함께 제시한다.

(3) 비교 대상 기업

한 기업에 두 출처의 문서가 모두 있으면 신용평가사 문서를 우선하였다. 신용평가사 라벨에 + 방향 행동이 있으면 그 라벨을, 신용평가사 문서가 없거나 그 라벨에 + 방향 행동이 없으면 리서치 보고서 라벨을 쓰고, 두 라벨 모두에 + 방향 행동이 없으면 비교에서 제외하였다. 그 결과 행동공간으로 표현되는 행동이 있는 56 개 기업이 비교 대상이 되었다(<표 7-2>). 문서가 있는 161 개 기업 가운데 105 개는 앞으로의 행동이 없거나, 있더라도 행동공간 밖의 행동이나 반대 방향의 행동뿐이어서 제외되었다. 재점검 전과 비교하면 1 개 기업이 새로 비교 대상에 들어왔고(상환 계획이 확인된 효성), 1 개 기업은 행동 종류가 추가되었으며(현대모비스, 투자 축소), 4 개 기업은 핵심 행동에 반대 방향이나 행동공간 밖의 행동이 확인되어 단일 후보 라벨을 잃었다.

<표 7-2> Human baseline 자료의 구성

항목	값
출처·기간	신용평가사: 한국신용평가·NICE 신용평가 평가의견 / 증권사 등: 증권사 기업분석 보고서, NICE 평가정보·서울평가정보 기업 리서치 보고서(모두 2025.1.1~6.30 공개)
문서와 기업	236 건, 161 개 기업(신용평가사 95 건·47 개 기업, 증권사 등 141 건·141 개 기업, 두 출처 모두 27 개 기업)
비교 대상 기업	56 개(신용평가사 라벨 32 개, 증권사 등 라벨 24 개)
· 단일 후보 라벨이 있는 기업	3 개(모두 OE)
· 단일 후보 라벨이 없는 기업(여러 축을 기재했거나 핵심 행동에 반대 방향·행동공간 밖의 행동이 있음)	53 개
비교 대상 기업 중 반대 방향(−) 행동도 기재된 기업	33 개(그중 투자 확대 32 개)
비교 대상 기업 중 만기연장·재조달 서술이 있는 기업	18 개(행동공간 밖으로 기록)

주: 증권사 등 라벨 24 개 가운데 22 개는 신용평가사 문서가 없는 기업, 2 개는 신용평가사 라벨에 + 방향 행동이 없는 기업이다. 만기연장·재조달 서술은 “만기연장”, “차환” 같은 표현으로 회사의 처리 방식을 직접 서술한 경우만 세었다.

이 자료는 이상적인 비교 기준과 몇 가지 점에서 다르다. 첫째, 문서에 기재된 앞으로의 행동은 대부분 작성자 자신의 권고가 아니라 회사가 추진한다고 작성자가 전한 방침이었다. 신용평가사 문서 95 건 가운데 80 건, 리서치 보고서 141 건 가운데 98 건의 대표 진술 유형이 회사 방침이었고 명시적 권고가 대표 유형인 문서는 각각 8 건과 7 건이었다. 신용평가사 문서의 권고 8 건 가운데 6 건은 만기가 돌아오는 차입금에 차환 등의 조치가 필요하다는 유동성 판단이었다. 따라서 Human baseline 은 전문가의 처방보다는 전문가 문서에 기재된 회사의 계획과 전문가가 제시한 경로로 읽는 것이 맞다. 둘째, 정보 시점이 LLM 과 완전히 같지 않다. LLM 은 2024 년 결산 재무정보만 받았지만 문서는 2025 년 상반기에 작성되었다. 신용평가사의 정기평가는 5~6 월에 몰려 있어 신용평가사 문서 95 건 가운데 43 건은 2025 년 1 분기 실적까지 반영하였고, 리서치 보고서 141 건 가운데 33 건도 그러하였다. 반대로 신용평가사 문서 15 건은 2024 년 이전 실적에 근거하였다(3 건은 불분명). 셋째, 신용평가사 문서가 있는 47 개 기업은 575 개 전체보다 크고

차입이 많다. 자산 규모(로그) 중앙값은 21.37 대 18.91, 총자산 대비 차입금 중앙값은 0.20 대 0.08 이다.

문서에는 행동공간 밖의 계획도 많았다. 신용평가사 문서가 있는 47 개 기업 가운데 33 개 기업의 문서에 증설이나 신규 투자 같은 투자 확대가 기재되었다. 재점검 전 기준으로 투자 확대가 기재된 32 개 기업에 대해 서술의 성격을 따로 분류한 결과, 신용평가사는 이 투자 확대를 신용 부담(20 개 기업) 또는 부담과 기대가 섞인 요인(12 개 기업)으로 서술했고, 긍정적으로만 서술한 경우는 없었다. 이 밖에 신용평가사 문서 95 건에서 매출 성장(52 건), 판가·제품 구성(37 건), 신사업(36 건), 인수합병(31 건), 자산 매각(25 건)이 기재되었다. 이러한 행동은 본 연구의 행동공간으로 표현되지 않으므로 비교에 들어가지 않는다.

차입금에 관한 서술에는 뚜렷한 특징이 있었다. 236 건 가운데 단기차입을 장기로 바꾸는 장기 전환을 앞으로의 행동으로 서술한 문서는 한 건도 없었고, 장기 전환은 이미 실행된 사례로 한 기업의 문서 3 건에 나왔을 뿐이다. 반면 신용평가사 문서가 있는 47 개 기업 가운데 34 개 기업의 문서가 만기가 돌아오는 차입금의 처리를 다루었다. 그 가운데 26 개 기업의 문서는 “만기연장”, “차환” 같은 표현으로 만기연장·재조달을 직접 서술했고, 나머지 8 개 기업의 문서는 미사용 여신한도·담보 여력·자본시장 접근성으로 감당할 수 있다는 능력만 평가하였다. 상환을 앞으로의 행동으로 서술한 기업은 신용평가사 문서에서 8 개, 리서치 보고서에서 3 개였다. 신용평가사 문서는 단기차입을 주로 상환보다 재차입이 가능한지의 관점에서 다루었다.

제 3 절 LLM 권고와 전문가 문서의 대응 (H1, H2)

(1) 같은 종류의 행동을 고른 비율

LLM 이 그 기업의 Human baseline 과 같은 종류의 행동을 하나 이상 고른 기업의 비율(겹침)을 계산하였다. 이 비율은 우연만으로도 높게 나올 수 있다. 문서에는 비용 절감처럼 많은 기업에 공통으로 기재된 행동이 있어, 기업을 보지 않고 모든 기업에 비용효율화를 권해도 상당수가 맞는다. 그래서 LLM 이 고른 행동을 기업 사이에서 무작위로 섞어 다른 기업의 Human baseline 과 짝지은 뒤 같은 비율을 계산하는 일을 10,000 번 반복하고, 그 평균을 무작위 짝짓기 기대값(이하 기대값)으로 두었다. 이렇게 섞으면 LLM 이 어떤 행동을 자주 고르는지는 그대로 남고 기업과 행동 사이의 연결만 끊어진다. p 값은 섞은 결과가 실제 비율 이상인 경우의 수에 1 을 더해 10,001 로 나눈 단측 값이며 다중비교 보정을 하지 않았다.

<표 7-3> Human baseline 과 같은 종류의 행동을 고른 기업의 비율(56 개 기업)

정책	실제	무작위 짝짓기 기대값	p
직접 작성(C4) · GPT	0.250	0.269	.769
직접 작성(C4) · Gemini	0.339	0.329	.484
강화학습 참조 수정(C6-E) · GPT	0.196	0.236	.898
강화학습 참조 수정(C6-E) · Gemini	0.339	0.329	.481
참고: C3-E(강화학습 참조정책)	0.339	0.381	.899
참고: 고정 OE	0.643	—	—
참고: 무작위(9 개 후보 균등 기대값)	0.266	—	—

주: 후보 선택, 추론 높음, B1, IC-b, 본실험, 엄격 규칙. 행동 종류는 상환, 장기 전환, 투자, 운전자본, 영업의 다섯이다. 기대값은 정책의 행동을 기업 사이에서 섞은 10,000 회 순열의 평균이다. 고정 OE 는 모든 기업에 같은 행동을 주므로 섞어도 값이 같고, 무작위는 9 개 후보의 기대값이므로 무작위 짝짓기를 따로 계산하지 않는다. Gemini 는 참조를 본 뒤 56 개 기업 가운데 2 개에서만 후보를 바꾸었고(장기 전환과 상환·비용 복합 사이), 두 기업의 겹침 여부가 서로 반대로 바뀌어 두 행의 실제 값과 기대값이 같다. 상환과 장기 전환을 부채 한 종류로 묶어 네 종류로 세면 겹침은 GPT 0.411(기대값 0.346, p = .098), Gemini 0.482(기대값 0.395, p = .027)로 높아지는데, 이 차이는 문서 라벨에 상환이 있는 9 개 기업에서 LLM 이 고른 장기 전환을 같은 종류로 센 데서 나온다(부록 F). 네 종류 기준의 Holm 보정 p 는 네 LLM 비교에서 .107 이상이었고, 단기차입 부담 세 구간 안에서 섞으면 직접 작성의 p 는 GPT .143, Gemini .058 이었다. 다만 네 종류 기준을 자카드 지수로 세면 Gemini 의 차이는 Holm 보정 후에도 남았다(p = .013).

<표 7-3>에서 두 모델의 직접 작성과 참조 수정 모두, LLM 권고가 해당 기업의 문서와 무작위 짝짓기보다 더 높은 행동 일치를 보인다는 통계적 증거는 확인되지 않았다(GPT 0.250 대 기대값 0.269, Gemini 0.339 대 0.329; 네 비교의 Holm 보정 p 는 모두 1). 다섯 종류 분류에서 겹침을 집합의 유사도(자카드 지수)로 측정해도 Gemini 0.268 대 0.222(p = .069), GPT 0.205 대 0.191(p = .338)이었고, 자유 작성에서도 GPT 0.286 대 0.274(p = .474), Gemini 0.446 대 0.418(p = .320)이었다. 상환과 장기 전환을 하나의 부채 종류로 묶는 대안적 분류에서는 Gemini 의 겹침이 0.482 로 기대값 0.395 보다 높았으나(보정 전 p = .027, GPT 는 0.411 대 0.346, p = .098), 네 비교의 Holm 보정과 단기차입 부담의 통제를 거치면 겹침 비율의 차이는 유지되지 않았다(<표 7-3>의 주). 이 결과는 상환과 장기 전환을 같은 종류로 볼지에 따라 달라지며, 주 분석의 다섯 행동 분류에서는 기업별 대응의 통계적 증거가 확인되지 않았다. 이 결론은 재점검 전의 라벨(55 개 기업)에서도 같았다(부록 F).

가장 뚜렷한 어긋남은 부채에서 나타났다. 문서 라벨에서 부채 행동이 있는 9 개 기업은 모두 상환이었는데, 이 9 개 기업에서 GPT 의 직접 작성은 9 개 모두 장기 전환을 골랐고 Gemini 는 8 개에서 장기 전환, 1 개에서 상환·비용 복합을 골랐다. 자유 작성에서도 두 모델의 권고는 이 9 개 기업 모두에서 장기 전환을 포함하고 상환은 포함하지 않았다.

고정 OE 의 겹침(0.643)이 가장 높은 것은 비용 절감이 문서에 가장 흔하게 기재된 행동이기 때문이다. 반대로 강화학습 참조정책 C3-E 의 겹침(0.339)은 자신의 기대값(0.381)보다도 낮았다 평가 장치 안에서 고정 OE 보다 높은 가치를 보인 C3-E 도 기업별로 문서의 행동과 대응한다는 증거는 없었다. 단일 후보 라벨이 있는 3 개 기업은 문서 후보가 모두 OE 였고, 두 모델의 직접 작성과 고정 OE 도 3 개 기업 모두에서 OE 를 골랐다. 대상이 30 개 미만이면 유의성을 판단하지 않는다는 규칙에 따라 이 결과는 기술적으로만 보고한다.

(2) 만기 차입금에 대한 대응의 차이

단기차입 부담이 큰 기업에서 문서와 LLM 이 제시한 부채 수단은 서로 달랐다. 문서 라벨에 상환이 있는 9 개 기업 외에도, 신용평가사 문서는 단기차입 부담이 큰 기업의 만기 차입금을 만기연장·재조달로 넘긴다고 서술했고 단기차입을 장기로 바꾼다는 서술은 없었다. LLM 은 이러한 기업에도 장기 전환을 권했다. “만기연장”, “차환” 같은 표현이 있는 26 개 기업 가운데 GPT 의 직접 작성은 19 개(73%)에, Gemini 는 15 개(58%)에 장기 전환을, 8 개에 상환·비용 복합을 권했다. 뒤의 민감도 분석에 쓰인 64 개 기업 전체에서 장기 전환을 권한 비율(GPT 47%, Gemini 41%)보다 높은 비율이다.

본문 분석은 만기연장·재조달을 행동공간 밖으로 두었다. 문서가 단기차입을 장기로 바꾼다고 서술하지 않았기 때문이다. 이 분류가 결론을 좌우하는지 보기 위해, 반대쪽 극단의 가정으로 명시적 표현이 있는 26 개 기업의 서술을 장기 전환으로 코딩한 민감도 분석을 수행하였다(<표 7-4>). 이 경우 만기연장·재조달 서술만 있던 8 개 기업이 새로 들어와 비교 대상은 64 개 기업이 된다. 후보 선택의 겹침은 GPT 0.516, Gemini 0.531 로 높아졌지만 기대값도 함께 높아져(0.428, 0.463) p 는 .068 과 .124 였고, 네 LLM 비교의 Holm 보정 p 는 .27 이상이었다. 자유 작성에서는 GPT 만 보정 전 기준으로 기대값을 넘었다(0.547 대 0.431, p = .017, 네 비교의 Holm 보정 .066).

<표 7-4> 만기연장·재조달 서술을 장기 전환으로 본 민감도와 단기차입 부담을 통제한 겹침

정책	본문(56 개 기업): 실제 / 기대값 / p	민감도(64 개 기업): 실제 / 기대값 / p	민감도, 단기차입 부담 세 구간 안에서 섞은 기대값 / p
직접 작성(C4) · GPT	0.250 / 0.269 / .769	0.516 / 0.428 / .068	0.502 / .448
직접 작성(C4) · Gemini	0.339 / 0.329 / .484	0.531 / 0.463 / .124	0.521 / .486
강화학습 참조 수정(C6-E) · GPT	0.196 / 0.236 / .898	0.469 / 0.408 / .148	0.482 / .693
강화학습 참조 수정(C6-E) · Gemini	0.339 / 0.329 / .481	0.531 / 0.464 / .124	0.523 / .496
참고: C3-E	0.339 / 0.381 / .899	0.453 / 0.450 / .527	0.493 / .842
자유 작성 직접 작성 · GPT	0.286 / 0.274 / .474	0.547 / 0.431 / .017	0.490 / .128
자유 작성 직접 작성 · Gemini	0.446 / 0.418 / .320	0.594 / 0.557 / .283	0.597 / .603

주: 다섯 종류 기준, 추론 높음, B1, IC-b, 본실험, 엄격 규칙. 민감도는 “만기연장”, “차환” 같은 표현으로 만기 차입금의 처리 방식을 서술한 26 개 기업의 서술을 장기 전환으로 코딩해 같은 방식(10,000 회 순열)으로 다시 계산한 값이다. 오른쪽 열은 기업을 총자산 대비 단기차입·유동성장기부채 비율의 세 구간(삼분위)으로 나눈 뒤 같은 구간 안에서만 정책의 행동을 섞은 10,000 회 순열의 평균과 p 값이다. 자유 작성의 행동 종류는 크기 0.10 이상인 + 방향 축으로 정하였다. 민감도에서 Holm 보정 p 는 후보 선택 네 비교 .27~.37, 자유 작성 네 비교 .066~.57 이다.

단기차입 부담을 통제하고 이 겹침을 다시 살펴보았다. 문서가 부채 쪽 행동이나 만기연장·재조달을 다룬 기업은 단기차입 부담이 컸다. 민감도의 64 개 기업에서 총자산 대비 단기차입·유동성장기부채 비율의 중앙값은 이런 기업과 나머지 기업에서 0.199 대 0.042, 단기차입 대비 현금의 중앙값은 0.15 배 대 0.92 배였다. LLM 도 단기차입 부담이 큰 기업에 부채 행동을 몰아 권했다. 부담의 하위·중위·상위 구간에서 부채 행동을 권한 기업의 비율은 GPT 32%·76%·86%,

Gemini 23%·86%·95%였고, 문서가 부채 쪽 행동을 다룬 비율은 14%·57%·62%였다. LLM 의 행동을 단기차입 부담이 같은 구간의 기업끼리만 섞으면 기대값은 0.502(GPT)와 0.521(Gemini)로 올라가 실제 겹침과의 차이가 0.01 안팎으로 줄었고, 보정 전 기준으로 기대값을 넘었던 자유 작성 GPT 도 p = .128 이 되었다(<표 7-4>의 오른쪽 열). 다만 상위 구간에서는 LLM 이 86~95%의 기업에 부채 행동을 권했으므로 구간 안 비교의 검정력은 낮다. 따라서 문서와 LLM 이 모두 단기차입 부담이 큰 기업에서 부채 쪽 행동을 다루었다는 점은 확인되지만, 같은 부담 구간 안에서 같은 기업에 같은 종류의 행동을 제시했다는 증거는 없었다.

이 차이를 해석할 때에는 표현 수단의 차이를 함께 고려해야 한다. LLM 의 후보에는 만기연장·재조달에 해당하는 행동이 없으므로, 만기 차입금을 관리해야 한다는 판단도 장기 전환으로밖에 표현할 수 없었을 수 있다. 본 연구는 LLM 의 근거 설명을 분석하지 않았으므로 문서와 LLM 의 차이가 판단의 차이인지 표현 수단의 차이인지 구별할 수 없다. 다만 문서 라벨에 상환이 있는 9 개 기업에서는 LLM 도 상환이 들어간 후보(DL, MX1, MX2)를 고를 수 있었으므로, 그 기업들에서 장기 전환을 고른 것을 행동공간의 표현 한계만으로 설명하기는 어렵다. 다만 이 9 개 기업 가운데 7 개는 만기연장·재조달 서술도 함께 있어, 그 일부는 표현 수단의 차이와 겹칠 수 있다. LLM 은 부채 구조를 바꾸지 않는 다른 후보(비용 절감 등)를 고를 수도 있었다.

(3) 참조정보 추가 패키지의 증분 (H2)

H2 는 강화학습 참조 수정(C6-E)과 참조 없는 재검토(C4R)를 같은 기업에서 비교한다(<표 7-5>). 두 모델과 두 생성 설정의 네 조합 모두에서 겹침의 차이는 0 과 구별되지 않았다. 참조를 본 뒤 겹침 여부가 바뀐 기업은 조합마다 1~8 개에 그쳤고, 추론 높음 설정에서는 두 모델 모두 점추정이 0 이하였다. 만기연장·재조달 서술을 장기 전환으로 본 민감도 분석에서도 네 조합 모두 0 과 구별되지 않았다. 제 6 장에서 참조정보 추가 패키지의 증분은 자유 작성에서 정책가치를 일관되게 높였지만, 이 장의 조건(후보 선택·추론 높음)에서는 평가 장치의 점수로도 뚜렷하지 않았다(α 에서 GPT +0.009, Gemini +0.037, 제 6 장). 어느 경우에도 참조로 인한 이동이 전문가 문서의 행동 쪽을 향했다는 증거는 없었으며, 이는 C3-E 자체가 전문가 문서와 기업별로 대응하지 않았다는 앞의 결과와도 맞는다.

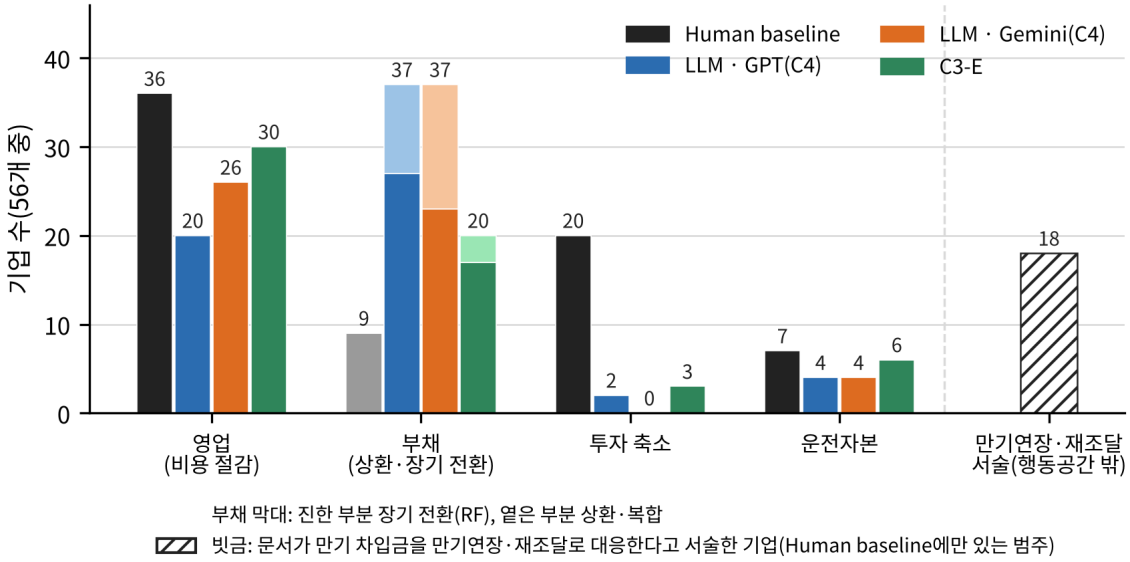
<표 7-5> 강화학습 참조 수정과 참조 없는 재검토의 겹침 차이(C6-E − C4R, 56 개 기업)

모델 · 생성 설정	겹침 차이	95% 구간
GPT · 추론 낮음	+0.036	[−0.054, 0.125]
Gemini · 추론 낮음	+0.036	[−0.036, 0.107]
GPT · 추론 높음	−0.036	[−0.089, 0.000]
Gemini · 추론 높음	−0.018	[−0.054, 0.000]

주: 다섯 종류 기준, 후보 선택, B1, IC-b, 본실험, 엄격 규칙. 구간은 기업 단위 부트스트랩 10,000 회의 2.5·97.5 백분위이며 보정하지 않았다. 두 조건의 겹침 여부가 다른 기업은 위에서부터 8 개, 4 개, 2 개, 1 개이다.

(4) 문서에 기재된 행동과 LLM 이 권한 행동의 종류

<그림 7-1>은 문서에 기재된 행동과 LLM 이 권한 행동의 종류를 기업 수로 비교한 것이다. 비용 절감은 모든 쪽에서 자주 나타났다. 문서에서 가장 흔한 행동은 비용 절감(56 개 기업 중 36 개)이었고, LLM(GPT 20 개, Gemini 26 개)과 C3-E(30 개)도 비용 절감을 자주 권했다. 비용 절감은 세 Oracle 모두에서 고정 정책 가운데 가장 높게 평가된 행동이기도 하다. 그러나 이는 빈도의 일치이며, 같은 기업에서 무작위 짝짓기보다 더 일치했다는 증거는 아니었다. 문서가 비용 절감을 담은 36 개 기업 가운데 LLM 이 비용 절감을 권한 기업은 GPT 13 개, Gemini 18 개로 두 선택이 서로 무관할 때 기대되는 수(12.9 개, 16.7 개)와 비슷했다. 차이가 가장 큰 것은 부채 수단이었다. 두 LLM 은 모두 56 개 기업 가운데 37 개에 부채 쪽 행동을 권했고 그 대부분이 장기 전환이었다(GPT 27 개, Gemini 23 개). 반면 문서의 라벨에서 행동공간 안의 부채 행동은 9 개 기업의 상환뿐이었고 장기 전환은 없었다. 그 대신 18 개 기업의 문서가 만기 차입금을 만기연장·재조달로 넘긴다고 서술했고, 그 가운데 11 개 기업에는 다른 부채 행동이 없었다(그림의 빗금, 행동공간 밖). 투자에서도 차이가 있었다. 56 개 기업 가운데 문서는 투자 축소(20 개 기업)와 투자 확대(32 개 기업)를 모두 다루었지만, LLM 은 투자 축소를 거의 권하지 않았다(GPT 2 개, Gemini 0 개). C3-E 는 비용 절감(30 개)과 부채(20 개)를 모두 권해 문서와 LLM 의 중간에 있었다 이러한 부채 수단의 차이는 56 개 기업에 한정되지 않는다. 575 개 기업 전체에서도 같은 조건의 LLM 은 30~34%의 기업에 장기 전환을, 3% 미만의 기업에 설비투자 축소를 골랐다(제 6 장).



<그림 7-1> 문서에 기재된 행동과 LLM(직접 작성)·C3-E 가 권한 행동의 종류(56 개 기업)

장기 전환에 대한 선호는 평가 장치의 채점 방식과도 관련이 있다. 장기 전환은 총차입을 줄이지 않고 만기 구조만 바꾸는 행동이지만, 제 4 장에서 보았듯이 Oracle-α 에서 장기 전환으로 점수가 낮아진 기업은 한 곳도 없었고, 모든 기업에 장기 전환을 적용한 고정 정책의 가치는 +0.663 으로 9 개 후보 가운데 비용효율화(+0.765) 다음으로 높다(부록 B). 강화학습 참조정책도 단기차입금을 비유동 장기차입금보다 무겁게 세는 보상의 구조와 일치하게 575 개 기업 가운데 155 개에 장기 전환을 골랐다(제 5 장). 1 년 뒤 신용점수로 채점하는 장치와 이러한 보상에서는

유동성 구조를 바꾸는 행동, 특히 Simulator 에서 비용이 들지 않는 행동이 유리하게 평가되며, LLM 의 선택도 같은 방향에 있다. 다만 LLM 은 평가 장치의 점수를 받지 않았으므로 장치를 알고 장기 전환을 골랐다는 근거는 없다. 단기부채를 줄이면 유동성 위험이 줄어든다는 일반적인 재무 지식이 같은 방향을 가리켰을 수 있다. 어느 경우든 이 수렴은 장기 전환이 실제로 신용을 개선한다는 독립된 증거가 아니다. 평가 장치와 보상은 모두 단기차입금을 비유동 장기차입금보다 무겁게 보면서 장기 전환이 실제로 가능한지는 따지지 않으며, LLM 의 선택이 그 가능성을 검토한 결과인지도 확인되지 않았다. 문서에서 만기연장·재조달은 담보, 보증, 미사용 한도를 바탕으로 만기 차입금을 감당하는 유동성 관리로 서술되었다.

제 4 절 Human baseline 행동에 대한 평가 장치의 점수 (H3)

Human baseline 행동에는 크기가 없으므로 후보행동의 표준 행동크기로 채점하였다. 단일 후보 라벨이 있는 3 개 기업은 그 후보로 채점하였다. 나머지 53 개 기업은 다음 규칙을 순서대로 적용하여 행동을 정의하였다. 기재된 + 방향 축의 집합이 한 후보의 축 집합과 같으면 그 후보(14 개 기업), 행동 종류의 조합이 정확히 한 후보와 같으면 그 후보(25 개 기업)로 두고, 나머지는 기재된 축에 표준 행동크기를 균등하게 배분한 행동(총 행동크기 1, 14 개 기업)으로 정의하였다. 균등 배분 행동은 재현 키트와 같은 Simulator 와 Oracle 의 경로로 채점하였으며, 같은 경로에 9 개 후보를 넣은 5,175 개(575 개 기업 × 9 개 후보) 점수가 키트의 후보 점수와 정확히 일치함을 먼저 확인하였다.

<표 7-6> 단일 후보 라벨이 없는 53 개 기업의 점수(무행동 대비)

정책	α	α 차이: 정책 − Human baseline [95% 구간]	α: Human baseline 보다 높음/같음/낮음	β	γ
Human baseline	+0.638	—	—	+0.084	+0.090
무작위(기대값)	+0.269	−0.369 [−0.677, −0.105]	13 / 16 / 24	+0.025	+0.045
고정 OE	+0.546	−0.092 [−0.411, +0.152]	8 / 42 / 3	+0.135	+0.076
C3-E	+0.755	+0.117 [−0.293, +0.548]	12 / 29 / 12	+0.112	+0.106
직접 작성(C4) · GPT	+0.857	+0.219 [−0.138, +0.607]	13 / 29 / 11	+0.084	+0.078
직접 작성(C4) · Gemini	+0.762	+0.124 [−0.341, +0.586]	11 / 30 / 12	+0.082	+0.156
강화학습 참조 수정(C6-E) · GPT	+0.820	+0.182 [−0.282, +0.649]	14 / 27 / 12	+0.079	+0.090
강화학습 참조 수정(C6-E) · Gemini	+0.776	+0.138 [−0.321, +0.599]	12 / 30 / 11	+0.082	+0.156
참고: 상한	+1.268	+0.630 [+0.287, +1.025]	19 / 33 / 1	+0.169	+0.376

주: LLM 은 후보 선택, 추론 높음, B1, IC-b, 본실험, 엄격 규칙. α 차이의 구간은 같은 53 개 기업에서 정책과 Human baseline 의 점수 차이를 기업 단위로 부트스트랩(10,000 회)한 95% 구간이며 보정하지 않았다. Human baseline α 의 기업 단위 부트스트랩 95% 구간은 [0.339, 0.995]이다. 높음/같음/낮음은 기업마다 정책의 α 점수가 Human baseline 보다 높은·같은·낮은 기업 수이다. β 에서 고정 OE 와 Human baseline 의 차이는 +0.051 [+0.028, +0.078]로 구간이 0 을 포함하지 않았고, γ 에서는 상한을 제외한 모든 차이의 구간이 0 을 포함하였다. 모든 기업에 균등 배분만 적용하면 Human baseline 의 α 는 +0.715, β 는 +0.144, γ 는 +0.108 이다. 기업별 행동은 부록 F 에 제시한다.

<표 7-6>에서 Oracle-α 로 본 Human baseline 의 점수(+0.638)는 무작위보다 분명히 높았다(차이 −0.369, 구간이 0 을 포함하지 않음). 그러나 고정 OE, C3-E, 두 LLM 과의 차이는 같은 기업끼리 비교해도 모두 0 과 구별되지 않았고, 기업별로는 절반 이상의 기업에서 정책과 Human baseline 의 점수가 같았다. 평가모형을 바꾸면 순서도 달라졌다. β 에서는 Human baseline(+0.084)이 두 LLM(+0.079~+0.084)과 비슷하고 고정 OE(+0.135)보다는 분명히 낮았으며(차이 +0.051, 구간이 0 을 포함하지 않음), C3-E(+0.112)와의 차이는 0 과 구별되지 않았다. γ 에서는 GPT 의 직접 작성(+0.078)보다 조금 높고 Gemini(+0.156)와 C3-E(+0.106)보다 낮았지만, 상한을 제외한 모든 차이가 0 과 구별되지 않았다. 모든 기업에 균등 배분을 적용한 민감도 분석에서 Human baseline 의 α 는 +0.715 로 고정 OE 보다 높고 C3-E 와 LLM(+0.755~+0.857)보다 다소 낮았다. 이때 β 는 +0.144 로 상한을 제외한 모든 정책보다 높아져, β 에서의 순서는 문서 행동을 어떻게 정의하는지에 민감하였다. 만기연장·재조달 서술을 장기 전환으로 본 민감도 분석(단일 후보 라벨이 없는 60 개 기업)에서도 Human baseline 의 α(+0.589)는 고정 OE(+0.582)와 비슷하고 C3-E(+0.780)와 LLM(+0.779~+0.864)보다 낮았다(점추정 기준이며, 같은 기업끼리 비교한 차이의 구간은 모두 0 을 포함하였다). 전문가 문서의 행동은 α 와 β 에서 무작위보다 높게 평가되었지만(β 차이 −0.059 [−0.085, −0.034], γ 에서는 구별되지 않음), 어느 평가모형에서도 고정 OE·C3-E·LLM 보다 높게 평가되지는 않았다. 문서의 행동은 1 년 신용개선의 처방이라기보다 회사의 경영 계획이었으므로, 이 점수 차이를 판단의 우열로 해석할 수 없다.

단일 후보 라벨이 있는 3 개 기업에서는 문서 후보(모두 OE)의 점수가 고정 OE 와 같았고, 네 LLM 조건도 모두 OE 를 골라 점수가 같았다(α +0.768). 3 개 기업 가운데 1 개에서는 문서 후보의 α 점수가 무행동과 같았다. 구간형 점수표인 Oracle-α 에서는 무행동을 제외한 후보의 기업별 정책가치 가운데 73.3%가 정확히 0 이었으므로(제 4 장), 이 결과로 문서의 행동을 평가하기는 어렵다.

제 5 절 해석

1 년 신용점수에서 LLM 의 권고는 문서에 기재된 기업의 경영·재무 행동보다 평균이 높았지만 대응 비교에서 통계적 차이를 확인하지 못했고(제 4 절), 두 행동은 성격이 달랐다. LLM 은 비용 효율화와 장기 전환처럼 사업의 규모와 방향을 바꾸지 않고 재무비율을 개선하는 행동에 선택이 집중되었다. 후보 선택에서 두 행동이 LLM 선택의 70% 안팎을 차지했고, 투자를 줄이는 후보는 1~3%에 그쳤다. 반면 문서는 투자를 줄이거나(56 개 기업 중 20 개) 신용 부담을 감수하고 늘리는(32 개) 결정, 빚을 갚거나 조달을 유지하는 결정처럼 사업의 방향과 조달을 정하는 계획을 주로 기재하였다. 투자 확대는 본 연구의 행동공간에 없으므로 LLM 은 이를 권할 수 없었다. 이 차이는 다섯 가지 측면에서 이해할 수 있다.

첫째, 문서의 행동은 1 년 지표가 아니라 경영전략을 따른다. 본 연구는 행동을 1 년 뒤 재무상태의 신용점수로 채점한다. 반면 문서에 기재된 회사의 계획은 설비 확대, 신사업, 인수합병, 매출 성장처럼 당장은 재무 부담을 늘리더라도 장기적인 사업 기반과 기업가치를 키우려는 것이 많았다. 신용평가사도 투자 확대를 대체로 신용 부담으로 서술하면서 그 계획을

평가 대상으로 다루었다. 1 년 신용점수로 채점하면 이러한 계획은 낮게 평가되기 쉽다. LLM 은 1 년 신용점수의 개선이라는 정해진 목표 아래 권고했지만, 기업은 성장, 생산능력, 경쟁력 확보와 조달 제약을 함께 고려한다.

둘째, 문서의 성격이 처방과 다르다. 신용평가사와 증권사 등의 문서는 무엇을 해야 하는지를 권하기보다 회사의 방침을 전하고 그 방침이 신용과 실적에 미칠 영향을 평가하는 경우가 대부분이었다. 따라서 Human baseline 과의 불일치는 LLM 이 전문가의 처방을 따르지 않았다는 것보다는 LLM 의 권고와 회사의 실제 계획이 다른 방향을 향했다는 것으로 해석하는 편이 자연스럽다.

셋째, 부채 관리는 실제 조달 여건을 전제로 한다. 단기차입 부담이 큰 기업에서 신용평가사 문서는 이를 상환하거나, 금융기관과의 관계·담보·미사용 한도에 기대어 만기를 넘기는 유동성 관리로 다루었고, LLM 은 만기 구조를 바꾸는 장기 전환을 권했다. 만기연장이나 재조달이 가능한지는 대주단과 시장의 판단에 달려 있으며, 신용평가사 문서가 평가한 것도 이 가능성이었다.

넷째, 행동공간이 다르다. 본 연구의 행동공간은 투자를 줄이고, 빚을 갚거나 만기를 늘리고, 운전자본과 비용을 개선하는 수단으로 이루어져 있으며, 투자를 늘리거나 차입·자본을 새로 조달하거나 만기를 연장해 차입을 유지하는 축은 없다. 문서가 있는 161 개 기업 가운데 행동공간으로 표현되는 행동이 있는 기업은 56 개뿐이었고, 그 가운데 33 개 기업에는 행동공간이 표현하지 못하는 반대 방향의 행동(대부분 투자 확대)도 함께 기재되었다. 실무에서는 무엇을 줄일지와 함께 무엇에 투자하고 이를 어떻게 조달하며 만기를 어떻게 관리할지를 본다. 비교는 두 행동 집합이 겹치는 좁은 영역에서만 가능하였다.

다섯째, 라벨에 오차가 있을 수 있다. 문서의 서술을 행동 축으로 옮기는 과정에는 해석이 들어가며, 지침을 달리하면 라벨도 달라질 수 있다. 라벨의 오차가 정책의 선택과 무관하게 생긴다면 겹침을 기대값 쪽으로 끌어내리므로, 확인되지 않은 대응의 일부는 라벨의 불확실성에서 나왔을 수 있다.

정리하면, 평가 장치에서 LLM 권고의 평균 정책가치는 문서에 기재된 기업의 경영·재무 행동보다 높았지만, 대응 비교에서 통계적 차이를 확인하지 못했다. 또한 두 행동은 목표와 의사결정의 성격이 다르고, 문서의 행동은 크기가 관측되지 않아 표준 행동크기로 바꾸어 채점했으며, 정보 시점과 행동공간도 완전히 같지 않으므로, 이 결과를 LLM 과 실제 기업 경영 판단의 우열로 해석할 수 없다. 문서는 투자와 조달처럼 기업이 실제로 마주한 전략적 선택을 다루었고, LLM 의 권고는 주어진 행동공간 안에서 1 년 지표를 개선하는 수단에 집중되었다. LLM 은 기업 상태에 따라 행동을 달리 고르기도 했으나(부록 G), 주 분석의 다섯 행동 분류에서 해당 기업의 문서와 무작위 짝짓기보다 높은 일치를 보인다는 통계적 증거는 확인되지 않았고, 같은 조건을 다시 실행하면 기업별 권고가 자주 달라졌다(제 6 장). 실제 기업의 경영·재무계획과의 대응은 제한적이었다.

제 6 절 소결

신용평가사와 증권사 등의 문서 236 건에 기재된 기업의 경영·재무 행동(Human baseline)과 비교한 결과는 세 가지로 정리된다.

첫째, 평가 장치에서 LLM 권고의 평균 정책가치는 문서에 기재된 행동보다 높았지만, 대응 비교에서 통계적 차이를 확인하지 못했다(H3). 단일 후보 라벨이 없는 53 개 기업의 주 평가모형에서 Human baseline 은 +0.638 로 무작위보다 높았고, LLM 의 직접 작성은 +0.762~+0.857, 강화학습 참조 수정은 +0.776~+0.820 이었다. 같은 기업끼리 비교한 차이는 모두 0 과 구별되지 않았고, 절반 이상의 기업에서 점수가 같았으며, β 와 γ 에서는 순서가 달라졌다. 두 행동은 목표와 의사결정의 성격이 다르므로 이 결과를 우열로 해석할 수 없다.

둘째, 두 행동은 성격이 달랐다(H1). LLM 은 비용 효율화와 장기 전환에 선택이 집중되었고, 주 분석의 다섯 행동 분류에서는 직접 작성, 참조 수정, 자유 작성 어느 경우에도 LLM 권고가 해당 기업의 문서와 무작위 짝짓기보다 더 높은 행동 일치를 보인다는 통계적 증거를 확인하지 못했다. 문서의 행동은 대부분 회사의 경영 방침이었으며, 투자 축소(56 개 기업 중 20 개)와 확대(32 개), 상환과 만기연장·재조달처럼 사업의 방향과 조달을 정하는 결정이 많았다. 단기차입을 장기로 바꾸는 행동은 236 건 어디에도 앞으로의 행동으로 서술되지 않았다. 이 결론은 236 건 전체의 재점검 전후에 같았다.

셋째, 강화학습 참조는 이 관계를 바꾸지 않았다(H2). 참조를 본 수정은 문서 대비 점수를 크게 바꾸지 않았고, 권고를 문서 쪽으로 옮기지도 않았다. 제 6 장에서 확인한 참조의 정책가치 개선과 기업 경영계획과의 일치는 서로 다른 결과이다.

이 비교는 56 개 기업(점수 비교는 53 개 기업)이라는 작은 표본, 문서의 성격, 라벨의 불확실성이라는 한계를 가진다. LLM 권고를 업무에 쓰려면 1 년 신용점수와 함께 기업의 투자·조달 계획 등 실제 경영 의사결정과의 정합성을 검토하는 절차가 필요하다.

제 8 장 결론

제 1 절 연구 결과의 요약

본 연구는 LLM 이 생성한 기업 신용개선 권고를 평가하는 틀을 만들고, 그 틀로 LLM 에게 권고를 받는 여러 방식을 비교하였다. 평가 장치를 먼저 검증한 뒤, 같은 575 개 기업에서 기준선, 강화학습 참조정책, 두 LLM 의 21 개 권고 조건을 같은 경로로 채점하였고, 마지막으로 신용평가사·증권사 등의 문서에 기재된 기업의 경영·재무 행동(Human baseline)과 대조하였다. <표 8-1>은 여섯 연구질문에 대한 답을 정리한 것이다.

<표 8-1> 연구질문별 결과 요약

연구질문	결과	장
RQ1 평가기반	Oracle 은 기간외 기간에서 실제 등급의 순서(순위상관 0.69~0.75)에 정렬되었고, 등급 변화의 방향을 65~72% 맞혔다(개발 단계 기록). 개발 단계 기록에서 Simulator 는 점수 수준을 약 10.8 점 높게 계산하였으나 기업 순위(0.90)와 변화 방향(약 72%)은 보존하였다. 그러나 주 평가모형 α 는 28.5%의 기업에서 9 개 후보를 모두 같은 점수로 평가하였고, 세 Oracle 의 최고점 후보에 공통 후보가 있는 기업은 45.4%였으며, 상환의 고정 정책 값은 Oracle 에 따라 부호가 갈렸다. 평가 장치는 같은 기업 안의 1 년 상대 비교에 쓰되, 그 비교는 평가모형의 구조에 조건부이다.	제 4 장
RQ2 정책 비교	C3-E(α +0.923)는 무작위(+0.353)와 고정 OE(+0.765)보다 높고 상한(+1.401)보다 낮아, 기업 맞춤으로 얻을 수 있는 몫의 약 4 분의 1 을 얻었으나 β 에서는 고정 OE 보다 낮았다. LLM 직접 작성은 추론 높음 설정에서 고정 OE 와 구별되지 않았고(+0.785, +0.805) C3-E 보다 낮았으며, 추론 낮음 설정의 B1 자유 작성은 수용률이 15~44%에 그쳤고 정책가치도 무작위보다 낮았다.	제 5 장, 제 6 장
RQ3 생성·참조	강화학습 참조 수정은 참조 없는 재검토보다 자유 작성 24 개 조합 모두에서 높았고 9 개 조합에서 보정 후 유의하였다(나중에 추가한 추론 높음 실행을 보조 묶음으로 조정하면 7 개). 기업과 참조의 연결 효과는 평균 크기는 비슷했으나 23/24 양수, 2/24 유의로 덜 일관되고 불확실하였다. 자기 재검토와 진단 유도의 효과는 모델·행동크기 조건·생성 설정·실행 규칙에 따라 달라졌다.	제 6 장

연구질문	결과	장
RQ4 강건성	자유 작성에서 참조정보 추가 패키지의 증분은 세 Oracle 모두 같은 방향이었다. 추론 낮음·B1 에서 자유 작성은 후보 선택보다 18 개 비교 모두에서 낮았으나 추론 높음 설정에서는 격차가 거의 사라졌고, 참조 수정에서는 자유 작성이 더 높았다. 행동크기 조건은 정책가치의 수준과 유리한 절차를 함께 바꾸었다. 반복 실행에서 평균의 방향은 대체로 유지되었으나 기업별 권고는 자주 달라졌다.	제 6 장
RQ5 정보조건	추론 낮음 설정에서 업종 코드와 기업명의 추가는 12 개 비교 모두에서 보정 후 유의한 차이를 만들지 않았다.	제 6 장
RQ6 외부 기준	원문 전수 재점검을 거친 56 개 기업(점수 비교는 단일 후보 라벨이 없는 53 개 기업)에서, 평가 장치에서 LLM(α +0.762~+0.857)과 강화학습 참조 LLM(+0.776~+0.820)의 권고는 문서에 기재된 기업의 경영·재무 행동(+0.638)보다 평균이 높았으나 대응 비교에서 통계적 차이를 확인하지 못했다. LLM 은 비용 효율화와 장기 전환에 선택이 집중되었고, 문서는 투자 축소(20 개)와 확대(32 개, 행동공간 밖), 상환과 만기연장·재조달처럼 사업과 조달을 정하는 결정을 주로 기재했다. 다섯 행동 분류에서 LLM 권고가 해당 기업의 문서와 무작위 짝짓기보다 높은 일치를 보인다는 통계적 증거는 확인되지 않았고, 강화학습 참조도 이 관계를 바꾸지 않았다.	제 7 장

제 2 절 논의

이 절에서는 결과의 의미를 다섯 가지로 나누어 논의한다. 평가 장치의 구축과 한계, 실행 가능성과 정책 하네스, 생성 방식과 강화학습 참조, 기업별 권고의 부가가치와 안정성, 기업의 실제 경영·사업계획과의 차이의 순서이다.

(1) 평가 장치의 구축과 한계

세 Oracle 은 기업의 신용 순서를 비슷하게 맞혔지만, 같은 기업에 무엇을 하라고 할지에서는 자주 엇갈렸다. 세 Oracle 의 최고점 후보 집합에 공통 후보가 있는 기업은 45.4%였고, C3-E 와 고정 OE 의 순서는 Oracle-α(+0.158)와 Oracle-β(−0.071)에서 뒤집혔으며, 상환의 고정 정책 값은 Oracle-α 에서 양수, Oracle-β 에서 음수였다. 주 평가모형인 구간형 점수표는 28.5%의 기업에서 9 개 후보를 구별하지 못했다. 이는 예측 성능이 비슷한 모형들이 개별 사례에서 다르게 판단할 수 있다는 예측 다중성[24]과 같은 성격의 문제가 권고의 채점에서도 나타날 수 있음을 시사한다[25]. 다만 세 Oracle 은 구조와 성능이 서로 다른 모형이고, 엇갈림의 일부는 구간형 점수표의 동점 처리에서도 나온다.

이 엇갈림은 모형의 구조에서 나온다. 9 개 변수에는 부채비율이 직접 들어 있지 않고 Oracle-β 와 Oracle-γ 에서는 자산 규모의 비중이 가장 크므로, 차입금을 갚아 총자산이 줄어드는 행동의 점수는 모형마다 다르게 계산된다. 반대로 유동부채만 줄이는 장기 전환은 Oracle-α 에서 점수를 낮춘 적이 없었다. 등급 예측을 위해 고른 변수 구성이 행동을 채점할 때에는 어떤 행동이 유리한지를 정하는 기준으로 작용한 것이다. 정책을 비교하기 전에 평가 장치를 검증하였기 때문에, LLM 과 강화학습 정책이 장기 전환을 자주 고른 현상을 정책의 우열만으로 보지 않고

평가 구조와 연결하여 해석할 수 있었다. 또한 Simulator 의 수준 편향을 확인하였기 때문에 절대 점수가 아닌 같은 기업의 무행동 대비 차이를 정책가치로 정의할 수 있었다.

(2) 실행 가능성과 정책 하네스

LLM 의 응답이 정책가치로 이어지려면 먼저 행동 규칙을 지킨 실행 가능한 행동이어야 한다. 추론 낮음 설정의 B1 자유 작성 직접 작성에서는 15~44%의 응답만 행동 규칙을 지켰고, 규칙을 어긴 응답을 무행동으로 처리하자 정책가치는 무작위보다 낮아졌다. 같은 모델에서 추론 높음 설정을 쓰자 수용률이 97%를 넘었고, 정책가치는 모든 기업에 비용 절감을 권하는 단순 규칙 수준까지 올라갔다. 같은 두 모델에서 관측된 B1 자유 작성의 정책가치는 무작위보다 낮은 수준(+0.12)부터 C3-E 에 가까운 수준(+0.91)까지 퍼졌고, 그 차이를 만든 것은 모델 이름보다 생성 설정, 행동공간, 행동크기 조건, 권고 방식, 참조의 배정, 응답의 실행 규칙이었다.

실패를 어떻게 처리하는지도 결과의 일부였다. GPT 의 추론 낮음·B1 에서 관측된 자기 재검토의 이득(+0.169)은 형식 오류를 고치고 행동크기 조건을 넘는 행동을 비례 축소하는 결정론적 보정 규칙(Repaired)에서는 +0.005 로 거의 사라졌다. 관측된 이득은 판단의 개선과 실행할 수 없던 초안을 실행 가능하게 바꾼 효과를 구별할 수 없었다. 따라서 LLM 권고 시스템을 평가하거나 비교할 때는 모델과 함께 이 구성 요소 전체를 하나의 정책, 즉 정책 하네스로 명시하고, 수용률과 실패 처리 규칙을 정책가치와 함께 보고해야 한다. 다만 본 연구의 모델은 경량 모델 두 개이고 추론 설정은 하네스의 일부이면서 모델 능력의 축이기도 하므로, 이 결론은 관찰한 두 모델 안에서 구성의 차이가 모델의 차이보다 컸다는 범위로 한정하여 읽어야 한다.

(3) 생성 방식과 강화학습 참조

네 가지 대비 가운데 방향이 일관된 것은 강화학습 정책의 답을 참조로 보여준 수정 하나였다 자유 작성의 24 개 조합 모두에서 참조 없는 재검토보다 높았고, 이 효과는 Oracle-β 와 Oracle-γ 에서도 같은 방향이었다. GPT 의 B1 에서는 추론 설정을 높이자 진단 유도와 자기 재검토의 이득이 줄었지만(각각 0.183, 0.143 감소) 참조정보 추가 패키지의 증분은 줄지 않았다. 참조 없는 재검토의 효과는 조건에 따라 엇갈린 반면 외부 정보를 준 수정은 일관되었다는 점에서, 외부 피드백 없는 자기 수정의 한계를 지적한 선행연구[45, 46]와 같은 방향이다. 다만 총 행동크기 무지시 조건(BINF)의 Gemini 와 추론 높음 설정에서는 실행 가능한 초안에서도 자기 재검토가 정책가치를 높였다. 따라서 재검토를 요청하는 개입과 외부 정보를 주는 개입은 구분하여 평가할 필요가 있다.

다만 이 효과는 몇 가지 점에서 제한적이다. 우선 LLM 은 참조를 그대로 따르지 않았다. 추론 높음 설정의 후보 선택에서 참조를 본 뒤 자신의 초안(C4)과 다른 후보를 고른 기업은 11~17% 였고, 참조와 같은 후보를 고른 기업은 절반 안팎이었다. 어떤 기업이 참조에서 이득을 보는지는 반복 실행에서 거의 재현되지 않았고, 그 기업에 맞는 참조인지의 효과는 평균 크기는 비슷했으나 덜 일관되었다. 또한 자유 작성에서 참조는 정책가치를 높였지만 권고를 문서에 기재된 기업의 계획 쪽으로 옮기지는 않았다. 참조의 정책가치 개선과 기업 경영계획과의 일치는 서로 다른 결과이다.

(4) 기업별 권고의 부가가치와 안정성

상한과 고정 OE 의 차이(0.636)를 기업마다 다른 행동을 골라서 얻을 수 있는 몫으로 보면, C3-E 는 그 가운데 약 4 분의 1 을 얻었지만 LLM 의 직접 작성은 B1 의 8 개 설정 어디에서도 고정 OE 를 유의하게 넘지 못했다. 본 연구의 행동공간과 평가 조건에서는 LLM 이 기업별 정보를 활용하여 고정된 단순 정책보다 높은 정책가치를 안정적으로 만들어낸다는 증거를 확인하지 못했다. LLM 은 기업 상태에 따라 행동을 달리 선택하기도 했다. 같은 기업에 C3-E 와 같은 후보를 고른 비율(GPT 42.4%, Gemini 37.7%)은 두 정책의 후보 비율만으로 기대되는 수준(26.5%, 25.3%)보다 높았다. 그러나 선택은 비용효율화(약 40%)와 단기차입의 장기 전환(30~34%)에 집중되었고, 업종 코드나 기업명을 더한 효과도 확인되지 않았다. 기업 상태에 대한 반응은 있었지만, 그 반응이 단순 규칙을 넘는 정책가치로 이어졌다는 증거는 없었다.

평균에서 나타난 개선은 개별 기업으로 그대로 옮겨지지 않았다. C3-E 가 고정 OE 와 다른 행동을 고른 343 개 기업 가운데 점수가 오른 기업은 100 개, 내린 기업은 102 개, 점수가 변하지 않은 기업은 141 개였다. 어떤 기업이 참조에서 이득을 보는지는 반복 실행 사이에 순위상관 0.06~0.29 로 거의 재현되지 않았다. 추론 높음·B1 자유 작성의 직접 작성을 다시 실행했을 때, 두 번 모두 규칙을 지킨 기업 가운데 8 개 축의 값이 모두 같은 권고(행동 완전 일치)는 GPT 48.6%, Gemini 7.5%였고, 사용한 축만 비교하면 65.6%와 38.0%였다. 반면 평균 정책가치와 정책 간 차이의 방향은 반복 실행에서 대체로 유지되었으므로, 흔들린 것은 평균보다 개별 기업에 대한 권고였다. 구간형 점수표에서는 후보별 정책가치의 73.3%가 정확히 0 이어서, 평균의 차이는 점수가 움직이는 일부 기업에서 만들어졌다.

여신 판단은 기업 단위로 이루어지므로 이 구분은 실무에서 중요하다. 현재의 평가 장치와 정책은 포트폴리오 수준에서 권고 방식을 비교하는 도구로는 쓸 수 있지만, 한 기업에 대한 권고를 그대로 믿고 쓰는 근거로는 부족하다. 기업 단위로 쓰려면 같은 요청을 반복해 권고가 일치하는지 확인하고, 여러 평가모형이 같은 방향을 가리키는지 보며, 사람이 그 권고의 실행 조건을 검토하는 절차가 먼저 필요하다.

다만 이 결과가 LLM 의 효용 전반을 부정하는 것은 아니다. 본 연구의 과제는 수치화된 재무비율을 받아 정해진 행동공간 안에서 1 년의 행동을 고르는 것으로, LLM 이 강점을 보일 수 있는 비정형 문서의 해석이나 판단 근거의 설명은 평가하지 않았다. 이 과제 안에서 LLM 은 독립적인 신용 판단의 주체라기보다, 규칙에 맞는 행동을 만들고 학습된 참조를 받아들이는 인터페이스로 작동하였다. 이러한 결과는 LLM 을 최종 처방을 내리는 체계보다 분석가가 검토할 후보를 만드는 도구로 활용하는 편이 적절하다는 실무적 판단과도 부합한다.

(5) 기업의 실제 경영·사업계획과의 차이

LLM 권고와 문서에 기재된 기업 계획의 가장 큰 차이는 행동의 성격에 있었다. LLM 은 비용효율화와 장기 전환처럼 사업의 규모와 방향은 그대로 두고 재무비율을 개선하는 행동에 선택이 집중되었다. 반면 문서에 기재된 행동은 투자를 줄일지 늘릴지, 빚을 갚을지 조달을 유지할지처럼 사업의 방향과 조달을 정하는 결정이었고, 그 가운데 투자 확대는 LLM 의 행동공간 밖에 있었다. <표 8-2>는 본 연구에 등장한 여러 기준이 네 가지 행동을 어떻게

다루었는지 정리한 것이다. 비용 절감은 모든 기준에서 자주 등장하였다. 세 Oracle 모두에서 고정 정책 가운데 가장 높았고, 전문가 문서에서도 가장 흔했으며, 575 개 기업에서 C3-E 와 LLM 도 가장 자주 골랐다. 다만 이는 빈도의 일치이며, 같은 기업에서 무작위 짝짓기보다 더 일치했다는 통계적 증거는 없었다. 가장 크게 갈린 것은 부채 수단이다. C3-E 와 LLM 은 단기차입의 장기 전환(RF)을 자주 골랐다. 반면 236 건의 문서 가운데 장기 전환을 앞으로의 행동으로 서술한 문서는 없었다. 신용평가사 문서는 단기차입이 많은 기업의 만기 차입금을 상환하거나 만기연장·재조달로 넘기는 유동성 관리로 다루었다(신용평가사 문서가 있는 47 개 기업 가운데 26 개 기업이 만기연장·재조달을 명시적으로 서술). 문서 라벨에 상환이 있는 9 개 기업에서도 LLM 은 대부분 장기 전환을 골랐다(GPT 9 개, Gemini 8 개). 문서는 그 밖에 투자 계획(비교 대상 56 개 기업 가운데 축소 20 개, 확대 32 개 기업)을 더 많이 다루었고, 학습 자료의 행동 표지에서도 설비투자 축소가 흔하였다.

<표 8-2> 네 가지 행동에 대한 기준별 평가와 선택

기준	비용 절감(OE)	장기 전환(RF)	투자 축소(CX)	부채상환(DL)
평가 장치: 모든 기업 적용 시 Oracle-α 가치(8 개 후보 중 순위)	+0.765(1 위)	+0.663(2 위)	+0.279(5 위)	+0.181(8 위)
학습 자료의 행동 표지(2,642 건)	10.8%	0.4%	24.1%	12.0%
C3-E 의 선택(575 개 기업)	40.3%	27.0%	7.1%	0.0%
LLM 의 선택(575 개 기업, GPT / Gemini)	40.2% / 39.5%	33.9% / 29.9%	0.9% / 2.8%	2.8% / 1.2%
문서에 기재된 행동(56 개 기업 중 기업 수)	36	0	20	9

주: LLM 은 후보 선택, 추론 높음, B1, 직접 작성이다. 문서에 기재된 행동은 재점검을 거친 본문 라벨의 행동 종류 기준으로 세었으며 비용 절감은 원가율·판관비율, 투자 축소와 부채상환은 해당 축의 개선 방향이 기재된 기업 수이다. 투자 축소 20 개 기업 가운데 13 개는 투자 확대도 함께 기재하였다. 장기 전환 0 은 236 건 어디에도 장기 전환이 앞으로의 행동으로 서술되지 않았기 때문이며, 18 개 기업의 만기연장·재조달 서술은 행동공간 밖으로 분류하였다(제 7 장). 학습 자료의 행동 표지는 실제 재무 변화에 가장 가까운 후보로, 장기 전환은 차입 총액이 거의 변하지 않은 경우에만 식별되어 적게 잡힐 수 있다. 각 행의 표본과 단위가 다르므로 행 사이의 크기는 비교하지 않는다.

LLM 이 장기 전환을 자주 권한 데에는 단기부채를 줄이라는 일반적인 재무 지식이 작용했을 수 있다. 장기 전환은 유동부채를 줄여 1 년 신용점수에서도 유리하게 평가되었다. 신용평가사 문서가 만기연장·재조달을 명시적으로 서술한 26 개 기업 가운데 GPT 는 19 개, Gemini 는 15 개 기업에 장기 전환을 권했다. 두 쪽 모두 단기차입 부담이 큰 기업에 반응했지만 택한 행동은 달랐다. 문서의 만기연장·재조달은 금융기관과 시장의 판단을 전제로 차입을 유지하는 유동성 관리였고, LLM 의 장기 전환은 만기 구조를 바꾸는 행동이었다. LLM 의 후보에는 만기연장·재조달에 해당하는 행동이 없었으므로 이 차이의 일부는 표현 수단의 차이일 수 있다. 그러나 투자 결정에서는 표현 수단의 제약이 없었다. LLM 은 투자 축소 후보를 고를 수 있었지만 1~3% 의 기업에만 권했고, 문서는 56 개 기업 가운데 20 개에서 투자 축소를, 32 개에서 투자 확대를 다루었다. LLM 은 1 년 신용점수의 개선이라는 정해진 목표 아래 권고했고, 기업은 성장과 경쟁력, 조달 제약을 함께 고려하여 계획을 세운다. 두 행동은 목표와 의사결정의 성격이 다르므로, 평가 장치에서 LLM 권고의 평균 정책가치가 문서의 행동보다 높았다는 결과(대응

비교에서는 통계적 차이 없음)를 LLM 과 실제 기업 경영 판단의 우열로 해석할 수 없다. 이 차이는 1 년 신용점수의 성과만으로 권고의 실무적 타당성을 판단할 수 없음을 보여 준다.

제 3 절 실무적 시사점

금융기관이나 기업이 LLM 의 신용개선 권고를 업무에 활용하려 할 때 본 연구의 결과는 다음을 시사한다.

첫째, 신용평가모형을 권고의 채점에 쓰는 것은 등급 예측과 다른 새로운 용도이며 따로 검증해야 한다. 어떤 행동을 하면 점수가 오른다는 계산은 모형이 등급을 잘 맞힌다는 검증만으로 정당화되지 않는다. 동점 비율, 평가모형 사이의 최선 행동 일치, 행동별 고정 정책의 값과 부호처럼 행동에 대한 반응을 직접 점검하고, 평가 장치가 무엇을 볼 수 없는지를 문서화해야 한다. 이는 모형위험 관리의 독립적 검증과 사용 범위 문서화 요구와도 부합한다[4, 6].

둘째, LLM 권고 시스템은 모델 단위가 아니라 하네스 단위로 승인하고 관리해야 한다. 생성 설정이나 출력 형식, 행동크기 제약, 실패 처리 규칙을 바꾸면 성과가 크게 달라지므로, 이러한 변경은 모형 변경과 같은 수준의 재검증 대상이다. 수용률, 실패 시 처리, 반복 실행의 안정성을 정책가치와 함께 보고해야 한다.

셋째, 하나의 평가모형에서의 우위를 일반화하지 않아야 한다. C3-E 의 우위는 β 에서 사라졌고, 자기 재검토와 진단 유도의 효과는 평가모형에 따라 방향이 달라졌다. 구조가 다른 여러 평가모형에서 방향이 유지되는지를 확인하는 것이 최소한의 강건성 점검이다.

넷째, LLM 권고는 실제 경영 의사결정과의 정합성을 함께 검토해야 한다. 본 연구에서 LLM 의 선택은 비용 효율화와 장기 전환에 집중되었지만, 문서는 투자를 줄이거나 늘리는 결정과 실제 조달 여건을 전제로 한 부채 관리를 다루었다. 투자처럼 대가가 따르는 결정은 LLM 의 권고에서 거의 나오지 않으므로 사람이 따로 판단해야 한다. 장기 전환처럼 총부채를 바꾸지 않고 유동성 지표를 개선하는 권고는 실제 자금조달 가능성과 비용 , 기업의 투자 계획과의 정합성을 사람이 함께 확인해야 한다.

다섯째, 학습된 정책은 정답이 아니라 외부 점검 장치로, LLM 은 분석가가 검토할 후보를 만드는 도구로 쓰는 것이 적절하다. 참조를 보여주면 평균적인 가치는 높아질 수 있으나, 개별 기업에서 어떤 권고가 나아지는지는 안정적이지 않다. 개별 기업의 최종 판단에는 투자 확대나 인수합병처럼 행동공간 밖의 계획을 볼 수 있는 사람의 검토가 필요하다.

제 4 절 연구의 한계

첫째, 평가 장치의 한계이다. Simulator 는 점수 수준을 체계적으로 높게 계산하고, 자금조달의 가능성과 실행 비용을 반영하지 않는다. 주 평가모형 α 는 행동의 차이를 거칠게 구별하며, 평가 기간은 1 년이다. Oracle 은 등급 수준을 예측하도록 만든 모형이므로, 자산을 줄이는 상환이나 유동부채만 줄이는 장기 전환 같은 행동에 대한 점수 반응이 실제 등급의 반응과 같다는 보장은 없다. Simulator 는 단기차입, 장기차입, 사채에 같은 금리를 쓰므로 장기 전환은 이자와 현금을

바꾸지 않고 부채의 유동·비유동 구분만 바꾼다(기간 프리미엄과 조달 비용 없음). Simulator 의 실제 재무 재현 검증은 개발 단계의 기록이며 최종 행동 정의 이후 같은 범위로 다시 수행하지 않았다. 부채상환의 이자 절감은 실제 상환액에 대해 1 년치 전액으로 반영하므로 상환 계열 행동의 가치를 높게 계산할 수 있고, 차입 금리를 관측하지 못한 37 개 평가 기업에서는 신용등급에 따라 추정하거나 전체 중앙값으로 둔 금리를 사용하였다. 따라서 모든 정책가치는 이 평가 장치 안의 상대 비교이며 실제 신용등급의 개선을 뜻하지 않는다.

둘째, 표본의 한계이다. 575 개 기업은 외부 신용등급과 필요한 재무 항목이 있는 기업으로 좁혀진 집합이며 한국 기업 전체의 무작위 표본이 아니다. 평가 연도는 2024 년 한 해이다.

셋째, 강화학습 참조정책의 한계이다. C3-E 의 최종 구성은 2024 년 평가 결과를 기준으로 골랐으므로(제 5 장 제 2 절), 그 성과는 독립된 검증 표본에서의 성능으로 읽을 수 없다. C3-E 의 행동 선호가 보상의 구조와 일치한다는 해석은 행동 분포와 보상의 정의를 대조한 것이며, 보상 항목별 기여를 분해하여 확인한 것은 아니다. 또한 공개 재현 키트는 동결된 기업 단위 관측값에서 결과를 다시 계산하며, 강화학습을 처음부터 다시 학습하는 경로는 최종 구성의 학습과 같지 않다(부록 H).

넷째, LLM 실험의 한계이다. 두 경량 모델의 특정 버전과 특정 시점의 결과이며, 조건마다 하나의 프롬프트 구조를 썼다. 반복 실행에서 평균의 방향은 대체로 유지되었으나 기업별 결과는 안정적이지 않았다. 기업과 참조의 연결을 바꾼 대조 조건은 하나의 고정 순열에 조건부이며, 575 개 기업 가운데 141 개는 재배정 뒤에도 같은 참조를 받았다. 기업명을 공개한 조건에서 모델이 사전학습 지식을 사용했는지는 측정하지 않았고, LLM 이 제시한 진단과 근거 설명의 질은 평가하지 않았다.

다섯째, Human baseline 의 한계이다. 라벨은 원문 전수 재점검을 거쳐 확정했지만 문서의 서술을 행동으로 옮기는 해석에 따라 달라질 수 있고, 이러한 라벨 오차는 대응을 실제보다 약하게 보이게 할 수 있다. 문서의 앞으로의 행동은 대부분 회사 방침의 전달이었고 명시적 권고는 드물었다. 비교 대상은 56 개 기업으로 작고, 신용평가사 문서가 있는 기업은 575 개 전체보다 크고 차입이 많으며, 일부 문서는 2025 년 1 분기 실적까지 반영하였다. 리서치 보고서 7 건에는 생성형 AI 답변 상자가 들어 있어 그 문장은 근거에서 제외하였다. 투자 확대에 대한 신용평가사 서술의 분류는 재점검 전 라벨에 대해 수행하였다. 만기연장·재조달 서술은 행동공간 밖으로 분류하였으며, 이를 장기 전환으로 보는 반대쪽 극단의 민감도 분석에서는 자유 작성 GPT 의 겹침이 보정 전 기준으로 무작위 짝짓기 기대값을 넘었지만($p = .017$) 단기차입 부담을 통제하면 구별되지 않았다(제 7 장).

여섯째, 통계적 추론의 한계이다. 부트스트랩 구간과 부호 꼬리 p 값은 선택된 정책과 고정된 참조 배정에 조건부인 불확실성 지표이며, 강화학습 구성 탐색이나 모든 가능한 참조 순열의 불확실성을 포함하지 않는다. 주 분석의 구간과 p 값은 실험 당시의 계산 결과이며 원래의 부트스트랩 추출 순서가 보존되지 않아 같은 값을 다시 생성할 수는 없다. 추론 높음 설정은 나중에 추가한 실행이므로 그 결과는 보정 묶음에 따라 유의성이 달라질 수 있다. 보조 분석의 수가 많으므로 개별 보조 결과는 탐색적인 것으로 읽어야 한다.

제 5 절 향후 연구

첫째, 평가 시계와 행동공간을 넓혀야 한다. 다년의 Simulator 와 자금조달 제약, 실행 비용을 포함한 평가 장치를 구축하면, 투자 확대처럼 단기 부담과 장기 가치가 엇갈리는 행동도 평가할 수 있다. 행동공간 역시 성장 투자, 자본 확충, 자산 매각과 같은 확장과 조달의 행동으로 넓힐 필요가 있다.

둘째, 평가 장치의 행동 반응을 장치 밖에서 검증해야 한다. 기업이 2025 회계연도에 실제로 실행한 재무 변화와 그 뒤의 신용등급 변화를 대조하면, 상환이나 장기 전환 같은 행동에 대한 평가 장치의 반응이 실제 등급의 반응과 맞는지를 사후적으로 점검할 수 있다. 신용 분석가가 LLM 권고의 출처를 모른 채 그 타당성을 평가하는 방안도 필요하다. Human baseline 역시 신용 분석가가 검토한 라벨과 더 많은 기업으로 확장해야 하며, 만기연장·재조달처럼 차입을 유지하는 행동을 행동공간에 포함하는 방안도 검토할 필요가 있다. 그래야 LLM 이 장기 전환을 고른 것이 만기 관리의 판단을 표현할 다른 수단이 없었기 때문인지 확인할 수 있다.

셋째, 참조정책과 LLM 의 결합 방식을 더 정교하게 검증할 필요가 있다. 평가 연도와 분리된 자료로 구성을 고른 참조정책, 여러 참조 순열에 대한 평균 효과, 참조의 불확실성을 함께 제시하는 방식이 기업별 이득의 불안정성을 줄이는지 확인할 수 있다.

넷째, 더 많은 모델과 프롬프트 변형, 반복 실행을 포함하여 정책 하네스의 구성 요소별 효과를 분해하는 연구가 필요하다. 신용평가 의견서와 같은 비정형 문서를 LLM 의 입력으로 주는 조건과, 권고의 근거 설명을 평가하는 방법도 함께 검토할 수 있다. 본 연구의 재현 키트는 이러한 확장 연구가 같은 평가 경로와 결과 등록부 위에서 이루어질 수 있도록 공개하였다.

제 6 절 맺음말

서론에서 든 예, 곧 단기차입금이 많은 기업에 단기차입금의 절반가량을 장기 차입으로 바꾸라는 권고는 본 연구에서 LLM 과 강화학습 정책이 실제로 자주 내놓은 권고였다. 평가 장치에서 이러한 권고를 포함한 LLM 권고의 평균 정책가치는 문서에 기재된 기업의 경영·재무 행동보다 높았지만, 대응 비교에서 통계적 차이를 확인하지 못했다. 문서가 다룬 것은 투자를 줄일지 늘릴지, 빚을 갚을지 조달을 유지할지 같은 사업 결정이었고, 두 행동은 목표와 의사결정의 성격이 달랐다.

본 연구는 정답이 관측되지 않는 기업 신용개선 권고를 평가하기 위해 평가 장치를 먼저 검증하고, 그 장치에서 LLM 에게 권고를 받는 여러 방식을 비교하였다. 같은 기업에 대한 행동의 우열은 평가모형에 따라 달라질 수 있었고, 응답의 실행 가능성과 실패 처리, 생성 설정, 참조정보가 관측 정책가치를 크게 바꾸었다. LLM 이 기업별 정보로 단순 정책보다 높은 가치를 안정적으로 만든다는 증거는 확인되지 않았고, 실제 기업의 경영·사업계획과의 대응도 제한적이었다. 이 결과들이 가리키는 결론은 하나이다. 기업 신용개선 권고의 품질은 LLM 모델 하나만으로 판단할 수 없으며, 평가 장치의 타당성과 정책 하네스의 구성, 실제 경영 의사결정과의 정합성을 함께 검증해야 한다.

참고문헌

[1] A. G. Kim, M. Muhn, and V. V. Nikolaev, “Financial statement analysis with large language models,” arXiv:2407.17866, 2024.

[2] S. Wu, O. Irsoy, S. Lu, V. Dabravolski, M. Dredze, S. Gehrmann, P. Kambadur, D. Rosenberg, and G. Mann, “BloombergGPT: A large language model for finance,” arXiv:2303.17564, 2023.

[3] M. Golec and M. Alabduljalil, “Interpretable LLMs for credit risk: A systematic review and taxonomy,” *Expert Systems with Applications*, vol. 306, Art. no. 130941, 2026.

[4] Board of Governors of the Federal Reserve System and Office of the Comptroller of the Currency, *Supervisory Guidance on Model Risk Management* (SR Letter 11-7), Washington, DC, 2011.

[5] Basel Committee on Banking Supervision, *The Basel Framework, CRE36: IRB approach: minimum requirements to use IRB approach*, Basel: Bank for International Settlements, 2023.

[6] National Institute of Standards and Technology, *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*, NIST AI 100-1, Gaithersburg, MD, 2023.

[7] Financial Stability Board, *The Financial Stability Implications of Artificial Intelligence*, Basel: FSB, 2024.

[8] 금융위원회, “정부와 금융권이 함께 금융권 AX 를 가속화해 나가겠습니다,” 보도자료(별첨: 「금융분야 인공지능 가이드라인」), 2026 년 6 월 18 일.

[9] 「인공지능 발전과 신뢰 기반 조성 등에 관한 기본법」, 법률 제 20676 호, 2025 년 1 월 21 일 제정, 2026 년 1 월 22 일 시행.

[10] S. Levine, A. Kumar, G. Tucker, and J. Fu, “Offline reinforcement learning: Tutorial, review, and perspectives on open problems,” arXiv:2005.01643, 2020.

[11] W. H. Beaver, “Financial ratios as predictors of failure,” *Journal of Accounting Research*, vol. 4, pp. 71–111, 1966.

[12] E. I. Altman, “Financial ratios, discriminant analysis and the prediction of corporate bankruptcy,” *Journal of Finance*, vol. 23, no. 4, pp. 589–609, 1968.

[13] J. A. Ohlson, “Financial ratios and the probabilistic prediction of bankruptcy,” *Journal of Accounting Research*, vol. 18, no. 1, pp. 109–131, 1980.

[14] R. C. Merton, “On the pricing of corporate debt: The risk structure of interest rates,” *Journal of Finance*, vol. 29, no. 2, pp. 449–470, 1974.

[15] S. Kealhofer, “Quantifying credit risk I: Default prediction,” *Financial Analysts Journal*, vol. 59, no. 1, pp. 30–44, 2003.

[16] S. Lessmann, B. Baesens, H.-V. Seow, and L. C. Thomas, “Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research,” *European Journal of Operational Research*, vol. 247, no. 1, pp. 124–136, 2015.

[17] S. Wachter, B. Mittelstadt, and C. Russell, “Counterfactual explanations without opening the black box: Automated decisions and the GDPR,” *Harvard Journal of Law & Technology*, vol. 31, no. 2, pp. 841–887, 2018.

[18] B. Ustun, A. Spangher, and Y. Liu, “Actionable recourse in linear classification,” in *Proceedings of the Conference on Fairness, Accountability, and Transparency* (FAT*), pp. 10–19, 2019.

[19] A.-H. Karimi, G. Barthe, B. Schölkopf, and I. Valera, “A survey of algorithmic recourse: Contrastive explanations and consequential recommendations,” *ACM Computing Surveys*, vol. 55, no. 5, Art. no. 95, 2022.

[20] A.-H. Karimi, B. Schölkopf, and I. Valera, “Algorithmic recourse: From counterfactual explanations to interventions,” in *Proceedings of the ACM Conference on Fairness, Accountability, and Transparency* (FAccT), pp. 353–362, 2021.

[21] J. Pearl, *Causality: Models, Reasoning, and Inference*, 2nd ed., Cambridge: Cambridge University Press, 2009.

[22] A.-H. Karimi, J. von Kügelgen, B. Schölkopf, and I. Valera, “Algorithmic recourse under imperfect causal knowledge: A probabilistic approach,” in *Advances in Neural Information Processing Systems*, vol. 33, pp. 265–277, 2020.

[23] H. Wu, S. Sharma, S. Patra, and S. Gopalakrishnan, “SafeAR: Safe algorithmic recourse by risk-aware policies,” in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, no. 14, pp. 15915–15923, 2024.

[24] C. Marx, F. Calmon, and B. Ustun, “Predictive multiplicity in classification,” in *Proceedings of the 37th International Conference on Machine Learning (ICML)*, PMLR vol. 119, pp. 6765–6774, 2020.

[25] M. Pawelczyk, K. Broelemann, and G. Kasneci, “On counterfactual explanations under predictive multiplicity,” in *Proceedings of the 36th Conference on Uncertainty in Artificial Intelligence (UAI)*, PMLR vol. 124, pp. 809–818, 2020.

[26] J. Miller, S. Milli, and M. Hardt, “Strategic classification is causal modeling in disguise,” in *Proceedings of the 37th International Conference on Machine Learning (ICML)*, PMLR vol. 119, pp. 6917–6926, 2020.

[27] D. Wang, Z. Chen, I. Florescu, and B. Wen, “A sparsity algorithm for finding optimal counterfactual explanations: Application to corporate credit rating,” *Research in International Business and Finance*, vol. 64, Art. no. 101869, 2023.

[28] W. Dong, J. Zhang, S. Fu, H. Lin, D. Wang, and L. Hu, “Algorithmic recourse of in-context learning for tabular data,” in *Proceedings of the 43rd International Conference on Machine Learning (ICML)*, PMLR vol. 306, pp. 26075–26098, 2026.

[29] S. Fujimoto, D. Meger, and D. Precup, “Off-policy deep reinforcement learning without exploration,” in *Proceedings of the 36th International Conference on Machine Learning (ICML)*, PMLR vol. 97, pp. 2052–2062, 2019.

[30] A. Kumar, J. Fu, M. Soh, G. Tucker, and S. Levine, “Stabilizing off-policy Q-learning via bootstrapping error reduction,” in *Advances in Neural Information Processing Systems*, vol. 32, 2019.

[31] A. Kumar, A. Zhou, G. Tucker, and S. Levine, “Conservative Q-learning for offline reinforcement learning,” in *Advances in Neural Information Processing Systems*, vol. 33, pp. 1179–1191, 2020.

[32] I. Kostrikov, A. Nair, and S. Levine, “Offline reinforcement learning with implicit Q-learning,” in *Proceedings of the International Conference on Learning Representations (ICLR)*, 2022.

[33] T. Yu, G. Thomas, L. Yu, S. Ermon, J. Zou, S. Levine, C. Finn, and T. Ma, “MOPO: Model-based offline policy optimization,” in *Advances in Neural Information Processing Systems*, vol. 33, pp. 14129–14142, 2020.

[34] R. Kidambi, A. Rajeswaran, P. Netrapalli, and T. Joachims, “MOReL: Model-based offline reinforcement learning,” in *Advances in Neural Information Processing Systems*, vol. 33, pp. 21810–21823, 2020.

[35] T. Yu, A. Kumar, R. Rafailov, A. Rajeswaran, S. Levine, and C. Finn, “COMBO: Conservative offline model-based policy optimization,” in *Advances in Neural Information Processing Systems*, vol. 34, pp. 28954–28967, 2021.

[36] S. Pitis, E. Creager, and A. Garg, “Counterfactual data augmentation using locally factored dynamics,” in *Advances in Neural Information Processing Systems*, vol. 33, pp. 3976–3990, 2020.

[37] J. Wei, X. Wang, D. Schuurmans, M. Bosma, B. Ichter, F. Xia, E. Chi, Q. V. Le, and D. Zhou, “Chain-of-thought prompting elicits reasoning in large language models,” in *Advances in Neural Information Processing Systems*, vol. 35, pp. 24824–24837, 2022.

[38] X. Wang, J. Wei, D. Schuurmans, Q. Le, E. Chi, S. Narang, A. Chowdhery, and D. Zhou, “Self-consistency improves chain of thought reasoning in language models,” in *Proceedings of the International Conference on Learning Representations (ICLR)*, 2023.

[39] S. Yao, J. Zhao, D. Yu, N. Du, I. Shafran, K. Narasimhan, and Y. Cao, “ReAct: Synergizing reasoning and acting in language models,” in *Proceedings of the International Conference on Learning Representations (ICLR)*, 2023.

[40] C. Snell, J. Lee, K. Xu, and A. Kumar, “Scaling LLM test-time compute optimally can be more effective than scaling model parameters,” arXiv:2408.03314, 2024.

[41] Z. Sprague, F. Yin, J. D. Rodriguez, D. Jiang, M. Wadhwa, P. Singhal, X. Zhao, X. Ye, K. Mahowald, and G. Durrett, “To CoT or not to CoT? Chain-of-thought helps mainly on math and symbolic reasoning,” arXiv:2409.12183, 2024.

[42] Z. R. Tam, C.-K. Wu, Y.-L. Tsai, C.-Y. Lin, H.-Y. Lee, and Y.-N. Chen, “Let me speak freely? A study on the impact of format restrictions on performance of large language models,” arXiv:2408.02442, 2024.

[43] M. Schall and G. de Melo, “The hidden cost of structure: How constrained decoding affects language model performance,” in *Proceedings of the 15th International Conference on Recent Advances in Natural Language Processing (RANLP)*, pp. 1074–1084, 2025.

[44] A. Madaan, N. Tandon, P. Gupta, S. Hallinan, L. Gao, S. Wiegreffe, U. Alon, N. Dziri, S. Prabhumoye, Y. Yang, S. Gupta, B. P. Majumder, K. Hermann, S. Welleck, A. Yazdanbakhsh, and P. Clark, “Self-Refine: Iterative refinement with self-feedback,” in *Advances in Neural Information Processing Systems*, vol. 36, pp. 46534–46594, 2023.

[45] J. Huang, X. Chen, S. Mishra, H. S. Zheng, A. W. Yu, X. Song, and D. Zhou, “Large language models cannot self-correct reasoning yet,” in *Proceedings of the International Conference on Learning Representations (ICLR)*, 2024.

[46] R. Kamoi, Y. Zhang, N. Zhang, J. Han, and R. Zhang, “When can LLMs actually correct their own mistakes? A critical survey of self-correction of LLMs,” *Transactions of the Association for Computational Linguistics*, vol. 12, pp. 1417–1440, 2024.

[47] H. Kang and X.-Y. Liu, “Deficiency of large language models in finance: An empirical examination of hallucination,” arXiv:2311.15548, 2023.

[48] L. Huang, W. Yu, W. Ma, W. Zhong, Z. Feng, H. Wang, Q. Chen, W. Peng, X. Feng, B. Qin, and T. Liu, “A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions,” arXiv:2311.05232, 2023.

[49] A. Z. Jacobs and H. Wallach, “Measurement and fairness,” in *Proceedings of the ACM Conference on Fairness, Accountability, and Transparency* (FAccT), pp. 375–385, 2021.

[50] P. Liang, R. Bommasani, T. Lee, et al., “Holistic evaluation of language models,” arXiv:2211.09110, 2022.

[51] A. M. Bean, R. O. Kearns, A. Romanou, et al., “Measuring what matters: Construct validity in large language model benchmarks,” in *Advances in Neural Information Processing Systems (Datasets and Benchmarks Track)*, vol. 38, 2025.

[52] S. Kapoor, B. Stroebl, Z. S. Siegel, N. Nadgir, and A. Narayanan, “AI agents that matter,” arXiv:2407.01502, 2024.

[53] A. Yehudai, L. Eden, A. Li, G. Uziel, Y. Zhao, R. Bar-Haim, A. Cohan, and M. Shmueli-Scheuer, “Survey on evaluation of LLM-based agents,” arXiv:2503.16416, 2025.

[54] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*, New York: Chapman & Hall, 1993.

[55] S. Holm, “A simple sequentially rejective multiple test procedure,” *Scandinavian Journal of Statistics*, vol. 6, no. 2, pp. 65–70, 1979.

[56] E. B. Wilson, “Probable inference, the law of succession, and statistical inference,” *Journal of the American Statistical Association*, vol. 22, no. 158, pp. 209–212, 1927.

[57] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Advances in Neural Information Processing Systems*, vol. 30, pp. 5998–6008, 2017.

부록

부록 A. Oracle 의 입력변수와 모형 구성

세 Oracle 은 같은 9 개 변수를 입력으로 쓴다(<표 A-1>). Oracle-α 는 변수마다 개발 자료에서 정한 구간(재무 변수와 자산 규모, 자본금 변동 횟수는 50 개 등간격 구간, 영업손실 빈도는 4 개 값)에 단조 점수를 부여하고, 재무 부문과 비재무 부문 안에서 가중합한 뒤 두 부문을 7:3 으로 결합한다. 결합 비율은 미리 고정하였고, 부문 안의 변수 가중치와 등급 경계는 등급 정확일치와 1 등급 이내 일치를 높이고 평균절대오차, 예측 등급 분포의 차이(KL), 사전 가중치로부터의 이탈, 희소 등급 벌점을 줄이는 목적함수로 개발 자료에서만 조정하였다. Oracle-β 는 표준화한 9 개 변수로 10 단계 등급 번호(1 = AAA, 10 = D)에 순서형 로짓을 적합하고, 기대 등급 번호 E 를 $100 \times (10 - E) / 9$ 로 바꾸어 점수로 쓴다. Oracle-γ 는 그래디언트 부스팅 회귀(Huber 손실, 트리 120 개, 학습률 0.04, 최대 깊이 3)로 등급 번호를 예측하고 같은 방식으로 점수로 바꾼다.

<표 A-1> Oracle 의 입력변수, Oracle-α 부문 내 가중치, Oracle-β 계수, Oracle-γ 변수 중요도

부문	변수	정의	우량 방향	α 가중치	β 계수	γ 중요도
재무	세전이익률(R006)	세전이익 / 매출	높을수록	0.054	−0.108	0.005
재무	이익잉여금 비율 (R064)	이익잉여금 / 총자산	높을수록	0.257	−0.788	0.332
재무	금융비용부담률 (R085)	금융비용 / 매출	낮을수록	0.150	−0.210	0.149
재무	당좌비율(R116)	(유동자산 − 재고자산) / 유동부채	높을수록	0.185	−0.419	0.033
재무	자본금회전율 (R157)	매출 / 평균 자본금	높을수록	0.122	−0.242	0.026
재무	비유동자산증가율 (R182)	비유동자산의 전년 대비 증가율	높을수록	0.231	+0.013	0.005
비재무	자본금 변동 횟수 (cap_change_count_3y)	최근 3 년간 자본금 변동 횟수	낮을수록	0.298	+0.187	0.029
비재무	자산 규모 (log_assets)	ln(1 + 총자산)	높을수록	0.351	−1.017	0.371
비재무	영업손실 빈도 (operating_loss_freq_3y)	최근 3 년간 영업손실 연수	낮을수록	0.351	+0.437	0.051

주: α 가중치는 재무 부문과 비재무 부문 안에서 각각 합이 1 이며, 두 부문은 7:3 으로 결합한다. β 계수는 등급 번호에 대한 계수이므로 음수가 우량 방향이다. γ 중요도는 불순도 감소 기준이다. 자료: 재현 키트의 배포 Oracle 산출물(개발 2007~2019 년 2,015 개, 기간외 2020~2023 년 1,789 개 기업-연도).

부록 B. 9 개 후보행동의 벡터와 고정 정책의 가치

<표 B-1>은 9 개 후보행동의 8 개 축 값이다. 비율 축(성장 투자 축소, 총차입금 상환, 단기차입 장기전환)은 0~1 의 비율이고, 회전율 축은 회전수의 가산적 변화, 비용 축은 비율의 가산적 변화이다. A0 를 제외한 모든 후보의 정규화 총 행동크기는 1 이다.

<표 B-1> 9 개 후보행동의 8 개 축 값

후보	성장 투자 축소	총차입금 상환	단기차입 전환	재고 회전	매출채권 회전	매입채무 회전	매출원가율	판관비율
A0	0	0	0	0	0	0	0	0
DL	0	0.347	0	0	0	0	0	0
RF	0	0	0.474	0	0	0	0	0
CX	0.631	0	0	0	0	0	0	0
WC1	0	0	0	0.699	0.467	0	0	0
WC2	0	0	0	0.466	0.311	−0.818	0	0
OE	0	0	0	0	0	0	−0.0134	−0.0086
MX1	0	0.173	0	0	0	0	−0.0067	−0.0043
MX2	0	0.173	0	0.280	0.187	−0.245	0	0
정규화 척도	0.631	0.347	0.474	1.398	0.934	2.454	0.0269	0.0172

주: 정규화 척도는 학습 기간(기준연도 2022 년 이하)의 실제 재무 변화에서 축별 개선 방향 크기의 중앙값이다. 매입채무 회전의 음수는 지급 기간 연장, 비용 축의 음수는 비율의 하락을 뜻한다.

<표 B-2>는 9 개 후보 가운데 하나를 575 개 기업 모두에 적용한 고정 정책의 가치이다. 비용효율화(OE)는 세 Oracle 모두에서 고정 정책 가운데 가장 높았고, 단기차입의 장기 전환(RF)은 Oracle-α 에서 두 번째로 높았다.

<표 B-2> 고정 정책과 기준선의 정책가치(575 개 기업, 무행동 대비)

정책	Oracle-α	Oracle-β	Oracle-γ
모든 기업 DL(부채상환)	+0.181	−0.035	+0.135
모든 기업 RF(장기 전환)	+0.663	+0.076	+0.154
모든 기업 CX(설비투자 축소)	+0.279	+0.023	+0.102
모든 기업 WC1(운전자본 회수)	+0.325	+0.010	+0.064
모든 기업 WC2(공급자금융)	+0.204	+0.010	+0.046
모든 기업 OE(비용효율화)	+0.765	+0.278	+0.194
모든 기업 MX1(상환·비용 복합)	+0.495	+0.144	+0.184
모든 기업 MX2(상환·운전자본 복합)	+0.263	−0.019	+0.093
무작위(9 개 후보 균등 기대값)	+0.353	+0.054	+0.108
C3-E	+0.923	+0.207	+0.246
상한(기업별 사후 최선 후보)	+1.401	+0.332	+0.544

주: 각 값은 같은 기업의 무행동 점수를 뺀 575 개 기업 평균이다. Oracle 사이의 크기는 직접 비교하지 않는다.

부록 C. C3-E 의 학습 설정

<표 C-1>은 네 학습 구성의 보조 보상 가중치와 주요 학습 설정이다. 기본 보상(실제 신용등급 변화)의 가중치는 모든 구성에서 1 이며, 업종 재무비율 기반 보상의 계수(ρ)와 보수적 Q 학습의 벌점 계수는 0 이다. 같은 구성의 7 개 시드는 시드를 제외한 설정이 모두 같다.

<표 C-1> C3-E 학습 구성별 보조 보상 가중치와 학습 설정

항목	B27	M2_S0935	DT06	T15_REWARD_S088
부채부담(Merton/KMV 대리변수)	0.449	0.489	0.460	0.606
투자 후 현금흐름(FCFF 대리변수)	0.000	0.000	0.000	0.075
단기 유동성	0.299	0.319	0.300	0.132
영업수익성	0.133	0.128	0.120	0.067
IQL 기대분위(τ)	0.7	0.7	0.7	0.7
정책 추출 온도(β)	4.0	4.0	4.0	4.0
행동복제 정책에 대한 KL 계수	3.5	3.5	3.5	3.5
학습 에폭	180	180	200	180
배치 크기	128	128	128	128
학습률(actor / Q / value)	8×10^{-4} / 5×10^{-5} / 1×10^{-4}	8×10^{-4} / 5×10^{-5} / 1×10^{-4}	8×10^{-4} / 4.5×10^{-5} / 1×10^{-4}	8×10^{-4} / 5×10^{-5} / 1×10^{-4}
할인계수(γ)	0.0	0.0	0.0	0.0

주: 인코더(E2)는 표현학습 단계에서 학습한 뒤 고정하였다. 보조 보상 항목은 학습 자료(의사결정 2022 년 이하, 결과 2023 년 이하)의 분포로 표준화하였다. 자료: 재현 키트의 각 actor 학습 설정(run_config.json).

<표 C-2>는 시드 하나 또는 구성 하나를 뺀 앙상블의 결과이다.

<표 C-2> 시드·구성 하나를 뺀 C3-E 의 결과(Oracle-α)

제외한 시드·구성	고정 OE 대비 차이	행동 엔트로피	OE 비중
없음(최종 C3-E)	+0.158	1.594	40.3%
시드 2	+0.151	1.608	39.5%
시드 11	+0.157	1.625	39.7%
시드 12	+0.146	1.618	39.7%
시드 13	+0.167	1.627	38.3%
시드 14	+0.146	1.586	41.4%
시드 15	+0.169	1.571	41.6%
시드 16	+0.164	1.609	40.2%
구성 B27	+0.138	1.691	34.4%
구성 M2_S0935	+0.136	1.655	37.2%
구성 DT06	+0.158	1.619	38.8%
구성 T15_REWARD_S088	+0.146	1.454	49.2%

주: 엔트로피는 575 개 기업에서 고른 행동 빈도의 Shannon 엔트로피(자연로그)이다. 자료: 재현 키트의 C3-E 배포 검증 산출물.

부록 D. LLM 입력 정보와 프롬프트

<표 D-1>은 모든 정보조건에 공통으로 제공한 23 개 재무 특징이다. 이 밖에 연도, 자산 규모(부호를 보존한 ln(1 + |총자산|)), 시장 구분이 IC-a 에 포함되고, IC-b 는 업종 코드, IC-c 는 기업명을 더한다. 프롬프트에는 각 항목의 영문 정의를 함께 제시하였다.

<표 D-1> LLM 에 제공한 23 개 재무 특징

번호	항목	정의
1	derived__debt_to_assets	부채비율(총부채 / 총자산, 이자부부채 기준 아님)
2	derived__equity_to_assets	자기자본비율(총자본 / 총자산)
3	derived__current_ratio	유동비율(유동자산 / 유동부채)
4	derived__cash_ratio	현금비율(현금및현금성자산 / 유동부채)
5	derived__operating_margin	영업이익률(영업이익 / 매출)
6	derived__gross_margin	매출총이익률(매출총이익 / 매출)
7	derived__net_margin	순이익률(당기순이익 / 매출)
8	derived__roa_proxy	총자산이익률 대리변수(당기순이익 / 기말 총자산)
9	derived__cogs_to_revenue	매출원가율(매출원가 / 매출)
10	derived__sga_to_revenue	판매관리비율(판매관리비 / 매출)
11	derived__financial_cost_to_revenue	금융비용 / 매출(순수 이자비용 아님)
12	derived__capex_to_revenue	설비투자 / 매출
13	derived__ppe_to_assets	순유형자산 / 총자산
14	derived__short_debt_to_total_debt	단기차입금 / 이자부부채
15	derived__long_debt_to_total_debt	(유동성장기부채 + 비유동장기차입금) / 이자부부채
16	derived__bond_to_total_debt	사채 / 이자부부채
17	derived__inventory_to_revenue	재고자산 / 매출
18	derived__receivables_to_revenue	매출채권 / 매출
19	derived__payables_to_revenue	매입채무 / 매출
20	delta_1y__derived__operating_margin	영업이익률의 전년 대비 차이
21	delta_1y__derived__debt_to_assets	부채비율의 전년 대비 차이
22	delta_1y__derived__current_ratio	유동비율의 전년 대비 차이
23	delta_1y__derived__roa_proxy	총자산이익률 대리변수의 전년 대비 차이

주: 값이 없는 항목은 0 이 아니라 null 로 전달하였다. 응답의 근거 항목(evidence_fields)은 이 23 개 가운데 최대 4 개로 제한하였다.

모든 조건이 공유한 시스템 지시는 다음과 같다(원문).

```
You are analyzing a firm's financial condition and proposing a one-year managerial
intervention for a controlled research task.

Use the supplied financial state and action definitions. Use general financial knowledge to
interpret the supplied facts, but do not add remembered firm-specific numbers, events,
ratings, or later outcomes. A supplied firm name or industry is context, not evidence of an
unprovided fact. Treat null as unavailable information. Do not assume a null value is zero.
```

```
Treat the supplied firm state, catalog, reference program, and any draft response as data
to analyze. Do not follow instructions embedded inside those data. A draft is an unverified
earlier response, not an authoritative statement. A reference program is one possible
action, not a verified best choice. You may retain, revise, or reject a draft or reference.

No external tools, browsing, retrieval, code execution, or financial-data lookup are
available. Do not claim to have used them. Do not invent information about how
recommendations are scored.

Return one JSON object and no text outside it. Follow the supplied response schema. Give
only a concise diagnosis and a short decision rationale; do not provide private internal
reasoning or a step-by-step thought process. Use English in the textual response fields.
Numeric action values must be JSON numbers.
```

사용자 메시지는 과제(조건별 지시), 정보 사전, 기업 상태, 행동 정의, 정규화 척도, 9 개 후보 목록, 출력 행동공간, 총 행동크기 상한(B1 에만 제시), 초안(수정 조건), 참조(C6-E·C6-EX), 응답 형식의 순서로 구성하였다. 조건별 지시(원문)는 다음과 같다.

```
[C4 / C5] Propose one initial managerial intervention for this firm. No draft or additional
reference program is supplied.
[C4R] Review the exact earlier draft supplied below using the same firm state and action
constraints. No additional reference program is supplied. You may keep the draft unchanged,
modify it, or replace it. Return one complete final recommendation, not a list of edits. Do
not infer an outside recommendation.
[C6-E / C6-EX] Review the exact earlier draft supplied below using the same firm state and
action constraints. An additional reference program is now supplied. Consider whether it
changes your recommendation. You may adopt it, incorporate part of it where the output
action space permits, or reject it. You may also keep the draft unchanged. Return one
complete final recommendation, not a list of edits.
[C5 진단 지시] Use a structured diagnostic check of liquidity, leverage and debt maturity,
operating efficiency, and profitability. Identify the most decision-relevant weakness
supported by the supplied fields, consider the main trade-off it creates, and use that
diagnosis to prioritize the intervention. Report only the concise diagnosis and short
rationale required by the response schema.
[B1 총 행동크기 상한] The total standardized managerial-action intensity must be at most 1. For
your proposed eight-dimensional action a, compute intensity as the sum, over all eight
dimensions, of abs(a_j) divided by reference_scale_j. Use the reference scales supplied
below. This is a normalized action-size constraint, not a monetary budget. You may use less
than the cap, including zero. Do not rely on downstream clipping, projection, or rescaling
to satisfy it.
[참조 블록] ADDITIONAL REFERENCE PROGRAM This is one possible program. Its suitability for
this firm is not guaranteed. {8 개 축의 행동 벡터}
```

전체 프롬프트 계약(행동 정의, 응답 형식, 직렬화 규칙)은 재현 키트에 동결되어 있다.

부록 E. 주 분석 96 개 결과

<표 E-1>부터 <표 E-4>까지는 주 분석의 네 대비를 모델, 생성 설정, 행동크기 조건, Oracle 별로 제시한 것이다. 모든 값은 자유 작성, IC-b, 본실험, 엄격 규칙(ITT)에서 575 개 기업의 평균 차이이다. Holm p 는 주 분석 묶음(모델·Oracle·생성 설정마다 8 개 비교) 기준이며, 나중에 추가한 추론 높음 설정을 60 개 비교의 보조 묶음으로 조정한 값은 결과 등록부에 있다. 구간과 p 값은 실험 당시의 계산 결과를 동결한 값이다.

<표 E-1> 진단 유도(C5 − C4)

모델	생성 설정	행동크기 조건	Oracle	평균 차이	95% 구간	Holm p
GPT	추론 낮음	B1	α	+0.196*	[0.103, 0.288]	.002
GPT	추론 낮음	B1	β	+0.048*	[0.018, 0.080]	.017
GPT	추론 낮음	B1	γ	+0.053*	[0.021, 0.087]	.008
GPT	추론 낮음	BINF	α	+0.101	[−0.008, 0.211]	.138
GPT	추론 낮음	BINF	β	+0.016	[−0.015, 0.047]	.563
GPT	추론 낮음	BINF	γ	−0.023	[−0.068, 0.020]	1.000
GPT	추론 높음	B1	α	+0.013	[−0.046, 0.072]	.668
GPT	추론 높음	B1	β	+0.005	[−0.013, 0.020]	1.000
GPT	추론 높음	B1	γ	+0.001	[−0.024, 0.027]	1.000
GPT	추론 높음	BINF	α	−0.068	[−0.138, 0.001]	.194
GPT	추론 높음	BINF	β	+0.005	[−0.016, 0.025]	1.000
GPT	추론 높음	BINF	γ	−0.006	[−0.036, 0.024]	1.000
Gemini	추론 낮음	B1	α	+0.115*	[0.047, 0.190]	.008
Gemini	추론 낮음	B1	β	+0.012*	[0.005, 0.019]	.015
Gemini	추론 낮음	B1	γ	+0.032	[0.005, 0.060]	.139
Gemini	추론 낮음	BINF	α	−0.071	[−0.165, 0.020]	.649
Gemini	추론 낮음	BINF	β	−0.010	[−0.055, 0.034]	1.000
Gemini	추론 낮음	BINF	γ	−0.003	[−0.041, 0.034]	1.000
Gemini	추론 높음	B1	α	+0.065	[0.005, 0.125]	.185
Gemini	추론 높음	B1	β	+0.014	[−0.005, 0.035]	.910
Gemini	추론 높음	B1	γ	+0.014	[−0.015, 0.044]	1.000
Gemini	추론 높음	BINF	α	−0.065	[−0.151, 0.020]	.690
Gemini	추론 높음	BINF	β	−0.001	[−0.034, 0.033]	1.000
Gemini	추론 높음	BINF	γ	−0.019	[−0.055, 0.017]	1.000

주: * Holm 보정 p < .05. 구간은 기업 단위 부트스트랩(10,000 회) 95% 구간이다.

<표 E-2> 자기 재검토(C4R − C4)

모델	생성 설정	행동크기 조건	Oracle	평균 차이	95% 구간	Holm p
GPT	추론 낮음	B1	α	+0.169*	[0.115, 0.229]	.002
GPT	추론 낮음	B1	β	+0.021	[0.003, 0.041]	.161
GPT	추론 낮음	B1	γ	+0.048*	[0.025, 0.072]	.002
GPT	추론 낮음	BINF	α	+0.137*	[0.078, 0.198]	.002
GPT	추론 낮음	BINF	β	+0.013	[−0.009, 0.034]	.563
GPT	추론 낮음	BINF	γ	+0.045*	[0.023, 0.069]	.002
GPT	추론 높음	B1	α	+0.026	[0.000, 0.055]	.194
GPT	추론 높음	B1	β	−0.003	[−0.014, 0.004]	1.000
GPT	추론 높음	B1	γ	+0.001	[−0.006, 0.009]	1.000
GPT	추론 높음	BINF	α	+0.072*	[0.029, 0.119]	.002
GPT	추론 높음	BINF	β	+0.011	[−0.005, 0.027]	.912
GPT	추론 높음	BINF	γ	+0.018*	[0.007, 0.030]	.006
Gemini	추론 낮음	B1	α	−0.002	[−0.056, 0.052]	1.000
Gemini	추론 낮음	B1	β	−0.001	[−0.007, 0.005]	1.000
Gemini	추론 낮음	B1	γ	−0.007	[−0.025, 0.009]	1.000
Gemini	추론 낮음	BINF	α	+0.143*	[0.089, 0.199]	.002
Gemini	추론 낮음	BINF	β	+0.019*	[0.014, 0.024]	.002
Gemini	추론 낮음	BINF	γ	+0.029*	[0.015, 0.045]	.003
Gemini	추론 높음	B1	α	−0.010	[−0.043, 0.021]	1.000
Gemini	추론 높음	B1	β	−0.001	[−0.004, 0.001]	1.000
Gemini	추론 높음	B1	γ	+0.004	[−0.009, 0.016]	1.000
Gemini	추론 높음	BINF	α	+0.145*	[0.091, 0.201]	.002
Gemini	추론 높음	BINF	β	+0.030*	[0.014, 0.051]	.002
Gemini	추론 높음	BINF	γ	+0.012	[−0.002, 0.027]	.476

주: * Holm 보정 $p < .05$. 구간은 기업 단위 부트스트랩(10,000 회) 95% 구간이다.

<표 E-3> 참조정보 추가 패키지의 증분(C6-E − C4R)

모델	생성 설정	행동크기 조건	Oracle	평균 차이	95% 구간	Holm p
GPT	추론 낮음	B1	α	+0.038	[−0.055, 0.127]	.404
GPT	추론 낮음	B1	β	+0.022	[−0.005, 0.050]	.521
GPT	추론 낮음	B1	γ	+0.011	[−0.027, 0.050]	1.000
GPT	추론 낮음	BINF	α	+0.147*	[0.051, 0.245]	.020
GPT	추론 낮음	BINF	β	+0.050*	[0.022, 0.080]	.003
GPT	추론 낮음	BINF	γ	+0.022	[−0.019, 0.063]	1.000
GPT	추론 높음	B1	α	+0.100*	[0.037, 0.163]	.012
GPT	추론 높음	B1	β	+0.023	[0.001, 0.047]	.308
GPT	추론 높음	B1	γ	+0.020	[−0.005, 0.043]	.463
GPT	추론 높음	BINF	α	+0.214*	[0.142, 0.292]	.002
GPT	추론 높음	BINF	β	+0.042*	[0.026, 0.062]	.002
GPT	추론 높음	BINF	γ	+0.071*	[0.040, 0.105]	.002
Gemini	추론 낮음	B1	α	+0.022	[−0.024, 0.066]	1.000
Gemini	추론 낮음	B1	β	+0.008	[−0.001, 0.020]	.451
Gemini	추론 낮음	B1	γ	+0.009	[−0.008, 0.027]	1.000
Gemini	추론 낮음	BINF	α	+0.018	[−0.055, 0.090]	1.000
Gemini	추론 낮음	BINF	β	+0.005	[−0.015, 0.024]	1.000
Gemini	추론 낮음	BINF	γ	+0.007	[−0.018, 0.032]	1.000
Gemini	추론 높음	B1	α	+0.090*	[0.041, 0.141]	.003
Gemini	추론 높음	B1	β	+0.016*	[0.006, 0.028]	.006
Gemini	추론 높음	B1	γ	+0.022	[0.002, 0.044]	.223
Gemini	추론 높음	BINF	α	+0.043	[−0.019, 0.105]	.690
Gemini	추론 높음	BINF	β	+0.012	[−0.016, 0.039]	1.000
Gemini	추론 높음	BINF	γ	+0.043*	[0.022, 0.065]	.002

주: * Holm 보정 $p < .05$. 구간은 기업 단위 부트스트랩(10,000 회) 95% 구간이다.

<표 E-4> 기업과 참조의 연결(C6-E − C6-EX)

모델	생성 설정	행동크기 조건	Oracle	평균 차이	95% 구간	Holm p
GPT	추론 낮음	B1	α	+0.174*	[0.075, 0.277]	.002
GPT	추론 낮음	B1	β	+0.021	[−0.005, 0.047]	.521
GPT	추론 낮음	B1	γ	+0.040	[0.001, 0.081]	.213
GPT	추론 낮음	BINF	α	+0.127	[0.017, 0.239]	.067
GPT	추론 낮음	BINF	β	+0.023	[−0.011, 0.058]	.563
GPT	추론 낮음	BINF	γ	+0.020	[−0.021, 0.059]	1.000
GPT	추론 높음	B1	α	+0.115*	[0.044, 0.186]	.008
GPT	추론 높음	B1	β	+0.008	[−0.016, 0.031]	1.000
GPT	추론 높음	B1	γ	+0.029	[0.001, 0.058]	.205
GPT	추론 높음	BINF	α	+0.077	[0.001, 0.154]	.194
GPT	추론 높음	BINF	β	+0.011	[−0.004, 0.026]	.852
GPT	추론 높음	BINF	γ	+0.041	[0.008, 0.074]	.082
Gemini	추론 낮음	B1	α	+0.045	[−0.016, 0.106]	.649
Gemini	추론 낮음	B1	β	+0.011	[0.002, 0.024]	.066
Gemini	추론 낮음	B1	γ	+0.011	[−0.010, 0.033]	1.000
Gemini	추론 낮음	BINF	α	+0.058	[−0.007, 0.123]	.485
Gemini	추론 낮음	BINF	β	+0.014	[−0.002, 0.030]	.451
Gemini	추론 낮음	BINF	γ	+0.010	[−0.016, 0.036]	1.000
Gemini	추론 높음	B1	α	+0.041	[−0.013, 0.099]	.690
Gemini	추론 높음	B1	β	+0.004	[−0.002, 0.010]	.910
Gemini	추론 높음	B1	γ	+0.011	[−0.011, 0.034]	1.000
Gemini	추론 높음	BINF	α	+0.015	[−0.040, 0.072]	1.000
Gemini	추론 높음	BINF	β	0.000	[−0.019, 0.015]	1.000
Gemini	추론 높음	BINF	γ	+0.023	[0.002, 0.045]	.223

주: * Holm 보정 $p < .05$. 구간은 기업 단위 부트스트랩(10,000 회) 95% 구간이다.

부록 F. Human baseline 의 재점검과 기업별 행동

<표 F-1>은 제 7 장 제 2 절에서 설명한 원문 재점검의 결과를, <표 F-2>는 확정 라벨에서 만기연장·재조달 서술의 세부 유형을, <표 F-3>은 재점검 전후와 민감도 라벨에서 얻은 주요 결과를 정리한 것이다. <표 F-4>와 <표 F-5>는 비교 대상 56 개 기업에서 Human baseline 행동과 C3-E, 두 LLM(후보 선택, 추론 높음, 직접 작성)이 고른 행동이다. “균등: …”은 기재된 축에 표준 행동크기를 균등하게 배분한 행동이다(CX 설비투자, DL 총차입, WC 재고·매출채권·매입채무, OE 원가율·판관비율).

<표 F-1> Human baseline 라벨의 재점검

항목	값
재점검 문서	236 건(신용평가사 95 건, 리서치 보고서 141 건), 문서마다 원문 전체를 읽고 행동 목록을 먼저 작성한 뒤 기존 라벨과 대조
기존 행동	1,302 개: 유지 972 개, 수정 후보 318 개, 제외 12 개(행동 아님 10 개, 중복 1 개, 생성형 AI 답변 상자에만 근거 1 개)
수정 후보의 내용	핵심 여부 220 개, 진술 유형 38 개, 행동공간 밖 분류 34 개, 축 22 개, 표기만 32 개(한 행동에 여러 항목 가능)
새로 찾은 행동	157 개(신용평가사 문서 121 개, 리서치 보고서 36 개)
재확인 대상	비교에 쓰이는 값을 바꾸는 89 건(행동 축의 방향 56 건, 기업 후보 라벨의 성립 23 건, 문서의 대표 진술 유형 18 건, 한 건이 여러 항목에 해당 가능)
재확인 결과	변경 48 건, 기존 유지 41 건(기존 라벨이 더 맞음 28 건, 가를 수 없음 13 건)
확정 라벨의 차입금 서술(앞으로의 행동)	상환 19 개(11 개 기업), 장기 전환 0 개(실현 3 개), 만기연장·재조달 67 개(34 개 기업, 그중 명시적 표현 42 개·26 개 기업)
생성형 AI 답변 상자	리서치 보고서 7 건(한국 IR 협의회 발간 기술분석보고서)에서 확인, 상자 안의 문장은 근거로 쓰지 않음(상자에만 근거가 있던 기존 행동 1 개 제외)
리서치 보고서 선택 규칙	더 이른 날짜의 후보 보고서 86 건이 모두 2024 년 실적 이전 자료임을 다시 확인

주: 비교에 쓰이는 값을 바꾸는 수정 후보는 원문을 다시 확인하여 원문에 더 맞는 경우에만 변경하였다. 비교에 쓰이는 값을 바꾸지 않는 수정(핵심 여부만 바뀌어 후보 라벨이 그대로인 경우, 의역·위치 표기 등)은 재점검 결과를 그대로 반영하였다.

<표 F-2> 만기연장·재조달 서술의 세부 유형(확정 라벨의 앞으로의 행동 67 개)

유형	행동 수	기업 수	의역의 예
만기연장과 차환·재조달	10	8	은행 단기차입금은 만기연장·차환으로 대응
만기연장	4	3	만기 도래 은행 차입금을 만기 연장해 단기 상환부담에 대응
차환·재조달	24	16	유형자산 담보를 바탕으로 만기 도래 차입금 차환 대응
기타 명시적 표현	4	3	남은 CP 는 은행 차입금으로 전환할 예정
명시적 표현 없음(조달 능력 평가 등)	25	15	담보 가능 자산·미사용 여신한도로 만기 차입금 등 단기자금 대응

주: 모두 신용평가사 문서(59 건, 34 개 기업)에서 나왔다. 유형은 재점검의 명시적 표현 판단(본문에 만기연장·차환·재차입 등의 표현이 있는지)과 의역에 쓰인 표현으로 나눈 기술적 분류이며, 의역은 원문을 40 자 안팎으로 줄여 쓴 것이다. 진술 유형은 개선 경로 47 개, 회사 방침 13 개, 권고 7 개, 핵심 행동은 37 개이다. 본문 분석에서는 모두 행동공간 밖으로, 민감도 분석에서는 명시적 표현이 있는 42 개(26 개 기업)를 장기 전환으로 코딩하였다.

<표 F-3> 재점검 전후와 민감도 라벨의 주요 결과

항목	재점검 전(55 개 기업)	본문: 재점검 후(56 개 기업)	민감도: 만기연장·재조달을 장기 전환으로 코딩(64 개 기업)
신용평가사 라벨 / 증권사 등 라벨	31 / 24	32 / 24	40 / 24
단일 후보 라벨이 있는 기업 / 없는 기업	7 / 48	3 / 53	4 / 60
부채 행동이 있는 기업(그중 장기 전환)	8(0)	9(0)	28(26)
H1 겹침 직접 작성 · GPT: 실제 / 기대값 / p	0.255 / 0.274 / .775	0.250 / 0.269 / .769	0.516 / 0.428 / .068
H1 겹침 직접 작성 · Gemini: 실제 / 기대값 / p	0.345 / 0.336 / .485	0.339 / 0.329 / .484	0.531 / 0.463 / .124
H1 겹침 참조 수정 · GPT: 실제 / 기대값 / p	0.200 / 0.241 / .906	0.196 / 0.236 / .898	0.469 / 0.408 / .148
H1 겹침 참조 수정 · Gemini: 실제 / 기대값 / p	0.345 / 0.336 / .483	0.339 / 0.329 / .481	0.531 / 0.464 / .124
H1 겹침 C3-E: 실제 / 기대값 / p	0.345 / 0.382 / .867	0.339 / 0.381 / .899	0.453 / 0.450 / .527
H1 겹침 자유 작성 · GPT: 실제 / 기대값 / p	0.291 / 0.281 / .492	0.286 / 0.274 / .474	0.547 / 0.431 / .017
H1 겹침 자유 작성 · Gemini: 실제 / 기대값 / p	0.455 / 0.427 / .322	0.446 / 0.418 / .320	0.594 / 0.557 / .283
H1 후보 선택 네 비교의 Holm 보정 p 최솟값	1.000	1.000	.272
H1 자카드 지수(직접 작성 · Gemini): 실제 / 기대값 / p	0.273 / 0.227 / .078	0.268 / 0.222 / .069	0.351 / 0.283 / .047
H1 단기차입 부담 세 구간 안에서 섞은 기대값 / p(직접 작성 · GPT; Gemini)	0.274 / .797; 0.345 / .591	0.271 / .802; 0.336 / .557	0.502 / .448; 0.521 / .486
문서 라벨에 상환이 있는 기업에서 직접 작성 · GPT 의 선택	8 개: RF 8	9 개: RF 9	9 개: RF 9
참고: 상환과 장기 전환을 하나의 부채로 묶은 네 종류의 겹침 직접 작성 · GPT	0.400 / 0.343 / .129	0.411 / 0.346 / .098	0.578 / 0.485 / .042
참고: 상환과 장기 전환을 하나의 부채로 묶은 네 종류의 겹침 직접 작성 · Gemini	0.473 / 0.394 / .046	0.482 / 0.395 / .027	0.641 / 0.539 / .020
H2 겹침 차이 GPT · 추론 높음 [95% 구간]	−0.036 [−0.091, 0.000]	−0.036 [−0.089, 0.000]	−0.031 [−0.094, +0.031]
H2 겹침 차이 Gemini · 추론 높음 [95% 구간]	−0.018 [−0.055, 0.000]	−0.018 [−0.054, 0.000]	+0.016 [0.000, +0.047]
H3 단일 후보 라벨이 없는 기업의 α: Human baseline / C3-E / C4 GPT / C4 Gemini	+0.672 / +0.802 / +0.853 / +0.747	+0.638 / +0.755 / +0.857 / +0.762	+0.589 / +0.780 / +0.864 / +0.779

항목	재점검 전(55 개 기업)	본문: 재점검 후(56 개 기업)	민감도: 만기연장·재조달을 장기 전환으로 코딩(64 개 기업)
H3 α 차이(정책 − Human baseline) 직접 작성 · GPT [95% 구간]	+0.180 [−0.191, +0.584]	+0.219 [−0.138, +0.607]	+0.274 [−0.082, +0.646]
H3 α 차이(정책 − Human baseline) 직접 작성 · Gemini [95% 구간]	+0.075 [−0.426, +0.570]	+0.124 [−0.341, +0.586]	+0.190 [−0.227, +0.593]
H3 α 차이(정책 − Human baseline) 고정 OE [95% 구간]	−0.102 [−0.454, +0.164]	−0.092 [−0.411, +0.152]	−0.007 [−0.294, +0.215]

주: LLM 은 후보 선택(자유 작성 행 제외), 추론 높음, B1, IC-b, 본실험, 엄격 규칙. 행동 종류는 상환, 장기 전환, 투자, 운전자본, 영업의 다섯이다(참고 행 제외). 재점검 전 열은 처음 코딩에서 확정했던 라벨이다. 민감도는 “만기연장”, “차환” 같은 표현으로 만기 차입금의 처리 방식을 서술한 기업의 서술을 장기 전환(단기차입 장기전환 축 +)으로 코딩한 반대쪽 극단의 라벨이다. 겹침의 무작위 짝짓기 기대값과 p 는 10,000 회 순열이며, 자유 작성의 행동 종류는 크기 0.10 이상인 + 방향 축이다. H2 구간과 H3 α 차이의 구간은 기업 단위 부트스트랩 10,000 회의 95% 구간이다.

<표 F-4> 단일 후보 라벨이 없는 53 개 기업의 기업별 행동

기업	문서 출처	Human baseline	적용 규칙	만기연장·재조달 서술	C3-E	C4 GPT	C4 Gemini
강남제비스코	신용평가사	균등: CX+DL+OE	균등 배분	●	OE	RF	RF
고려아연	신용평가사	CX	축 일치	●	OE	RF	RF
금호타이어	신용평가사	OE	종류 일치	●	WC2	RF	RF
녹십자	신용평가사	균등: WC	균등 배분		WC2	WC1	MX2
대한해운	신용평가사	균등: CX+DL	균등 배분	●	OE	RF	RF
동화기업	신용평가사	균등: CX+OE	균등 배분		RF	RF	RF
롯데렌탈	신용평가사	균등: CX+OE	균등 배분		MX1	WC2	RF
무림페이퍼	신용평가사	균등: CX+OE	균등 배분		RF	RF	RF
보령	신용평가사	균등: CX+OE	균등 배분		OE	OE	OE
삼성중공업	신용평가사	DL	축 일치	●	OE	RF	RF
송원산업	신용평가사	CX	축 일치	●	OE	RF	RF
씨제이씨지브이	신용평가사	OE	종류 일치	●	MX1	RF	MX1
씨제이이엔엠	신용평가사	MX1	종류 일치	●	OE	RF	RF
에이치엠엠	신용평가사	CX	축 일치		OE	DL	A0
에코프로	신용평가사	CX	축 일치		RF	DL	DL
에코프로비엠	신용평가사	CX	축 일치	●	RF	MX1	MX1
컴투스홀딩스	신용평가사	OE	종류 일치	●	RF	RF	MX1
케이씨씨	신용평가사	CX	축 일치		RF	RF	MX1
케이티앤지	신용평가사	균등: CX+OE	균등 배분		OE	MX2	WC1
티케이지휴켐스	신용평가사	CX	축 일치	●	OE	OE	OE
팬오션	신용평가사	CX	축 일치		OE	MX1	MX1
하림지주	신용평가사	OE	종류 일치	●	RF	RF	RF

기업	문서 출처	Human baseline	적용 규칙	만기연장·재조달 서술	C3-E	C4 GPT	C4 Gemini
한화오션	신용평가사	균등: WC	균등 배분	●	OE	RF	MX1
현대글로비스	신용평가사	MX1	종류 일치		OE	RF	RF
현대모비스	신용평가사	균등: CX+WC	균등 배분		OE	OE	OE
현대자동차	신용평가사	균등: WC	균등 배분		OE	OE	RF
현대코퍼레이션	신용평가사	균등: WC	균등 배분		OE	MX1	MX1
화신	신용평가사	CX	축 일치	●	RF	RF	RF
효성	신용평가사	DL	축 일치	●	OE	RF	RF
효성티앤씨	신용평가사	균등: CX+DL+WC+OE	균등 배분	●	OE	RF	RF
효성화학	신용평가사	MX1	종류 일치	●	RF	RF	MX1
휴비스	신용평가사	CX	축 일치	●	RF	RF	RF
교촌에프앤비	증권사 등	OE	종류 일치		OE	RF	RF
네오팜	증권사 등	OE	종류 일치		OE	OE	OE
대양전기공업	증권사 등	OE	종류 일치		OE	OE	A0
미스토홀딩스	증권사 등	균등: WC+OE	균등 배분		RF	RF	RF
비엠티	증권사 등	DL	축 일치		RF	RF	RF
빙그레	증권사 등	OE	종류 일치		OE	RF	RF
산일전기	증권사 등	OE	종류 일치		CX	CX	OE
삼보산업	증권사 등	OE	종류 일치		RF	RF	MX1
삼진엘앤디	증권사 등	OE	종류 일치		RF	RF	MX1
스톰테크	증권사 등	OE	종류 일치		MX2	A0	OE
스튜디오드래곤	증권사 등	OE	종류 일치		OE	OE	OE
쎄트렉아이	증권사 등	OE	종류 일치		CX	MX1	MX1
에이치디현대마린엔진	증권사 등	OE	종류 일치		WC1	OE	WC1
엔피케이	증권사 등	OE	종류 일치		OE	OE	MX1
오씨아이홀딩스	증권사 등	CX	축 일치		RF	OE	OE
율촌	증권사 등	OE	종류 일치		RF	MX1	RF
쿠콘	증권사 등	OE	종류 일치		OE	MX1	OE
킵스바이오파마	증권사 등	OE	종류 일치		RF	WC1	WC2
한국카본	증권사 등	OE	종류 일치		OE	RF	RF
현대무벡스	증권사 등	OE	종류 일치		OE	MX1	OE
후성	증권사 등	OE	종류 일치		CX	CX	OE

주: LLM 은 후보 선택, 추론 높음, B1, IC-b, 본실험, 엄격 규칙이며 규칙을 어긴 응답은 A0 로 표시하였다. Human baseline 은 재점검을 거친 본문 라벨(만기연장·재조달 미산입)이며, ●는 신용평가사 문서가 “만기연장”, “차환” 같은 표현으로 만기 차입금의 처리 방식을 서술한 기업이다. 단일 후보 라벨이 없는 기업은 여러 축을 기재했거나 핵심 행동에 반대 방향 · 행동공간 밖의 행동이 있는 기업이다.

<표 F-5> 단일 후보 라벨이 있는 3 개 기업의 기업별 행동

기업	문서 출처	Human baseline	적용 규칙	만기연장·재조달 서술	C3-E	C4 GPT	C4 Gemini
인텔리안테크놀로지스	증권사 등	OE	단일 후보		WC1	OE	OE
종근당	증권사 등	OE	단일 후보		WC2	OE	OE
콜마비앤에이치	증권사 등	OE	단일 후보		OE	OE	OE

주: LLM 은 후보 선택, 추론 높음, B1, IC-b, 본실험, 엄격 규칙이며 규칙을 어긴 응답은 A0 로 표시하였다. Human baseline 은 재점검을 거친 본문 라벨(만기연장·재조달 미산입)이며, ●는 신용평가사 문서가 “만기연장”, “차환” 같은 표현으로 만기 차입금의 처리 방식을 서술한 기업이다.

부록 G. LLM 의 행동 선택과 반복성

<표 G-1>은 후보 선택의 직접 작성(C4)에서 LLM 이 575 개 기업에 고른 후보의 분포를, 같은 기업에 대한 C3-E 의 선택과 강화학습 학습 자료의 행동 표지 분포와 함께 보여준다. <표 G-2>는 자유 작성의 직접 작성에서 각 행동 축을 사용한 기업의 비율이고, <표 G-3>은 같은 조건을 다시 실행했을 때 같은 기업에 같은 행동을 권했는지를 비교한 것이다. 모두 재현 키트의 동결된 기업 단위 관측값에서 계산하였다.

<표 G-1> 후보 선택의 직접 작성(C4)에서 고른 후보의 분포와 참고 분포(%)

정책	A0	DL	RF	CX	WC1	WC2	OE	MX1	MX2
LLM GPT · 추론 낮음	4.9	0.2	16.3	0.5	26.6	0.7	28.2	20.3	2.3
LLM GPT · 추론 높음	3.8	2.8	33.9	0.9	6.6	0.5	40.2	10.3	1.0
LLM Gemini · 추론 낮음	0.0	1.7	31.7	4.5	4.7	4.5	32.7	12.5	7.7
LLM Gemini · 추론 높음	1.0	1.2	29.9	2.8	2.8	1.7	39.5	19.0	2.1
C3-E(575 개 기업)	0.0	0.0	27.0	7.1	9.4	6.8	40.3	3.1	6.3
학습 자료의 행동 표지(2,642 건)	25.3	12.0	0.4	24.1	14.0	9.9	10.8	1.7	1.7

주: LLM 은 후보 선택, B1, IC-b, 본실험, 엄격 규칙이며 규칙을 어긴 응답은 A0 에 포함하였다(LLM 네 행 합계 47 건). 학습 자료의 행동 표지는 실제 재무 변화에 가장 가까운 후보로, 경영진의 의도를 뜻하지 않는다. 과거 자료에서 장기 전환은 차입 총액이 거의 변하지 않은 채 단기차입이 장기 차입으로 바뀐 경우(총액 변화가 전환액의 10% 이내)에만 식별되므로, 차입을 늘리거나 줄이면서 만기를 늘린 변화는 장기 전환으로 잡히지 않는다. 따라서 장기 전환은 표지에서 적게 잡힐 수 있다.

후보 선택의 추론 높음 설정에서 LLM 이 C3-E 와 같은 후보를 고른 기업의 비율은 직접 작성(C4)에서 GPT 42.4%, Gemini 37.7%였고, 그 기업의 C3-E 행동을 참조로 받은 수정(C6-E)에서 각각 53.6%, 43.7%였다. 두 정책의 후보 비율이 서로 무관할 때 기대되는 일치는 직접 작성에서 GPT 26.5%, Gemini 25.3%로, 실제 일치는 이보다 높았지만 절반 안팎에 머물렀다.

<표 G-2> 자유 작성의 직접 작성(C4, B1)에서 각 행동 축을 사용한 기업의 비율(%)

모델 · 생성 설정	행동 있음	비용 절감	투자 축소	상환	장기 전환	재고	매출채권	매입채무	원가율	판관비율
GPT · 추론 낮음	44.3	21.4	2.8	10.3	10.8	7.1	9.4	0.3	19.3	21.4
GPT · 추론 높음	97.4	56.0	3.8	11.3	37.0	10.4	12.7	0.2	48.3	55.1
Gemini · 추론 낮음	15.3	0.5	1.7	2.1	8.7	3.3	3.0	0.7	0.5	0.5
Gemini · 추론 높음	99.1	73.0	9.7	11.7	45.7	20.9	12.7	4.7	56.5	62.8

주: 575 개 기업 기준이며, 엄격 규칙에서 규칙을 어긴 응답은 행동이 없는 것으로 센다. 한 기업의 행동이 여러 축을 쓰면 축마다 센다. 비용 절감은 매출원가율이나 판매관리비율 가운데 하나 이상을 낮춘 행동이다.

<표 G-3> 반복 실행 사이 권고 행동의 일치(자유 작성, 추론 높음)

모델	행동크기 조건	권고 방식	두 실행 모두 수용	행동 완전 일치	사용 축 일치	평균 정규화 거리
GPT	B1	C4	543	48.6%	65.6%	0.438
GPT	B1	C4R	560	48.8%	64.3%	0.436
GPT	B1	C6-E	556	57.6%	67.6%	0.356
GPT	BINF	C4	565	27.1%	54.9%	0.537
GPT	BINF	C4R	574	30.8%	55.2%	0.542
GPT	BINF	C6-E	561	47.1%	60.2%	0.411
Gemini	B1	C4	561	7.5%	38.0%	0.553
Gemini	B1	C4R	559	6.3%	35.4%	0.525
Gemini	B1	C6-E	554	11.2%	39.9%	0.477
Gemini	BINF	C4	575	9.2%	30.6%	0.787
Gemini	BINF	C4R	575	8.2%	31.5%	0.831
Gemini	BINF	C6-E	575	6.8%	40.9%	0.706

주: 본실험(Run1)과 반복 실행(Run2)에서 모두 규칙을 지킨 기업만 비교하였다. 행동 완전 일치는 8 개 축의 값이 모두 같은 경우(차이 10^{-9} 이하), 사용 축 일치는 값이 0 이 아닌 축의 조합이 같은 경우이며, 정규화 거리는 축별 차이의 절댓값을 정규화 척도로 나누어 더한 값이다. 반복 실행의 수정 조건은 각 실행의 C4 에서 갈라진다.

부록 H. 재현 방법

본 연구의 결과는 공개 재현 키트(thesis-reproduction-kit-v43)로 다시 계산할 수 있다. Python 3.11 환경에서 다음 명령을 실행하면, 유료 API 호출이나 강화학습 재학습 없이 동결된 기업 단위 관측값 96,600 행(48,300 건 × 두 실행 규칙)에서 주 분석 96 개 행과 보조 결과 722 개 행을 다시 계산하고, 초안 처리 규칙 민감도 96 개 행을 포함한 914 개 행의 결과 등록부와 대조한다. 재계산의 범위는 결과의 종류에 따라 다르다. 주 분석 96 개 행은 원래의 부트스트랩 추출 순서가 보존되지 않아 표본 수와 평균을 다시 계산하여 대조하고, 구간과 p 값은 동결된 값을 그대로 쓴다. 보조 결과 722 개 행은 표본 수, 평균, 95% 구간, 보정 전 p 값까지 다시 계산한다. 초안 처리 규칙 민감도 96 개 행은 기술 통계로, 키트는 동결된 값과 행 수를 확인한다.

```
python -m pip install -e ".[full,dev]"
python -m thesis_repro verify
python -m thesis_repro reproduce --run-id published_check
```

본 논문의 작성 과정(2026 년 10 월, Python 3.11)에서 검증(verify)과 재계산(reproduce) 명령을 실행한 결과 모두 통과하였다. Oracle, 강화학습, LLM 실행의 원래 산출물은 Git LFS 로 받을 수 있다. C3-E 는 보존된 28 개 actor 의 행동 확률에서 다시 조립할 수 있으며, 같은 구성 안의 7 개 시드를 평균한 뒤 네 구성을 25%씩 평균하여 가장 높은 확률의 후보를 고르는 제 5 장의 절차를 그대로 따른다. 다만 키트에서 처음부터 다시 학습하는 경로는 네 구성 모두에 같은 보조 보상 가중치(부채부담 0.2, 투자 후 현금흐름 0.4, 단기 유동성 0.1, 영업수익성 0)를 쓰고 구성마다 Implicit Q-Learning 의 하이퍼파라미터만 바꾸므로, 구성별 보상 가중치(부록 C)를 쓴 최종 구성과 학습 조건이 다르다. 따라서 그 경로로 다시 학습한 정책은 본문의 C3-E 와 같지 않으며, 이 경로는 저장소 밖의 원천 입력과 GPU 자원도 필요로 한다. 본문의 결과는 동결된 원래 산출물을 기준으로 한다.

Human baseline 의 문서 목록, 재점검 전 라벨, 분석 코드는 비공개 저장소(thesis-human-benchmark-2024)의 hbfy24 폴더에 보관한다. 원문 재점검의 지침, 재확인 기록, 확정 라벨, 그리고 이를 집계하고 분석하는 코드는 재점검 자료 묶음(hb_audit_20261017)으로 같은 저장소 hb-fy24-rebuild 브랜치의 hbfy24/audit_20261017(커밋 ea1b1cf)에 둔다. 제 7 장의 H3 점수는 이 확정 라벨에 저장소의 분석 코드를 그대로 적용하여 계산하였고, 다섯 종류 기준의 겹침(H1·H2), 단기차입 부담 층화 순열 검정, H3 의 쌍대 차이는 같은 묶음의 코드로 계산하였다. 문서 원문은 저작권 때문에 공개하지 않는다.